

引用格式: 张振超, 卢瑞华, 刘宣广, 等. Cot-FresUNet: 基于孪生神经网络与时空依赖模型的多模态遥感变化检测方法[J]. 地球信息科学学报, 2026, 28(4): 0000-0000. [Zhang Z C, Lu RH, Liu X G, et al. Cot-FresUNet: A multimodal remote sensing change detection method based on Siamese Neural Networks and spatiotemporal dependency modeling[J]. Journal of Geo-information Science, 2026, 28(4): 0000-0000.] DOI:10.12082/dqxxkx.2026.250451; CSTR:32074.14.dqxxkx.2026.250451

Cot-FresUNet: 基于孪生神经网络与时空依赖模型的多模态遥感变化检测方法

张振超^{1,2*}, 卢瑞华^{1,2}, 刘宣广^{1,2}, 戴晨光¹, 朱 坤¹, 王自全¹

1. 信息工程大学, 郑州 450001; 2. 智能空间信息国家级重点实验室, 北京 100020

Cot-FresUNet: A Multimodal Remote Sensing Change Detection Method Based on Siamese Neural Networks and Spatiotemporal Dependency Modeling

ZHANG Zhenchao^{1,2*}, LU Ruihua^{1,2}, LIU Xuanguang^{1,2}, DAI Chenguang¹, ZHU Kun¹, WANG Ziquan¹

1. Information Engineering University, Zhengzhou 450001, China; 2. National Key Laboratory of Intelligent Spatial Information, Beijing 100020, China

Abstract: [Objectives] Remote sensing change detection technology is crucial for urban management, environmental monitoring, and disaster emergency response, as it provides timely and accurate information on changes in the Earth's surface. However, traditional change detection methods based solely on remote sensing images face limitations such as the inability to fully capture complex changes and the lack of effective integration of multi-source data, leading to inaccurate detection results. The integration of remote sensing images with Digital Surface Models (DSM) is a promising solution, but challenges remain in effectively fusing data from different modalities and accurately aligning their spatiotemporal features. This paper aims to address these issues by proposing a novel multimodal remote sensing change detection method that enhances the accuracy and robustness of change detection through effective data fusion and spatiotemporal feature integration. **[Methods]** To address the limitations of traditional change detection methods, this paper proposes a multimodal remote sensing change detection method named Cot-FresUNet, based on a Siamese neural network and a spatiotemporal dependency model. The method leverages optical images and DSM data as inputs and employs a two-dimensional twin neural network architecture in the encoding stage. This architecture is enhanced by a multi-scale feature fusion mechanism, which significantly improves the model's ability to integrate common features from multimodal data and distinguish subtle similarities and differences in feature representations. Additionally, the proposed spatiotemporal dependency model fully integrates the temporal continuity and spatial correlation of surface changes through multi-temporal feature interaction, thereby enhancing the model's capacity to represent and detect changes accurately. In the decoding

收稿日期: 2025-09-22; 修回日期: 2025-11-19.

基金项目: 国家自然科学基金项目(42301464); 河南省自然科学基金项目(252300420301); 智慧地球重点实验室开放基金(KF2023YB02-09); 嵩山实验室资助项目(221100211000-04). [**Foundation items:** National Natural Science Foundation of China, No.42301464; Natural Science Foundation of Henan Province, No.252300420301; Program of Key Laboratory of Smart Earth, No.KF2023YB02-09; Songshan Laboratory Project, No.221100211000-04.]

作者简介: 张振超(1991—), 男, 安徽芜湖人, 博士, 讲师, 主要从事遥感多模态变化检测研究. E-mail: zhzhc_1@163.com

stage, spatial pyramid pooling is utilized to obtain multi-scale features, which further enhances the deep fusion of local features with global contextual information. This comprehensive approach ensures that the model can effectively capture both fine-grained and large-scale changes in the monitored areas. **[Results]** The effectiveness of the proposed Cot-FresUNet method was evaluated on the publicly available 3DCD dataset and compared with eight existing methods. The results demonstrated significant improvements, with the proposed method achieving a 14.45% increase in F_1 -score and a 15.77% increase in Mean Intersection over Union (mIoU) compared to the previous best-performing method. Detailed analysis of the feature maps and learning effects at different stages of the model revealed the strengths of the proposed architecture. Furthermore, the performance of four fusion strategies, including early fusion and late fusion, was compared, and the fusion of optical imaging and DSM inputs was proven to achieve the highest accuracy in change detection through ablation experiments. Finally, the complexity metrics of eight types of models were compared, and the proposed method showed significant advantages in terms of parameter count and computational cost, making it highly efficient for practical applications. **[Conclusions]** The results indicate that the proposed Cot-FresUNet method can effectively improve the accuracy of multimodal change detection and address the issues of feature confusion, reliance on single-feature representations, and insufficient interaction of different spatiotemporal information that are commonly found in traditional twin neural network models. This study not only provides a robust solution for remote sensing change detection but also opens new avenues for future research in multimodal data integration and spatiotemporal analysis. The proposed method's ability to integrate optical images and DSM data through an advanced fusion mechanism and its enhanced representation of spatiotemporal features make it a valuable tool for applications in urban management, environmental monitoring, and disaster response.

Key words: remote sensing change detection; multi-modal; Siamese Neural Networks; feature fusion; spatiotemporal dependency model; information interaction; Digital Surface Model (DSM)

***Corresponding author:** ZHANG Zhenchao, E-mail: zhzhc_1@163.com

摘要:【目的】遥感变化检测技术在城市管理、环境监测和灾害应急响应等领域应用广泛,但传统基于遥感影像的变化检测技术存在诸多不足,联合遥感影像和数字表面模型(Digital Surface Model, DSM)的多模态变化检测技术有望解决以上问题,但面临数据融合方式不清晰、不同模态时空特征融合效果欠佳等问题。针对上述问题,本文提出了一种基于孪生神经网络与时空依赖模型的多模态遥感变化检测方法(Cot-FresUNet),以提升不同模态遥感数据变化检测过程中的特征融合效果。

【方法】首先,以配准后的光学影像和DSM数据作为输入,在编码阶段利用二维孪生神经网络和多尺度特征融合机制,提升模型对多模态数据共有特征的融合能力以及异同特征的辨别能力;其次,设计时空依赖模型,通过多时相特征交互,充分融合地表变化的时间连续性和空间相关性,提高模型对变化特征的表征能力;最后,在解码阶段,利用空间金字塔池化获取多尺度特征,加强局部特征和全局上下文信息的深度融合。【结果】在公开数据集3DCD上进行了8种方法的对比实验,本文方法取得的 F_1 -score和平均交并比(Mean Intersection over Union, mIoU)分别比现有最佳方法(GSTM-SCD)提升了14.45%和15.77%。分析了模型在不同阶段的特征图和学习效果,对比了早期融合、后期融合等4种融合策略的模型性能;通过消融实验证明了融合光学影像和DSM输入能取得最高的变化检测精度。最后,对比了8类模型的复杂度指标,本方法在参数量和运算代价2个关键指标上都展现出了明显的优势。【结论】本方法能有效提升多模态变化检测精度,改善传统孪生神经网络模型存在的特征混淆、特征单一和不同时空信息交互不充分的问题。

关键词: 遥感变化检测;多模态;孪生神经网络;特征融合;时空依赖模型;信息交互;数字表面模型(DSM)

1 引言

遥感变化检测技术通过对比不同时期的遥感影像,识别地表覆盖与土地利用的变化信息,在自然环境监测^[1-3]、城市规划与管理^[4-6]、灾害应急响应

以及农业生产规划^[7]等领域发挥出重要的应用价值^[8]。随着我国遥感技术的不断发展,高分辨率遥感影像越来越容易获取,为精细化的城市遥感变化检测提供了丰富的数据资源^[9]。

然而,传统基于单一模态遥感影像的变化检测

技术通常面临一些问题^[10-11]。首先, 尽管从物体的俯视图或鸟瞰图中提取的二维光谱和纹理特征在识别水平空间中物体顶面的颜色过渡或纹理变化方面是有效的, 但它们无法识别垂直三维空间中的高度变化。例如, 在建筑物高度变化、地形起伏等场景中, 仅依靠二维遥感影像难以准确检测出这些变化。其次, 单模态变化检测在很大程度上取决于多时相图像之间的像素间配准质量。由于配准误差, 变化对象的边缘可能会在变化图中变得不规则和粗糙。第三, 由于多时相图像可以从不同太阳位置的不同视角获取, 因此在该类图像上由于摄影视角和阴影遮挡引起的倾斜误差也不同。先前研究人员通过早期融合的方式堆叠不同时相的遥感影像, 输入到全连接神经网络(Fully Connected Network, FCN)中检测变化信息, 但是双时相同一位置的像素间可能存在匹配误差, 导致变化结果图产生错位、误检测等问题^[12]。为克服单模态变化检测的缺陷, 伴随多模态遥感数据的广泛获取, 多模态遥感变化检测技术迅速发展, 得到了广泛重视^[13]。

在多模态遥感变化检测技术的发展过程中, 孪生神经网络(Siamese Neural Network)作为一种有效的特征提取和匹配框架得到了广泛关注。其通过双分支结构分别提取双时相影像特征并融合, 通过对比学习提取输入数据的差异, 有效提升了检测的鲁棒性与准确性。现有用于变化检测的网络也有诸多, 例如, UNet^[14]通过编解码器和跳跃连接结构有效提取融合图像特征; FresUNet^[15]通过增加ResNet18的残差块结构, 增加了下采样池化操作, 从而提高特征提取的准确性; SiamUNet_conc^[16]利用共享网络分别处理双时相影像, 进而在不影响其他区域的情况下定位变化; SiamUNet_diff^[16]利用Siamese网络基本结构和U-Net网络结构, 将遥感影像的特征提取功能与卷积神经网络的分割能力结合起来, 实现遥感影像变化检测任务; EMGS-Net^[17]通过粗到细的编码器-解码器结构、基于空谱协同注意力的变化信息增强模块(Change Information Enhancement Module, CIEM)和变化信息引导模块(Change Information Guidance Module, CIGM), 实现双时相遥感影像语义变化检测性能提升; GSTM-SCD^[18]通过GOST-Mamba编码器、双向3D变化扫描策略及拓扑关系正则化损失函数, 实现多时序遥感影像的高效时空依赖建模与语义变化检测; DamageFormer^[19]通过孪生Transformer编码

器提取多时相图像非局部特征, 结合轻量级双任务解码器实现检测。同时, Wang等^[20]提出了一种基于孪生卷积网络的多传感器图像有监督变化检测方法, 该网络的孪生特征提取器是基于膨胀卷积和“网中网”的结构而设计, 在国产GF-2和ZY-3影像上取得了较佳的检测结果。Zhang和Lu^[21]应用共享权值的孪生卷积网络从双时相图像中提取特征, 推导出双时相特征的差值, 并将其用于标记变化类型。并将该方法与几种经典的方法(例如, CVA、IRMAD)以及Gong等^[22]、Li等^[23]提出的新兴方法进行了比较, 表明他们的方法准确性最高。

多模态遥感变化检测技术通过结合多种数据源(如光学影像、数字表面模型(Digital Surface Model, DSM)等), 能够提供更全面的信息, 从而更准确地识别地表覆盖与土地利用的变化。其按照双时相输入数据差异, 旧时相和新时相的数据模态组合分为以下4种情形: $\{A\} \rightarrow \{B\}$; $\{A\} \rightarrow \{A, B\}$; $\{A, B\} \rightarrow \{A\}$; $\{A, B\} \rightarrow \{A, B\}$ 。其中, 本文聚焦于每个时相均有一对多模态数据的情形, 即旧时相和新时相中都可以使用正射影像和DSM数据。这种情形下的多模态变化检测研究具有重要意义, 但现有基于深度学习的多模态遥感变化检测方法在数据融合上适应性较差, 易受不同模态异同属性特征干扰, 且特征间的时空交互不够彻底, 难以充分发挥多模态特征潜力。尽管已有研究尝试解决多模态遥感变化检测中的全色影像、正射影像、DSM数据等多模态数据融合问题, 但现有方法在多源数据融合的时空交互上仍存在一定的局限性。例如, Zhang等^[24]针对三维激光点云数据与正射影像的多模态变化检测问题, 将不同模态数据转化为含有高程信息的灰度栅格地图, 输入到孪生卷积神经网络中以检测每个栅格的变化信息; Chen等^[25]通过在不同形状维度上拼接特征将双时相语义特征输入到状态空间模型中; 庄会富等^[26]提出了一种异源影像无监督变化检测方法来解决多时相异源影像对特征融合提取问题, 并实现了无标注样本下的无监督变化检测。但上述方法在捕捉时空依赖关系时主要依靠孪生网络框架, 通过权重共享的多分支编码器实现时空交互, 限制了多时相特征交互并导致计算冗余。

为解决上述问题, 本文提出了一种基于孪生神经网络^[27-30]与时空依赖模型的多模态遥感变化检测方法(命名为“Cot-FresUNet”)。该方法以配准的

RGB遥感正射影像和DSM数据作为输入,针对融合时易产生的异源信息融合不深入的问题,采用后期融合来增强特征互补性。其次,为有效整合空间和时间特征,设计了时空依赖模型,通过多时相特征交互充分利用地表变化的时间连续性和空间相关性,以提高模型对变化特征的表征能力。最后,引入空间金字塔池化捕捉多尺度特征,加强局部特征和全局上下文信息的深度融合,进一步增强模型的泛化能力。实验部分,本文还对比了不同特征融合架构,包括早期融合和后期融合,并将其与前馈神经网络进行了比较。基于不同阶段特征图的特征可视化,分析了模型性能和融合机理,对多模态融合模型设计给出了建议。

2 研究方法

2.1 Cot-FresUNet模型概述

Cot-FresUNet模型结构主要包括编码器、解码器、时空依赖模型以及多尺度特征融合模块,如图1所示。输入数据包括双时相的RGB影像和DSM数据,输出结果是一个二维掩膜(Mask),用于显示地形中的变化区域。首先,构建孪生特征编码器^[31]以提取双时相数据的多尺度语义特征。孪生特征编码器由两个共享权重的编码器组成,并行处理双时相数据,这种模型架构可以保证特征提取的一致性,且能有效降低因双时相影像配准误差造成的误检漏检现象。具体地,引入时空依赖模型(Cot-SR)^[32]

增强同类影像不同时相间的时空交互,并利用空间金字塔池化(Atrous Spatial Pyramid Pooling, ASPP)捕捉多尺度特征,增强全局特征表达能力,从而更好地反映地形变化的空间连续性和时间相关性^[33-34]。在特征融合阶段,结合多模态数据提供的信息:RGB图像提供了丰富的颜色和纹理信息,DSM数据包含了高程信息和断裂线位置等细节。通过编码器处理,这些特征被提取出来并进一步融合形成更精细的地形特征。Cot-FresUNet模型在输入时区分不同模态数据,使得不同时相间的共性特征和特异性特征能更好地交互,减少了对多模态时空特征的配准精度的依赖程度,有望弥补单一数据源的特征表示能力缺陷,进而提升模型的泛化性能。

2.2 特征编码器

在Cot-FresUNet架构中,特征编码器采用残差块(Residual Block)结构,这一设计能够有效解决深层网络中的梯度消失和网络退化问题,确保网络在增加深度的同时依然具备强大的特征提取能力。编码器共包括4层,每层包含一个阶段模块。每个阶段模块由2个残差块和一个下采样模块构成。每个残差块内部的具体处理流程包括卷积层(Conv3×3)、批量归一化(BatchNormalization, BN)和激活层(Rectified Linear Unit, ReLU)^[35],如图2所示。

残差块结构有效缓解了梯度消失现象,使得梯度能够在网络层间更好地传播,从而提高模型效率。同时批量归一化(BN)有助于网络参数均一




图1 Cot-FresUNet多模态遥感变化检测模型框架

Fig. 1 The Cot-FresUNet multimodal remote sensing change detection model framework




图2 编码器网络结构

Fig. 2 Encoder network structure

化,进一步增强模型的泛化能力。激活层(ReLU)用于引入非线性变换,从而提高模型的表达能力。通过多层次、多阶段的编码器设计, Cot-FresUNet能够提取深度特征,保持模型较好的泛化性能。

2.3 时空依赖模型 Cot-SR

图1中的Cot-SR模块是基于非局部单元的扩展,旨在对跨时间信息进行建模,并增强未变化区域特征^[32]。如图3所示, Cot-SR模块同时处理来自不同模态的2个时间特征 $\hat{X}_1, \hat{X}_2 \in R^{c \times h \times w}$ 。首先,从 $\hat{X}_1, \hat{X}_2$ 中投影出6个向量 $q_1, q_2 \in R^{H \times c'}$, $k_1,$

$k_2 \in R^{c' \times H}$ 和 $v_1, v_2 \in R^{c \times H}$ 。其中, q_1, q_2 为查询向量(Query Vectors),用于捕捉特征图中的关键信息,维度为 $H \times c'$,其中 H 是特征图的空间维度, c' 是降维后的通道数; k_1, k_2 为键向量(Key Vectors),用于与查询向量进行匹配,维度为 $c' \times H$; v_1, v_2 为值向量(Value Vectors),用于存储特征图的实际信息,维度为 $c \times H$,其中 c 是原始特征图的通道数。其次,基于投影向量生成2个注意力矩阵 $A_1, A_2 \in R^{H \times H}$,这2个矩阵分别记录每个时间分支中的语义焦点^[32]。

$$A_1 = \phi(q_1 \times k_1) \quad (1)$$

$$A_2 = \phi(q_2 \times k_2) \quad (2)$$

最后,将每个注意力矩阵应用于其对应的反向时间分支上,投影出相互关联的信息,从而实现特征的增强。

$$\tilde{X}_1 = \hat{X}_1 + v_1 \times A_2 \quad (3)$$


$$\tilde{X}_2 = \hat{X}_2 + v_2 \times A_1 \quad (4)$$

式中: $\tilde{X}_1$ 和 $\tilde{X}_2$ 表示经过特征增强后的输出。

通过这种方式,Cot-SR模块能够有效学习跨时间的语义一致性,增强未变化区域特征,从而提高模型对时间变化的鲁棒性^[32]。

2.4 多尺度特征融合

在数据输入解码器前引入ASPP,通过多尺度的特征融合和提取,增强模型对不同尺度目标的检测能力。ASPP是一种包含多个分支的并行结构,每个分支通过扩张卷积对特征图进行操作,各分支



X_1, X_2 : 输入数据 A_1, A_2 : 注意力得分矩阵 $\otimes$ 矩阵乘法
 q_1, k_1, v_1 : 从 X_1 生成的查询、键和值向量 $\oplus$ 特征图相加
 q_2, k_2, v_2 : 从 X_2 生成的查询、键和值向量 Softmax : 归一化函数

图3 Cot-SR 基本结构

Fig. 3 Basic architecture of Cot-SR

在最后将多尺度特征融合。和传统空间金字塔池(Spatial Pyramid Pooling, SPP)相比,ASPP的每个分支主要由具有一定扩张率的空洞卷积组成,这种设计能够在不增加计算量的情况下扩大感受野,同时有效避免大量池化导致的空间分辨率降低问题^[36]。

在本网络中,ASPP模块共包括4个分支,分别采用扩张率为6、12、18和24的3×3空洞卷积。通过动态调整填充参数,每个分支输出一个与输入大小相同的特征图,分别捕捉不同尺度的信息。最后将输出沿第一维度堆叠并逐元素求和,得到最终的多尺度特征图。这一过程不仅保留了特征图的空间分辨率,还增强了模型对多尺度信息的表征能力,提高模型的鲁棒性^[36]。

2.5 解码器

解码器部分由4层组成,每层都包含一个阶段模块,每个阶段模块由2个残差块和一个下采样模块组成,每个残差块包括转置卷积层(TrConv3×3)、批量归一化(BN)和激活层(ReLU)^[35],如图4所示。在解码过程中,数据首先经过TrConv3×3层进行变换,然后进行批量归一化(BN),最后应用ReLU激活函数。这个过程在每个层级中都会重复,直到达到预定层数。

对于输出 x ,使用对数Softmax激活函数(式(5))生成预测的变化图,该函数将每个样本的概率转换为0到1之间的值,使得概率最高的样本被选中为预测结果。训练阶段使用负对数似然函数(式(6))更新网络权重,该函数用于计算预测结果与实际结果之间的误差,并根据误差调整网络权重,以最小

化预测误差。在本研究中,负对数似然函数是二元交叉熵损失函数(式(7))的具体实现形式,通过负对数似然函数,模型能够学习到最优的权重参数,从而提高变化检测的准确性。

$$\log_softmax(x) = \log\left(\frac{e^{x_i}}{\sum_k e^{x_k}}\right) \quad (5)$$

式中: x 表示输入向量,包含每个样本的特征值; x_i 表示输入向量中第 i 个元素值; e^{x_i} 为输入向量中第 i 个元素的指数值,用于计算每个类别的未归一化概率; $\sum_k e^{x_k}$ 为输入向量中所有元素的指数值之和。

$$nll_{loss}(CM_i, CM_i^{gt}) = -\sum_{j=1}^C (CM_{i,j}^{gt} \log(CM_{i,j}) + (1 - CM_{i,j}^{gt}) \log(1 - CM_{i,j})) \quad (6)$$

式中: C_i 为模型对第 i 个样本的预测概率分布; CM_i^{gt} 为第 i 个样本的真实标签分布; C 为类别总数; $CM_{i,j}^{gt}$ 为第 i 个样本在第 j 类的真实标签值; $CM_{i,j}$ 为第 i 个样本在第 j 类的预测概率值。

2.6 损失函数

变化检测结果的每个像素仅存在2种标签:变化(Change)或不变(Unchanged)。在实际情况中,未变化区域的像素数量通常远多于发生变化区域所占的像素数量,这会导致样本类别之间的不平衡。为解决这个问题,本文采用二元交叉熵(Binary Cross-Entropy, BCE)^[37]作为损失函数。BCE不仅可以缓解样本类别的不平衡问题,还能减少假阳性(将正常区域误判为变化区域)或假阴性(将变化区域误判为正常区域)的情况,从而提升模型的性能




图4 解码器架构

Fig. 4 Architecture of the decoder network

和稳健性^[38]。在具体实现中,二元交叉熵损失函数通过负对数似然函数(式(7))来计算预测结果与实际结果之间的误差。此外,由于二元交叉熵对于错误预测的惩罚更为严格,该损失函数有助于模型更容易地学习到正确的分类边界。BCE函数通过比较预测概率值 $p(y)$ 和实际标签 y (0或1)两部分计算损失值,对于标签 y 为1,如果预测值 $p(y)$ 越接近1,则损失值越小。反之,如果预测值越接近0,则损失值越大。在训练阶段,模型对每个像素点的预测结果会与真实标签(变化或未变化)进行逐一比较,并根据下式计算出相应的BCE损失值。

$$Loss = -\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(y_i)) + (1 - y_i) \cdot \log(1 - p(y_i)) \quad (7)$$

式中: N 为样本总数; y_i 为第 i 个样本的真实标签; $p(y_i)$ 表示模型预测第 i 个样本发生变化的概率; $\log(p(y_i))$ 用于预测发生变化的概率的对数值; $\log(1-p(y_i))$ 用于预测未发生变化的概率的对数值。

3 数据来源与实验设置

3.1 实验数据

本文实验所采用的数据为公开数据集3DCD,数据覆盖西班牙巴利亚多利德市的城区,包括历史中心和周边商业区^[39]。3DCD数据包含2010年和2017年的遥感影像,以及2个时相各自相同时间的DSM数据,同时提供有地面真实变化区域。其中光学正射影像图和LiDAR数据均来自西班牙国家地理信息中心,通过LiDAR数据生成数字表面模型

(DSMs),并通过计算2010年和2017年DSM差值结合精细人工标注来获得变化标签,数据详情见表1及表2。3DCD数据集提供了不同时相高分辨率的光学正射影像图、DSM数据,且二者已完成配准,适合于本文多模态变化检测任务。

具体地,图片大小为400像素×400像素,对数据进行归一化和可视化,如图5所示。

3.2 参数设置

实验使用的损失函数为二分类交叉熵损失函数“BCE”,具体通过负对数似然函数(式6)来实现,不排除标签中为0部分。二分类损失函数的权重系数为[0.1, 0.9],训练的轮数根据不同的模型设置为不同的轮次,学习率为0.0001,优化器的类型是“Adamw”。优化器中的一阶和二阶动量衰减系数

表1 3DCD数据集基本信息

Tab. 1 Basic information of the 3DCD dataset

数据类型	图像大小/(像素×像素)	分辨率/m
RGB遥感影像(2010,2017)	400×400	0.50
DSM数据(2010,2017)	400×400	0.50
建筑物变化标签	400×400	0.50

表2 3DCD数据集变化与不变像素比例

Tab. 2 Proportion of changed and unchanged pixels in the 3DCD dataset

数据类型	影像数/景	变化比例/%	不变比例/%
Training	257	5	95
Testing	94	4	96
Validation	33	5	95




图5 3DCD数据集可视化实例

Fig. 5 Visualization of the 3DCD examples

为[0.9, 0.999], 学习率下降后的最小学习率为0.000 005, 权重衰减的系数为0.001, 学习率调整策略为“Step_Lr”, 训练周期 *epoch* 为300, 学习率下降的倍率为0.75。

3.3 精度评价指标

在精度评价方面, 采用混淆矩阵(Confusion Matrix)、交并比(Intersection over Union, IoU)、平均交并比(mean Intersection over Union, mIoU)、精度(Precision)、召回率(Recall)、 F_1 -Score对模型的检测结果进行评估。计算公式如下:

$$IoU = \frac{TP}{TP + FN + FP} \quad (8)$$

$$mIoU = \frac{IoU(+) + IoU(-)}{2} \quad (9)$$

$$Precision = \frac{TP}{TP + FP} \quad (10)$$

$$Recall = \frac{TP}{TP + FN} \quad (11)$$

$$F_1 - Score = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (12)$$

式中: *TP*(True positive)代表预测为变化, 实际也为变化的像素点数量; *FP*(False positive)代表预测为变化, 实际为非变化的像素点数量; *FN*(False negative)代表预测为非变化, 实际为变化的像素点数量; *TN*(True negative)代表预测为非变化, 实际也为变化的像素点数量。*IoU*和*mIoU*值越高则模型性能越好^[38]。

3.4 对比实验设置

为验证本文数据输入和融合方式的优越性, 将其与其他3种方式进行对比实验。① Cot-FresUNet_1: 将同一时相的遥感影像和DSM影像组合, 输入编码器提取特征, 然后进行时空依赖模型并融合, 最后通过解码器得到变化检测结果, 如图6(b)所示; ② Cot-FresUNet_2: 将不同时相的遥感影像和DSM数据分别组合, 输入编码器提取特征, 随后进行时空依赖模型并融合, 最终通过解码器生成变化检测结果, 如图6(c)所示; ③ Cot-FresUNet_3: 将不同时相的遥感影像和DSM数据分别组合, 输入编码器提取特征, 在时空依赖模型后对遥感影像特征进行串联融合、对DSM数据特征进行差分操作, 然后通过串联将两组特征融合, 最终输入解码器得到变化检测结果, 如图6(d)所示。

4 实验结果分析

4.1 模型性能对比实验

为验证本文提出的Cot-FresUNet方法在3DCD数据集上的有效性, 将本方法与7种主流的变化检测方法对比, 涵盖“前馈型(Feed-forward)”结构与“孪生型(Siamese)”结构、早期融合与后期融合、差分策略与拼接策略等主流设计范式, 具体包括: ① 以UNet^[14]为代表的单时相语义分割框架; ② 在UNet基础上嵌入Fresnet卷积的FresUNet^[15]; ③ 采用权重共享双编码器并在融合阶段使用通道拼接的SiamUNet_conc^[16]; ④ 采用权重共享双编码器但在融合阶段使用差分操作的SiamUNet_diff^[16]。以及EMGS-Net^[17]、GSTM-SCD^[18]和DamageFormer^[19]网络。评价指标选取 F_1 -Score与*mIoU*, 二者分别从“像素级一致性”与“区域级完整性”两个维度对模型进行量化考核, 结果如表3所示。

表3的定量评价结果表明, Cot-FresUNet在 F_1 -Score和*mIoU*上均取得了最佳成绩, 分别为74.32%和57.53%, 本方法在多模态遥感变化检测的准确性和一致性上均优于其他7种方法。精度提升一方面因为Cot-FresUNet在编码端引入Cot-SR模块, 此模块通过捕捉跨时相、跨尺度的上下文信息, 有效抑制了伪变化; 另一方面, 金字塔池模块通过每个分支同时对特征图进行操作, 在不增加计算量的情况下扩大感受野, 同时避免了大量池化操作导致的空间分辨率降低。

图7所示的各网络检测可视化结果进一步验证了上述结论。其中, 红色框表示检测正确区域, 黄色表示未检测到或检测错误区域。可见, Cot-FresUNet对建筑物、道路等人工地物的轮廓刻画与实际真值贴合度更好, 边缘毛刺与内部孔洞大幅减少。特别是在建筑物高度变化和地形起伏的区域, Cot-FresUNet能够更准确地检测出这些垂直方向的建筑物变化。这是因为Cot-FresUNet在编码阶段利用孪生神经网络和多尺度特征融合机制, 提升了模型对多模态数据共有特征的融合能力以及异同特征的辨别能力, 能更好地学习和融合DSM高度变化信息; 在时空依赖模型中, 通过多时相特征交互, 充分融合了地表变化的时间连续性和空间相关性, 从而提高了模型对垂直方向建筑物变化的检测能力; 而黄色框所示的“漏检/误




图6 不同融合优化策略实验设计

Fig. 6 Experimental design of different fusion strategies

表3 模型性能精度评价

Tab. 3 Evaluation of model performance (%)

模型	F_1 -Score	$mIoU$
UNet	46.72	30.55
FresUNet	48.36	31.81
SiamUNet_conc	50.62	33.97
SiamUNet_diff	52.74	35.83
EMGS-Net	58.12	40.95
GSTM-SCD	59.87	41.76
DamageFormer	47.12	30.73
Cot-FresUNet(本文模型)	74.32	57.53

注:加粗的数值为各列最大值。

检区域”中,GSTM-SCD与FresUNet在建筑物高度变化和地形起伏的区域出现了大块的“空洞化”漏检,SiamUNet系列则因差分或拼接策略对弱变化不敏感,导致阴影、小型临时建筑等被误判为噪声。EMGS-Net在 F_1 -Score和 $mIoU$ 上表现较好,但该方法在处理复杂地形和小型变化区域时仍存在一些漏检和误检现象,特别是在建筑物边缘和道路连接处,检测结果不够精确。GSTM-SCD在区域级完整性上仍有提升空间。尤其是在处理大型建筑物和复杂地形时,GSTM-SCD倾向于过度分割,导致一些实际未变化的区域被误




图7 各方法检测结果

Fig. 7 Qualitative results of different methods

判为变化区域。DamageFormer在处理高分辨率影像时表现一般,其 F_1 -Score和 $mIoU$ 均较低,表明DamageFormer在识别细微变化和处理多模态数据时存在一定的局限性,尤其在结合RGB影像和DSM数据时特征融合能力不足,导致检测结果不够准确。

4.2 Cot-FresUNet特征图分析

图8展示了Cot-FresUNet模型在训练过程中4个不同阶段(Stage1—Stage4)的部分特征图。左侧的4张图片是原始输入的不同时相的影像、DSM数据,第二列是二值变化真值,后面4列为不同阶段的特征图。Stage1通过2个残差块对输入数据进行




图8 模型性能对比实验特征图

Fig. 8 Feature maps of different models

初步的特征提取,主要提取基本的边缘和纹理特征,特征图主要反映了模型对输入数据的基本特征感知能力,为后续的特征提取提供了基础。Stage2进一步深化特征提取,能够捕捉到更复杂的地物结构和空间关系,进一步细化了地物的边缘和纹理特征。Stage3继续深化特征提取,增强特征的非线性表达能力。这一阶段特征对地物细节的捕捉能力提高,能够更好地识别出地物的变化特征。Stage4通过ASPP捕捉不同尺度下的地物变化特征,全面识别出面积的区域变化和小面积的细节变。通过这些特征图,可以观察到模型在不同阶段对地物要素的响应情况,尤其是在处理大面积街区 and 宽阔道路等重要变化区域时表现出色;同时,对于小面积房屋和狭窄道路等细节变化,模型仍有提升空间。

4.3 融合策略对比实验

采用相同实验方法,对比不同融合策略对变化检测精度的影响,实验结果如表4所示。在4种方

法中,Cot-FresUNet的 F_1 -Score和 $mIoU$ 取得最大值,具有最强的泛化性且对变化信息的综合识别能力较高。由此证明,本文方法引入后期融合及时空依赖模型的基础上,同时考虑RGB遥感影像及DSM数据间的差异特征并融合,有利于减少信息冗余,增强特征互补性,使得模型能够有效捕捉到图像间的变化,从而提高变化检测的准确性和效率。而将同一时相的RGB遥感影像与DSM数据直接融合会产生异源数据干扰,融合时易产生噪声,影响了变化检测的准确性和时效性。

表4 不同融合策略性能评价

Tab. 4 Evaluation of different fusion strategies (%)		
模型	F_1 -Score	$mIoU$
Cot-FresUNet(本文模型)	74.32	57.53
Cot-FresUNet_1	42.16	31.10
Cot-FresUNet_2	49.23	33.76
Cot-FresUNet_3	54.23	36.72

注:加粗的数值为各列最大值。

4.4 消融实验

为证明 Cot-FresUNet 中各模块的有效性,本文将改进的 FresUNet 孪生网络作为基础网络,随后将提出的 Cot-SR、ASPP 依次加入基础网络中,并探讨仅使用 RGB 或 DSM 数据对模型检测结果的影响,通过 F_1 -Score 和 $mIoU$ 进行评估。由表 5 可知,随着各个模块的加入,基础网络模型对变化区域的检测能力逐步提升。加入 Cot-SR 模块后, F_1 -Score 提升了 13.8%, $mIoU$ 提升了 2.29%,表明该模块能够有效建模时空依赖关系;加入 ASPP 模块后, F_1 -Score 提升了 23.74%, $mIoU$ 提升了 24.56%,表明该模块能够有效捕捉多尺度特征。仅使用光学影像作为输入 F_1 -Score 为 69.69%, $mIoU$ 为 53.48%,原因在于光学影像只能提供二维的光谱信息和纹理信息变化,无法识别建筑物高度变化,导致在建筑物高度变化中漏检误检,变化检测精度下降;而 DSM 数据能有效补充建筑物高度变化信息。由于 3DCD 数据集相对较小,建筑物变化样本小,因此模型仅通

过 DSM 数据很难得到有效信息,对应的 F_1 -Score 和 $mIoU$ 评估数值极低,无法实现对目标的变化检测。

4.5 模型复杂度分析

为了测试模型的复杂度,本文对比了各模型的参数量 (Params) 和每秒浮点运算次数 (FLOPS),如表 6 所示。本方法的参数量为 1.30 Mb,与参数量最大的 DamageFormer (48.16 Mb) 相比,本方法的参数量减少了约 97.3%,仅比 FresUNet (1.29 Mb) 略高 0.01 Mb,几乎可以忽略不计,能够证明本方法具有轻量化优势,模型更为高效、易于部署。在运算代价方面,与运算代价最大的 EMGS-Net (216.08 G) 相比,本方法的 FLOPs 减少了约 98.3%,仅比 FresUNet (3.83 G) 高 0.03 G。综合变化检测精度来看,本方法在参数量和运算代价 2 个关键指标上都展现出了明显的优势。较低的参数量和运算代价有助于提高模型的训练和推理速度,从而在实际部署时能够更快地响应和处理数据。

表 5 消融实验结果精度
Tab. 5 Ablation study results accuracy (%)

输入数据	模型	F_1 -Score	$mIoU$
光学影像 + DSM	FresUNet (w/o. CotSR,ASPP)	48.36	31.81
	Cot-FresUNet(w/o. ASPP)	62.16	34.10
	Cot-FresUNet(w/o. CotSR)	72.10	56.37
	Cot-FresUNet	74.32	57.53
仅使用光学影像	Cot-FresUNet	69.69	53.48
仅使用 DSM	Cot-FresUNet	2.70	1.37

注:w/o 表示“without”;加粗的数值为各列最大值。

表 6 模型复杂度对比分析
Tab. 6 Analysis of model complexity

模型	Params (Mb)	FLOPS (G)
UNet	1.35	14.35
FresUNet	1.29	3.83
SiamUNet conc	2.74	35.01
SiamUNet diff	1.66	21.41
EMGS-Net	23.92	216.08
GSTM-SCD	31.55	72.21
DamageFormer	48.16	202.50
Cot-FresUNet (本文模型)	1.30	3.86

注:加粗的数值为各列最小值。

5 结论与讨论

5.1 结论

针对现有多模态变化检测数据融合方法不确定、不同模态时空特征融合效果欠佳等问题,本文提出了一种基于孪生神经网络与时空依赖模型的多模态遥感变化检测方法。该方法以正射影像和 DSM 数据为输入,设计时空依赖模型实现多时相特征交互,最后利用空间金字塔池捕捉多尺度特征,实现多模态变化检测。在 3DCD 数据集上进行实验,结果表明:

(1)在与 UNet、FresUNet、SiamUNet_conc、Sia-

mUNet_diff、EMGS-Net、GSTM-SCD 和 DamageFormer 7种现有模型的对比实验中, Cot-FresUNet均展现出了最优的检测新娘功能, 有效提升了多模态变化检测的整体精度, F_1 -score 和 $mIoU$ 分别比现有最佳分数提升了14.45%和15.77%。这些结果验证了本方法在处理多模态数据变化检测上具有显著的优越性。

(2) 融合策略对比实验证明, 在后期融合和时空依赖模型的基础上, 考虑RGB、DSM的差异特征并进行融合, 能够减少信息冗余, 有效提高模型的检测性能。相较其他输入和融合方式, F_1 -Score平均提升25.78%, $mIoU$ 平均提升23.67%。

(3) 消融实验验证了Cot-FresUNet中各模块的有效性, 结果表明, Cot-FresUNet中加入Cot-SR和ASPP模块能够显著提升模型性能, F_1 -Score和 $mIoU$ 分别提高了25.96%和25.72%。同时证明, 仅使用RGB或DSM数据会导致模型检测性能受限。因而多模态数据融合对提升模型性能至关重要。

(4) Cot-FresUNet在提升变化检测能力的同时兼顾了模型复杂度, 其参数量仅为1.30 Mb, 运算代价仅为3.86 G。证明本方法在实际部署时具有较高的实用性和可扩展性, 适用于多种实际应用场景。

5.2 讨论

虽然本模型较现有多模态变化检测方法较为显著, 但在训练时仅使用了3DCD数据集, 具有一定的局限性。同时, 3DCD数据集规模相对较小, 在一定程度上限制了模型的适应性和泛化能力。为解决上述问题, 在后续工作中, 计划通过数据增强和合成数据生成的方法, 来模拟更多样的场景和变化类型, 提高本文方法在实际应用中的性能和可靠性, 使其能更好地适应各种变化检测任务。

AI使用说明: 本文在英文摘要部分使用了AI技术, 主要用于语言通顺、英文初步翻译以及语法检查等方面。

利益冲突: Conflicts of Interest

所有作者声明不存在利益冲突。

All authors disclose no relevant conflicts of interest.

作者贡献: Author Contributions

张振超和卢瑞华参与实验设计; 卢瑞华和刘宣广完成实验操作; 张振超、卢瑞华、刘宣广、戴晨光、朱坤、王自全参与论文的写作和修改。所有作者均阅读并同意最终稿件的提交。

The study was designed by ZHANG Zhenchao and LU Ruihua. LU Ruihua and LIU Xuanguang conducted the experiments; ZHANG Zhenchao, LU Ruihua, LIU Xuanguang, DAI Chenguang, ZHU Kun and WANG Ziquan contributed to the writing and revision of the manuscript. All authors have read and approved the final manuscript.

参考文献(References):

- [1] 张继贤, 顾海燕, 倪欢, 等. 遥感智能变化检测的深度学习方法: 演变与发展趋势[J]. 测绘学报, 2025, 54(8): 1347-1370. [Zhang J X, Gu H Y, Ni H, et al. Deep learning methods for remote sensing intelligent change detection: Evolution and development[J]. Acta Geodaetica et Cartographica Sinica, 2025, 54(8): 1347-1370.] DOI: 10.11947/j. AGCS.2025.20240417
- [2] 周昱亨, 刘深波, 贺皇, 等. 基于多尺度特征融合的遥感变化检测网络[J]. 激光与光电子学进展, 2025, 62(10): 356-365. [Zhou Y H, Liu S B, He H, et al. Remote sensing change detection network based on multi-scale feature fusion[J]. Laser & Optoelectronics Progress, 2025, 62(10): 356-365.] DOI: 10.3788/LOP242519
- [3] 李增元, 陈尔学, 覃先林, 等. 中国林草遥感技术研究与应用: 最新进展、挑战与对策[J]. 遥感学报, 2025, 29(6): 1804-1830. [Li Z Y, Chen E X, Qin X L, et al. Research and application of forestry and grassland remote sensing technology in China: Recent progress, challenges and countermeasures[J]. National Remote Sensing Bulletin, 2025, 29(6): 1804-1830.] DOI: 10.11834/jrs.20255044
- [4] 庞世燕, 郝京京, 左志奇, 等. 融合密集连接和自注意力机制的高分辨率遥感影像变化检测方法[J]. 测绘学报, 2024, 53(12): 2244-2253. [Pang S, Hao J, Zuo Z, et al. A high-resolution remote sensing images change detection method via the integration of dense connections and self-attention mechanisms[J]. Acta Geodaetica et Cartographica Sinica, 2024, 53(12): 2244-2253.] DOI: 10.11947/j. AGCS.2024.20230454
- [5] Song X P, Sexton J O, Huang C Q, et al. Characterizing the magnitude, timing and duration of urban growth from time series of Landsat-based estimates of impervious cover[J]. Remote Sensing of Environment, 2016, 175: 1-13. DOI: 10.1016/j.rse.2015.12.027
- [6] Li X C, Gong P, Liang L. A 30-year (1984—2013) record of annual urban dynamics of Beijing City derived from Landsat data[J]. Remote Sensing of Environment, 2015, 166: 78-90. DOI: 10.1016/j.rse.2015.06.007
- [7] 蒙继华, 林圳鑫, 高心雨, 等. 地球大数据支撑可持续农业10年进展[J]. 地球信息科学学报, 2025, 27(11): 2531-

2551. [Meng J H, Lin Z X, Gao X Y, et al. Ten years of progress in big earth data for sustainable agriculture[J]. *Journal of Geo-Information Science*, 2025, 27(11): 2531-2551.]
- [8] Jing C B, Zhou W Q, Qian Y G, et al. A novel approach for quantifying high-frequency urban land cover changes at the block level with scarce clear-sky Landsat observations[J]. *Remote Sensing of Environment*, 2021, 255: 112293. DOI:10.1016/j.rse.2021.112293
- [9] Sun W W, Yang G, Chen C, et al. Development status and literature analysis of China's earth observation remote sensing satellites[J]. *National Remote Sensing Bulletin*, 2020, 24(5): 479-510. DOI:10.11834/jrs.20209464
- [10] 张宇, 庄会富, 张祥, 等. MSF-UNet: 空间-频率双域特征融合的 SAR 影像无监督变化检测方法[J]. *地球信息科学学报*, 2025, 27(9): 2213-2229. [Zhang Y, Zhuang H F, Zhang X, et al. MSF-UNet: A mamba-based spatial-frequency feature fusion U-Net for unsupervised change detection in SAR images[J]. *Journal of Geo-information Science*, 2025, 27(9): 2213-2229.] DOI: 10.12082/dqxxkx.2025.250269
- [11] Liu T F, Xu J J, Lei T, et al. AEKAN: Exploring superpixel-based AutoEncoder Kolmogorov-Arnold network for unsupervised multimodal change detection[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2025, 63: 5601114. DOI:10.1109/TGRS.2024.3515258
- [12] 刘宣广, 李玉洁, 张振超, 等. CVS-Net: 基于时空关系建模与边缘信息强化的遥感影像语义变化检测方法[J]. *地球信息科学学报*, 2025, 27(5): 1144-1162. [Liu X G, Li Y J, Zhang Z C, et al. CVS-net: Semantic change detection in remote sensing images using spatial-temporal modeling and edge enhancement[J]. *Journal of Geo-information Science*, 2025, 27(5): 1144-1162.] DOI: 10.12082/dqxxkx.2025.240668
- [13] Liu T F, Zhang M Y, Gong M G, et al. Commonality feature representation learning for unsupervised multimodal change detection[J]. *IEEE Transactions on Image Processing*, 2025, 34: 1219-1233. DOI:10.1109/TIP.2025.3539461
- [14] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional networks for biomedical image segmentation[C]//*Medical Image Computing and Computer-Assisted Intervention - MICCAI 2015*. Cham: Springer, 2015: 234-241. DOI: 10.1007/978-3-319-24574-4_28
- [15] Pegia ME, Jónsson B, Moumtzidou A, et al. Comparative analysis of learning-based approaches for change detection in satellite images[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2025, 18(1): 3766-3781. DOI:10.1109/JSTARS.2024.3522350
- [16] Caye Daudt R, Le Saux B, Boulch A. Fully convolutional Siamese networks for change detection[C]//*2018 25th IEEE International Conference on Image Processing (ICIP)*. IEEE, 2018: 4063-4067. DOI:10.1109/ICIP.2018.8451652
- [17] Zuo X B, Jin F, Ding L, et al. Multitask Siamese network guided by enhanced change information for semantic change detection in bitemporal remote sensing images[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2025, 18: 61-77. DOI: 10.1109/JSTARS.2024.3487137
- [18] Liu X G, Dai C G, Ding L, et al. GSTM-SCD: Graph-enhanced spatio-temporal state space model for semantic change detection in multi-temporal remote sensing images [J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 2025, 230: 73-91. DOI:10.1016/j.isprsjprs.2025.09.003
- [19] Chen H, Nemni E, Vallecorsa S, et al. Dual-tasks Siamese transformer framework for building damage assessment [C]//*IGARSS 2022 - 2022 IEEE International Geoscience and Remote Sensing Symposium*. IEEE, 2022: 1600-1603. DOI:10.1109/IGARSS46834.2022.9883139
- [20] Wang M Y, Tan K, Jia X P, et al. A deep Siamese network with hybrid convolutional feature extraction module for change detection based on multi-sensor remote sensing images [J]. *Remote Sensing*, 2020, 12(2): 205. DOI:10.3390/rs12020205
- [21] Zhang W X, Lu X Q. The spectral-spatial joint learning for change detection in multispectral imagery[J]. *Remote Sensing*, 2019, 11(3): 240. DOI:10.3390/rs11030240
- [22] Gong M G, Zhan T, Zhang P Z, et al. Superpixel-based difference representation learning for change detection in multispectral remote sensing images[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2017, 55(5): 2658-2673. DOI:10.1109/TGRS.2017.2650198
- [23] Li K Y, Li Z, Fang S. Siamese NestedUNet networks for change detection of high resolution satellite image[C]//*Proceedings of the 2020 1st International Conference on Control, Robotics and Intelligent System*. ACM, 2021: 42-48. DOI:10.1145/3437802.3437810
- [24] Zhang Z C, Vosselman G, Gerke M, et al. Detecting building changes between airborne laser scanning and photogrammetric data[J]. *Remote Sensing*, 2019, 11(20): 2417. DOI:10.3390/rs11202417
- [25] Chen H, Song J, Han C X, et al. ChangeMamba: Remote sensing change detection with spatiotemporal state space model[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2024, 62: 4409720. DOI:10.1109/TGRS.2024.3417253
- [26] 庄会富, 郭建林, 薛倩, 等. 联合混合 CNN 和相似性评估的异源影像无监督变化检测方法[J]. *地球信息科学学报*, 2025, 27(2): 507-521. [Zhuang H F, Guo J L, Xue Q, et al. Unsupervised change detection method for heteroge-

- neous image combining hybrid CNN and similarity assessment[J]. *Journal of Geo-Information Science*, 2025, 27(2): 507-521.] DOI:10.12082/dqxxkx.2025.240535
- [27] Fang S, Li K Y, Shao J Y, et al. SNUNet-CD: A densely connected Siamese network for change detection of VHR images[J]. *IEEE Geoscience and Remote Sensing Letters*, 2022, 19: 8007805. DOI:10.1109/LGRS.2021.3056416
- [28] Zhang M X, Liu Z, Feng J, et al. Remote sensing image change detection based on deep multi-scale multi-attention Siamese transformer network[J]. *Remote Sensing*, 2023, 15(3): 842. DOI:10.3390/rs15030842
- [29] Zhang M Y, Xu G L, Chen K M, et al. Triplet-based semantic relation learning for aerial remote sensing image change detection[J]. *IEEE Geoscience and Remote Sensing Letters*, 2019, 16(2): 266-270. DOI: 10.1109/LGRS.2018.2869608
- [30] Li M M, Liu X G, Wang X Q, et al. Detecting building changes using multimodal Siamese multitask networks from very-high-resolution satellite images[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2023, 61: 5404322. DOI:10.1109/TGRS.2023.3290817
- [31] 李星华, 黄艳媛. 高分影像变化检测的孪生差分特征融合网络[J]. *测绘科学*, 2023, 48(5): 129-139. [Li X H, Huang Y Y. Siam-differential feature fusion network for change detection of high-resolution images[J]. *Science of Surveying and Mapping*, 2023, 48(5): 129-139.] DOI: 10.16251/j.cnki.1009-2307.2023.05.016
- [32] Ding L, Guo H T, Liu S C, et al. Bi-temporal semantic reasoning for the semantic change detection in HR remote sensing images[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2022, 60: 5620014. DOI: 10.1109/TGRS.2022.3154390
- [33] 衡雪彪, 许捍卫, 唐璐, 等. 基于改进全卷积神经网络模型的土地覆盖分类方法研究[J]. *地球信息科学学报*, 2023, 25(3): 495-509. [Heng X B, Xu H W, Tang L, et al. Research on land cover classification method based on improved fully convolutional neural network model[J]. *Journal of Geo-Information Science*, 2023, 25(3): 495-509.] DOI:10.12082/dqxxkx.2023.220435
- [34] 吴小所, 王利玲, 吴朝阳, 等. 基于双时相特征筛选的遥感图像变化检测模型[J]. *地球信息科学学报*, 2023, 25(11): 2268-2280. [Wu X S, Wang L L, Wu (C/Z)Y, et al. Remote sensing change detection model based on dual temporal feature screening[J]. *Journal of Geo-Information Science*, 2023, 25(11): 2268-2280.] DOI:10.12082/dqxxkx.2023.230377
- [35] Pegia M E, Moumtzidou A, Gialampoukidis I, et al. Bi-asUNet: Learning change detection over sentinel-2 image pairs[C]//*Proceedings of the 19th International Conference on Content-based Multimedia Indexing*. ACM, 2022: 142-148. DOI:10.1145/3549555.3549574
- [36] Liu R R, Tao F, Liu X T, et al. RANet: A residual ASPP with attention framework for semantic segmentation of high-resolution remote sensing images[J]. *Remote Sensing*, 2022, 14(13): 3109. DOI:10.3390/rs14133109
- [37] 范自柱, 王松, 张泓, 等. 基于 W-Net 的高分辨率遥感卫星图像分割[J]. *华南理工大学学报(自然科学版)*, 2020, 48(12): 114-124. [Fan Z Z, Wang S, Zhang H, et al. W-net-based segmentation for remote sensing satellite image of high resolution[J]. *Journal of South China University of Technology (Natural Science Edition)*, 2020, 48(12): 114-124.] DOI:10.12141/j.issn.1000-565X.200365
- [38] 龚良雄, 李星华, 程远明, 等. 时空差异增强与自适应特征融合的轻量级遥感影像变化检测网络[J]. *测绘学报*, 2025, 54(1): 136-153. [Gong L X, Li X H, Cheng Y M, et al. A lightweight remote sensing images change detection network utilizing spatio-temporal difference enhancement and adaptive feature fusion[J]. *Acta Geodaetica et Cartographica Sinica*, 2025, 54(1): 136-153.] DOI: 10.11947/j. AGCS.2025.20240299
- [39] Coletta V, Marsocci V, Ravanelli R. 3dcd: A new dataset for 2d and 3d change detection using deep learning techniques[J]. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, 2022, XLIII-B3-2022: 1349-1354. DOI: 10.5194/isprs-archives-xliii-b3-2022-1349-2022

■ 本文图文责任编辑: 蒋树芳 黄光玉