



哈尔滨工业大学学报
Journal of Harbin Institute of Technology
ISSN 0367-6234, CN 23-1235/T

《哈尔滨工业大学学报》网络首发论文

题目: 关系引导的粗细颗粒度专家多模态知识图谱补全模型
作者: 超木日力格, 陈宇桐, 翁彧
收稿日期: 2025-12-25
网络首发日期: 2026-03-31
引用格式: 超木日力格, 陈宇桐, 翁彧. 关系引导的粗细颗粒度专家多模态知识图谱补全模型[J/OL]. 哈尔滨工业大学学报.
<https://link.cnki.net/urlid/23.1235.T.20260330.1124.002>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

关系引导的粗细颗粒度专家多模态知识图谱补全模型

超木日力格, 陈宇桐, 翁彧

(中央民族大学 信息工程学院 100081 北京)

摘要:针对多模态知识图谱补全任务中, 现有方法对关系信息及其跨模态交互关注不足的问题, 构建关系引导的粗细颗粒度专家多模态知识图谱补全模型(RG-FCEC), 自适应生成高质量实体表示, 提升多模态知识图谱补全性能。设计关系引导的粗细颗粒度专家, 提取携带专家权重以及关系权重的模态嵌入特征; 构建结构特征引导的跨模态信息融合机制, 通过结构模态信息增强视觉与文本模态的语义表征能力; 融合多模态预测结果实现多路并行决策。此外, 通过最小化专家间互信息完成专家网络解耦。在三个公开基准数据集上的实验表明, 该模型可有效优化多模态知识图谱补全效果。

关键词: 关系引导; 粗细颗粒度; 专家模块; 多模态知识图谱补全; 多模态融合
中图分类号: TP391

Relation-guided fine-and-coarse-grained expert multimodal knowledge graph completion model

Chaomu Rilige, Chen Yutong, Weng Yu

(College of Information Engineering, Minzu University of China, Beijing 100081, China)

Abstract: To address the problem of insufficient attention paid by existing methods to relational information and its cross-modal interactions in multimodal knowledge graph completion tasks, a Relation-guided Fine-and-Coarse-grained Expert model for MMKGC (RG-FCEC) is constructed, which adaptively generates high-quality entity representations to improve MMKGC performance. Relation-guided fine-and-coarse-grained experts are designed to extract modal embedding features carrying both expert weights and relation weights. A structure-feature-guided cross-modal information fusion mechanism is established to enhance the semantic representation capability of visual and textual modalities through structural modal information, and the fusion of multimodal prediction results is implemented to achieve multi-path parallel decision-making. In addition, the decoupling of expert networks is completed by minimizing the mutual information among experts. Experiments on three public benchmark datasets demonstrate that the proposed model can effectively optimize the performance of multimodal knowledge graph completion.

Keywords: relation guidance; fine-and-coarse granularity; expert module; multimodal knowledge graph completion; multimodal fusion

收稿日期: 2025-12-25; 录用日期: 2026-03-03;

基金项目: 中央高校基本科研业务费专项资金资助项目(2024QNYL07); 海南省哲学社会科学规划课题(HNSK(ZC) 25-236)

作者简介: 超木日力格(1988—), 女, 博士研究生, 讲师; 陈宇桐(2002—), 女, 硕士研究生

通信作者: 翁彧, wengyu@muc.edu.cn

知识图谱在众多领域中扮演着关键角色。例如在医疗领域，金志刚等^[1]的工作表明，融合医疗知识图谱能有效提升电子健康记录中命名实体识别的准确性；何霆等^[2]的综述进一步指出，基于 EHR 构建的医疗知识图谱是临床决策支持等高级应用的基石。随着多模态数据采集与处理技术的发展，知识图谱逐渐从单一模态扩展到多模态知识图谱（Multimodal Knowledge Graph, MMKG）^[3]。在多模态知识图谱的研究中，由于不同模态数据信息不均衡，其不可避免缺失部分信息，影响多模态知识图谱的应用，为解决这一问题，研究人员围绕多模态知识图谱的补全展开研究，以填补缺失的三元组。传统的知识图谱补全模型通常将实体和关系映射到低维向量空间，通过向量运算建模语义关联，代表模型如 TransE^[4], TransH^[5], TransR^[6]等，这些模型虽然具有一定的补全能力，但在处理过程中可能导致不同模态信息丢失，无法捕捉不同模态之间的关系。

为了减少模态信息丢失并且充分利用不同模态之间的互补性，研究开始倾向于将实体不同模态进行融合，并设计出了多种融合策略。IMF 模型分别提取不同模态特征，利用双线性融合捕捉模态复杂交互，同时加入对比学习进行多模态融合^[7]；MKGformer 通过粗粒度前缀引导交互、细粒度关联感知融合模块整合视觉与文本特征^[8]；陈巧红等^[9]在多模态视觉问答模型中，通过门控机制，实现了从视觉模态内部到文本-视觉模态间的多层次自适应融合，显著提升了特征整合的精细度。这些融合策略获得了不同模态之间的高质量嵌入，但往往忽略了捕捉模态内的多样性以丰富实体表示。

研究人员近年来在捕捉模态内部信息方面付出了大量的精力。例如，VisualBERT^[10]和 ViLBERT^[11]等方法证明，利用文本描述与视觉视角的差异可生成更稳健的实体嵌入；MoMoK 模型通过为每个模态构建关系引导的模态知识专家，捕捉单一模态不同特征，生成关系感知的模态嵌入来获得更高质量的模态嵌入^[12]。

·目前的多模态知识图谱补全模型大多只关注图像等实体模态信息，而对关系本身蕴含的信息以及不同模态之间关系关注不够充分。尽管 MoMoK 等模型通过引入关系引导的模态专家有效捕捉了模态内多样性，但在特征聚合的精细度、跨模态的深层协同上仍有提升空间。为解决此类问题，本文提出关系引导的粗细颗粒度专家多模态知识图谱补全模型（RG-FCEC）。相较于 MoMoK 采用单一权重，本模型采用专家权重与关系权重粗细颗粒度双重权重机制，实现了全局静态先验与局部动态适应的结合；MoMoK 侧重于模态内部，未充分关注不同模态间的协同互补，而本模型设计了结构特征引导的跨模态信息融合，实现了跨模态的深层融合。通过在 MKG-Y^[13], MKG-W, KVC16K^[14]三个公开数据集上的大量实验，结果表明本模型优于各种基线模型。

1 相关工作

1.1 多模态知识图谱补全

多模态知识图谱补全核心在于协同建模三元组结构信息与实体的图像、文本、语音等多模态特征，以自动挖掘多模态知识图谱中缺失的事实三元组。多模态知识图谱补全

(Multimodal Knowledge Graph Completion, MMKGC) 技术主要分为两类。一类是基于模态融合的补全方法, 通过注意力机制、跨模态映射等技术, 将多模态特征融合, 强化实体, 提升模型能力, 如 IMVIA^[15], TBKGC^[16], RSME^[17]。另一类是基于模态协同推理的补全方法, 依托多模态数据的语义关联构建推理规则。例如 PathSem-MedKGC^[18]利用知识图谱路径结构与实体文本语义的协同推理, 缓解医疗 KGC 中的实体与路径稀疏问题; ReranKGC^[19]则设计了检索-重排的协同框架, 先由文本模态高效检索候选实体, 再由多模态证据联合进行精细重排, 实现更鲁棒的协同推理。MMKGC 在尽管 MMKGC 已取得进展, 但仍面临模态异质性适配, 复杂关系推理等挑战。

1.2 关系建模

知识图谱推理中的关系建模技术历经了从静态全局嵌入到动态上下文感知的深刻演进。早期模型如 TransE 将关系视为实体向量间的固定平移, 开创了嵌入学习范式, 但难以建模复杂关系。后续工作引入更丰富的数学变换来增强表达能力, 例如 ComplEx^[20]在复数空间进行双线性建模, 而 RotatE^[21]将关系定义为复平面上的旋转, 统一建模了对称、逆反等关系模式。随着图神经网络兴起, 研究重点转向对局部结构的感知, 如 CompGCN^[22]在消息传递中联合学习实体与关系表示。当前的前沿已超越对关系本身的静态参数化, 进入动态情境化推理阶段: 模型通过融合时间、文本等多模态上下文, 使关系语义能够随情境动态演化。目前关系建模的核心正从设计通用的表示函数, 转向构建能够理解并响应丰富上下文的智能推理系统。

1.3 模态融合策略

模态融合一直是多模态知识图谱补全的主流技术之一, 其技术发展经历了从浅层特征组合到深度结构化协同的演进过程。早期方法侧重于特征层面的简单操作式融合, 代表性模型如 IKRL 模型通过跨模态注意力从多张相关图像中聚合视觉信息, 并与知识图谱结构嵌入相结合^[23]; MoSE 模型则引入模态专家进行自适应加权融合^[24]。

随着研究深入, 模态融合逐渐转向交互增强与结构感知的阶段。在交互增强方面, MKGformer 利用跨模态 Transformer 架构统一编码文本与视觉特征, 实现深层次的语义对齐与交互。同时, 图神经网络技术推动了结构化融合范式的兴起, 使融合过程能够感知并利用图谱的拓扑结构。例如, MMKGR 模型系统性地提出了一个多跳多模态推理框架, 通过元路径引导的消息传递机制, 在复杂路径上迭代地聚合和推理多模态信息, 显著提升了模型处理复杂查询的能力^[25]。

近期研究的焦点已转向全局关联引导的深度自适应融合, 强调从图谱的整体拓扑与语义关联中挖掘信息, 以指导更精准的多模态融合。典型工作如 LAFA, 其核心在于设计了一个链接感知的融合层^[26]。该机制不仅计算中心实体与邻居的多模态关联以动态分配注意力与融合权重, 更能从一跳邻居的局部上下文中隐式捕获更丰富的图结构信息。

目前如何更加高效地应用图谱中的信息并设计出更加适合的融合策略仍是研究人员所努力的方向。

1.4 混合专家模型

混合专家模型(Mixture of Experts, MoE)^[27]是一种基于“分而治之”策略的稀疏激活架构，其核心思想在于通过动态组合多个专业化子模型（专家）与轻量级门控网络协同完成学习任务，在突破传统密集模型扩展瓶颈的同时实现性能与计算效率的平衡。专家模块应用场景广泛：在大规模语言模型中，以 MoE 架构模型 GLaM 为代表，其稀疏专家网络通过推理阶段仅激活部分参数，实现了算力消耗降低与任务性能提升的兼顾^[28]；在跨模态检索与生成领域，引入稀疏混合专家架构是扩展基础模型容量的重要路径，如基于 CLIP 框架^[29]，V-MoE 模型将 MoE 融入其图像编码器，在几乎不增加计算开销的前提下显著提升了模态匹配精度^[30]。在多模态知识图谱补全方面，MoMoK 通过建立关系引导的模态知识专家网络，获得单一模态不同特征以优化预测。

混合专家模型在多模态知识图谱补全方面可以帮助获得更高质量实体嵌入，提升多模态知识图谱补全模型准确率与鲁棒性。

2 模型设计与实现

模型主要包括以下 4 个模块：多模态特征预处理与初始嵌入生成、粗细颗粒度专家加权融合、结构特征引导的跨模态信息融合、多模态多路并行联合决策。




图 1 关系引导的粗细颗粒度专家多模态知识图谱补全模型

Fig.1 Relation-guided fine-and-coarse-grained expert multimodal knowledge graph completion model

2.1 多模态特征预处理与初始嵌入生成

为了更好地得到不同角度的高质量实体特征，对实体不同模态进行特殊处理。首先，对于图像与文本模态，分别使用预训练模型 VGG^[31]与 BERT^[32]进行原始模态特征提取，对于结构模态，原始模态特征将在训练过程中通过三元组数据从头学习。

2.2 粗细颗粒度专家加权融合

2.2.1 粗细双权重专家特征编码

得到初始特征嵌入后，进入粗细颗粒度专家模块。在模块内为每个模态新建 K 个专家，记为 $S_{m,1}, S_{m,2}, \dots, S_{m,K}$ ，学习单一模态的不同特征，其经过专家学习后的嵌入为 $N_{m,1}^e, N_{m,2}^e, \dots, N_{m,K}^e$ ，公式表示为 $N_{m,i}^e = S_{m,i}(e_m)$ ，其中 e_m 为原始模态特征。

得到专家学习后的实体嵌入后，为实体嵌入赋予粗与细两种不同颗粒度权重。粗颗粒度权重是单一模态层面下全局考虑得到的静态权重：设置可学习参数专家权重 E_w ，在训练过程中得到单模态不同专家的静态权重， E_w 提供单一模态层面下专家权重的全局特征分布，不考虑关系；细颗粒度权重是根据不同关系得到的动态权重：实体嵌入进入关系门控，得到关系引导的关系权重 $G_i(N_{m,i}^e, r)$ ， $G_i(N_{m,i}^e, r)$ 可以实现根据关系的动态特征适配，生成关系特定的动态权重，实现特征级的精细化调节。

关系权重的计算公式为：

$$G_i(N_{m,i}^e, r) = \frac{\exp\left(\left(\mathbf{U}_m(N_{m,i}^e) + \delta_{m,i}\right) / \sigma(\varepsilon_r)\right)}{\sum_{j=1}^K \exp\left(\left(\mathbf{U}_m(N_{m,j}^e) + \delta_{m,j}\right) / \sigma(\varepsilon_r)\right)}, \text{ where } \delta_{m,i} \sim \mathcal{N}(0, \mathbf{U}_m(N_{m,i}^e)) \quad (1)$$

式中： $\mathbf{U}_m(\cdot)$ 为投影层； ε_r 为关系感知温度参数，每个关系学习一个独立的温度参数，通过 Sigmoid 函数约束到 (0,1) 区间，控制权重分布的尖锐程度； $\delta_{m,i}$ 是可调高斯噪声^[33]，其设置为标准正态分布，在训练过程中不衰减，设置一个可学习参数 w_{noise} 来调整噪声添加强度。最终带权专家学习后实体嵌入公式为的计算公式为：

$$e_{i_weighted} = N_{m,i}^e G_i(N_{m,i}^e, r) E_w \quad (2)$$

式中 $e_{i_weighted}$ 带权专家学习后实体嵌入。

静态权重（专家重要性权重）提供全局知识指导，动态权重（关系权重）实现局部上下文适应。两者共同作用，实现了专家模块的基础保障与精准调节。

2.2.2 自适应加权的专家信息融合

为防止模型对特定专家过于依赖，提升模型的鲁棒性，引入自适应加权的专家信息融合策略，对专家提取的实体嵌入进行自适应融合输出。

对 $N_{m,1}^e, N_{m,2}^e, \dots, N_{m,K}^e$ ，除加权融合外，同时对其进行平均融合，作为加权融合的补充。加权融合与平均融合之间的自适应平衡利用参数 α_i 实现。其过程为：设置可学习的基础参

数 α_{param} 和 M_{w_i} ; α_{param} 作为 α_i 的基础值, 通过 Sigmoid 函数归一化后作为加权融合的系数; M_{w_i} 作为模态自适应权重, 用于控制不同模态 (结构、视觉、文本) 下专家平衡策略的敏感度, M_{w_i} 通过可学习的方式为各模态提供独立的调节系数, 使 α_i 在保持 Sigmoid 归一化特性的同时能够适应不同模态的特征分布差异, 自适应调节加权专家输出与平均专家输出的融合比例, 得到专家模块最终的输出。

$$\alpha_i = \sigma(\alpha_{\text{param}}) \cdot M_{w_i} \quad (3)$$

式中: $\sigma(\cdot)$ 代表 Sigmoid 函数, i 代表结构\文本\图像不同模态。

$$e_{i_output} = \alpha_i \times e_{i_weighted} + (1 - \alpha_i) \times e_{i_decoupled} \quad (4)$$

式中: $e_{i_weighted}$ 代表专家特征的加权输出, $e_{i_decoupled}$ 代表专家特征的平均输出, i 代表结构\文本\图像不同模态。

2.2.3 基于互信息最小化的专家解耦

为了使不同专家能够提取不同视角的嵌入, 引入基于对比对数比上界 (CLUB) [34] 的互信息估计, 对模态内多专家嵌入表示的冗余信息进行量化与抑制, 间接对互信息进行上界约束与最小化, 最终实现专家决策的信息解耦。

具体而言, 模块首先构建变分近似网络 $Q_{\theta,m}$, 用于逼近不同专家嵌入间的真实条件概率分布 $P(V_{m,j}^e | V_{m,i}^e)$ 。互信息的上界可通过如下目标函数进行估计:

$$\mathcal{L}_{\text{club}} = \frac{1}{K^2} \sum_{m \in \mathcal{M}} \sum_{e \in \mathcal{B}} \sum_{i=1}^K \sum_{j \neq i}^K \left(\log Q_{\theta,m}(N_{m,j}^e | N_{m,i}^e) - \sum_{e' \in \mathcal{B} - \{e\}} \log Q_{\theta,m}(N_{m,j}^{e'} | N_{m,i}^e) \right) \quad (5)$$

式中: K 表示单个模态下的专家数量, $\mathcal{M}$ 为多模态知识图谱中的模态集合, $\mathcal{B}$ 代表训练过程中的一个实体批次, m 为模态索引, e 是实体集中的实体, e' 是从批次 $\mathcal{B}$ 中采样的除 e 之外的其他实体, i, j 为专家网络索引且 $i \neq j$, $Q_{\theta,m}(y|x)$ 是由参数为 θ 的神经网络参数化的变分近似网络, 用于逼近 y 给定 x 时的真实后验概率分布。

为保障变分近似的准确性, 模块进一步引入 KL 散度损失 $\mathcal{L}_{\text{exid}}$, 优化变分分布与真实条件分布的拟合程度:

$$\mathcal{L}_{\text{exid}} = \mathbb{D}_{\text{KL}} \left[P(N_{m,j}^e | N_{m,i}^e) \parallel Q_{\theta,m}(N_{m,j}^e | N_{m,i}^e) \right] \quad (6)$$

式中: $\mathbb{D}_{\text{KL}}$ 为 KL 散度, 用于衡量两个概率分布间的差异, $P(N_{m,j}^e | N_{m,i}^e)$ 是专家嵌入间的真实条件概率分布 (实验中假设为高斯分布)。

该损失与主 MMKGC 模型在训练中采用批次级交替优化策略, 每处理一个批次数据, 先固定互信息估计并更新主模型, 通过计算主损失来优化参数, 随后固定主模型并更新互信息估计部分, 以优化其互信息上界的估计能力。

2.3 结构特征引导的跨模态信息融合

结构模态在知识图谱中通常更加稳定可靠，并且相对于文本，图像模态更不易缺失。为打破了模态间的信息壁垒，并将结构信息稳定性传递给其他模态，建立了结构特征引导的跨模态信息融合。

结构特征引导的跨模态信息融合机制旨在通过结构模态增强视觉与文本模态的语义理解能力，首先对各模态原始嵌入进入粗细颗粒度专家加权融合模块，随后将处理后的结构与文本、视觉等其他模态的特征进行跨模态融合。结构模态嵌入通过模态映射层映射至对应目标模态特征空间，动态调节结构信息对目标模态的指导强度，以视觉/文本模态专家模块适配器的参数 α_i 使模型能够根据具体任务需求自主利用结构信息。最终，通过残差连接的形式将映射后的结构特征融入目标模态，在保留原始模态特征的同时引入结构语义指导，显著提升了多模态表示的一致性与语义丰富度，为后续的知识推理任务奠定了坚实基础。

$$e_s = e_{\text{str_output}} \quad (7)$$

$$e_i = e_{\text{img_output}} + \tanh(\alpha_{\text{img}}) \cdot T(e_s) \quad (8)$$

$$e_t = e_{\text{text_output}} + \tanh(\alpha_{\text{text}}) \cdot T(e_s) \quad (9)$$

其中 $T(\cdot)$ 是模态映射层。

2.4 多模态多路并行联合决策

传统模型通常将各模态融合之后进行预测，未能充分考虑到不同模态的独立贡献。为解决这一问题，采用了多路并行联合决策，将文本、图像、结构以及融合后的模态并行送入独立的评分支路同步计算，得到各自的评分，再将这些评分相加得到最终的综合评分，选择评分最高的候选实体作为最终预测结果，通过并行整合不同模态信息以实现联合决策。

经过结构特征跨模态指导得到的文本嵌入，图像嵌入以及经过专家模块得到的结构嵌入进入多路并行联合决策模块。

2.4.1 双头注意力的多模态特征深度融合

多模态多路并行联合决策模块先将不同模态映射为同一维度，随后进入线性层使用基于内容的线性打分的注意力机制，采用双头注意力机制并行架构，利用一个共享的线性投影层将各子空间的高维特征映射为标量重要性分数。在每个注意力头内部，通过 **Softmax** 函数对分数进行归一化，动态生成反映当前语境下各模态贡献度的权重：

$$\alpha_p^{(j)} = \frac{\exp(W_{\text{attn}}^{\top} \cdot \mathcal{L}_p^{(j)}(e_j))}{\sum_{m \in \{s, i, t\}} \exp(W_{\text{attn}}^{\top} \cdot \mathcal{L}_p^{(m)}(e_m))}, \quad j \in \{s, i, t\} \quad (10)$$

式中： $\alpha_p^{(j)}$ 为第 p 个注意力头下不同模态的归一化贡献权重， $\mathcal{L}_p^{(j)}$ 为第 p 个注意力头下不同模态的模态映射层， $W_{\text{attn}}^{\top}$ 为共享线性注意力层的权重矩阵，其中 $p \in \{1, 2\}$ 。

此后根据权重进行融合，再对融合后的模态 c_p 进行特征增强，得到模态 v_p ，最后对两次得到的结果进行平均融合得到多模态实体融合的嵌入 e_{mm} 。

$$c_p = \sum_{j \in \{s, i, t\}} \alpha_p^{(j)} \cdot \mathcal{L}_p^{(j)}(e_j) \quad (11)$$

$$v_p = \text{Dropout}\left(\text{ReLU}\left(W_{\text{enh}} \cdot c_p + b\right)\right) \quad (12)$$

$$e_{\text{mm}} = \frac{1}{K} \sum_{p=1}^K v_p \quad (13)$$

式中： W_{enh} 、 b 分别为特征增强层的可学习权重矩阵与偏置向量， $K=2$ 。

通过两次并行处理，可以捕获不同层次的特征表示，增强模型的表达能力和特征抽象能力，每层处理可以独立捕获不同的特征组合和模态间关联模式，实现多模态信息的深度互补与富集。通过多层结果的平均降低模型对单一特征组合的依赖，通过两次并行处理并对结果求平均，可以减少单次处理中的随机波动，提高模型在不同场景下的稳定性和泛化能力。




图2 多模态融合

Fig.2 Multimodal fusion

关系融合遵循与实体融合相同的流程，但处理的是关系嵌入而非实体嵌入。

2.4.2 多支路独立评分的并行联合决策机制

在得到融合模态以后，对四种模态进一步采用 Tucker^[35]评分函数，从每个模态的角度衡量三元组的合理性，公式为：

$$\mathcal{S}_m(h, r, t) = \mathcal{W}_m \times_1 \hat{h}_{m,r} \times_2 r_m \times_3 \hat{t}_{m,r} \quad (14)$$

式中： $\times_i$ 表示沿第 i 个模式的张量乘积， r_m 是每个模态下关系 r 的可学习嵌入， $\mathcal{W}_m$ 是训练过程中学习的核心张量。采用交叉熵损失对每个三元组进行训练：对于给定三元组 (h, r, t) ，在尾实体预测任务中以 t 为黄金标签，在头实体预测任务中以 h 为黄金标签。

每个模态的训练目标可表示为：

$$\mathcal{L}_m = - \sum_{(h,r,t) \in T} \left(\log \frac{\exp(\mathcal{S}_m(h,r,t))}{\sum_{h' \in \mathcal{E}} \exp(\mathcal{S}_m(h',r,t))} + \log \frac{\exp(\mathcal{S}_m(h,r,t))}{\sum_{t' \in \mathcal{E}} \exp(\mathcal{S}_m(h,r,t'))} \right) \quad (15)$$

这是标准知识图谱补全模型的训练目标，多模态联合决策模块对其进行扩展，为每个模态训练一个独立的评分函数。多模态联合决策模块的整体训练目标可表示为：由于不同模态的训练目标具有一致的预测目标，因此直接将它们组合起来，得到最终的损失函数。

$$\mathcal{L}_{\text{kgc}} = \sum_{m \in \mathcal{M} \cup \{J\}} \mathcal{L}_m \quad (16)$$

训练时，模型整体的损失函数为：

$$\mathcal{L} = \mathcal{L}_{\text{kgc}} + \lambda \mathcal{L}_{\text{club}} \quad (17)$$

通过较小的损失权重 λ 在训练初期优先保证模型的预测学习，随后再逐步借助专家解耦来促进各专家学习到差异化且不重叠的特征。

3 实验

3.1 实验设置

3.1.1 数据集

本文采用三个公开数据集对模型进行评估，所有数据集均包含 3 种模态：结构三元组、实体图像和实体描述。分别是 **MKG-W**、**MKG-Y** 和 **KVC16K**。其中，**MKG-W** 和 **MKG-Y** 分别是 **Wikidata**、**YAGO** 和 **DBpedia** 的子集；**KVC16K** 基于微视频百科全书 **KuaiPedia** 修改而来。

这些数据集均为包含图像和文本模态的真实世界多模态知识图谱。数据集的详细信息如表1所示。

表1 数据集信息
Tab.1 Dataset information

Dataset	#entity	#Relation	#Train	#Valid	#Test	#Image		#Text	
						Num	Dim	Num	Dim
MKG-W	15000	169	34196	4276	4274	14463	383	14123	384
MKG-Y	15000	28	21310	2665	2663	14244	383	12305	384
KVC16K	16015	4	180190	22523	22525	14822	768	14822	768

3.1.2 评估指标

评估过程中使用 **MRR**（平均倒数排名）以及命中率 **Hit@1**，**Hit@3**，**Hit@10** 3 个有效实体指标衡量模型性能。

3.1.3 基准方法

为进行全面对比，选取 21 种最新的当前最优多模态知识图谱补全方法作为基准方法，为确保对比的公正性，所有基线模型均在的实验环境下，使用相同的训练、验证、测试数据

集划分、相同的评估指标，并基于相同的骨干网络进行重新训练或评估，以消除因实验设置差异对性能结果造成的影响。具体分为以下两类：

单模态知识图谱补全方法：

- TransE：将关系视为向量空间中的平移操作，构建“头实体+关系 $\approx$ 尾实体”的映射。
- DistMult^[36]：利用对角矩阵表示关系，通过头尾实体与关系矩阵的双线性点积评估三元组。
- ComplEx：在复向量空间中建模，通过复数乘法刻画非对称与反对称关系。
- RotatE：在复空间中用旋转操作表示关系，处理对称、反对称等多种关系模式。
- PairRE^[37]：为每个关系学习两个向量，通过头尾实体分别与对应关系向量的交互计评估。
- Tucker：基于张量分解，通过核心张量融合实体与关系嵌入，构建评分函数进行预测。

多模态知识图谱补全方法：

- IKRL^[38]：结合 TransE 与注意力机制，融合实体多图像特征与结构嵌入。
- TBKGC：在 TransE 基础上引入多模态翻译约束，联合优化结构与跨模态语义一致性。
- TransAE^[39]：通过自编码器压缩多模态特征，将低维表示输入 TransE 进行补全。
- RSME：利用关系感知的模态选择机制，动态筛选相关模态特征。
- MMKRL^[40]：引入跨模态一致性损失与数据扰动。
- VBKGC^[41]：基于预训练多模态模型提取特征，采用孪生负采样提升训练质量。
- OTKGE^[42]：基于最优传输理论对齐多模态特征分布，再融合进行预测。
- MoSE：构建多模态子模型并加权集成，适应模态异构场景。
- MMRNS^[13]：利用多模态信息设计关系感知的负采样，降低训练偏差。
- MANS^[43]：基于模态相似性筛选负样本，增强对比学习效果。
- IMF：构建交互式多模态融合模块，实现文本、图像与结构融合。
- QEB^[44]：根据查询关系动态调整多模态特征权重，生成查询感知的实体表示。
- VISTA^[45]：借助跨模态 Transformer 对齐图像区域与文本，结合结构嵌入进行补全。
- AdaMF^[46]：自适应学习关系相关的模态权重，并结合对抗训练提升泛化能力。
- MoMoK：构建关系引导的模态专家网络，融合不同模态的特征表示。

3.1.4 超参数设置

实验基于 PyTorch 实现，所有实验在安装有 Ubuntu 20.04.1 操作系统和单块 NVIDIA 4090 的 Linux 服务器上进行。每个模态设置 3 个专家，变分近似网络（隐藏层维度为 256）和投影层（隐藏层维度为 128）均采用两层 MLP 实现，激活函数为 ReLU。训练过程中，批处理大小设为 1024；嵌入维度 d 在 {200, 300, 400} 中进行调整；采用 Adam 优化器优化模型，学习率在 $\{1e^{-4}, 5e^{-4}, 1e^{-3}, 2e^{-3}, 5e^{-3}\}$ 中进行选择；损失权重在 $\{1e^{-5}, 5e^{-5}, 1e^{-4}, 5e^{-4}, 2e^{-3}\}$ 中进行调整。不同数据集上的单次实验约耗时 6~8 小时。

各数据集超参数设置如表 2 所示。

表2 不同数据集最优超参数配置
Tab.2 Optimal Hyperparameter Configurations for Various Datasets

数据集	嵌入维度	学习率	损失权重
-----	------	-----	------

MKG-W	200	$1e^{-3}$	$1e^{-4}$
MKG-Y	200	$5e^{-4}$	$1e^{-5}$
KVC16K	300	$5e^{-3}$	$1e^{-4}$

3.2 性能对比 (RQ1)

在性能对比实验中，将本模型与众多基线进行全面比较，相关评估结果如表3所示。

表3 RG-FCEC与基线模型性能对比

Tab.3 Performance comparison between RG-FCEC and baseline models

model	MKG-W		MKG-Y		KVC16K			
	MRR	Hit@1	MRR	Hit@1	MRR	Hit@1	Hit@3	Hit@10
TransE	29.17	21.04	30.65	23.88	8.51	0.64	10.96	23.22
DisMult	20.96	15.83	25.26	19.33	6.37	3.13	6.11	12.51
ComplEx	24.90	19.89	28.72	22.06	12.75	7.48	13.79	23.18
RotaE	33.37	26.82	34.97	29.13	14.35	8.24	15.39	26.17
PairRE	34.90	28.24	32.01	25.53	13.22	9.70	16.63	27.22
Tucker	29.39	23.43	37.34	34.55	15.50	9.76	17.24	27.58
IKRL	32.32	26.11	33.42	30.66	11.13	5.52	11.46	22.39
TBKGC	31.46	25.31	33.99	30.43	5.39	0.35	5.04	15.52
TransAE	30.00	21.13	28.11	25.69	10.91	5.31	11.44	21.89
MMKRL	30.17	22.19	36.82	31.76	8.78	3.89	8.99	18.34
RSME	29.03	23.37	34.46	31.78	12.32	7.14	13.21	22.05
VBKGC	30.61	28.87	37.01	33.96	14.69	8.28	15.81	27.04
OTKGE	34.66	24.84	35.66	31.55	8.77	5.01	9.31	15.35
MOSE	33.24	27.77	36.28	33.64	8.81	4.75	9.26	16.00
IMF	34.60	28.70	35.79	32.95	12.01	7.44	14.82	21.60
QEB	32.38	25.33	34.37	29.36	12.06	5.57	13.03	21.01
VISTA	32.92	26.12	30.45	24.87	11.89	6.97	12.66	24.27
AdaMF	34.23	27.21	38.09	33.49	15.26	8.56	16.71	28.29
MANS	30.88	24.89	29.03	25.23	10.42	5.91	11.01	20.55
MMRNS	35.03	28.59	35.88	30.52	13.31	7.51	14.19	24.68
MoMoK	34.93	29.63	37.81	34.85	16.64	10.46	17.90	28.67
RG-FCEC	36.03	30.4	38.12	35.11	17.19	10.85	18.47	29.4
提升	+2.85%	+2.59%	+0.81%	+0.74%	+3.31%	+3.73%	+3.18%	+2.76%

在所有数据集与评价指标上，本模型性能最优。以 **MKG-W** 为例，本模型的 MRR 达到 36.03%，Hits@1 达到 30.4%，较排名第二的模型分别提升 2.85 个百分点和 2.59 个百分点；在 **MKG-Y** 数据集上，本模型的 MRR 达到 38.12%，Hit@1 达到 35.11%，较排名第二的模型分别提升 0.81 个百分点和 0.74 个百分点；在 **KVC16K** 数据集上，本模型的 MRR 达到 17.19%，Hit@1 达到 10.85%，Hits@3 达到 18.27%，Hit@10 达到 29.46%，较 MoMoK 分别提升 3.31 个百分点，3.73 个百分点，3.18 个百分点和 2.76 个百分点，体现出其在专业领域的优异适配性。

3.3 消融实验 (RQ2)

本研究旨在评估提出的模型中包含的关键模块的有效性。为了与原始方法进行比较分析，开发了 4 种不同的模型变体，每个变体性能都有不同程度的降低，具体分析如下：

(1) 删除粗细颗粒度权重变体 (w/o CFG)：删除粗细颗粒度专家中的专家重要性权重与关系权重。

(2) 删除自适应加权的专家信息融合变体 (w/o EIFVA)：删除模型中的自适应加权的专家信息融合模块。

(3) 删除专家解耦变体 (w/o MI)：删除模型内的专家解耦模块。

(4) 删除结构特征引导的跨模态信息融合变体 (w/o SG-CMF)：删除模型中的结构特征与文本特征及结构特征与图像特征的融合。

实验结果如表 4 所示：

表4 消融实验
Tab.4 Ablation study

	MKG-Y		MKG-W		KVC16K			
	MRR	Hit@1	MRR	Hit@1	MRR	Hit@1	Hit@3	Hit@10
完整模型	38.15	35.07	36.03	30.4	17.06	10.68	18.34	29.4
w/o CFG	38.08	35.00	33.99	28.21	16.40	10.11	17.76	28.58
w/o EIFVA	37.98	34.9	35.52	29.94	16.98	10.52	18.3	29.5
w/o MI	37.86	34.74	25.60	30.09	16.87	10.51	18.14	29.32
w/o SG-CMF	38.03	34.87	35.03	29.48	16.64	10.36	17.94	28.78

- 去除粗细颗粒度权重后，各数据集指标均下降，原因是失去了专家权重的全局知识指导和关系权重的局部上下文适应功能，模型无法给不同专家赋予不同权重，模型各指标准确性显著下降。说明利用专家权重以及关系权重得到更优质的模态嵌入，是模型性能提升的关键因素。
- 去除自适应加权的专家信息融合后，数据指标均下降，缺少平均融合的补充后，模型可能过于依赖某些专家，导致不能充分应用各个专家信息，致使模型性能下降。
- 删除专家解耦模块后，MRR, Hit@1 等指标下降，删除此模块后，专家网络无法实现解耦，使专家提取的特征未能充分聚焦于模态不同方面，不能充分提取多角度模态信息，模型准确率显著降低。
- 删除结构特征引导的跨模态信息融合后，导致无法充分使用结构特征所包含的内容与其稳定性，无法利用结构模态信息增强视觉与文本模态的语义理解能力，模型的预测准确率降低，说明将结构模态与其他模态融合，将结构模态的稳定性传递给其他模态在模型中发挥着重要作用。

3.4 超参数影响 (RQ3)

为探究本模型关键超参数对性能的影响，在 **MKG-W**, **MKG-Y**, **KVC16K** 3 个数据集上进行了系统性分析，重点考察以下参数对模型的影响。

3.4.1 学习率

学习率 (learning rate, lr) 的核心功能是控制模型参数更新的步长，过大易导致训练震荡且难以收敛，过小则收敛缓慢或陷入局部最优。

各数据集指标随 lr 变化如下所示：




图 3 MRR 随 lr 变化

Fig. 3 MRR varies with lr




图 4 Hit@1 随 lr 变化

Fig.4 Hit@1 varies with lr




图 5 Hit@3、Hit@10 随 lr 变化

Fig.5 Hit@3、Hit@10 varies with lr

实验表明，学习率对模型性能有重要影响。对于 **MKG-Y** 数据集来说，当 $lr=0.0005$ 时，MRR 达到 38.12, Hit@1 达到 35.11。对于 **MKG-W** 数据集，当 $lr=0.001$ 时，MRR 达到 36.03, Hit@1 达到 30.4。对于 **KVC16K** 数据集来说，当 $lr=0.005$ 时，MRR 达到 17.19, Hit@1 达到

10.85,Hit@3 达到 18.47,Hit@10 达到 29.46。

3.4.2 损失权重

损失权重 (λ) 在本模型中专门调控专家解耦部分损失在整体优化目标中的权重比例,作用是平衡主任务损失与辅助约束损失的贡献比例,确保模型在学习核心任务目标的同时,有效利用辅助约束提升表征质量。

各数据集指标随 λ 变化如下所示:




图 6 MRR 随 λ 变化

Fig.6 MRR varies with λ




图 7 Hit@1 随 λ 变化

Fig.7 Hit@1 varies with λ




图 8 Hit@3、Hit@10 随 λ 变化

Fig.8 Hit@3、Hit@10 varies with λ

当 λ 过小时,专家特征趋于同质化,导致多视角信息利用不足; λ 过大则特征过度解耦,引发碎片化,干扰模型优化与泛化。对于 **MKG-Y** 数据集,当 $\lambda=1e^{-5}$ 时, MRR 达到 38.12, Hit@1 达到 35.11。对于 **MKG-W** 数据集,当 $\lambda=1e^{-4}$ 时, MRR 达到 36.03, Hit@1 达到 36.4。对于 **KVC16K** 数据集来说,当 $\lambda=1e^{-4}$ 时, MRR 达到 17.19, Hit@1 达到 10.85, Hit@3 达到 18.47,Hit@10 达到 29.46。

3.5 案例分析

3.5.1 关系权重有效性实例分析

为直观验证 RG-FCEC 模型中关系权重机制的有效性,对 **MKG-W** 数据集中三种代表性实体关系 (Cast Member、Screenwriter、Occupation) 的关系权重进行了可视化,如图 9 所示。在 Cast Member 和 Occupation 中,Expert_1 都在结构模态上占据主导地位;Expert_2 在 Screenwriter 这一关系上表现出压倒性的统治力。Expert_3 在视觉模态上表现非常活跃。模型能根据关系语义自适应且差异化地分配各模态的关系权重。这表明模型能根据关系语义动态选择特征,该关系感知机制成功将先验知识注入多模态融合过程,使模型可依据关系需求精准调配专家资源,从而提升补全性能。




图 9 不同关系下不同专家权重热力图

Fig.9 Heatmap of adaptive expert weights across relations

3.5.2 跨模态融合实例分析

为了直观验证模型跨模态融合的优势,选取 **MKG-W** 数据集中 (THE Beatles, influenced by,?) 三元组进行补全,正确的尾实体应为 Oasis。设计使用结构特征引导的跨模态信息融合与去除结构特征引导的跨模态信息融合两种模式进行对比。两种模式下模型输出的 Top-1 预测与正确尾实体在候选实体中的排名如表 5 所示。

表5 结构特征引导的跨模态融合消融实验性能对比
Tab.5 Performance Comparison of Ablation Experiments on Cross-Modal Fusion Guided by Structural Features

	Top-1预测	正确尾实体在候选实体中的排名
使用结构特征引导的跨模态信息融合	Oasis	1
去除结构特征引导的跨模态信息融合	THE Beatles	24

由表所示,当使用结构特征引导的跨模态信息融合时,模型可以正确输出尾实体 Oasis;当消融掉结构特征引导的跨模态信息融合时,模型输出的 Top-1 预测为 The Beatles,且正确尾实体排名为 24。由此可见,本模型使用的跨模态融合策略可以提升模型准确率。

3.6 模型在噪声与模态缺失场景下的鲁棒性分析

针对现实场景中多模态数据的噪声与缺失问题, RG-FCEC 模型通过三重机制展现了内在的鲁棒性设计。

首先,模型的关系门控机制实现了动态噪声抑制。通过关系感知温度参数与可调高斯噪声,模型能根据当前关系的语义需求,自适应调节各专家权重的分布特性。当检测到某模态数据质量低下时,关系权重会自动降低噪声模态的贡献度,形成有效的软屏蔽效应。其次,结构引导的跨模态融合提供了知识补全能力。当图像或文本模态严重缺失时,模型通过残差连接将稳定的结构特征注入目标模态,利用 α_i 动态调节融合强度。此外,专家解耦机制通过互信息最小化确保各专家学习的特征表示相互独立,防止噪声模态通过梯度传播污染其他模态的编码过程,提升了模型的容错能力。

模型构建了层次化的鲁棒性防御机制,为多模态知识图谱补全任务在真实嘈杂环境下的稳定应用提供了坚实保障。

3.7 模型计算开销分析

RG-FCEC 的计算开销主要体现在多专家机制与多路并行架构带来的参数量增长和推理时间影响。在参数量方面,模型为每个模态配置 3 个专家,特征维度为 256,每个专家层的参数量约为 $O(K \times D^2)$,其中 K 为专家数量, D 为特征维度。相较于传统单投影层呈线性增长;同时维护四套独立的评分函数分支,需要存储多份 Tucker 核心张量权重。然而,模型采用权重共享的线性打分层进行注意力计算,将融合模块参数开销控制在 $O(D)$ 水平,有效避免了二次方膨胀。

在推理效率方面,尽管存在多个预测分支,但各分支逻辑独立可在 GPU 上实现高度并行化,整体推理时间取决于最耗时的单路计算。专家数量的增加带来约 3 倍计算开销,但因数值较小处于可接受范围。推理阶段移除了训练时的专家解耦损失计算,减少了模型推理时

间。

综合来看,模型通过增加特征提取宽度来提升模型表达能力,同时利用硬件并行特性控制时间开销,在保证性能提升的同时维持了合理的计算效率。

结语

本文提出一种新型多模态知识图谱补全(MMKGC)框架——关系引导的粗细颗粒度专家推理模型,旨在借助关系引导,从实体的原始模态信息中学习更高质量的模态特征,并基于模态知识专家整合多模态信息。将结构模态与文本、图像模态分别进行融合,最终利用多路并行决策完成图谱补全。通过互信息估计对专家网络进行解耦,以增强模型的表达能力。实验结果表明,的设计在多个公开基准数据集上均能取得当前最优性能,同时具备良好的鲁棒性。当前模型虽然在静态多模态知识图谱补全任务中表现出色,但仍存在超参数选择需要人工干预及计算复杂度较高等问题,且未充分考虑真实知识图谱的时序演化特性与增量学习需求。展望未来,模型的模块化架构为支持时序演化与增量学习提供了良好基础。关系引导机制和专家网络结构具备天然的扩展性,粗细颗粒度专家模块中的关系感知机制可扩展为时间感知的动态调节机制,而多路并行决策的独立评分分支设计便于实现渐进式更新。未来工作将重点探索通过引入时间感知的关系权重计算和时间戳注入机制,结合记忆增强网络与持续学习技术,在保持原有知识的同时有效吸收新信息,使模型从静态补全向动态演化推理迈进。同时,未来将探索自适应超参数优化算法,以减少人工干预,最终构建能够适应真实知识图谱持续演化特性的、无需人工选择超参数的高效自适应智能补全系统。

参考文献

- [1] 金志刚,何晓勇,岳顺民,等.融合知识图谱的医疗领域命名实体识别[J].哈尔滨工业大学学报,2023,55(05):50-58. DOI: 10.11918/202201126
Jin Zhigang, He Xiaoyong, Yue Shunmin, et al. Named entity recognition in medical domain combined with knowledge graph[J]. Journal of Harbin Institute of Technology, 2023, 55(05): 50-58. DOI: 10.11918/202201126
- [2] 何霆,吴雅婷,王华珍,等.基于 EHR 的医疗知识图谱研究与应用综述[J].哈尔滨工业大学学报,2018,50(11):137-144. DOI:10.11918/j.issn.0367-6234.201806001
He Ting, Wu Yating, Wang Huazhen, et al. A survey of medical knowledge graph based on EHR[J]. Journal of Harbin Institute of Technology, 2018,50(11):137-144. DOI:10.11918/j.issn.0367-6234.201806001
- [3] Zhu Xiangru, Li Zhixu, Wang Xiaodan, et al. Multi-modal knowledge graph construction and application: A survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 36(2): 715-735. DOI: 10.1109/TKDE.2022.3224228
- [4] Bordes A, Usunier N, Garcia-Durán A, et al. Translating embeddings for modeling multi-relational data[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2013: 2787-2795. DOI: 10.5555/2999792.2999923

- [5] Wang Zhen, Zhang Jianwen, Feng Jianlin, et al. Knowledge graph embedding by translating on hyperplanes[C]//Proceedings of the 28th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2014: 1112-1119. DOI: 10.1609/aaai.v28i1.8870
- [6] Lin Yankai, Liu Zhiyuan, Sun Maosong, et al. Learning entity and relation embeddings for knowledge graph completion[C]//Proceedings of the Twenty-Ninth AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2015: 2181-2187. DOI: 10.1609/aaai.v29i1.9491
- [7] Li Xinhang, Zhao Xiangyu, Xu Jiaying, et al. IMF: Interactive multimodal fusion model for link prediction[C]//Proceedings of the ACM Web Conference 2023. 2023: 2572-2580. DOI: 10.1145/3543507.3583554
- [8] Chen Xiang, Zhang Ningyu, Li Lei, et al. Hybrid transformer with multi-level fusion for multimodal knowledge graph completion[C]//Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2022: 904-915. DOI: 10.1145/3477495.3531992
- [9] 陈巧红,项深祥,方贤,等.跨模态自适应特征融合的视觉问答方法[J].哈尔滨工业大学学报,2025,57(04):94-104. DOI:10.11918/202404002
Chen Qiaohong, Xiang Shenxiang, Fang Xian, et al. Visual question answering method based on cross-modal adaptive feature fusion[J]. Journal of Harbin Institute of Technology, 2025,57(04):94-104. DOI: 10.11918/202404002
- [10] Li Liunian Harold, Yatskar Mark, Yin Da, et al. What does BERT with vision look at?[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 5265-5275. DOI: 10.18653/v1/2020.acl-main.469
- [11] Lu Jiasen, Batra Dhruv, Parikh Devi, et al. Vilbert: Pretraining task-agnostic visiolinguistic representations for vision-and-language tasks [C]//Advances in Neural Information Processing Systems. 2019: 13-23. DOI: 10.48550/arXiv.1908.02265
- [12] Zhang Yichi, Chen Zhuo, Guo Lingbing, et al. Multiple heads are better than one: Mixture of modality knowledge experts for entity representation learning[C]//Proceedings of the 13th International Conference on Learning Representations (ICLR). 2025:1-19. DOI: 10.48550/arXiv.2405.16869
- [13] Xu Derong, Xu Tong, Wu Shiwei, et al. Relation-enhanced negative sampling for multimodal knowledge graph completion[C]//Proceedings of the 30th ACM International Conference on Multimedia. 2022: 3857-3866. DOI: 10.1145/3503161.3548388
- [14] Zhang Yichi, Chen Zhuo, Guo Lingbing, et al. NativE: Multi-modal Knowledge Graph Completion in the Wild[C]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2024: 1-11. DOI: 10.36227/techrxiv.171259566.60211714/v1
- [15] Li Zhen, Wang Jiben, Chen Zhuo, et al. Unifying Within and Across: Intra-Modality Multi-View Fusion and Inter-Modality Alignment for Knowledge Graph Completion[C]//Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2025: 1-5. DOI: 10.1109/ICASSP49660.2025.10890167
- [16] Mousselly-Sergie H, Botschen T, Gurevych I, et al. A multimodal translation-based approach for knowledge graph representation learning[C]//Proceedings of the 7th Joint Conference on Lexical and Computational Semantics (*SEM). 2018: 225-234. DOI: 10.18653/v1/S18-2027

- [17] Wang Meng, Wang Sen, Yang Han, et al. Is visual context really helpful for knowledge graph? A representation learning perspective[C]//Proceedings of the 29th ACM International Conference on Multimedia. 2021: 2735-2743. DOI: 10.1145/3474085.3475470
- [18] Lan Yinyu, He Shizhu, Zeng Xiangrong, et al. Path-based knowledge reasoning with textual semantic information for medical knowledge graph completion[J]. BMC Medical Informatics and Decision Making, 2021, 21(Suppl 9): 335. DOI: 10.1186/s12911-021-01622-7
- [19] Gao Meng, Xie Yutao, Chen Wei, et al. ReranKGC: A cooperative retrieve-and-rerank framework for multi-modal knowledge graph completion[J]. Neural Networks, 2025, 188: 107467. DOI: 10.1016/j.neunet.2025.107467
- [20] Trouillon T, Welbl J, Riedel S, et al. Complex embeddings for simple link prediction[C]//Proceedings of the International Conference on Machine Learning. PMLR, 2016: 2071-2080. DOI: 10.48550/arXiv.1606.06357
- [21] Sun Zhiqing, Deng Zhihong, Nie Jianyun, et al. RotatE: Knowledge Graph Embedding by Relational Rotation in Complex Space[C]//Proceedings of the International Conference on Learning Representations (ICLR). OpenReview.net, 2019: 1049-1066. DOI: 10.48550/arXiv.1902.10197
- [22] Vashishth S, Sanyal S, Nitin V, et al. Composition-based Multi-Relational Graph Convolutional Networks[C]//Proceedings of the International Conference on Learning Representations. 2020: 5250-5265. DOI: 10.48550/arXiv.1911.03082
- [23] Xie Ruobing, Liu Zhiyuan, Luan Huanbo, et al. Image-embodied knowledge representation learning[C]//Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI). 2017: 3140-3146. DOI: 10.24963/ijcai.2017/438
- [24] Zhao Yu, Cai Xiangrui, Wu Yike, et al. MoSE: Modality Split and Ensemble for Multimodal Knowledge Graph Completion[C]//Proceedings of the Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2022: 10527-10536. DOI: 10.18653/v1/2022.emnlp-main.719
- [25] Zheng Shangfei, Wang Weiqing, Qu Jianfeng, et al. Mmkgr: Multi-hop multi-modal knowledge graph reasoning[C]//Proceedings of the IEEE 39th International Conference on Data Engineering (ICDE). IEEE, 2023: 96-109. DOI: 10.1109/ICDE55515.2023.00015
- [26] Shang Bin, Zhao Yinliang, Liu Jun, et al. LAFA: Multimodal knowledge graph completion with link aware fusion and aggregation[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(8): 8957-8965. DOI: 10.1609/aaai.v38i8.28744
- [27] Bian Shuqing, Pan Xingyu, Zhao Wayne Xin, et al. Multi-modal mixture of experts representation learning for sequential recommendation[C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. 2023: 110-119. DOI: 10.1145/3583780.3614978
- [28] Du Zonglin, Rabinovich Ella, Mi Haoran, et al. Glam: Efficient scaling of language models with mixture-of-experts[C]//Proceedings of the International Conference on Machine Learning. PMLR, 2022: 5547-5569. DOI: 10.48550/arXiv.2112.06905
- [29] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//Proceedings of the International Conference on Machine Learning. PMLR, 2021: 8748-8763. DOI: 10.48550/arXiv.2103.00020
- [30] Riquelme C, Puigcerver J, Mustafa B, et al. Scaling vision with sparse mixture of experts[J]. Advances in Neural Information Processing Systems, 2021, 34: 8583-8595. DOI:

10.48550/arXiv.2106.05974

- [31] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]//Proceedings of the International Conference on Learning Representations (ICLR). 2015:1-14. DOI: 10.48550/arXiv.1409.1556
- [32] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2019: 4171-4186. DOI: 10.18653/v1/N19-1423
- [33] Shazeer N, Mirhoseini A, Maziarz K, et al. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer[C]//Proceedings of the 5th International Conference on Learning Representations. 2017:1-40. DOI: 10.48550/arXiv.1701.06538
- [34] Cheng Pengyu, Hao Weituo, Dai Shuyang, et al. CLUB: A contrastive log-ratio upper bound of mutual information[C]//Proceedings of the International Conference on Machine Learning (ICML). PMLR, 2020: 1779-1788. DOI: 10.48550/arXiv.2006.12013
- [35] Balazevic Ivana, Allen Carl, Hospedales Timothy M. Tucker: Tensor factorization for knowledge graph completion[C]//Proceedings of the Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2019: 5185-5194. DOI: 10.18653/v1/D19-1522
- [36] Yang Bishan, Yih Wen-tau, He Xiaodong, et al. Embedding Entities and Relations for Learning and Inference in Knowledge Bases[C]//Proceedings of the 3rd International Conference on Learning Representations. 2015:1-12. DOI: 10.48550/arXiv.1412.6575
- [37] Chao Linlin, He Jianshan, Wang Taifeng, et al. PairRE: Knowledge Graph Embeddings via Paired Relation Vectors[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. 2021: 4360-4369. DOI: 10.18653/V1/2021.ACL-LONG.336
- [38] Xie Ruobing, Liu Zhiyuan, Luan Huanbo, et al. Image-embodied knowledge representation learning[C]//Proceedings of the 26th International Joint Conference on Artificial Intelligence. 2017: 3140-3146. DOI: 10.24963/ijcai.2017/438
- [39] Wang Zikang, Li Linjing, Li Qiudan, et al. Multimodal data enhanced representation learning for knowledge graphs[C]//Proceedings of the International Joint Conference on Neural Networks. IEEE, 2019: 1-8. DOI: 10.1109/IJCNN.2019.8852079
- [40] Lu Xinyu, Wang Lifang, Jiang Zejun, et al. MMKRL: A robust embedding approach for multi-modal knowledge graph representation learning[J]. Applied Intelligence, 2022, 52(7): 7480-7497. DOI: 10.1007/s10489-021-02693-9
- [41] Zhang Yichi, Zhang Wen. Knowledge graph completion with pre-trained multimodal transformer and twins negative sampling[C]//Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2022:1-8. DOI: 10.48550/arXiv.2209.07084
- [42] Cao Zongsheng, Xu Qianqian, Yang Zhiyong, et al. OTKGE: Multi-modal knowledge graph embeddings via optimal transport[J]. Advances in Neural Information Processing Systems, 2022, 35: 39090-39102.
- [43] Zhang Yichi, Chen Mingyang, Zhang Wen. Modality-aware negative sampling for multi-modal knowledge graph embedding[C]//Proceedings of the International Joint Conference on Neural Networks. IEEE, 2023: 1-8. DOI:

10.1109/IJCNN54540.2023.10191314

- [44] Wang Xin, Meng Benyuan, Chen Hong, et al. TIVA-KG: A multimodal knowledge graph with text, image, video and audio[C]//Proceedings of the 31st ACM International Conference on Multimedia. 2023: 2391-2399. DOI: 10.1145/3581783.3612266
- [45] Lee Jaesun, Chung Chanyoung, Lee Hochang, et al. VISTA: Visual-textual knowledge graph representation learning[C]//Findings of the Association for Computational Linguistics: EMNLP. 2023: 7314-7328. DOI: 10.18653/v1/2023.findings-emnlp.488
- [46] Zhang Yichi, Chen Zhuo, Liang Lei, et al. Unleashing the power of imbalanced modality information for multi-modal knowledge graph completion[C]//Proceedings of the Joint International Conference on Computational Linguistics, Language Resources and Evaluation. 2024: 17120-17130. DOI: 10.48550/arXiv.2402.15444

