



计算机应用与软件

Computer Applications and Software

ISSN 1000-386X, CN 31-1260/TP

《计算机应用与软件》网络首发论文

题目：基于多模态融合的行人轨迹预测方法
作者：宋志强，周鹏，宋利鹏
收稿日期：2025-11-09
网络首发日期：2026-03-13
引用格式：宋志强，周鹏，宋利鹏. 基于多模态融合的行人轨迹预测方法[J/OL]. 计算机应用与软件. <https://link.cnki.net/urlid/31.1260.TP.20260312.1817.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于多模态融合的行人轨迹预测方法

宋志强^{1*} 周鹏² 宋利鹏²

¹ (无锡学院自动化院 江苏 无锡 214105)

² (南京信息工程大学自动化院 江苏 南京 210044)

摘要：针对传统行人轨迹预测方法在长时预测中易产生误差累积及多模态生成不足的问题，文章提出一种基于目标条件的多模态双向轨迹预测模型。该方法以条件变分自动编码器(CVAE)为基础，引入扩散模型(Diffusion)提升潜变量的表达能力，并结合目标点引导与前后向双向解码，有效增强轨迹连续性与预测精度。在 JAAD 与 PIE 数据集上的实验结果表明，该方法在短期、中期及长期预测中均优于现有方法。在 PIE 数据集上，NLL 由 18.0 降至 15.6(提升约 13.3%)。结果验证了该方法在精度、多样性与稳定性上的显著提升。

关键词：自动驾驶 轨迹预测 扩散模型 多模态融合

中图分类号：TN958.98

文献标志码：A

PEDESTRIAN TRAJECTORY PREDICTION METHOD BASED ON MULTIMODAL FUSION

Song Zhiqiang^{1*} Zhou Peng² Song Lipeng²

¹ (School of Automation, Wuxi University, Wuxi 214105, Jiangsu, China)

² (School of Automation, Nanjing University of Information Science and Technology, Nanjing 210044, Jiangsu, China)

Abstract: To address the issues of error accumulation in long-term predictions and insufficient multimodal generation in traditional pedestrian trajectory prediction methods, this paper proposes a goal-conditioned multimodal bidirectional trajectory prediction model. Based on the conditional variational autoencoder (CVAE), this method incorporates a diffusion model to enhance the expressive power of latent variables. Combined with goal-point guidance and bidirectional decoding (forward and backward), it effectively improves trajectory continuity and prediction accuracy. Experimental results on the JAAD and PIE datasets demonstrate that the proposed method outperforms existing approaches in short-, medium-, and long-term predictions. On the PIE dataset, the NLL decreased from 18.0 to 15.6 (an improvement of approximately 13.3%). These results validate the significant enhancements in accuracy, diversity, and stability achieved by this method.

Keywords: Autonomous driving Trajectory prediction Diffusion model Multi-modal fusion

0 引言

近年来，随着自动驾驶技术的快速发展，车辆在复杂交通环境中的安全感知需求日益增强。行人未来轨迹的准确预测是保障自动驾驶在动态交互场景中安全运行的核心能力之一^[1]。行人行为不仅受到交通密度、社会交互、环境布局等因素影响，还会因目的地规划与意图变化呈现明显的多模态特性。

因此，构建一个既能保持预测精度，又能覆盖真实不确定性的轨迹预测模型，对自动驾驶系统的安全性与稳定性具有重要意义。

传统轨迹^[2]预测方法通常依赖递归神经网络（如 LSTM、GRU）或时序卷积结构，通过自回归方式逐步生成未来位置^[3]。然而，由于每一步预测都依赖上一步的结果，这类模型往往在长时预测中出现误差累积，导

致轨迹逐渐偏离真实路径，当预测时长超过数百毫秒后性能明显下降^[4]。此外，许多方法并未显式建模行人的目标点（Goal/Endpoint），仅依靠局部历史运动推断未来走势，难以从全局上反映真实的行为规划。为此，近年来出现了一系列目标条件的预测方法，如 PECNet^[5]与 PRECOG^[6]，通过引入目标点约束提升轨迹一致性，但普遍采用单向解码，仍存在长期预测不稳定的问题。

在生成式建模方面，GAN^[7]与 CVAE^{[8][9]}被广泛用于多模态轨迹预测。特别是 Trajectron++^[10]通过 CVAE 结构结合图建模，实现了可控的多模态轨迹生成。然而，传统 CVAE 通常假设潜变量服从简单的各向同性高斯分布，难以表达行人轨迹的复杂、多峰与连续不确定性，从而导致生成多样性受限甚至潜变量塌缩。因此，如何提升潜变量的分布表达能力，是进一步改善预测质量的关键问题。

基于上述挑战，本文提出一种基于目标条件的多模态双向轨迹预测框架（Goal-Conditioned Bidirectional Trajectory Prediction）。与仅采用前向解码的传统方法不同，本文框架首先显式预测未来终点，再分别执行从历史轨迹出发的前向解码与从预测目标点反向生成的后向解码，并通过门控与注意力机制融合两条轨迹，实现了全局目标一致性与局部动态连续性的统一。这种双向解码思想与 Bitrap 研究一脉相承，但进一步引入目标点引导与多模态融合，使其更适用于复杂行人场景。

此外，为增强潜变量的表达能力，本文在 CVAE 框架中引入扩散模型（Diffusion Model）对潜在空间进行逐步加噪与去噪。扩散模型能够在连续潜空间中学习更复杂的多模态分布，缓解传统 CVAE 的局限性，从而生成更加丰富、稳健且物理合理的预测轨迹。

综上所述，本文的主要贡献如下：

1) 提出一种目标条件的多模态双向轨迹预测框架，有效缓解传统方法在长时预测中出现的误差累积与目标偏移问题。

2) 将 CVAE 与扩散模型相结合，提升潜变量分布建模能力，使生成的轨迹更加多样化、稳定且符合真实场景的物理规律。

3) 通过目标点引导与注意力融合机制同时强化短期动态描述与长期目标一致性，提升预测质量。

4) 在 JAAD 与 PIE 数据集上验证了方法的有效性，实验结果显示本文方法在短期、中期与长期预测中均优于现有主流方法。

1 相关工作

近年来，行人轨迹预测方法在时序建模、目标点建模、多模态语义融合以及生成式多模态建模等方向上取得了快速发展。传统基于 LSTM/GRU 的时序方法虽然能够捕捉短期动态，但由于自回归结构容易在长时预测中产生误差累积，难以适应复杂交通场景。近三年兴起的 Transformer 类方法，如 AgentFormer^[11]与 HiVT^[12]，通过自注意力机制实现强交互建模和全局时序理解，在多主体预测中表现出比传统 RNN 更强的长期稳定性。SceneTransformer^[13]等方法进一步融合场景语义，使轨迹预测更能够反映交通环境中的约束与动态。

目标条件（Goal-conditioned）预测已成为提升长期预测稳定性的重要趋势。Densetnt^[14]通过显式候选目标点采样与路径优化，有效提升了预测的可达性；Goal-Transformer^[15]采用端点感知的 Transformer 结构，在长时预测中进一步减少目标偏移；HiVT++^[16]等研究则表明，将目标意图融入结构化轨迹建模能够显著提升轨迹一致性。尽管这些方法对目标点建模进行了扩展，但通常依赖单向解码，无法有效缓解误差反向扩散的问题。

在生成式建模方面，CVAE 与 GAN 过去广泛用于多模态轨迹预测，但近年来扩散模型（Diffusion Model）

逐渐成为主流方向。MotionDiffuse^[17]首次展示了扩散模型在时序动作生成中的潜力; Multi-Agent Diffusion (MID)^[27]进一步将扩散机制引入多主体轨迹预测, 显著提升了模型对多峰分布的拟合能力; SceneDDPM^[28]则结合语义条件, 提高了模型在真实交通场景中的稳定性和预测多样性。这些研究表明, 扩散机制能显著改善潜变量空间的表达能力, 是对传统 CVAE 的有力补充。

在第一视角 (First-Person View, FPV) 场景中, 行人行为受视角偏移、遮挡、远距离视觉退化等因素影响, 多模态视觉特征与场景语义对于预测精度具有关键作用。Rasouli 等人提出的 PIE 数据集与模型体系为 FPV 场景下的行人外观、动作线索与意图估计提供了标准框架; JAAD 数据集则进一步引入行为状态、社会交互与场景语义信息, 用于支持更复杂的时序预测任务。最近 Stoler^[29]等人提出的 FPL 模型通过融合视觉外观、动作特征与 egocentric 感知, 实现了对第一视角运动行为的鲁棒预测。然而, 这些方法多数未结合扩散模型以增强潜变量分布表达, 也未采用前后向双向解码结构, 因此在长时预测中仍存在误差扩散问题。相比之下, 本文提出的“目标点引导 + CVAE 扩散潜变量增强 + 双向解码融合”框架在潜变量建模、目标一致性与长期稳定性方面实现统一设计, 更契合近三年 FPV 行人预测的发展趋势。

2 模型介绍

本文在第一人称视角 (First-Person View, FPV) 中实现了一个目标条件的多模态双向轨迹预测模型。

该模型旨在根据当前帧中目标的观察轨迹, 预测其未来的可能运动路径。设为在时间步 t 上观察到的过去轨迹, 其中每个元素 $X_t = [X_{t-\tau+1}, X_{t-\tau+2}, \dots, X_t]$ (x, y, w, h) 表示在 FPV 图像中目标的像素级位置与尺寸 (即边框中心位置和大小)。在给定观察序列 X_t 的前提下, 本文首先估计该目标的潜在意图 (目标位置) G_t , 然后再预测其在未来时间范围内的运动轨迹 $Y_t = [Y_{t+1}, Y_{t+2}, \dots, Y_{t+\delta}]$ 。本文将目标 $G_t = Y_{t+\delta}$ 定义为未来轨迹的终点, 其中 τ 和 δ 分别是观察和预测范围, 在训练阶段是可用的监督信息, 而在测试阶段则是待预测的关键变量。为清晰展示各模块之间的依赖关系, 本文在图 1 的基础上对整体网络结构进行进一步说明。模型由五个核心组件构成: 先验网络 (Prior Network) 根据历史轨迹编码得到的上下文特征 $p_\theta(Z|X_t)$, 学习未来潜变量的先验分布, 用于测试阶段的采样; 识别网络 (Recognition Network) 在训练阶段同时接收历史轨迹与真实未来目标, 学习后验分布 $q_\phi(Z|X_t, Y_t)$, 使模型在潜变量空间更好地拟合真实轨迹; Diffusion^[18]模块在识别网络产生的潜变量上执行加噪 - 去噪过程, 增强潜变量表示能力, 使其能够刻画复杂多模态分布; 目标点生成器 (Goal Generator) 根据去噪后的潜变量估计未来终点, 为双向解码提供全局约束 $p_\omega(G_t|X_t, Z)$; 双向轨迹解码器 (Bidirectional Decoder) $p_\psi(Y_t|X_t, G_t, Z)$ 由前向解码与后向解码组成, 分别从历史末端与预测终点同时生成轨迹, 并通过注意力融合得到最终轨迹输出。通过该结构, 模型能够在潜变量层面建模多峰不确定性, 同时在解码层面保证局部连续性与全局目标一致性。




图 1 整体网络结构

2.1 条件生成扩散模型

首先，本文采用历史轨迹序列 $X_t = [X_{t-\tau+1}, X_{t-\tau+2}, \dots, X_t]$ 作为模型输入。为了更有效地提取历史轨迹中的时序特征，首先通过时序卷积（Temporal Convolution）模块获取局部时间窗口内的短期运动趋势，增强对位置变化的动态感知能力，得到特征表示 $X_{conv} \in R^{B \times T \times C}$ 。随后， $X_{conv} \in R^{B \times T \times C}$ 被送入双向 GRU（Bi-GRU），进一步建模轨迹的长程时序依赖，提升模型对历史行为的理解能力。最后，采用加性注意力机制^[19]（Additive Attention）对双向 GRU 的输出进行加权融合，生成上下文感知的轨迹表示 $h_{att} \in R^{B \times H}$ ，该表示能够更有效地捕捉局部时序特征与潜在目标之间的关联。




图 2 CVAE 变量关系图

在训练中，地面真相目标 Y_t 由另一个产生的 GRU 编码。接下来将处理的数据传入到 CVAE 模型

中，图 2 为 CVAE 的变量关系模型图。本模型选用 CVAE 作为预测框架，是因为行人未来轨迹具有显著的多模态特性，单一确定性预测容易产生模糊平均路径，而 CVAE 通过在历史轨迹和场景条件下引入潜变量建模，可以同时生成多种合理且与历史一致的未来轨迹，并结合概率分布预测不确定性，从而提升预测的多样性与精度。

识别网络 $q_\theta(Z|X_t, Y_t)$ 需要 h_t 和 h_{Y_t} 来预测分布平均 μ_{Z_q} 和协方差 Σ_{Z_q} ，从而捕获观察和地面真相目标之间的依赖性。先验网络 $P_\theta(Z|X_t)$ 不假定对目标的了解，并且仅使用 h_t 预测 μ_{Z_p} 和 Σ_{Z_p} 。优化了 $N(\mu_{Z_p}, \Sigma_{Z_p})$ 和 $N(\mu_{Z_q}, \Sigma_{Z_q})$ 之间的 KL 损失。 Y_t 和 X_t 被先前的网络隐性地学习。潜在变量 Z 从 $N(\mu_{Z_q}, \Sigma_{Z_q})$ 中采样，并与 h_t 串联以预测多模式目标 $\hat{G}_t$ 与目标生成网络 $p_\theta(G_t|X_t, Z)$ 。在测试中，本文直接从 $N(\mu_{Z_p}, \Sigma_{Z_p})$ 和连接 h_t 绘制多个样品，以预测估计的目标 $\hat{G}_t$ 。本文使用 3 层多层感知器（MLP）作为先验网络和识别网络。

由于条件变分自编码器（CVAE）中对潜在空间的建模通常依赖于一个简单的各向同性高斯分布 $z \sim N(\mu_z, \Sigma_z)$ ，其表达能力有限，难以有效捕捉复杂的多模态分布，因此可能导致预测质量不稳定。为了解决这一问题，在识别网络之后引入了一个扩散模型（Diffusion Model），以增强潜变量的表达能力，从而

更准确地建模多模态的预测分布, 并提升长时间轨迹预测的性能。




图 3 前向扩散过程向潜在表示中注入高斯噪声

具体地, 本文对识别网络中采样得到的潜在变量 z 注入扩散噪声, 如图 3 所示, 将道路行人的潜在变量添加噪声, 提高潜在变量的分布表达和采样多样性: 在前向扩散过程中, 将标准高斯噪声按照时间步 t 添加至 z , 得到加噪后的潜在表示:

$$z_t = \sqrt{\alpha_t} z + \sqrt{1 - \alpha_t} \varepsilon, \varepsilon \sim N(0, 1) \quad (1)$$

其中 $\varepsilon = \frac{z_t - \sqrt{\alpha_t} \cdot z_0}{\sqrt{1 - \alpha_t}}$ 为前向扩散过程中与时间步相关的累积噪声系数。

在反向去噪过程中, 采用 v-prediction 的策略来预测噪声:

$$v = \sqrt{\alpha_t} \cdot \varepsilon - \sqrt{1 - \alpha_t} z_0 \quad (2)$$

相较于直接预测或噪声本身, 该方法在训练收敛性和稳定性方面具有更优表现。图 4 表示 Diffusion 模型的去噪过程, 通过多步反向去噪, 最终获得了更具表达能力的去噪潜变量 $\bar{z}_0 = \sqrt{\alpha_t} \cdot z_t - \sqrt{1 - \alpha_t} \cdot v$, 用于后续的目标生成与轨迹生成模块。




图 4 扩散模型在反向过程中对潜在变量进行去噪

总的来说, 在训练过程中, 识别网络利用的联合信息学习后验分布 $q_\phi(Z|X_t, Y_t)$, 使模型能够捕获真实未来轨迹的潜在意图。先验网络则基于单独学习先验分布 $P_\theta(Z|X_t)$, 用于测试阶段的潜变量采样。通过最小化两者之间的 KL 散度, 使先验分布逐步逼近后验分布, 从而保证测试阶段采样的潜变量仍具有真实轨迹的多模态特性。生成阶段中, 去噪后的潜变量既提供未来意图 (目标点) 的高维表示, 又为双向解码器提供多模态轨迹生成的条件输入。前后向解码器分别建模轨迹的局部动态与全局目标, 构成“先验-潜变量-目标-双向生成”的有机闭环。

2.2 双向轨迹解码器

双向解码器的设计旨在同时缓解自回归误差累积并提升全局目标一致性。传统前向解码器仅从当前状态出发逐步预测, 误差会随时间扩散; 而后向解码器从目标点出发反向生成, 使得生成轨迹天然朝向目标收敛。二者结合后, 前向分支更擅长局部平滑与动态一致性, 后向分支更擅长长期意图对齐; 注意力融合机制根据时间步自适应调整两者权重, 使最终轨迹在复杂场景中同时具备合理走势与目标可达性。多模态轨迹预测中, 为更好地结合潜在意图和运动模式, 本文提出一种基于目标点引导 (Goal Guidance) 与前后向双向解码 (Bidirectional Decoding) 相融合的轨迹生成方法。如图

5 所示,该解码器使用 GRU 解码器从 CVAE 编码的隐变量中生成未来轨迹,充分融合历史轨迹信息与预测目标点信息,并通过注意力机制自适应融合前向与后向预测轨迹,提升预测的连贯性与目标一致性,其中 G_g 为目标引导模块 (Goal Guidance)。




图 5 双向轨迹解码器

前向与后向解码(Forward & Backward Decoding)

具体的流程如下：设编码后的隐变量为 $z \in R^{B \times K \times D}$ ，对应 k 个预测模式，每个样本有 k 条潜在轨迹。设预测目标点集为： $G = \{g_k\}_{k=1}^K \in R^{B \times K \times D}$ ，初始化前向与后向解码器的隐状态： $h_0^f = f_{enc}(z), h_T^b = b_{enc}(z)$ ，前向解码从历史轨迹的最后一个点出发，后向解码则从预测目标点出发，反向生成。在前向和后向解码中，解码器都会根据历史轨迹选在最接近的目标点进行引导：

$$g_t = \arg \min \|g_k - r_t\| \quad (3)$$

其中 r_t 为当前参考点，在前向中为历史轨迹中的点或上一步预测点，后向解码中为当前时间步的推理点或目标点，选择后的目标点 g_t 与当前的轨迹点进行拼接后作为 GRU 输入的一部分：

$$u_t^f = [y_{t-\tau}; g_t], \quad u_t^b = [y_{t+\tau}; g_t] \quad (4)$$

前后解码分别为:

$$\begin{aligned} h_{t+1}^f &= GRU_f(u_t^f, W_f^i h_t^f + b_f^i) \\ h_{t+\delta-1}^b &= GRU_b(h_{t+\delta}^b, W_b^i \hat{Y}_{t+\delta} + b_b^i) \end{aligned} \quad (5)$$

完成前后向轨迹预测后, 引入注意力融合机制, 根据最终隐状态生成一个融合权重 $\alpha \in [0,1]$, 用于加权组合前向轨迹与后向轨迹, 如式(6)。使得模型可以自动学习当前轨迹时刻更依赖于哪一方向的预测, 从而提升轨迹连续性和合理性。

$$\begin{aligned}\alpha_k &= \sigma(W_\alpha[h_T^f; h_T^b]) \\ \hat{Y}_{t+\delta-1} &= \alpha_k \cdot \hat{y}_t^f + (1 - \alpha_k) \hat{y}_t^b\end{aligned}\quad (6)$$

2.3 轨迹预测及损失函数

对于轨迹预测，不是直接预测未来位置^[20]或从预测的未来速度进行整合，而是预测基于当前位置的变化。首先，它确保该模型将从当前位置开始预测轨迹，而与从头开始预测位置相比，初始损失较小。其次，由于轨迹注释并不总是准确的事实，目标可能比速度目标噪音要小。轨迹预测的损失由重构误差、潜变量 KL 散度损失与扩散去噪损失三部分构成。其中，重构误差采用 Best-of-Many (BoM) 策略^[21]，即在多条生成轨迹中仅选取与真实轨迹最接近的一条计算 L2 损失。该策略能够有效缓解多模态分布下的“平均化问题”，避免模型生成模糊、中庸的平均轨迹，提高模型对多峰轨迹分布的覆盖能力。L2 损失函数的公式为：

$$L_2 = \min_{i \in N} \|G_t - X_t - \hat{G}_t^i\| + \min_{i \in N} \sum_{\tau=t+1}^{t+\delta} \|Y_\tau - X_t - \hat{Y}_\tau^i\| + KLD \quad (7)$$

其中 $\hat{G}_t$ 和 $\hat{Y}_t$ 是相对于当前位置 X_t 的预测目标和轨迹。

KL 散度损失用于约束后验分布 $q_{\phi}(z|x,y)$ 与先验分布 $p_{\theta}(z|x)$ 的一致性,使模型在测试阶段能够从先验中采样得到合理潜变量,提升泛化能力。扩散去噪损失进一步增强潜变量空间的连续性与表达能力,使潜变量能

够覆盖更复杂的轨迹不确定性。KL 散度损失为:

$$L_{KL} = D_{KL}(q_{\phi}(z|x, y) \| p_{\theta}(z|x)) \quad (8)$$

在 KL 散度基础上, 添加扩散去损失, 在潜变量 z 上进行加噪—去噪训练, 保证模型能够从噪声恢复出干净的 z_0 , 提升生成的多样性与稳定性。三者结合共同促进模型在精度、稳定性与多样性之间取得平衡。

综上, 本文方法通过“潜变量增强 + 目标显式建模 + 双向解码融合”的方式, 将多模态表达能力、全局目标控制与局部动态一致性融为一体。Diffusion 强化了潜变量空间的复杂分布建模能力, 目标引导提供了全局约束, 而双向解码器在长时预测中有效抑制误差累积, 使最终轨迹在复杂场景中具有更好的精准性、连续性与目标一致性。

3 实验结果与分析

3.1 数据集与评估标准

在本节中, 本文在第一人称视角 (FPV) 轨迹预测数据集上对模型进行了经验评估, 并就模型设计与损失函数选择的影响进行了对比研究与讨论。实验使用了两个 FPV 数据集: Joint Attention in Autonomous Driving (JAAD)^[22]与 Pedestrian Intention Estimation (PIE)^[20]。

JAAD 数据集收录了 2800 条以 30Hz 注释的行人轨迹, 源自车载仪表盘摄像头拍摄的行驶视频。该数据集专注于行人行为预测与意图识别, 尤其是过街场景中的人车交互, 旨在提升自动驾驶系统对行人意图的提前感知能力, 从而降低交通事故风险。

JAAD 数据集包含 346 段高清 (1920×1080) 视频, 总时长约 30 小时, 对应 82032 个标注帧 (每段视频约 5.5 分钟)。其主要特征包括: 行人意图识别: 标注行人的过街意图 (如是否计划穿越), 并分析其与车辆运动之间的关系; 行为时序建模: 捕捉连续动作序列 (等待→观察→起步), 支持行为预测模型构建; 多模态交互分析: 结合行人视线方向、交通信号灯状态、车辆位置等因素, 探究对行人决策的影响。此外, JAAD 覆盖了多种复杂场景, 如学校周边的高密度人群、车辆遮挡导致的严重遮挡、以及夜间等低光照条件, 使其成为研究自动驾驶在复杂环境中行人意图预测的宝贵资源。

PIE 数据集通过真实交通场景视频捕捉行人的行为, 包含 53 个高分辨率视频片段 (1920×1080, 30fps), 总时长约 6 小时, 涵盖了十字路口、人行横道、夜间、雨天等多种复杂场景。标注信息丰富, 手动标注了 1842 名行人的边界框 (bounding boxes), 总计超过 230000 帧, 标注内容包括二元分类意图标签 (过马路/不过马路), 标注时间跨度从行人进入视野至决策点 (通常提前 1-2 秒进行预测), 同时涵盖行走、站立、奔跑、身体朝向、是否使用手机等行为属性, 以及车辆位置、交通灯状态、人行横道位置、遮挡情况等环境上下文信息。

在前人研究^[23]的基础上, 为了全面验证模型性能, 本文从三个维度开展实验, 系统评估其精度、多样性与稳定性:

(1) 预测精度 (Accuracy): 使用 ADE、FDE、C-ADE、CFDE 评估模型在短期、中期与长期预测中的轨迹偏差, 衡量时序精度与终点一致性;

(2) 生成多样性 (Diversity) : 采用 KDE-NL L^[25] 以及多样本轨迹方差来衡量模型对多峰轨迹分布的覆盖能力, 以反映生成结果的多模态丰富性;

(3) 预测稳定性 (Stability) : 在相同输入条件下多次采样潜变量, 分析预测轨迹的方差与误差波动, 评估模型在长时预测中的一致性与鲁棒性。

此外, 按照自动驾驶行为预测领域的通行实验设定, 本文分别在短期 (0.5s)、中期 (1.0s) 与长期 (1.5s) 预测任务上进行对比实验, 以验证模型在不同时间尺度下的综合性能表现。并且从 20 次随机采样得到的预测结果中, 选择 ADE 与 FDE 最小的 20 条轨迹进行统计分析^[24]。对于以上全部指标, 其数值越低代表模型性能越优。

3.2 实验环境

本文提出的算法使用 PyTorch 框架实现, 运行在 GPU 为 NVIDIA RTX3090ti、CPU 为 Intel Xeon Pla

tinum 8260、操作系统为 Ubuntu20.04 的服务器上。

本文采用 JAAD 与 PIE 数据集的标准训练/测试划分进行实验评估。评估时使用 0.5 秒 (15 帧) 的观察长度与 1.5 秒 (45 帧) 的预测范围。此外, 还在另一组实验中设置 3.2 秒 (8 帧) 的观测窗口, 并预测接下来 4.8 秒 (12 帧) 的行人轨迹。在所有数据集上, 模型的各编码器与解码器均采用 256 维隐藏层大小。

3.3 实验结果与分析

表 1 展示了本文方法与多种对比算法在 JAAD 和 PIE 数据集上的轨迹预测结果。对比方法涵盖了从传统线性模型 (Linear) 到基于时序神经网络的模型 (LSTM、B-LSTM), 以及融合环境与外观特征的深度方法 (FOL-X、PIEtraj) 和最新的生成式预测模型 (BiTrap-NP)。其中, BiTrap-NP 与本文均采用条件变分自编码器 (CVAE) 框架与双向预测思路, 因此被选作主要对比基线。

表 1 各模型在 JAAD 和 PIE 数据集上的结果

Methods	JAAD				PIE			
	ADE (0.5/1.0/1.5s)	C _{ADE}	C _{FDE}	NLL	ADE (0.5/1.0/1.5s)	C _{ADE}	C _{FDE}	NLL
B-LSTM ^[23]	150/533/1536	1447	5615	-	101/296/855	811	3259	-
FOL-X ^[3]	147/484/1374	1290	4924	-	47/183/584	546	2303	-
PIEtraj ^[20]	110/399/1280	1183	4780	-	58/200/636	593	2476	-
LSTM ^[20]	289/569/1558	1473	5766	-	172/330/911	837	3352	-
Linear ^[20]	233/856/2302	1565	6123	-	134/489/1365	950	3983	-
BiTrap-NP ^[26]	39/98/253	181	578	19	34/56/110	93	270	18
Ours	37/89/199	155	459	17.6	20/46/98	76	254	15.6

综合实验结果表明, 本文模型在 JAAD 与 PIE 两个数据集的短期、中期和长期预测任务中均取得

最优表现。在 JAAD 上, ADE 达到 37/89/199、FDE 达到 155/459/117.6, 相较 BiTrap-NP 下降约 5% - 20%;

在 PIE 上, FDE 为 15.6, 同样优于 BiTrap-NP 的 18。随着预测时间的延长, 本文方法的优势更加显著, 表明目标点引导与双向解码机制能够有效缓解传统单向自回归模型的误差累积问题, 从而更稳健地捕捉长时依赖和复杂场景下的多模态轨迹特征。此外, 在 KDE-NLL 指标上, 本文方法同样显著优于对比模型, 说明结合 CVAE 与 Diffusion 的潜变量建模能够更充分地覆盖真实轨迹分布, 提高多模态生成质量与轨迹多样性。由于 Diffusion 生成的潜变量更加平滑并具备连续性, 该结构在多次随机采样下的误差波动更小, 表明模型在潜变量变化下输出稳定性更强。

图 6 展示了本文模型在 JAAD 数据集上的可视化预测结果。从图中可以直观地看到, 模型在多种场景下对行人未来轨迹的预测表现。其中, 当行人正在过马路或停留在马路边缘时, 模型能够生成较为精确且符合实际情况的预测轨迹, 表现出对短期动态和意图变化的良好捕捉能力。然而, 从子图(b)的结果可以看出, 对于距离较远的行人, 模型的预测精度有所下降, 这可能受到天气条件、车辆遮挡、光照变化等环境因素的干扰, 导致视觉特征提取受限, 从而影响轨迹推断的准确性。这一现象提示, 未来的工作中可以考虑引入更强的多模态信息融合(如雷达或深度信息)、场景上下文建模以及增强的鲁棒特征提取方法, 以提升模型在复杂环境和长距离目标下的预测能力。



(a)



(b)

图 6 JAAD数据集可视化

3.4 消融实验

为分析各组件的作用, 本文基于 BiTrap-NP 进行逐步消融实验, 结果如表 2 所示。首先, 加入 Diffusion 模块 (BiTrap-NP+Diffusion) 后, 长期 ADE 由 253 降至 235, CFDE 从 578 降至 525, NLL 也有所降低, 说明扩散式潜变量增强能够提升多模态分布建模能力, 特别是在长期预测中显著改善误差累积。其次, 加入目标引导的双向轨迹解码器 (BiTrap-NP+Goal-BiDecoder) 时, 长期 ADE 降至 246, CFDE 降至 543。该模块通过目标点提供全局约束, 并利用前后向生成减少单向解码的误差扩散, 从而提升长期预测的一致性。当同时加入 Diffusion 与双向解码 (BiTrap-NP + Diffusion + Goal-BiDecoder) 时, 长期 ADE 进一步降至 232, CFDE 降至 509, 说明两者具有互补优势: Diffusion 增强潜变量表达, 双向结构提升时序一致性。在此基础上, 本文完整模型 (Ours) 在所有时间尺度均取得最佳结果, 长期 ADE 降至 199, CFDE 降至 459, NLL 降至 17.6, 表明本文方法在精度、多样性与长期稳定性方面均实现综合提升。

表 2 模型消融实验

	<i>ADE</i> (0.5/1.0/1.5s)	C_{ADE}	C_{FDE}	<i>NLL</i>
BiTrap-NP	39/98/253	181	578	19
BiTrap-NP+Diuffsion	39/93/235	167	525	18
BiTrap-NP++ 目标引导双向轨迹解码	39/94/246	172	543	18.4
BiTrap-NP+Diuffsion+ 目标引导双向轨迹解码	39/94/232	164	509	18.1
Ours	37/89/199	155	459	17.6

4 结 语

本文提出了一种基于目标条件的多模态双向轨迹预测模型，结合条件变分自动编码器（CVAE）与扩散模型（Diffusion）提升潜变量的多样性建模能力，并通过目标点引导与前后向双向解码有效缓解了长时预测的误差累积。在JAAD与PIE数据集上的实验结果表明，该方法在短、中、长期预测中均优于现有方法，尤其在长期预测中表现出更低的误差和更稳定的性能。同时，可视化结果进一步验证了模型在不同场景下的预测能力，能够生成多样化且符合真实行为规律的轨迹。实验也发现，当预测目标距离较远或受光照、遮挡、天气等因素影响时，模型的精度仍有下降趋势。未来工作将进一步探索多模态信息融合与场景语义建模，以提升模型在复杂环境下的鲁棒性与泛化能力。

参 考 文 献

[1] Pouw C A S, van der Vleuten G G M, Corbetta A, et al. Data-driven physics-based modeling of pedestrian dynamics[J]. Physical Review E, 2024, 110(6): 064102.

[2] Morais R, Le V, Tran T, et al. Learning regularity in

skeleton trajectories for anomaly detection in videos[C]//CVPR, 2019.

[3] 钱来,王伟.一种基于C-GRU飞行轨迹预测方法[J].电子测量技术,2022,45(10):87-92.

[4] Butepage J , Kjellstrom H , Kragic D .Anticipating Many Futures: Online Human Motion Prediction and Generation for Human-Robot Interaction[C]// 2018 IEEE International Conference on Robotics and Automation (ICRA), 2018: 4563 – 4570.

[5] Mangalam K, Girase H, Agarwal S, et al. It is not the journey but the destination: Endpoint conditioned trajectory prediction[EB]. arXiv preprint arXiv:2004.02025,2020.

[6] Rhinehart N , Mcallister R , Kitani K ,et al.PRECOG: PREdiction Conditioned On Goals in Visual Multi-Agent Settings[C]// 2019 IEEE/CVF International Conference on Computer Vision (ICCV), 2019.

[7] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. Advances in neural information processing systems, 2014, 27.

[8] Sohn K, Lee H, Yan X. Learning structured output representation using deep conditional generative models[J]. Advances in neural information processing systems, 2015, 28.

[9] Gupta A, Johnson J, Fei-Fei L, et al. Social gan: Socially acceptable trajectories with generative adversarial

- networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 2255-2264.
- [10] Salzmann T, Ivanovic B, Chakravarty P, et al. Trajectron++: Dynamically-feasible trajectory forecasting with heterogeneous data[C]//European Conference on Computer Vision. Cham: Springer International Publishing, 2020: 683-700.
- [11] Yuan Y, Weng X, Ou Y, et al. Agentformer: Agent-aware transformers for socio-temporal multi-agent forecasting[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 9813-9823.
- [12] Zhou Z, Ye L, Wang J, et al. Hivt: Hierarchical vector transformer for multi-agent motion prediction[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 8823-8833.
- [13] Ngiam J, Caine B, Vasudevan V, et al. Scene transformer: A unified architecture for predicting multiple agent trajectories[EB]. arXiv preprint arXiv:2106.08417, 2021.
- [14] Gu J, Sun C, Zhao H. Densent: End-to-end trajectory prediction from dense goal sets[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 15303-15312.
- [15] Karim R, Shabestary S M A, Rasouli A. Destine: Dynamic goal queries with temporal transductive alignment for trajectory prediction[C]//2024 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2024: 2230-2237.
- [16] Gupta J, Sharma S, Tuli S, et al. GOALNET: interleaving neural goal predicate inference with classical planning for generalization in robot instruction following[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(18): 20113-20122.
- [17] Zhang M, Cai Z, Pan L, et al. Motiondiffuse: Text-driven human motion generation with diffusion model[J]. IEEE transactions on pattern analysis and machine intelligence, 2024, 46(6): 4115-4128.
- [18] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[J]. Advances in neural information processing systems, 2020, 33: 6840-6851.
- [19] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[EB]. arXiv preprint arXiv:1409.0473, 2014.
- [20] Rasouli A, Kotseruba I, Kunic T, et al. PIE: A Large-Scale Dataset and Models for Pedestrian Intention Estimation and Trajectory Prediction[C]// 2019 IEEE/CVF International Conference on Computer Vision (ICCV), 2019.
- [21] Bhattacharyya A, Schiele B, Fritz M. Accurate and Diverse Sampling of Sequences based on a "Best of Many" Sample Objective[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018.
- [22] Kotseruba I, Rasouli A, Tsotsos J K. Joint attention in autonomous driving (JAAD)[EB]. arXiv preprint arXiv:1609.04741, 2016.
- [23] Bhattacharyya A, Fritz M, Schiele B. Long-Term On-board Prediction of People in Traffic Scenes Under Uncertainty[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018.
- [24] Sadeghian A, Kosaraju V, Sadeghian A, et al. SoPhie: An Attentive GAN for Predicting Paths Compliant to Social and Physical Constraints[C]// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019.
- [25] Thiede L A, Brahma P P. Analyzing the Variety Loss in the Context of Probabilistic Trajectory Prediction[C]// 2019

IEEE/CVF International Conference on Computer Vision (ICCV), 2019.

International Conference on Intelligent Robots and Systems (IROS). IEEE, 2023: 4037-4044.

- [26] Yao Y, Atkins E, Johnson-Roberson M, et al. Bitrap: Bi-directional pedestrian trajectory prediction with multi-modal goal estimation[J]. IEEE Robotics and Automation Letters, 2021, 6(2): 1463-1470.
- [27] Zhang S, Kai S, Chen C, et al. Multi-agent trajectory prediction with scalable diffusion transformer[C]//Proceedings of the 2024 6th International Conference on Distributed Artificial Intelligences. 2024: 103-111.
- [28] Wang Y, Tang C, Sun L, et al. Optimizing diffusion models for joint trajectory prediction and controllable generation[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 324-341.
- [29] Stoler B, Jana M, Hwang S, et al. T2FPV: Dataset and method for correcting first-person view errors in pedestrian trajectory prediction[C]//2023 IEEE/RSJ