



计算机应用
Journal of Computer Applications
ISSN 1001-9081,CN 51-1307/TP

《计算机应用》网络首发论文

题目：基于文本-图像融合强度可调的多模态目标检测算法
作者：裴江波，李炜，李艺洋
收稿日期：2025-11-17
网络首发日期：2026-02-06
引用格式：裴江波，李炜，李艺洋. 基于文本-图像融合强度可调的多模态目标检测算法[J/OL]. 计算机应用. <https://link.cnki.net/urlid/51.1307.TP.20260205.2107.008>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于文本-图像融合强度可调的多模态目标检测算法

裴江波, 李炜*, 李艺洋

(四川大学 空天科学与工程学院, 成都 610200)

(*通信作者电子邮箱 li.wei@scu.edu.cn)

摘要: 针对复杂场景下单一视觉模态在目标检测任务中表达能力受限、语义信息不足的问题, 提出了一种融合强度可调的多模态目标检测框架。该框架引入文本模态作为语义先验, 通过对文本数据进行全局语义建模, 从语义层面弥补视觉模态在类别辨识和语义关联方面的不足。考虑到文本数据本质上是对整体数据集的语义描述, 而非针对单幅图像的具体说明, 设计了基于类别预测软映射的语义增强模块, 实现对与当前图像内容相关语义信息的自适应筛选与强化, 有效抑制了无关语义噪声的干扰。为解决多模态融合过程中不同模态贡献不均的问题, 提出了融合强度可调机制, 通过动态调节视觉特征与语义特征的融合权重, 使模型能够根据输入数据的质量及任务需求实现最优信息融合。在 PASCAL VOC 和 DUT Anti-UAV 数据集上的实验结果表明, 相较于最优的基线方法, 所提方法的平均精度(AP)分别提高了 1.6 个百分点和 8.8 个百分点, 验证了该方法在多模态特征协同建模及复杂场景目标检测任务中的有效性与泛化能力。

关键词: 目标检测; 多模态融合; 文本-图像融合; 融合强度可调; 语义增强

中图分类号: TP183

文献标志码: A

Multimodal object detection method with adjustable text-image fusion intensity

PEI Jiangbo, LI Wei*, LI Yiyang

(School of Aeronautics and Astronautics, Sichuan University, Sichuan Chengdu 610200, China)

Abstract: To address the limitations of single visual modalities in object detection tasks within complex scenarios, particularly their limited expressive power and insufficient semantic information, a multimodal object detection framework with adjustable fusion intensity was proposed. A textual modality was introduced as a semantic prior, performing global semantic modeling on text data to compensate for the shortcomings of visual modalities in category recognition and semantic association at the semantic level. Considering that textual data was essentially a semantic description of the entire dataset rather than a specific description of a single image, a semantic enhancement module based on category prediction soft mapping was proposed. This module was used to adaptively filter and enhance semantic information relevant to the current image content, effectively suppressing interference from irrelevant semantic noise. To address the uneven contribution of different modalities during multimodal fusion, an adjustable fusion strength mechanism was proposed to achieve optimal information fusion based on the quality of the input data and task requirements by dynamically adjusting the fusion weights of visual and semantic features. Experimental results on the PASCAL VOC and DUT Anti-UAV datasets show that the average accuracy (AP) of the proposed method is improved by 1.6 percentage points and 8.8 percentage points, respectively, compared with the optimal baseline method. This verifies the effectiveness and generalization ability of the proposed method in multimodal feature collaborative modeling and object detection in complex scenes.

Keywords: object detection; multimodal fusion; text-image fusion; adjustable fusion intensity; semantic enhancement

0 引言

近年来, 随着深度学习技术的快速发展, 目标检测(Object Detection)任务取得了显著进展。从最早的两阶段检测器到单阶段检测器, 再到基于 Transformer 的端到端结构, 目标检测

算法的精度不断提升。然而, 这些目标检测方法大多依赖于单一模态的图像特征, 当目标的视觉特征稀少、外观不完整或者光照复杂时, 检测性能仍然面临显著挑战。例如, 在夜间、雾霾天气或低分辨率航拍等场景中, 目标往往呈现出模糊、遮挡严重或者边界不清的特征, 导致模型难以形成稳定

收稿日期: 2025-11-17; 修回日期: 2026-01-23; 录用日期: 2026-01-26。


基金项目: 体系与人工智能四川省重点实验室开创基金(SSA1202514)。

作者简介: 裴江波(2001—), 男, 山西长治人, 硕士研究生, 主要研究方向: 目标检测、多模态融合; 李炜(1980—), 男, 内蒙古人, 副研究员, 博士, 主要研究方向: 多模态融合、场景理解。


可靠的检测结果。因此,仅依靠图像模态的信息,难以支撑对复杂场景的鲁棒感知。

为弥补视觉信息的不完备性,研究人员逐渐探索引入多模态数据进行融合学习,提升模型的语义理解与推理能力,从而提升对复杂场景中目标的检测识别能力。其中,基于文本知识与图像融合的目标检测方法表现突出。典型代表如 CLIP^[1],通过在大规模图像-文本对数据集上进行对比学习,

实现图像与文本的语义空间对齐,为多模态目标检测奠定了基础;ViLD^[2]采用知识蒸馏的方式,将 CLIP 的语义知识迁移至目标检测器,从而增强了零样本检测能力;GLIP^[3]将检测任务和 grounding 任务统一,利用 CLIP 的编码器实现了图像区域与文本间的细粒度语义对齐;Grounding DINO^[4]在此基础上引入跨模态 Transformer 架构,通过融合特征增强器和语言引导查询模块,实现了图像文本特征的深度融合。



(a) 现有方法结构示意图



(b) 本文方法结构示意图

图1 本文方法与现有方法的比较

Fig. 1 Comparison of the method proposed in this paper with existing methods

这些方法普遍依赖于高质量的图文配对数据进行训练,并默认文本与图像在语义空间中具有高度一致性,从而能够在两种模态之间建立稳定的映射关系。然而,在开放集或特定领域的实际应用场景中,这一假设往往难以成立。一方面,开放环境下的数据分布具有显著的不确定性,文本信息的来源更加多样化,往往并非直接描述视觉对象的属性或语义内容,而是以任务规则、领域知识或操作规范的形式存在。另一方面,这类知识文本通常具备较强的抽象性和概念层次,缺乏与具体视觉实例之间的细粒度对应关系。因此,在此类场景中,文本信息虽可被视为对目标检测任务有潜在指导意义的“知识先验”,但其语义相关性和适配性存在显著差异,甚至可能包含冗余、模糊或语义偏移的信息。当这些异质性知识与视觉特征进行直接融合时,由于语义空间不一致或特征分布错配,模型可能难以有效捕获跨模态关联,从而在特征学习过程中引入额外的融合噪声。这种噪声不仅削弱了多模态

特征表征的判别性,也可能导致模型在跨域或开放集场景下的检测精度和泛化性能下降。

为了解决这类问题,本文提出一种知识强度可调的多模态目标检测方法,旨在针对知识质量和适配度的差异,实现文本知识和图像信息融合强度的自适应调节,如图 1 所示。该方法通过引入一个可调节参数,在特征融合过程中动态控制知识与视觉特征的贡献比例:当知识质量高、语义相关性强,模型增强知识特征的影响;而在知识冗余或者不确定性高时,则弱化其作用,以免噪声干扰。本文构建了包括文本特征提取、多尺度图像特征提取及多模态特征对齐融合在内的统一框架,并在检测解码阶段通过语义增强机制实现融合特征的自适应优化。该方法能够根据不同任务场景与知识输入质量,灵活平衡数据与知识的融合强度,从而提升模型在复杂、不完备场景下的检测鲁棒性与可解释性。

1 相关工作

1.1 目标检测模型

目标检测是计算机视觉的重要任务之一,是多模态融合目标检测的重要分支。早期目标检测模型主要分为两阶段检测器与单阶段检测器。两阶段目标检测算法通常先通过区域提议网络生成候选区域,再对这些区域进行类别识别和边界框回归,如 RCNN^[5]系列。这类方法识别准确率较高,但由于分阶段处理,检测速度相对较慢。单阶段目标检测算法则直接在整张图像上同时预测目标的类别和位置,因此能够实现更快的检测,如 YOLO 系列^[6]和 SSD^[7]。

近年来随着 Transformer^[8]架构在计算机视觉领域的广泛应用,出现了 VisionTransformer^[9]和 Swin VisionTransformer^[10]等基于 Transformer Encoder 的骨干网络,并在各类图像任务中展现出了强大潜力。为了简化目标检测的流程,Carion N^[11]等提出了基于 Transformer 的目标检测框架 DETR。DETR 极大地简化了检测流程,将可学习的目标查询与图像特征交互,直接得到预测输出,检测过程中不使用候选区域生成算法和 NMS 算法,因此该模型结构简单,易于拓展。但由于模型在注意力计算时会兼顾序列中的所有元素,因此 DETR 的收敛速度较慢,且由于未考虑多尺度的特征,模型对于小物体检测率较差。为了解决这些问题,出现了大量 DETR 的改进工作。Zhu X^[12]等提出了具有可变注意力模块的 Deformable DETR,通过生成参考点来引导模型的注意力,使得序列中的元素无需与其他所有元素计算注意力,只需与采样获得的部分元素计算注意力,极大地加快了收敛速度,并降低了计算复杂度。Jia D 等^[13]认为 DETR 采用一对一的匈牙利匹配,导致正负样本数量差距过大,有效的监督信号不足,所以收敛较慢。基于此提出了一种混合匹配方案,在训练过程中将原始的一对一匹配分支和一个辅助的一对多匹配分支相结合,允许正样本匹配多个查询,从而提高了训练效率。而 Zong Z 等^[14]提出了 Co-DETR,该模型使用一种协作混合分配训练方案,通过在 encoder 后加入一个一对多标签分配的辅助头,增强了编码器在端到端检测器中的学习能力,同时通过从这些辅助头中提取正坐标来生成额外的正查询,以提高解码器中正样本的训练效率。Hou X 等^[15]则在上述方法的基础上将位置关系先验作为注意力偏差来增强目标检测,通过引入了一个编码器来构建用于渐进式注意力细化的位置关系嵌入,并进一步将 DETR 的传统流式管道扩展为对比关系管道,在增加正样本的同时实现了较好的非重复预测。

1.2 多模态融合模型

Transformer 凭借其强大的序列建模能力和高度统一的架构设计,已成为多模态融合的主流框架。对于各种不同模态的信息,均可通过嵌入层转化为统一的序列化表示,并交由 Transformer 编码器进行处理。这一特性极大地简化了多模态模型的设计,出现了一系列基于注意力机制的预训练模型。

多模态预训练模型按照模型结构可以分为单流和双流两种结构。单流是指图片和文本在特征嵌入后就融合在一起输入后续的 Transformer 层。双流是指文本和图片先通过各自的编码层,再通过融合模块进行融合。ViLT^[16]是一种单流多模态模型,通过将图像和文本输入整合到一个统一的 Transformer 架构中,直接在视觉和语言特征上进行联合建模,从而避免了复杂的视觉特征提取器。ViLT 能够更高效地融合图像和文本信息,可用于多种多模态理解任务,如视觉问答、图像文本匹配和图像字幕生成等。但由于图像序列长度和文本序列长度往往相差较大,且没有显式对齐机制,完全依赖注意力机制进行学习,导致模型收敛较慢,对数据集数量也有较高要求。为了实现图像与文本的语义对齐,OpenAI^[1]提出了一种双流多模态模型 CLIP,图像与文本首先通过各自的特征编码器进行特征提取,再进行简单的融合。CLIP 在大规模的数据集上进行对比学习,使用图像-文本对数据进行训练,使模型能够学习到图像和文本的联合表示,其核心思想是将图像和文本映射到同一特征空间,使得相似的图像和描述在特征空间中距离更近。该模型具有较强的零样本学习能力,且模型易于拓展,有很多后续工作^[17-21]。由于 CLIP 使用简单的点积来衡量文本图像特征的相似度,因此对语义的理解不深入,对于数据稀缺或特定场景下的任务效果较差,且模型训练需要大量的计算资源。为了加强模型对多模态语义的理解,同时不引入过多的计算量,Li J^[22]等提出了 Albef,先通过图文对比学习实现跨模态对齐,再利用跨模态注意力机制进行特征融合,从而有效缓解了早期融合阶段噪声较大的问题。融合模块使用了 6 层 Transformer 结构,获得了更好的图文融合效果。为了充分利用上下文信息,实现模态间的细粒度对齐,汤君豪等^[23]提出了一种基于多模态上下文感知与区域交互建模的方法,通过上下文感知生成模块动态融合视觉和文本特征,生成多粒度语义查询向量,结合区域注意力,对图像各区域的语义关联性进行建模。

这些模型依赖全局的图文对齐和跨模态交互机制,从而学习到较为强大的联合表征,在语义理解层面展现出优越性。然而,它们主要关注特征的提取和融合,没有使用候选区域生成或解码器等用于目标检测的框架,因此对区域级别的目标感知较弱,难以提供目标检测所需的空间精确定位与实例区分能力。

为了提高视觉语言模型在需要精确定位的检测任务中的表现,Li LH 等^[3]提出了 GLIP 模型,在 CLIP 模型架构的基础上加入了候选区域生成网络,并将目标检测与短语定位两种任务统一起来,从而将目标检测转化为类别或短语与图像中的不同区域的细粒度对齐问题。通过在大量数据上进行训练,使模型能够将文本概念与图像中的区域对应起来,不仅提高了检测效果,还实现了开放词汇和零样本检测。由于使用了选区域生成网络,导致 GLIP 的结构较为复杂,训练需要大量数据,且推理速度较慢。OV-DETR^[24]则在 CLIP 模型的基础上加入 DETR 检测架构,将目标检测任务转化为输入查

询与相应对象之间的二元匹配,从 CLIP 模型中获得查询嵌入,来调节 Transformer 解码器,从而将图像与文本对应起来,实现了开集检测并提高了检测精度。以上模型通过弱监督方式训练,可检测的类型较为灵活,但相较于有监督检测模型精度较差,韩春禹等^[25]提出了一种利用文本信息辅助的显著性目标检测方法。利用自注意力和混合注意力模块实现文本和 RGB 模态的交互,在利用全局注意力提高显著性对象定位能力的同时,不造成局部细节的丢失。周炫余等^[26]提出了一种基于马尔科夫随机场的模型,用于推断图像候选框与文本实体表达之间的共指关系,基于此联合图像和文本信息,提高交通场景下行人检测精度。

上述方法在训练时均使用一一对应的图像和文本,达到了较好的图文对应效果,但模型难以系统性地学习到文本中的全局知识或特定场景下的通用规则。为此,本文提出了知识强度可调的多模态目标检测方法,利用文本中的通用性知识提高目标检测效果。

2 本文方法

2.1 整体框架

为了应对开放场景中多模态信息质量不均、语义相关性差异显著等问题,本文设计了一种融合强度可调的多模态目标检测框架。一般的跨模态注意力机制主要关注不同模态间的交互,忽略了模态内部的语义结构,且容易受到无关文本描述的干扰,从而导致语义对齐不稳定。因此,引入基于 Sinkhorn 算法的对齐机制,充分考虑各模态信息,从全局视角对视觉特征与文本特征进行对齐。同时为进一步抑制文本噪声,引入动态阈值控制机制减弱噪声对融合特征的影响。现有方法的文本模态大多与单张图片对应,未充分考虑文本

作为全局先验的情况,因此提出了语义增强机制,将全局语义增强特征注入检测头,从而实现视觉信息与语义先验的互补融合,提高目标检测的鲁棒性与语义判别能力。

具体而言,该框架通过在视觉特征与文本知识融合过程中引入动态调节机制,根据不同模态特征间的关联度调整融合强度,实现对“知识先验”利用程度的精细控制。该框架主要包括单模态特征提取模块、多模态特征融合模块和语义增强检测模块三个部分,其总体结构如图 2 所示。首先,在文本处理阶段,采用命名实体识别模型对输入的文本信息进行预处理,识别并标注文本中的关键实体,建立实体-指代映射关系,将指代词替换为其对应的名词。随后,根据检测任务的目标类型,对文本进行语义筛选,仅保留与任务高度相关的语句,以此提高文本知识的有效性并减少无关内容的干扰。经过处理后的文本输入到 BETR^[27]中得到文本特征 z_t 。与此同时,输入图像通过主干网络提取多尺度的特征,并输入 Transformer-Encoder 模块以捕捉多尺度上下文关系,得到增强的图像特征表示 z_i' 。将 z_t 、 z_i' 以及 α 输入到多模态特征融合模块。该模块采用 Sinkhorn 算法对跨模态 Token 进行最优匹配,使每个图像区域特征与其最相关的文本 Token 实现精确对齐,得到对齐后的文本特征 z_{align} 。通过引入可调节的系数 α ,模型能够动态控制不同模态之间的融合强度,从而在充分利用知识先验的同时避免过度依赖文本特征带来的噪声,实现知识约束与数据驱动的平衡。最终得到的融合特征表示为 z 。在语义增强检测阶段,将融合特征 z 输入到语义增强检测模块中得到初始预测 P 。同时,利用语义对齐特征 z_{align} 构建各类别的语义特征 G ,并通过语义映射操作生成增强的输出特征 $P \times G$ 。最后,将增强特征与原始特征进行拼接融合,得到最终检测结果。




图2 模型整体框架

Fig. 2 Framework of our model

2.2 多模态特征融合模块

首先对单模态的特征进行提取。图像分支使用 ResNet50 作为主干网络,从输入图像中提取多尺度的特征图;文本分支使用 BERT 模型,对输入文本进行分词得到词元向量,并

通过编码器进行编码得到具有细粒度语义信息的文本特征。为了实现文本与视觉特征间的高效对齐与自适应融合,本文提出一种基于 Sinkhorn 优化的模态融合模块。该模块通过 Sinkhorn 算法求解基于特征相似度求得图像与文本之间的最优分配方式,从而在软匹配意义下实现两种模态的精细对齐,有效提取与图像语义最相关的文本信息。进一步地,为应对不同模态信息质量与语义一致性差异,模块引入了融合强度控制系数 $\alpha \in [0,1]$, 以调节视觉特征与文本特征在融合表示中的相对贡献,实现对快模态融合强度的动态调控。该模块的整体结构如图 3 所示。




图3 多模态融合模块结构

Fig. 3 Structure of multimodal fusion module

首先将输入的文本特征 $z_t \in R^{N_t \times d}$ 和图像特征 $z_i^l \in R^{N_i^l \times d}$ 输入到 Sinkhorn 算法模块中, 其中 N_t 为文本特征的长度, N_i^l 为第 l 层图像特征的长度, d 为特征向量的维度。对特征进行 L2 归一化, 以保证特征分布的稳定性。

$$Z_t = L2 - \text{Norm}(z_t) \quad (1)$$

$$Z_i^l = L2 - \text{Norm}(z_i^l) \quad (2)$$

计算归一化图像特征与文本特征的点积相似度矩阵 S , 其中 S_{mn} 表示第 m 个图像区域的特征 Z_{im}^l 与第 n 个文本词元特征 Z_{tn} 之间的相关性:

$$S_{mn} = Z_{im}^l \cdot Z_{tn}^T \quad (3)$$

由于 Sinkhorn 算法在最小化总代价的情况下求解分配矩阵, 所以此处使用相似度矩阵的负值作为代价矩阵 C , 即:

$$C = -S \quad (4)$$

基于此代价矩阵, 通过 Sinkhorn 算法求解分配矩阵使得 Sinkhorn 距离 d_C^λ 最小, 即:

$$d_C^\lambda = \min \sum_{ij} D_{ij} C_{ij} - \frac{1}{\lambda} h(D) \quad (5)$$

其中, d_C^λ 为 Sinkhorn 距离, $D \in R^{N_i \times N_t}$ 为分配矩阵, $h(D) = -\sum D_{ij} \log D_{ij}$ 为 D 的信息熵, λ 为熵正则化参数, 为可学习参数, 在训练过程中根据数据的特征动态学习最合适的值。 λ 越大, 信息熵影响越小, 最终结果受成本矩阵影响越大, 匹配精度越高。对于简单明确的对应关系保持高精度匹配, 对于模糊复杂的对应关系则降低匹配精度, 以提升泛化性能。

为了进一步抑制不相关的文本噪声, 更准确地聚焦于有用的文本信息, 本文引入动态阈值控制机制对分配矩阵 D 进行稀疏化调整。具体地, 矩阵 D 的每一行表示一个图像区域与各文本词元的相关性。对于 D 的每一行 D_i , 计算该行的最大值:

$$\text{row_max} = \max_j (D_{ij}) \quad (6)$$

$$\text{Threshold} = T \cdot \text{row_max} \quad (7)$$

计算该行的动态阈值 Threshold , 如公式(7)所示。其中, T 为阈值因子, 是一个全局可调的超参数, 取值范围为 $[0, 1]$ 。阈值因子较高时, 筛选更严格, 仅保留最合适的对齐关系。阈值因子较低时, 筛选较为宽松, 有利于最大化地保留相关信息, 但可能让更多噪声参与训练, 影响模型鲁棒性。

基于此阈值构建一个二值化的掩码 M_i , 如式(8)所示。

$$M_i = \begin{cases} 1, & \text{if } D_{ij} \geq \text{Threshold}_i \\ 0, & \text{otherwise} \end{cases} \quad (8)$$

利用上述得到的二值化掩码向量从原始文本特征 z_t 中筛选与图像区域相关强度超过阈值的部分。对于每个图像区域 i , 将掩码 M_i 与文本特征 z_t 点乘, 仅保留筛选出的文本特征, 其他位置置 0, 得到其对应的对齐文本特征 $z_{t,i}^{\text{align}} \in R^{N_i \times d}$, 如式(9)所示:

$$Z_{t,i}^{\text{align}} = M_i \times z_t \quad (9)$$

将所有图像区域的对齐文本特征拼接, 最终得到与图像特征 z_i 对齐后的文本特征序列 $z_t^{\text{align},l} \in R^{N_i^l \times d}$, 如式(10)所示:

$$Z_t^{\text{align},l} = \text{concat}(Z_{t,1}^{\text{align}}, Z_{t,2}^{\text{align}}, \dots, Z_{t,N_i}^{\text{align}}) \quad (10)$$

对不同尺度的图像特征执行相同操作, 得到分别与不同尺度的图像特征对齐的文本特征, 将结果进行拼接并按一定比例与图像特征融合, 得到最终的融合特征, 如式(11)所示:

$$Z^{\text{fusion}} = \alpha \cdot \text{concat}(Z_t^{\text{align},l}) + (1 - \alpha) Z_i \quad (11)$$

该特征表示 Z^{fusion} 同时保留了视觉信息的结构细节与文本知识的语义约束, 并可通过调节强度系数灵活地控制两种模态的融合比重, 提升模型在不同场景下的准确性和鲁棒性。

2.3 语义增强检测模块

由于本文所使用的文本数据实质上是对整个数据集的整体性语义描述,而非针对单幅图像的局部性语义描述,因此其内部蕴含了关于所有类别的全局语义先验。然而,在识别特定图像中的某一类目标时,非相关类别的语义信息不仅缺乏判别贡献,甚至可能引入语义噪声,干扰特征对齐与类别判定的准确性。因此,构建了一种基于类别预测软映射的语义增强模块对输出结果进行修正,结构如图4所示。




图4 语义增强检测模块

Fig. 4 Semantic enhancement detection module

在语义增强模块中,首先将来自融合模块的多层次文本对齐特征 z_i^l 进行全局平均池化,以获得不同层级的语义压缩特征向量。为更准确地利用多层次特征的语义信息,引入了层级语义加权机制。为来自不同层级的特征设置一个可学习的融合权重矩阵,并通过 Softmax 归一化约束权重分布。通过多层特征的加权求和融合跨层语义信息,并通过多层感知器映射得到全局类别语义矩阵 $G \in R^{n_c \times d}$, 其中 n_c 表示类别数量, d 表示特征维度,与视觉特征及文本嵌入的特征维度保持一致,使得每个类别都能对应一行语义向量,保证语义增强计算的合理性。多层感知器采用三层全连接结构,并在各层引入非线性激活函数,将特征映射至更高阶的语义空间,并引入足够的非线性表示能力,从而建模不同类别之间潜在的高阶语义关系,使得语义增强模块能够更充分地融合类别语义信息与视觉特征表示,有效提升目标检测阶段对不同类别的判别能力。如式(12)所示:

$$G = MLP\left(\frac{1}{N} \sum_{l=0}^3 \omega_l \cdot GAP(z_i^l)\right) \quad (12)$$

其中, z_i^l 为多层次文本对齐特征, N 为多层级特征层数, ω_l 为各层级的融合权重, GAP 表示全局平均池化层, MLP 表示多层感知器。

在解码器得到初始输出 $F_0 \in R^{n_q \times d}$ 后,通过线性层将输出维度映射到检测类别空间,并经 softmax 函数得到各个类别的原始概率矩阵 $P \in R^{n_q \times n_c}$ 。将原始概率矩阵与全局类别语义矩阵相乘,并通过线性层映射到特征空间,得到语义增

强的特征 F_e , 将其与初始输出特征拼接得到最终的特征,如式(13)所示:

$$F = concat(F_0, P \times G \times W_G) \quad (13)$$

其中, W_G 为线性层参数矩阵, $concat$ 表示拼接操作。

最后,基于融合后的特征 F 进行目标类别与检测框的联合预测,从而实现语义层面的自适应增强。

3 实验与结果分析

3.1 实验设置

为验证所提出方法的有效性与泛化能力,本文在 PASCAL VOC 与 DUT Anti-UAV 两个具有代表性的数据集上进行了实验评估。

PASCAL VOC 数据集包含 20 个常见目标类别,具有较高的类别多样性与场景复杂性。实验中,训练集采用 VOC 2012 的 trainval 部分(共 11,540 张图像),测试集采用 VOC 2007 的 test 部分(共 4,952 张图像)。

DUT Anti-UAV 数据集以无人机为主要检测目标,覆盖多种视角与背景环境,具有较强的场景多样性与目标尺度变化特征。实验中,训练集使用 trainval 数据共 7,800 张图像,测试集 test 部分包含 2,200 张图像。

为引入文本知识,本文人工构建了基于典型场景的类别级知识描述文本,并通过命名实体识别模型对文本内容进行结构化预处理,以规范化实体指代关系并提高文本语义的一致性与可用性。例如:“Birds are feathered, winged vertebrates, most birds are capable of flight. Birds inhabit diverse environments, from forests to wetlands.” 不同类型的命名实体识别模型在上下文理解能力上存在差异,其命名实体识别质量将直接影响文本中关键信息的保留程度,从而对后续文本特征提取效果产生一定影响。实验中选用了基于 BERT 和 CRF 的命名实体识别模型,该模型利用 BERT 强大的上下文建模能力对文本进行深层语义表示学习,从而有效提升实体识别的效果,为后续文本特征提取提供更高质量的文本数据。

在性能评估方面,采用 MS-COCO 通用目标检测评价标准,包括平均精度(Average Precision, AP)、AP50、AP75 等指标。该评价体系通过在多个交并比阈值下计算平均 AP 值,能够综合反映检测模型在精度与召回率之间的平衡性能。

模型训练使用 AdamW 优化器,初始学习率设为 1×10^{-4} ,权重衰减为 1×10^{-4} ,动量参数 0.9。为了提高训练稳定性并加速收敛,引入多步学习率调度器,在训练第 10 轮将学习率衰减为原来的 10%。

3.2 文本预处理及质量指标

为了量化文本的质量,使用了文本错误率,关键词覆盖率,文本重复率三个指标,分别从结构完整性、语义相关性和信息冗余性三个维度对文本进行评估。

文本错误率(Text Error Rate, TER):用于评估文本在句法层面的完整性,从语法结构有效性角度对文本质量进行近似衡量。首先将文本划分为若干句子,通过句子中分词的成分判断其是否具备基本的语法结构。例如句子中同时存在主语成分以及谓语动词时,认为该句子在语法上是完整的;反之,则视为语法错误句。TER 定义为语法错误句子数与总句子数之比:

$$TER = \frac{1}{|Sents|} \sum_{s \in Sents} I_A(s) \quad (14)$$

$$I_A(x) = \begin{cases} 1, x \in A \\ 0, else \end{cases} \quad (15)$$

其中 $Sents$ 表示文本中的句子集合, $I_A(\cdot)$ 为指示函数, A 表示句法结构异常的集合。

关键词覆盖率(Keyword Coverage, KC):用于描述文本中与类别关键词直接相关的词汇的出现频率。给定类别集合 C_k ,首先对文本进行分词处理,得到词元序列 $lemma$ 。然后统计各类别关键词在文本中出现的频率,如计算公式如下:

$$KC = \frac{1}{|lemma|} count(C_k) \quad (16)$$

其中, $count(C_k)$ 表示类别关键词在文本中出现的次数。

文本重复率(Repetition Rate, RR):用于评估文本中内容重复的句子比例,反映文本中信息冗余的程度,防止因语句重复导致关键词覆盖率虚高。文本重复率的公式如下:

$$RR = \frac{N_{\text{重复句子数}}}{N_{\text{总句子数}}} \quad (17)$$

其中 $N_{\text{重复句子数}}$ 表示文本中被识别为重复的句子数量, $N_{\text{总句子数}}$ 表示文本中的句子总数。

高文本错误率或低关键词覆盖率的文本往往包含较多噪声,可能导致文本特征质量较差,甚至对视觉特征学习产生干扰,影响模型性能。为了缓解噪声的影响,模型中使用了强度可调的融合方式。通过对不同模态信息的融合强度进行调节,模型能够在文本质量较低的情况下,降低文本模态在融合过程中的影响,从而避免噪声或冗余信息对视觉特征学习造成干扰。融合权重的具体取值依据以上三项指标的评估结果,并结合数据集整体特征和场景复杂性进行经验设定。通过显式设定融合权重,可以为模型施加合理的偏置,提高模型的稳定性和可解释性。

3.3 算法性能对比

为了验证所提出方法的有效性,本文选取相关典型算法作为对比方法。DETR 作为端到端目标检测的代表性模型,将卷积神经网络与 Transformer 架构相结合,实现了无需候选框和非极大值抑制的统一检测框架。Deformable-DETR^[12]引入可变形注意力机制,提高了模型收敛速度和多尺度检测能力;Dn-DETR^[28]通过噪声对齐策略进一步加快了收敛速度;DAB-DETR^[29]利用锚框动态查询提供位置先验,提高了定位精度;DINO^[30]结合查询增强和知识蒸馏策略刷新了系列性能;Relation-DETR 将显式的位置关系先验作为注意力偏差,提高了收敛速度。Grounding DINO 将 DINO 检测框架与图文多模态模型相结合,通过对图像特征与文本特征进行深度交互与对齐,显著提升了模型在开放集目标检测和指代理解任务中的性能。在保持环境参数配置相同的情况下,将以上方法与本文方法进行了对比,结果如表 1 和表 2 所示。

表1 PASCAL VOC 数据集上的结果 单位: %

Tab. 1 Results on the PASCAL VOC dataset

unit: %

模型	AP	AP@50	AP@75
DETR	49.9	74.5	53.1
Deformable-DETR	59.9	82.4	66.7
Dn_DETR	56.7	76.6	61.7
Dab_DETR	56.4	76.6	62.0
Dino	58.8	78.5	64.3
Relation-DETR	66.9	86.4	73.4
Grounding DINO	66.0	76.6	71.8
Ours	68.5	87.6	75.2

表2 DUT Anti-UAV 数据集上的结果 结果: %

Tab. 2 Results on the DUT Anti-UAV dataset

unit: %

模型	AP	AP@50	AP@75
Dn_DETR	65.1	95.4	73.4
Dab_DETR	64.6	95.7	73.6
Dino	64.5	96.2	74.0
Relation-DETR	64.5	95.9	73.1
Ours	73.3	97.4	83.5

表 1 展示了各模型在 PASCAL VOC 数据集上的目标检测性能。可以看出,本文方法在各项指标上均优于现有代表性基于 Transformer 的检测模型。具体而言,所提出模型在 AP、AP@50、AP@75 三项指标上分别达到 68.5%、87.6%和 75.0%,相较于当前最优方法 Relation-DETR 分别提升了 1.6%、1.2%和 1.2%。这一性能增益表明,本文引入的可调融合机制与语义增强模块能够有效缓解文本知识与图像语义之间的不匹配问题,使模型在多类别复杂场景下表现出更强的语义对齐能力和跨模态信息提取能力。此外,模型在高 IoU 阈值(AP@75)下的性能提升尤为显著,说明所提出的跨模态语义约束有助于模型在边界精确性要求较高的检测任务中获得更优结果。

表 2 给出了各模型在 DUT Anti-UAV 数据集上的评估结果, 部分检测结果如图 5 所示。该数据集主要面向复杂背景下的小目标无人机检测任务, 对模型的特征表达能力与鲁棒性提出了更高要求。结果显示, 本文方法在 AP、AP@50 和 AP@75 上分别达到 73.3%、97.4% 和 83.5%, 相比当前最佳模型提升了 8.8%、1.5% 和 10.4%。其中, 在高精度指标 AP@75 上的显著提升表明, 本文方法在精细目标区域的识别与边界定位方面具有更高的鲁棒性和判别性。这一改进得益于语义增强模块在检测阶段的自适应修正机制, 该机制能够根据类别预测结果动态筛选与目标相关的文本语义, 从而减少无关类别带来的噪声干扰。




图5 DUT Anti-UAV 数据集检测结果

Fig. 5 DUT Anti-UAV Dataset Detection Results

3.4 消融实验

为进一步验证本文所提出各模块的有效性与合理性, 我们在基线模型上逐步引入融合模块与语义增强模块, 并计算其在不同指标下的检测性能。表 3 给出了各方法的消融实验结果。可以看出, 在引入融合模块后, 模型的 AP@50 提升 0.6%, 表明通过 Sinkhorn 算法实现的跨模态对齐能够有效增强图像与文本之间的语义一致性, 提高检测精度。当进一步加入语义增强模块后, AP@50 继续提升 0.6%, 在 PASCAL VOC 数据集上 AP 指标相比基线模型均有显著提升。

这一结果验证了两种模块的互补性: 前者提升了跨模态信息融合的准确性, 后者则通过类别预测驱动的语义筛选机制对检测结果进行了细粒度的语义修正, 从而整体提升了模型的性能与稳定性。

表3 消融实验结果 结果: %

Tab. 3 Ablation experiment results unit: %

模型	AP	AP@50	AP@75
Baseline	66.9	86.4	73.4
融合模块	67.4	87.0	73.8
语义增强模块	68.5	87.6	75.2

进一步地, 为分析融合强度系数 α 对模型性能的影响, 分别在 PASCAL VOC 和 DUT Anti-UAV 数据集上进行了参数敏感性实验。表 4 与表 5 展示了不同 α 值下的检测结

果, 其中 α 表示融合过程中文本特征的相对权重。 α 越大表示融合过程中文本所占比重越高。

从表 4 可以看出, 当 $\alpha \approx 0.3$ 时, VOC 数据集上各项指标达到最优; 当 α 进一步增大时, 性能逐渐下降, 说明过高的文本比重会引入语义噪声, 从而干扰视觉特征的判别能力。类似地, 在 DUT Anti-UAV 数据集上, $\alpha \approx 0.6$ 时性能最佳, 而当 α 增至 1 (即仅保留文本特征) 时, 各项指标显著下降, 验证了视觉特征在目标检测任务中的主导作用。值得注意的是, 当 $\alpha = 0$ (即未显式引入文本信息) 时, 模型的性能仍略高于基线模型, 这表明在训练过程中, 跨模态梯度传播促进了视觉编码器学习与文本语义相关的判别特征, 使模型即便在无文本输入时仍具备一定的语义泛化能力。

表4 VOC 数据集不同融合强度下的检测结果 结果: %

Tab. 4 Detection results of the VOC dataset at different fusion intensities unit: %

α	AP	AP@50	AP@75
0	68.2	87.2	75.0
0.3	68.5	87.6	75.2
0.6	68.5	87.4	75.0
0.9	66.1	85.6	72.2
1	49.0	66.0	54.4

表5 DUT Anti-UAV 数据集不同融合强度下的检测结果

结果: %

Tab. 5 Detection results of the DUT Anti-UAV dataset at different fusion intensities unit: %

α	AP	AP@50	AP@75
0	73.4	97.3	83.6
0.3	73.3	97.4	83.5
0.6	73.3	97.2	82.8
0.9	70.4	96.9	79.4
1	47.1	84.1	46.9

为了探究阈值因子对特征提取和噪声抑制的影响, 在三个不同阈值因子下进行了实验, 结果如表 6 所示。可以发现, 当阈值因子为 0.2 时, 模型效果较差, 说明低阈值保留了更多的噪声文本信息, 影响了整体检测性能。随着阈值因子增大至 0.8, 模型性能得到明显提升, 说明适度提高阈值因子能够有效削弱文本噪声干扰, 提升目标与语义之间的匹配质量。阈值因子提高至 1.0 后, 性能出现不同程度下降, 说明过高的阈值会导致模型获取的有用的语义信息减少。因此, 阈值因子的选取应保证模型在噪声抑制与有效信息保留之间取得平衡。

表6 VOC 数据集不同阈值因子下的检测结果 结果: %

Tab. 6 Detection results of the VOC dataset at different threshold factor unit: %

阈值因子	AP	AP@50	AP@75
0.2	65.4	85.2	71.6
0.8	68.5	87.6	75.2
1.0	67.2	86.7	73.9

此外，为了探究文本知识在小尺寸目标检测中的作用，构建了不完全标注的数据集，将原始数据集标注中的小尺寸目标隐去，并在该数据集上重新训练模型，并在完整测试集上进行评估。实验结果如表 7 所示。

表7 VOC 数据集隐去小目标后的检测结果 结果: %
Tab. 7 VOC dataset detection results after removing small targets unit: %

模型	AP	AP@50	AP@75
Baseline	66.2	85.2	72.8

模型	AP	AP@50	AP@75
Ours	66.8	86.1	73.1

可以发现，在不完全标注的数据集上模型的整体精度相较于完整标注时有所下降，但本文的模型仍优于基线模型。这表明文本信息在小目标标注缺失的情况下能够提供额外的语义补偿，使模型仍能识别部分未标注目标，具有较强的知识泛化与迁移能力。部分检测结果图如图 6 所示。

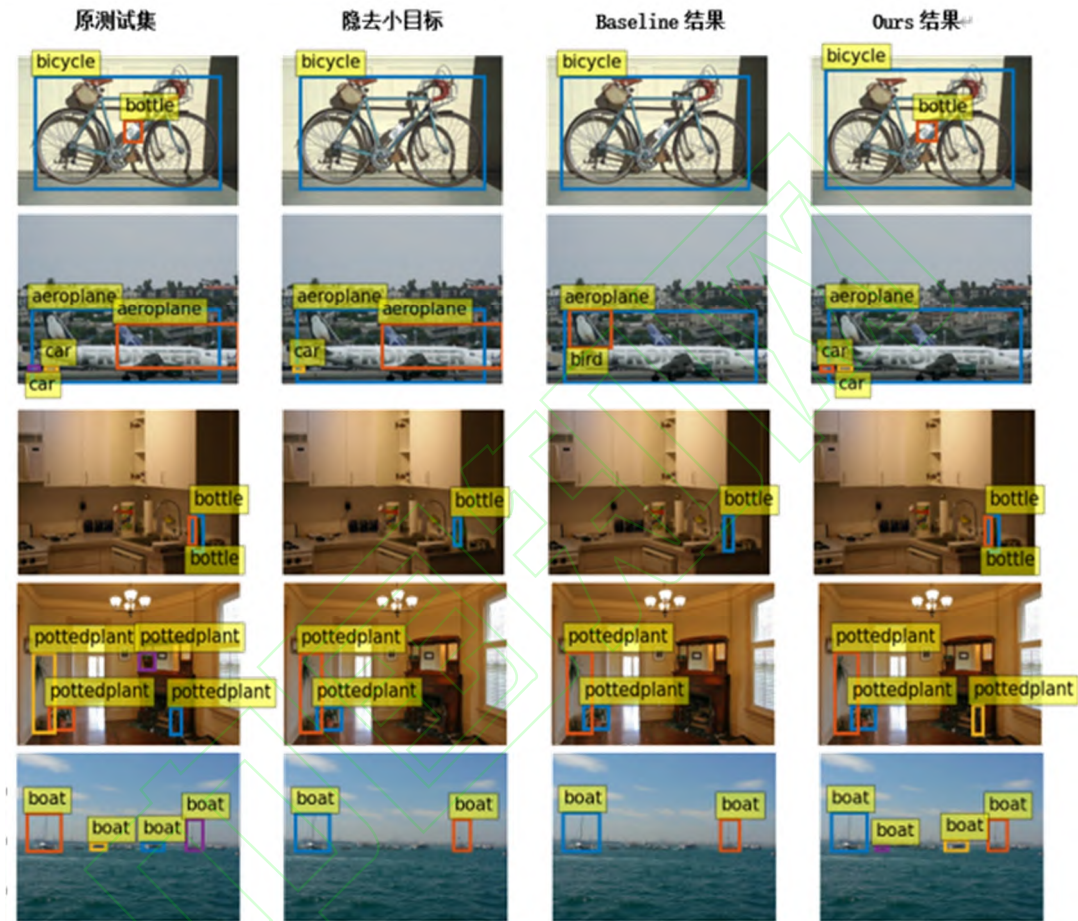


图6 VOC 数据集隐去小目标后的检测结果

Fig. 6 VOC dataset detection results after removing small targets

为了探究不同质量文本对模型性能的影响，使用了两段不同质量的文本进行了实验，结果如表 8 所示。结果表明，在高质量文本条件下，模型在适度的文本融合强度下取得最佳性能，而在低质量文本条件下，模型在融合强度较低时表现最佳，融合强度增加时并未提升性能。说明不同文本质量对应的最优融合权重存在明显差异，验证了采用加权融合机制以调节文本影响的重要性。

表8 VOC 数据集不同质量文本的检测结果
Tab. 8 VOC dataset detection results for different quality texts

数据集	文本错误率	关键词覆盖率	文本重复率	α	AP@75/%
VOC	0.06	0.11	0.01	0.0	75.0

数据集	文本错误率	关键词覆盖率	文本重复率	α	AP@75/%
	0.81	0.06	0.03	0.3	75.2
				0.6	75.0
				0.0	73.2
				0.3	73.1
				0.6	72.2

4 结语

本文提出了一种融合强度可调的多模态目标检测框架，旨在在复杂场景下充分利用图像与文本两种模态的信息互补性，以提升目标检测的鲁棒性与泛化能力。该框架通过引入可调节的融合强度系数，实现了对图像与文本特征融合程度

的动态控制,从而使模型能够根据不同模态数据的质量与任务需求分配信息权重,获得更优的融合效果。在 PASCAL VOC 与 DUT Anti-UAV 数据集上的实验结果表明,所提出的模型在各项指标上均显著优于主流检测框架。特别是在不同融合强度条件下,模型均表现出优于基线模型的性能,验证了融合强度可调机制对模型稳定性与性能上限的积极作用。

参考文献

- [1] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]// International conference on machine learning. PmLR, 2021:8748-8763.
- [2] GU X, LIN T, KUO W, et al. Open-vocabulary object detection via vision and language knowledge distillation[C]// International Conference on Learning Representations, 2022:15099-15120.
- [3] LI L H, ZHANG P, ZHANG H, et al. Grounded language-image pre-training[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022:10965-10975.
- [4] LIU S, ZENG Z, REN T, et al. Grounding dino: Marrying dino with grounded pre-training for open-set object detection[C]// European conference on computer vision. Springer, 2024:38-55.
- [5] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE, 2016,39(6): 1137-1149.
- [6] TIAN Y, YE Q, DOERMANN D. Attention-centric real-time object detectors [C]// The Thirty-ninth Annual Conference on Neural Information Processing Systems, 2025.
- [7] LIU W, ANGUELOV D, ERHAN D, et al. Ssd: Single shot multibox detector[C]// European conference on computer vision. Springer, 2016:21-37.
- [8] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017,30.
- [9] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An Image is Worth 16x16 Words: Transformers for image recognition at scale[C]// International Conference on Learning Representations, 2020:611-623.
- [10] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]// Proceedings of the IEEE/CVF international conference on computer vision, 2021:10012-10022.
- [11] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]// European conference on computer vision. Springer, 2020:213-229.
- [12] ZHU X, SU W, LU L, et al. Deformable DETR: Deformable transformers for end-to-end object detection[C]// International Conference on Learning Representations, 2021:894-910.
- [13] JIA D, YUAN Y, HE H, et al. Dets with hybrid matching[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2023:19702-19712.
- [14] ZONG Z, SONG G, LIU Y. Dets with collaborative hybrid assignments training[C]// Proceedings of the IEEE/CVF international conference on computer vision, 2023:6748-6758.
- [15] HOU X, LIU M, ZHANG S, et al. Relation detr: Exploring explicit position relation prior for object detection[C]// European Conference on Computer Vision. Springer, 2024:89-105.
- [16] KIM W, SON B, KIM I. Vilt: Vision-and-language transformer without convolution or region supervision[C]// International conference on machine learning. PMLR, 2021:5583-5594.
- [17] Wang Mengmeng, Xing Jiazheng, Liu Yong. Actionclip: a new paradigm for video action recognition[PP/OL].v1. (2021-09-17) [2025-12-29]. <https://arxiv.org/pdf/2109.08472>.
- [18] SHEN S, LI L H, TAN H, et al. How Much Can CLIP Benefit Vision-and-Language Tasks?[C]// International Conference on Learning Representations, 2022:14471-14485.
- [19] ZHANG R, ZENG Z, GUO Z, et al. Can language understand depth?[C]// Proceedings of the 30th ACM International Conference on Multimedia, 2022:6868-6874.
- [20] ZHANG R, GUO Z, ZHANG W, et al. Pointclip: Point cloud understanding by clip[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022:8552-8562.
- [21] XU J, De MELLO S, LIU S, et al. Groupvit: Semantic segmentation emerges from text supervision[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022:18134-18144.
- [22] LI J, SELVARAJU R, GOTMARE A, et al. Align before fuse: Vision and language representation learning with momentum distillation[J]. Advances in Neural Information Processing Systems, 2021,34: 9694-9705.
- [23] 汤君豪, 邓何霖, 雷印杰. 基于多模态上下文感知与区域交互建模的广义指称表达分割[J]. 电子制作, 2025,33(7): 20-26. (Tang J H, Deng H L, Lei Y J. Generalized reference representation segmentation based on multimodal context awareness and region interaction modeling [J]. Practical Electronics, 2025, 33(7): 20-26.)
- [24] ZANG Y, LI W, ZHOU K, et al. Open-vocabulary detr with conditional matching[C]// European Conference on Computer Vision. Berlin: Springer, 2022:106-122.
- [25] 韩春禹, 马骏, 沙洪涵, 等. 文本模态辅助的 RGB 显著性目标检测 [J]. 计算机工程与应用, 2025,61(17): 259-271. (Han C Y, Ma J, Sha H H, et al. Text-modal assisted RGB saliency object detection [J]. Computer Engineering and Applications, 2025, 61(17): 259-271.)
- [26] 周炫余, 刘娟, 卢笑, 等. 一种联合文本和图像信息的行人检测方法 [J]. 电子学报, 2017,45(1): 140-146. (Zhou X Y, Liu J, Lu X, et al. A pedestrian detection method combining text and image information [J]. Acta Electronica Sinica, 2017, 45(1): 140-146.)
- [27] DEVLIN J, CHANG M, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]// Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers), 2019:4171-4186.
- [28] LI F, ZHANG H, LIU S, et al. Dn-detr: Accelerate detr training by introducing query denoising[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022:13619-13627.
- [29] LIU S, LI F, ZHANG H, et al. DAB-DETR: Dynamic anchor boxes are better queries for DETR[C]// International Conference on Learning Representations, 2022:4173-7192.
- [30] ZHANG H, LI F, LIU S, et al. DINO: DETR with improved denoising anchor boxes for end-to-end object detection[C]// International Conference on Learning Representations, 2023:8587-8610.

This work is partially supported by Foundation of Sichuan Provincial Key Laboratory of Systems and Artificial Intelligence(SSAI202514).

PEI Jiangbo, born in 2001, M. S. candidate. His research interests include object detection, multimodal fusion

LI Wei, born in 1980, Ph. D., associate researcher. His research interests include multimodal fusion, scene understanding