

基于自监督学习与多模态数据融合的无标注鞋类推荐系统设计*

Design of Unlabeled Footwear Recommendation System
Based on Self-supervised Learning and Multimodal Data Fusion

林辰玮 郑庆翔 (湄洲湾职业技术学院信息中心, 福建 莆田 351119)

陈丽娜 黄媛媛 (湄洲湾职业技术学院后勤管理处, 福建 莆田 351119)

摘要:提出了一种基于自监督学习的无标注鞋类推荐系统,旨在解决传统方法在标注数据稀缺、用户冷启动和多模态特征融合方面的局限性。通过使用对比学习和图神经网络来减少对标注数据的依赖,降低数据采集成本,提升推荐系统在稀疏数据和冷启动场景中的表现。通过多模态特征的对齐和融合,提高推荐结果的精准性和用户满意度。

关键词:自监督学习;推荐系统;冷启动;无标注;多模态

Abstract: In this paper, an unlabeled footwear recommendation system based on self-supervised learning is proposed, aiming to address the limitations of traditional methods in terms of scarcity of labeled data, user cold-start and multimodal feature fusion. By using comparative learning and graph neural networks to reduce the dependence on labeled data, reduce the cost of data collection, and improve the performance of the recommended system in sparse data and cold-start scenarios. Alignment and fusion of multimodal features are used to improve the accuracy of recommendation results.

Keywords: self-supervised learning, recommended system, cold start, unlabeled, multimodal

随着电子商务的快速发展,鞋类行业也迎来了前所未有的增长,但由于缺乏标注数据、用户冷启动问题以及多模态特征(如图像、描述文本、价格等)的复杂性,鞋类推荐仍然面临诸多挑战。传统的推荐方法在应对这些问题时存在一定局限性。近年来,自监督学习(Self-Supervised Learning, SSL)作为机器学习领域的一项重要突破,展示了通过无标注数据挖掘潜在监督信号的强大能力。SSL通过生成伪标签,能够从数据本身的结构中提取有意义的特征,而无需依赖昂贵的人工标注。尤其是在推荐系统中,SSL结合了对比学习(Contrastive Learning)和图神经网络(Graph Neural Networks, GNNs),为处理稀疏数据、建模用户-物品关系提供了新的思路。

鞋类电商的推荐系统需要解决多模态数据融合,通常包含图像、文本描述和价格等不同形式的特征信息。如何有效对齐这些多模态特征,并将其融入推荐模型,是实现精准推荐的关键。此外,由于鞋类商品的消费具有一定的季节性和个性化特点,系统还需要具备动态适应能力。现有研究中,多模态推荐系统(如使用深度学习方法的图像-文本融合)已经取得一定进展,但对于无标注场景下的性能优化仍然不足。本文提出了一种基于自监督学习的无标注推荐系统,通过减少对标注数据的依赖,有效提升了稀疏数据和冷启动场景下的推荐效果。

1 研究现状

推荐系统是当代信息检索与机器学习领域的重要分支,其主要目标是根据用户历史行为预测其潜在兴趣,提供个性化的推荐服务。传统推荐系统方法包括基于内容的推荐、协同过滤推荐和混合推荐。基于内容的推荐依赖物品的元数据,例如鞋类的材质、品牌或价格,但其对用户偏好的建模能力有限。协同过滤推荐利用用户间的相似性或用户-物品交互的隐式关系,广泛应用于实际系统中。然而,这类方法容易受到数据稀疏性和冷启动问题的限制。混合推荐系统试图结合两者的优势,但其复杂性和

高计算成本限制了大规模应用。

随着深度学习的发展,深度神经网络被广泛应用于推荐系统中,包括深度矩阵分解、神经协同过滤等方法,通过非线性特征提取提升了推荐性能。然而,这些方法高度依赖标注数据,限制了其在大规模、动态场景中的泛化能力。

自监督学习(Self-Supervised Learning, SSL)作为近年来的一项重要技术,为无标注数据的建模提供了新思路。SSL通过设计预任务(P pretext Task)生成伪标签,从数据的内在结构中学习有意义的特征。主要技术路径包括对比学习(Contrastive Learning)、生成式模型(如BERT的掩码语言模型)和自回归模型(如GPT系列)^[1]。

在推荐系统中,SSL被证明对缓解数据稀疏性和冷启动问题具有重要作用。例如,对比学习通过最小化正样本间的距离、最大化负样本间的距离,有效增强了特征表达的区分性。此外,SSL还能够利用数据增强(Data Augmentation)生成更多交互信息,提高推荐系统的鲁棒性。

鞋类电商的推荐任务不仅涉及用户行为数据,还涉及商品的多模态特征,如图像、描述文本和价格。现有研究表明,多模态推荐系统通过融合不同模态信息能够更好地满足用户个性化需求。例如:基于卷积神经网络(CNNs)的图像特征提取模型在时尚推荐领域表现出色;基于预训练语言模型(如BERT)的文本分析方法能够从描述中提取出重要语义信息。然而,多模态数据的对齐与融合仍然面临挑战,包括特征维度的不一致、信息冗余及计算复杂度问题^[2]。

通过分析现有文献,可以总结出以下研究启示:自监督学习能够显著降低对标注数据的依赖,为大规模推荐任务提供新思路。对比学习的正负样本构造策略直接影响模型性能,如何设计高质量的样本对是关键研究问题。在多模态推荐任务中,SSL提供了新的数据融合与对齐方法,但仍需优化其在动态场景中的效率与鲁棒性。

* 福建省中青年教育科研项目(科技类):基于人工智能技术的电商推荐系统微观行为的研究(JAT241369);湄洲湾职业技术学院2024年教师教育科研项目:基于大数据的鞋业电商推荐系统的研究(MZY2426)

此外,目前的研究在以下方面存在不足:①计算复杂度高,SSL 通常需要多次训练迭代,限制了其在实际系统中的实时应用;②对噪声敏感,推荐系统中的数据噪声可能对比学习的性能产生显著影响;③泛化能力有限,当前方法往往针对单一场景优化,缺乏跨场景的适应性。

2 系统架构设计

2.1 问题定义与符号说明

本文提出的推荐系统架构集成了图神经网络(GNN)和自监督学习(SSL)技术。GNN 用于捕捉复杂的用户-物品交互关系,而 SSL 则帮助缓解数据稀疏问题。多模态特征融合模块结合了图像、文本和元数据等不同模态的特征,从而确保推荐系统能够更准确地理解商品特性,提升推荐效果。在鞋类电商推荐系统中,通过用户行为历史数据和鞋类多模态特征预测用户对未见过物品的偏好,以及用户历史行为和鞋类商品的多模态特征,预测用户对未见商品的偏好。具体问题定义如下:

1)用户集合和物品集合:定义用户集合 $U=\{\mu_1, \mu_2, \dots, \mu_m\}$ 和鞋类商品集合 $V=\{v_1, v_2, \dots, v_n\}$,其中 m 和 n 分别表示用户和商品的数量。

2)用户-物品交互矩阵:定义用户-物品交互矩阵 $A \in R^{m \times n}$,其中 $A_{ij}=1$ 表示用户 μ_i 与商品 v_j 之间存在交互(例如购买、点击),否则 $A_{ij}=0$ 。矩阵记录用户对商品的交互行为,如点击、收藏等。

3)多模态特征矩阵:定义鞋类商品的多模态特征集合为 $X=\{x_1, x_2, \dots, x_n\}$,每个商品的特征可以包括图像特征 x^{img} 、文本描述特征 x^{txt} 和元数据特征 x^{meta} 。

4)目标函数:给定用户历史行为 $\{A, X\}$,学习一个评分函数 $f(u_i, v_j)$,输出用户 μ_i 对商品 v_j 的偏好分数,定义为: $\hat{y}_{ij}=f(u_i, v_j; \theta)$ 。其中 θ 是模型参数。推荐系统目标是最大化实际交互 A_{ij} 和预测分数 $\hat{y}_{ij}$ 之间的一致性。

2.2 架构设计

本文提出的推荐系统主要由以下模块组成:用户-物品交互建模模块、多模态特征融合模块、自监督对比学习模块和推荐预测模块。

1)数据预处理模块:首先提取图像特征,利用预训练卷积神经网络(如 ResNet)获取高维图像嵌入;其次提取文本特征,使用 BERT 对商品描述文本进行语义建模;最后进行数据增强,设计多种增强策略(如裁剪、翻转和遮蔽),生成不同数据视图。

2)用户-物品交互建模模块:利用图神经网络(Graph Neural Network, GNN)构建用户-物品的二部图。对于每个用户 μ_i 和商品 v_j ,定义初始特征为:

$$h_{\mu_i}^{(0)}=E_u[i], h_{v_j}^{(0)}=E_v[j]$$

其中 E_u 和 E_v 分别是用户和商品的嵌入矩阵。

图神经网络的消息传递机制更新节点表示:

$$h_{\mu_i}^{(l+1)}=\sigma(\sum_{j \in N(\mu_i)} W^l h_{v_j}^{(l)}, h_{v_j}^{(l+1)}=\sigma(\sum_{i \in N(v_j)} W^l h_{\mu_i}^{(l)})$$

其中 $N(\cdot)$ 表示邻居节点集合, W^l 是第 l 层的可学习权重矩阵, $\sigma(\cdot)$ 是激活函数(如 ReLU)。

3)多模态特征融合模块:对每个商品的多模态特征 $x_j=\{x_j^{img}, x_j^{txt}, x_j^{meta}\}$ 进行特征提取与融合。图像特征 x_j^{img} :使用预训练卷积神经网络(如 ResNet)提取图像嵌入 $f_{img}(x_j)$;文本特征 x_j^{txt} :使用 BERT 提取文本嵌入 $f_{txt}(x_j)$;元数据特征 x_j^{meta} :通过多层感知机(MLP)映射为嵌入表示 $f_{meta}(x_j)$ 。融合后的多模态特征表示为:

$$h_{v_j}^{multi}=\text{Concat}(f_{img}(x_j), f_{txt}(x_j), f_{meta}(x_j))$$

4)自监督对比学习模块:利用对比学习生成正负样本对,从而增强节点表示的区分能力。对比损失定义为:

$$L_{\text{contrast}}=-\log \frac{\exp (\operatorname{sim}\left(h_{u_i}, h_{u_i}^{+}\right) / \tau)}{\sum_{k=1}^K \exp (\operatorname{sim}\left(h_{u_i}, h_{u_i}^{-}\right) / \tau)}$$

其中: $h_{u_i}^{+}$ 是正样本(如增强视图生成的嵌入), $h_{u_i}^{-}$ 是负样本。 $\operatorname{sim}(\cdot, \cdot)$ 表示相似度函数(如余弦相似度), τ 是温度系数。

5)推荐预测模块:综合用户和商品的最终表示,预测用户对商品的评分为 $\hat{y}_{ij}=\theta\left(h_{u_i}^{\tau} h_{v_j}\right)$ 。

2.3 模型训练与优化策略

1)联合损失函数:模型训练通过联合优化推荐损失和自监督损失: $L=L_{\text{rec}}+\gamma L_{\text{contrast}}$

其中: L_{rec} 是推荐损失(如二元交叉熵损失), γ 是权衡系数,用于控制两个损失项的相对重要性。

2)负样本采样策略:为提高对比学习效率,采用动态负样本采样机制,根据负样本的难易程度调整采样概率。

3)超参数调优:通过网格搜索优化关键超参数,包括学习率 η 、GNN 层数 L 、正负样本比例等。

通过结合自监督学习和多模态特征融合,有效缓解了电商推荐中的冷启动问题和数据稀疏性问题。模型的模块化设计提供了良好的扩展性,为多模态推荐任务的进一步优化提供了基础。

3 实验设计与过程

3.1 数据集说明与预处理

本研究实验所用数据主要来源于公开的电商推荐数据集,涵盖用户与鞋类商品的交互记录、商品图像、文本描述和价格等元数据。具体数据集信息如下:

1)用户行为数据:记录用户与商品的点击、收藏、购买等交互。
2)商品图像:每件商品配有高分辨率图像,用于提取视觉特征。
3)文本描述:包括商品名称、品牌、功能介绍等,用于提取语义特征。

4)结构化元数据:如价格、类别、库存等。

数据预处理过程如下:

1)数据清洗:去除重复记录和无效数据(如缺失值、异常值)。
2)用户与商品筛选:保留交互频率超过一定阈值的用户和商品,以降低数据稀疏性。

3)特征提取:首先提取图像特征,使用预训练的 ResNet-50 提取图像嵌入。其次提取文本特征,通过 BERT 生成文本的语义嵌入。最后提取元数据,对价格等数值型特征进行归一化处理。

实验使用的主要数据集包括以下两类:

1)公开数据集:包含鞋类商品的购买记录、用户评论文本和评分数据,以及商品图像。包含 10 000 个用户,5000 个商品,用户-商品交互记录 50 000 条,图像尺寸:224×224 以及文本数据(商品描述和评论,每条平均长度约为 50 个单词)。

2)自建鞋类电商数据集,来自某本地电商平台的真实交易记录,包含用户购买记录、鞋类商品图像、文本描述及商品分类等。包含 50 000 个用户,20 000 个商品,用户-商品交互记录 200 000 条。商品多模态特征包括:图像数据:分辨率为 256×256;文本数据:商品标题、评论及属性描述。

数据划分采用 80/10/10 的训练、验证和测试比例。即使用时间戳将数据集划分为训练集(80%)、验证集(10%)和测试集(10%),最后采用留一法(Leave-One-Out)生成测试数据^[3]。

3.2 实验评价指标

为全面评估推荐效果,选取以下指标:

1) 准确率指标 Precision@K: 定义为前 K 个推荐商品中, 用户实际感兴趣商品的比例:

$$\text{Precision@K} = \frac{1}{|U|} \sum_{\mu \in U} \frac{|R_{\mu}^K \cap G_{\mu}|}{K}$$

其中 R_{μ}^K 是用户 μ 的前 K 个推荐列表, G_{μ} 是用户实际交互的商品集合。

Recall@K: 衡量推荐结果覆盖真实交互商品的比例:

$$\text{Recall@K} = \frac{1}{|U|} \sum_{\mu \in U} \frac{|R_{\mu}^K \cap G_{\mu}|}{|G_{\mu}|}$$

2) 排序指标 NDCG@K (Normalized Discounted Cumulative Gain): 综合考虑推荐结果的相关性和位置权重:

$$\text{NDCG@K} = \frac{1}{|U|} \sum_{\mu \in U} \frac{\sum_{i=1}^K \frac{2^{\text{rel}(i)} - 1}{\log_2 i + 1}}{\text{IDCG@K}}$$

其中 $\text{rel}(i)$ 是第 i 个推荐商品的相关性分数, IDCG@K 是理想情况下的 DCG 值。

3) 自监督效果指标: 对比学习损失下降曲线, 评估对比学习模块对最终模型性能的贡献。

3.3 对比方法

实验中采用多种方法进行对比, 如传统推荐算法: 基于协同过滤的矩阵分解模型 (Matrix Factorization, MF)、基于内容的推荐方法 (Content-Based Filtering, CBF); 深度学习方法: Neural Collaborative Filtering (NCF)、Graph Neural Network-based 推荐方法 (LightGCN); 多模态推荐模型: 基于多模态特征的图卷积网络推荐模型 (MMGCN)、结合多模态和元路径的图嵌入学习方法 (M2GRL)。本文方法: 包括基本模型 (Baseline) 和增强版本 (Self-Supervised)^[4]。

3.4 实验过程

1) 数据预处理: 首先对图像特征提取, 使用 ResNet-50 提取商品图像嵌入, 维度为 2048。接下来对文本特征提取, 通过 BERT 提取商品描述嵌入, 维度为 768。最后对元数据编码, 为商品属性 (如品牌、价格、类型) 进行 one-hot 编码并通过 MLP 投射到相同维度。

2) 模型训练: 设定学习率, 采用初始学习率 $\eta=0.001$, 并使用 cosine decay 策略动态调整。同时对比学习参数, 正负样本对比比例设为 1:5, 温度系数 $\tau=0.07$ 。最后训练框架, 基于 PyTorch 实现, 采用 Adam 优化器。

3) 超参数调优: 使用验证集进行网格搜索, 调整超参数如 GNN 层数、嵌入维度、对比学习损失权重 λ 等。

4) 测试与评估: 在测试集上对比不同方法的 Precision@K、NDCG@K 等指标。

Top-N 推荐性能:

- 1) 准确率 (Precision@N): 衡量推荐列表中相关物品的比例。
- 2) 召回率 (Recall@N): 衡量相关物品被推荐的覆盖程度。

3) 归一化折损累积增益 (NDCG@N): 考虑物品在推荐列表中的排名权重。

模型训练效率:

- 1) 训练时间: 记录模型从初始化到收敛所需的时间。
- 2) 内存占用: 衡量模型对资源的需求。

3.5 实验结果与可视化

实验结果如表 1 所示。自监督损失下降曲线, 展示训练过程中对比学习损失的下降趋势, 验证其对模型收敛的促进作用。通过对冷启动用户 (交互数量少于 5 条) 的实验, 表明本文方法在 Precision 和 Recall 上相较于其他模型提升显著。

表 1 推荐效果对比

方法	Precision@10	Recall@10	NDCG@10
MF	0.152	0.273	0.182
NCF	0.211	0.342	0.267
LightGCN	0.243	0.371	0.302
MMGCN	0.259	0.392	0.319
本文方法	0.287	0.423	0.351

实验结果表明, 本文提出的基于自监督学习的模型在 Precision、Recall 和 NDCG 指标上均显著优于基线模型^[5]。特别是在处理冷启动用户和稀疏数据问题时, 表现出较强的鲁棒性。可视化结果进一步验证了多模态特征融合与自监督对比学习模块的有效性, 并且多模态数据的对齐与融合有效提升了推荐系统的准确性和泛化能力, 为实际应用提供了理论与实践支持^[6]。

4 结束语

推荐系统作为现代电商的核心驱动力, 在提升用户体验和企业收益方面发挥着关键作用。本文结合自监督学习的特性, 从无标注数据中挖掘潜在模式, 提出了一种高效、鲁棒且具有扩展性的鞋类推荐模型。实验结果验证了本文方法的有效性, 同时也指出了今后研究的方向。随着技术的不断发展, 推荐系统将进一步向高效性、智能化和个性化的方向迈进, 为各类电商场景提供更加全面的解决方案。

参考文献

[1] 王良彬, 丘昌鑫, 李佳. 自监督学习在推荐系统中的应用[J]. 计算机科学与应用, 2023, 45(2): 101-104

[2] 王良彬, 丘昌鑫, 李佳. 智能推荐系统技术综述[J]. 信息技术与信息化, 2021, 37(12): 123-130

[3] 崔杰, 王彬. 基于图神经网络的推荐系统研究[J]. 计算机应用, 2022, 45(8): 2235-2243

[4] 李敏, 刘娜. 基于自监督学习的多模态推荐模型研究[J]. 数据挖掘与知识发现, 2021, 30(5): 87-95

[5] 王建峰, 胡明. 基于协同过滤和矩阵分解的推荐系统研究[J]. 计算机工程与应用, 2021, 57(13): 56-62

[6] 孔德财, 崔杰, 汤怡, 等. 智能推荐系统中的自监督学习研究[J]. 计算机科学与技术, 2023, 61(7): 1754-1760

[收稿日期: 2025-02-21]

(上接第 98 页)

[5] 慈智, 赵会军, 郭鹏, 等. 聚结分离器油水分离效率模拟试验研究[J]. 流体机械, 2015, 43(5): 1-5, 49

[6] 张喜家. 聚结内件对三相分离器分离性能及流场分布影响的研究[D]. 青岛: 中国石油大学, 2016.

[7] 金睿珠. 耦合场下水油乳液液滴微观运动特性研究[D]. 青岛: 青岛科技大学, 2020

[8] 邢雷. 旋流场内离散相油滴聚结机理及分离特性研究[D]. 大庆: 东北石油大学, 2019

[9] 刘森. 亲疏水纤维组合形态对油水分离性能的影响关系研究[D]. 上海: 华东理工大学, 2017

[10] 刘震, 赵会军, 吕孝飞, 等. 波纹聚结板表面粗糙效应数值模拟研究[J]. 石油机械, 2019, 47(5): 101-106

[11] 赵剑锋. 结构参数与操作参数对聚结板油水分离性能的影响研究[D]. 西安: 西安石油大学, 2017

[收稿日期: 2025-02-14]