



现代雷达
Modern Radar
ISSN 1004-7859,CN 32-1353/TN

《现代雷达》网络首发论文

题目： 基于轨迹优化的多模态端到端自动驾驶模型研究
作者： 周亦威，蒋佳凯，陈诗雨，肖嗣伟
网络首发日期： 2026-03-31
引用格式： 周亦威，蒋佳凯，陈诗雨，肖嗣伟. 基于轨迹优化的多模态端到端自动驾驶模型研究[J/OL]. 现代雷达.
<https://link.cnki.net/urlid/32.1353.TN.20260331.1308.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于轨迹优化的多模态端到端自动驾驶模型研究

周亦威^{1,2,3,*}, 蒋佳凯¹, 陈诗雨¹, 肖嗣伟¹

(1.上海理工大学管理学院, 上海 200093; 2.上海理工大学智慧应急管理学院, 上海 200093; 3.上海理工大学智慧城市交通研究院, 上海 200093)

【摘要】近年来端到端自动驾驶技术飞速发展, 成为学术界和工业界的研究热点。端到端自动驾驶将感知、预测和规划整合为一个整体, 以规划为目标, 相较于传统的自动驾驶顺序执行的模块化设计, 能有效地解决累计延误和模块协调的问题。然而, 当前的端到端自动驾驶模型的研究尚未充分利用多模态融合信息, 这使得模型检测能力十分受限, 尤其在复杂的环境中, 存在着许多安全隐患。因此, 本文提出了一种基于轨迹优化的多模态端到端自动驾驶模型, 该模型在端到端自动驾驶 FusionAD 框架的基础上, 对规划模块的“特征交互与轨迹生成—安全优化建模—轨迹优化求解”三级结构提出了改进, 使用了一种基于拟牛顿法改进的 L-BFGS 优化求解算法, 替换了原有的基于牛顿法求解的 IPOPT 方法。本模型基于 nuScenes 数据集评估验证, 并和各类主流算法比较, 结果表明, L-BFGS 的综合性能最好, 碰撞率持平的基础上, 平均位移误差减小了 2%。此外, 本文进一步将模型应用于 nuScenes 的黑夜场景中, 激光雷达的引入使碰撞率降低了 18.5%, 并对比 L-BFGS 和各类主流算法, 结果表明, 模型在黑夜场景下轨迹碰撞率 (CR_traj) 下降了 5.6%。此研究验证了激光雷达在自动驾驶的潜力, 并提升了自动驾驶规划的安全性。

关键词: 端到端自动驾驶; 多模态; L-BFGS; 轨迹优化; 黑夜场景应用

中图分类号: TP18; U461.91 文献标志码: A

Research on Memory-Efficient Optimization-Based Multimodal End-to-End Autonomous Driving Model

ZHOU Yiwei^{1,2,3,*}, JIANG Jiakai¹, CHEN Shiyu¹, XIAO Siwei¹

(1.Business School, University of Shanghai for Science and Technology, Shanghai 200093; 2.School of Intelligent Emergency Management, University of Shanghai for Science and Technology, Shanghai 200093; 3. Smart Urban Mobility Institute, University of Shanghai for Science and Technology, Shanghai 200093)

【Abstract】In recent years, there has been stunning progress in the development of end-to-end autonomous driving technology, which constitutes a major research topic in both academia and industry. End-to-end autonomous driving integrates perception, prediction, and planning into one framework, with planning as the final objective. Compared with the sequential implementation of traditional autonomous driving with a modular design, this approach can effectively reduce the impact of cumulative delay and module coordination problems. However, existing research on end-to-end autonomous driving models does not take full advantage of multi-modal fusion information, thus limiting the detection capability of models in complex environments and bringing many safety risks. This paper discusses a multimodal end-to-end autonomous driving model based on trajectory optimization. It builds upon an already existing FusionAD framework for end-to-end autonomous driving and extends a three-level structure of planning modules for feature interaction and trajectory generation, safety optimization modeling, and trajectory optimization solver, further developing it by an enhanced L-BFGS optimization algorithm based on the quasi-Newton method to replace the original IPOPT methodology based on the Newton method. It is also benchmarked and validated on the nuScenes dataset for various elaborated models, compared with various mainstream algorithms. Results show that L-BFGS showed the best overall performance; it reduces the average displacement error by 2% at comparable collision rates. The model was then applied to the nighttime scenarios in nuScenes, where the integration of LiDAR resulted in an 18.5% reduction in collisions. The trajectory collision rate (CR_traj) in nighttime scenarios is reduced by 5.6%. The research, therefore, proves that incorporation supports LiDAR's significant role in autonomous driving and further ensures the safety of autonomous driving planning.

通讯作者: 周亦威, 上海理工大学管理学院人工智能系副教授。E-mail: zywadam@163.com

基金项目: 国家社科基金后期资助项目 (24FJYB002); 上海汽车工业科技发展基金会课题 (2401)

Keywords: End-to-End Autonomous Driving; Multimodal; L-BFGS; Trajectory Optimization; Nighttime Scenario Application

1 前言

自动驾驶是人工智能领域的重要研究方向之一，在预防交通事故、缓解交通拥堵、提高通行效率、减少排放等方面具有广泛的应用前景^[1]。传统的自动驾驶系统采用模块化设计思路，常用的是复杂的按规则设计的方案，这通常无法有效处理道路上发生的大量情况^[2]。不同模块的优化目标并不相同，比如检测模块追求平均精度，规划模块关注驾驶的安全性与舒适性，整个系统可能无法与统一的目标保持一致^[2]，系统存在协同性不足的问题。此外，模块化形式会造成串行延迟积累，实时反应会变慢，这在车辆高速行驶的场景里会十分危险。为了解决这些问题，业内迫切需要一种新的自动驾驶思路让系统的协同效率变好。也能够提升实时响应能力。

于是，一个可靠且以规划为导向的端到端自动驾驶系统 UniAD^[3]诞生并得到了广泛的关注认可，该模型将全栈的驾驶任务集成在一个网络中，实现了端到端的优化和推理，在自动驾驶的各个任务上都表现出了卓越的性能，引起了业界广泛的关注。相比模块化自动驾驶，端到端自动驾驶将感知、预测和规划的所有环节整合为一个整体，以规划结果为目标，有效地解决了累计延误和模块协调问题。

然而现实中对自动驾驶的严苛要求仍未得到满足，自动驾驶系统的识别准确率、反应速度等各方面还需要进一步加强。因此，许多研究受到了 UniAD 的启发，致力于开发出新的端到端自动驾驶模型，以进一步提升自动驾驶系统的性能。如 VAD^[4]利用矢量化的智能体运动和地图元素作为显式的实例级规划约束，克服了传统的栅格化图像的场景计算量大，且忽略了实例级别的结构信息的缺点，有效提高了规划的安全性和系统运行速度。

我们关注到近期的自动驾驶事故的发生，如小米 su7 事故由于系统未能及时识别到施工路障，导致车辆没有及时减速避障。这意味着自动驾驶系统若单纯依靠摄像头信息，在复杂的驾驶场景（例如黑夜、雾天）中往往不足以准确地识别出障碍物、车辆、行人等物体，

这严重影响后续决策与规划的可靠性，构成巨大的安全隐患。因此使用多模态融合策略（如激光雷达与多视角图像的融合）对于提升自动驾驶的安全性是一种十分有效的方案，已经有大量的研究致力于高效的多模态融合策略，如 TransFusion^[5] 基于注意力机制的特征级融合，深度整合了 Transformer 架构，创新性地将 Transformer 的注意力机制应用于多模态特征融合；BEVFusion^[6] 基于鸟瞰图（BEV）的统一表征融合，提出了在 BEV 空间中进行多模态特征融合的新范式，以卷积神经网络为主，通过优化的 BEV 池化操作和全卷积网络实现特征融合，很好地保留了几何和语义信息；FusionFormer^[7] 完全基于 Transformer，在融合编码模块中引入了可变形注意力和残差结构，避免了传统方法中显式转换到鸟瞰图空间时的信息损失。

上述工作为多模态感知提供了技术基础，但它们主要聚焦于感知层面的特征融合，对融合后的信息如何高效地用于下游规划任务关注较少。近年来，端到端自动驾驶模型逐步将多模态感知与规划模块联合优化，以 FusionAD^[8]为代表，构建了一个基于 Transformer 的多模态融合网络（利用注意力机制融合了激光雷达点云与多视角图像），并建立了名为 FMSPnP 的模式感知预测和状态感知规划模块，其在各项任务指标上都达到了超越 UniAD 的先进水平，这切实符合当下的需求。然而，我们注意到 FusionAD 虽然加入了多模态输入，并创建了新的模块以充分利用融合信息，但其在规划模块中的轨迹优化环节对规划性能的提升效果有待进一步探索。

轨迹优化是自动驾驶规划模块的核心环节之一，它对于初步生成的轨迹再做调整，让行驶轨迹更安全舒适。然而，自动驾驶场景下的轨迹优化问题是一个规模大且高度非线性、非凸的约束调整问题，需要高效实时地求出高质量的车辆轨迹。而优化算法的选择直接影响着求解的效率和准确率。在优化方法的选择上，基于一阶梯度下降的方法（如 Adaptive Moment Estimation, Adam^[9]、Adadelta^[10]）计算效率高、占内存少，但处理高度非线性、多约束的轨迹调整问题时，收敛速度常偏

慢, 计算的结果精度不太够。序列二次规划 (Sequential Quadratic Programming, SQP) 方法虽能有效地处理约束, 还可以借助拟牛顿法近似 Hessian 矩阵减少计算力, 可是局部优化算法对初始值比较敏感, 动态场景里初始轨迹偏得远, 容易让求解失败或结果不好。而内点法 (如 Interior Point OPTimizer, IPOPT^[11]) 通过障碍函数将约束问题转化为一系列无约束问题, 然后使用牛顿法或拟牛顿法求解, 让搜索路径保持在可行域里, 减少了对初始点的依赖, 虽然通常能得到更可靠的解, 但计算 Hessian 矩阵的成本很高, 且问题条件数不好时, Hessian 矩阵可能没法保持正定, 干扰收敛稳定性。相较之下, 有限内存拟牛顿法 L-BFGS^[12] (Limited-memory Broyden-Fletcher-Goldfarb-Shanno) 在轨迹优化任务中展现出更好的整体效果, 它用历史一阶梯度信息近似 Hessian 矩阵的逆, 兼顾二阶信息的快速收敛, 还大大减少了存储成本, 比一阶方法更精准, 比二阶方法更适合大规模问题。且具有不错的数值稳健性, 问题条件数差

2 方法

2.1 模型框架

本文基于多模态自动驾驶模型 FusionAD^[8], 使用了一种名为 L-BFGS 的拟牛顿优化算法改进模型。模型整体框架如图 1 所示。

在 BEV 编码器中, 模型将多视角图像通过一个主干网络进行特征提取, 然后用 FPN 网络生成图像特征; 在激光雷达分支上, 先将激光雷达点云数据体素化, 再用于 SECOND 网络生成 BEV 特征。接着将两个分支的 BEV 特征通过一个基于 Transformer 多模态时间融合框架, 分别通过点云交叉注意力和图像交叉注意力来融合激光雷达特征和图像特征, 再用时间自注意力将得到的特征和前一帧的历史 BEV 特征融合, 经过 6 层融合编码后, 生成最终的融合后的 BEV 特征。感知模块中的检测、跟踪和地图任务, 主要遵循 UniAD^[3] 的设置。预测模块把历史轨迹和当前位置编码成一个带有动态信息和场景上下文的“运动查询”, 通过注意力机制, 从全局锚点里挑出和当前的历史状态以及位置匹配的锚点, 作为初步的轨迹假设。初始化后的运动查询, 通过可变形注意力与统一的 BEV 融合特征进行交互, 之后把它

时仍能维持收敛。尽管存在许多改进的 L-BFGS 变种^[13,14], 但考虑到算法成熟度与代码稳定性, 本文选择使用原版的 L-BFGS 优化算法, 并结合适当的约束处理策略, 以在自动驾驶中实现高效、稳定的轨迹求解。

综上所述, 针对纯视觉模型在夜间等复杂环境下感知能力受限的问题, 以及现有端到端模型 FusionAD 在轨迹优化环节仅采用通用求解器 IPOPT、未充分发挥多模态信息潜力且求解效率与稳定性有待提升的不足。为进一步增强自动驾驶模型在复杂环境下的规划性能, 提升安全性, 本文在 FusionAD 模型的基础上, 提出了使用 L-BFGS 优化算法的多模态端到端自动驾驶模型, 替换了 IPOPT 优化器, 同时为了凸显出多模态输入的重要性以及 L-BFGS 算法在复杂环境的效果, 我们从 nuScenes^[15] 中提取了 99 个黑夜场景数据集, 并对比分析了如 Adam、SLSQP、Adadelta 等主流优化算法的性能, 结果表明本模型相比 FusionAD 在规划性能上有一定的提升, 对于提高车辆安全性和舒适性具有重要意义。

放进模态自注意力模块里让不同驾驶意图进行交互, 预测出一条符合逻辑的行驶轨迹。之后借助精炼网络模块对于生成的轨迹做逐步改进, 缩小位移误差。

规划模块具体如图 2 所示。在原模型中, FusionAD 是由“特征交互与轨迹生成层—安全优化建模层—轨迹优化求解层”组成的三层级联的架构。“特征交互与轨迹生成层”用可学习的命令嵌入来表示导航信号, 将自行车查询和命令组成的规划查询输入进 BEV 特征里, 和经 MLP 处理过的自行车信息融合在一起, 这样就得到对应的状态嵌入, 这个状态嵌入会被解码成未来的路径点。

“安全优化建模层”会把安全约束转换为可优化的数学模型, 包含目标函数的构建和可微分碰撞损失。我们的核心改进在“轨迹优化求解层”, 原模型使用的是 IPOPT 优化器 (基于牛顿法的内点法框架) 来处理刚生成的初始轨迹以实现轨迹优化。这个方法虽然理论上存在收敛优势, 但在自动驾驶的实时规划场景中, 却存在明显的局限。它需要专门构造并求解大规模的 Hessian 矩阵, 计算和存储的成本都很高; 且其作为一种局部优化的方法, 它的收敛性特别依赖初始轨迹的可行性, 在动态车辆密集的场景里, 很容易因为初始点不可行而优化失败。

因此，我们设计了 L-BFGS 算法进行替换，解决了原方法在自动驾驶场景中计算开销大，收敛不稳定的问题。

相较于 IPOPT 求解中使用的牛顿法需要构造并求解 Hessian 矩阵，而 L-BFGS 属于拟牛顿法，只需要维护一段有限长度的历史梯度差分队列，通过双循环递归算法近似 Hessian 矩阵的逆，既能维持超线性收敛性，也能比较明显地降低高维度轨迹优化问题的内存占用与计算开销。根据 nuScenes 数据集涉及的优化问题的变量维度以及 L-BFGS 文献^[12]的推荐，本文设定 L-BFGS 的

记忆窗口大小为固定值 10。这一设计尤其适合 nuScenes 数据集提供的复杂城市市场景里那种大规模、高频率的规划需求。优化的过程中，算法根据当下帧的局部场景信息实时去更新轨迹参数，尽量减少全批量优化带来的延迟积累，满足自动驾驶系统对毫秒级响应时间的要求。此外，它可以和前端特征筛选模块协同工作，专注于关键障碍物相关的梯度分量，一定程度上抑制多模态感知数据融合可能引发的梯度振荡，维持稳定的数值收敛性。




图 1 模型整体框架图

Fig.1. Overall Model Framework Diagram




图2 规划模块框架图

Fig.2. Framework Diagram of the Planning Module

2.2 优化算法

2.2.1 轨迹优化问题建模

在轨迹优化问题中，我们需要最小化目标函数：

$$f: R^n \rightarrow R, \min f(x)$$

其中， x 是优化变量，表示轨迹参数向量； n 是优化变量的维度。

在轨迹优化问题中， $x = [x_0, y_0, x_1, y_1, \dots, x_{T-1}, y_{T-1}]^T$

其中， T 是轨迹长度（规划步数）； (x_t, y_t) 为时刻 t 下轨迹点的二维坐标。显然， $n = 2T$ 。而经过优化后的轨迹点坐标就是要求解的目标。

在自动驾驶规划中存在许多的需求，包括生成平滑的轨迹（与参考轨迹尽可能接近）、避免与障碍物发生碰撞、保持运动连续性等等。在尝试了多种约束组合后，我们发现轨迹跟踪约束、速度平滑性约束和碰撞避免约束的组合产生的规划效果最好。因此，我们定义总损失函数为：

$$L(x) = L_{\text{track}}(x) + \lambda_v L_{\text{velocity}}(x) + \lambda_c L_{\text{collision}}(x) \quad (1)$$

其中， $L_{\text{track}}(x)$ 为跟踪损失，最小化轨迹点与参考点之间的欧氏距离平方和，保证轨迹与参考轨迹尽可能接近；

$L_{\text{velocity}}(x)$ 为速度惩罚，最小化相邻轨迹点之间的位移变化，保证轨迹平滑； $L_{\text{collision}}(x)$ 为碰撞损失，使用高斯函数创建排斥场，距离障碍物越近，排斥力越大，避免与障碍物发生碰撞； λ_v 为速度惩罚权重系数； λ_c 为碰撞惩罚权重系数。具体计算公式如下：

$$\begin{aligned} L_{\text{track}}(x) &= \sum_{t=0}^{T-1} \|x_t - \tau_t\|_2^2 \\ L_{\text{velocity}}(x) &= \sum_{t=1}^{T-1} \|(x_t - x_{t-1})\|_2^2 \\ L_{\text{collision}}(x) &= \sum_{t=0}^{T-1} \sum_{j=1}^{N_t} \phi(\|x_t - o_{t,j}\|_2) \end{aligned} \quad (2)$$

$$\phi(d) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{d^2}{2\sigma^2}\right) \quad (3)$$

其中， $x_t = [x_t, y_t]^T$ ，表示优化轨迹的第 t 个点的坐标； $\tau_t = [\tau_t^x, \tau_t^y]^T$ ，表示参考轨迹的第 t 个点的坐标； $o_{t,j}$ 为时刻 t 的第 j 个障碍物的位置坐标向量； N_t 为时刻 t 的障碍物数量； $\phi(\bullet)$ 为高斯排斥势函数； σ 为高斯函数的标准差，控制排斥力的作用范围。

2.2.2 L-BFGS 应用流程

针对自动驾驶场景对求解实时性与数值稳定性的要求，本文采用有限内存拟牛顿法（L-BFGS）进行轨迹优化。它不直接计算目标函数的 Hessian 矩阵，而是通过有限次历史迭代的梯度差信息，通过双循环递归算法隐式构造一个近似逆 Hessian 矩阵 H_k [12]，维持超线性收敛速度的同时，将内存开销从 $O(n^2)$ 降至 $O(m*n)$ ，恰好匹配自动驾驶规划中轨迹优化的实时性与稳定性需求。

本研究将 L-BFGS 运用于自动驾驶场景轨迹优化的完整流程框架如图 3 所示。具体环节如下：

第一步：输入初始轨迹、障碍物位置数据，初始化 L-BFGS 优化器，设置优化参数。我们初始化学率为 0.1，最大迭代次数 200，线搜索遵循 Wolfe 条件。损失函数权重配置：参考轨迹跟踪损失权重为 1.0；速度平滑惩罚权重为 0.1；碰撞避免损失权重为 8.0。物理参数配置：高斯核标准差为 0.8 米；障碍物过滤范围 5.0 米；轨迹点时间间隔 0.5 秒；规划未来轨迹的时间步数为 6。

我们的参数配置主要遵循了 FusionAD^[8]，主要区别在于引入了速度平滑惩罚权重和高斯核标准差，在控制变量下，将速度平滑惩罚权重从 0.1 增加到 0.2 时，平均碰撞率会从 0.116% 提升到了 0.142%；设为 0.05 时，L2 为 0.706，性能仅提升 0.002，效果不佳。将高斯核标准差从 0.8 降低到 0.7 会导致轨迹碰撞率从 0.349% 提升到 0.417%，增加到 0.9 时轨迹碰撞率提升到了 0.387%，因此分别选择了 0.1 和 0.8。

第二步：优化循环。调用 closure 函数（closure 函数在优化算法中是一个封装了损失计算和梯度计算的函数），梯度清零后进行总损失计算，包括跟踪损失、速

度惩罚和碰撞损失，其中计算碰撞损失时每个时间步都需要检查是否有障碍物，如果没有则跳过该时间步的计算。

第三步：梯度计算与参数更新。先反向传播计算出梯度，再使用 L-BFGS 算法更新参数，使用双循环递归算法进行求解并强 Wolfe 线搜索，再进行收敛条件检查：

包括梯度范数收敛、函数值相对变化和最大迭代次数检查。

第四步：结果返回。如果轨迹优化满足了收敛条件（梯度范数阈值 $1e-5$ ，函数值相对变化阈值 $1e-9$ ，最大迭代次数 200），则返回优化后的轨迹，否则回到第二步继续进行迭代。




图3 L-BFGS 实现轨迹优化流程图

Fig.3. Flowchart of L-BFGS-based Trajectory Optimization

3 实验与分析

3.1 数据准备

本研究采用城市道路下的自动驾驶数据集 nuScenes 对提出的多模态自动驾驶模型进行训练与评估。nuScenes 数据集是由 Motional 团队开发的一个公开大型自动驾驶数据集,收集了波士顿和新加坡的 1000 个驾驶场景,包含了白天、黑夜、雨天等各类场景,拥有 850

个标注场景用于训练, 150 个场景用于验证, 每个场景长达 20s,以 2Hz 的准确 3D 边界框标注了 23 个对象类,包括约 140 万张相机图像、39 万次激光雷达扫描、140 万次雷达扫描和 140 万个物体边界框,均为 4 万关键帧。其提供自动驾驶车辆整个传感器套件的数据 (6 个摄像头、1 个激光雷达、5 个雷达、GPS、IMU)。

由于本研究着重研究端到端自动驾驶模型在黑夜场

景下的性能表现,除了在 nuScenes 的 150 个验证场景上评估了模型的性能,还结合了 nuScenes 数据集的场景特点,利用 nuScenes 提供的场景元数据中的 "night" 标签,从 850 个标注场景中提取所有包含 "night" 关键词的场景,共获得 99 个黑夜场景。这些场景的地理分布为:波士顿 46 个,新加坡 53 个;道路类型覆盖城市主干道、居民区道路和高速公路;交通密度根据场景中动态障碍物的平均数量划分为低密度(<5 个障碍物/帧)、中密度(5-15 个障碍物/帧)和高密度(>15 个障碍物/帧),分别占比约 30%、50%和 20%。该筛选结果能够较全面地代表黑夜环境下的驾驶情况,为模型评估提供了充分的测试基础。

3.2 评价指标

我们对于模型的性能提升主要体现在规划指标,为了对本模型进行客观的评价,使用 nuScenes 规划任务所规定的以下几个指标:

(1) 平均位移误差 (L2): 衡量轨迹的准确性,计算在固定预测时长(8 秒,对应 nuScenes 规划任务的标准设置)内,每个时间步的预测位置与真实位置之间的欧几里得距离,再对所有时间步和所有样本取平均值。公式如下:

$$L2 = \frac{1}{N} \sum_{i=1}^N \frac{1}{T_i} \sum_{t=1}^{T_i} \|P_{pred}^{(i,t)} - P_{gt}^{(i,t)}\|_2 \quad (4)$$

其中, N 是测试样本总数。 T_i 为第 i 个样本的有效轨迹

长度。 $P_{pred}^{(i,t)}$ 为第 i 个样本在时间步 t 的预测位

置。 $P_{gt}^{(i,t)}$ 为第 i 个样本在时间步 t 的真实位置。

(2) 轨迹碰撞率 (CR_traj): 衡量单条完整轨迹的安全性。判定一条预测轨迹是否与场景中任意一个动态交通参与者的预测未来边界框发生碰撞。碰撞判定标准为边界框交并比 (IoU) 大于 0.1,若轨迹对应的自行车边界框与任一障碍物边界框在任一时刻的 $\text{IoU} > 0.1$,则认定该轨迹发生碰撞。公式如下:

$$CR_traj = \frac{1}{N} \sum_{i=1}^N \Pi \left[\bigcup_{t=1}^{T_i} \text{Collision}(B_{pred}^{(i,t)}, B_{env}^{(i,t)}) \right] \quad (5)$$

其中, $\Pi[\cdot]$ 为指示函数,碰撞时为 1,无碰撞为 0。 $B_{pred}^{(i,t)}$

为预测车辆边界框。 $B_{env}^{(i,t)}$ 为障碍物边界框。 $\bigcup$ 表示轨迹中任一时刻发生碰撞即记为碰撞。

(3) 平均碰撞率 (CR_avg): 反映所有轨迹在所有时间步上的平均碰撞频率。该指标统计所有预测轨迹与所有障碍物在所有时间步上发生的碰撞次数,然后除以轨迹总数,最后在所有测试场景上取平均。公式如下:

$$CR_avg = \frac{1}{N} \sum_{i=1}^{T_i} \Pi \left[\text{Collision}(B_{pred}^{(i,t)}, B_{env}^{(i,t)}) \right] \quad (6)$$

3.3 对比实验

我们对比分析多种不同参数配置下的优化结果,选择了最优的配置,配置详见 2.2.2。此外,我们也对比测试了各类优化算法在 nuScenes 验证数据集的优化结果,我们列出了原模型使用的 IPOPT 优化器结果、一些主流且效果较好的算法以及 L-BFGS,如表 1 所示。我们注意到,尽管在轨迹碰撞率 (CR_traj) 和平均碰撞率 (CR_avg) 上, L-BFGS 与 IPOPT 的结果均为 0.116% 和 0.349%,但是对比其它的方法可以发现,在这两项指标上, L-BFGS 和 IPOPT 已经达到了最好。而在平均位移误差 (L2) 上, L-BFGS 比 IPOPT 降低了 0.014m,性能提高了 2%。

我们也注意到各类优化算法收敛后,性能结果上是较为接近的,原因在于我们使用的碰撞规避项是高斯排斥势函数, sigma 为 0.8 较大,高斯函数相对平坦,使得在初始轨迹附近的局部邻域内,目标函数近似为强凸。这解释了各优化算法均能收敛到相近的轨迹,且 L-BFGS 表现出更快收敛速度的原因。需要强调的是,这种局部凸性并不否定轨迹优化问题的全局非凸性,而是通过参数设计使局部求解更加高效。

表 1 不同优化算法在 nuScenes 验证数据集结果

Table 1 Performance of Different Optimization Algorithms on the

nuScenes Validation Set			
方法	CR_avg/%↓	CR_traj/%↓	L2/m↓
IPOPT ^[11]	0.116	0.349	0.708
Adam ^[9]	0.222	0.914	0.615
Adadelta ^[10]	0.122	0.449	0.671
SLSQP	0.116	0.366	0.705
L-BFGS ^[13]	0.116	0.349	0.694

我们也比较了目前主流的一些端到端自动驾驶模

型的规划性能，以验证本模型在碰撞优化部分的改进性能，如

表 2 所示。相较于传统的纯视觉模型 ST-P3、VAD 和 UniAD，本模型有着不俗的性能，平均碰撞率 0.116%，比大多数模型的表现都更好。比多模态输入的 FusionAD，本模型在平均位移误差上降低了 0.116%；和近期新发布的 SOTA 水平的 OmniNAV 相比，尽管在碰撞率上高出了 0.06%，但在平均位移误差上小了 0.676%，性能高出 49%，这体现了本模型融入激光雷达点云，并使用 L-BFGS 轨迹优化的方法对于驾驶安全性的提升是有效的。而相较于 SparseDrive-B 平均碰撞率只有 0.06%，本模型的性能稍弱。其采用的 SparseDrive 是一种基于稀疏场景表示的端到端自动驾驶范式，通过对称稀疏感知模块以稀疏实例表示统一多个任务，信息传输会更高效，语义信息更丰富。在后续的研究中，如能进一步提高摄像头与点云的信息融合以及语义信息的保留，模型性能将得到进一步的提升。

表 2 不同模型在 nuScenes 数据集规划性能对比

Table 2 Planning Performance Comparison of Different Models on the nuScenes Dataset

方法	CR_avg/%↓	CR_traj/%↓	L2/m↓
ST-P3 ^[20]	0.71	-	2.11
VAD ^[4]	0.14	-	0.37

SparseDrive-B ^[18]	0.06	-	0.58
OmniNAV ^[19]	0.11	-	1.37
UniAD ^[3]	0.31	1.46	1.03
FusionAD ^[8]	0.116	0.37	0.81
本模型	0.116	0.349	0.694

3.4 黑夜场景应用

我们分别测试了模型使用 L-BFGS 算法下在 nuScenes 黑夜场景中无激光雷达输入和有激光雷达输入下核心的性能差异，如表 3 所示。我们可以清楚地看到在各项任务指标中，引入激光雷达后的性能提升较多，尤其是在感知能力上，NDS 从 0.628 提升到了 0.804，性能提升 28%；mAP 从 0.619 提升到了 0.836，性能提升 35%，体现了激光雷达在黑夜场景下高水平的感知能力。高效的感知能力对于提升自动驾驶的安全性十分重要，根据表 4 中 Tracking、Mapping、Prediction、Occupancy 和 Planning 各方面性能对比，可以发现由于感知能力的提升，使得各方面的任务性能都有显著的提升效果，AMOTA 提升 3.8%，AMOTP 减小 14.7%，车道线检测率提升 29.5%，ADE 减小 50.6%，FDE 减小 49.2%，最重要的是最终规划结果表明碰撞率下降 18.5%，位移误差减小 33.6%，大大提升了自动驾驶车辆在黑夜场景行驶的安全性。

表 3 有无激光雷达输入的性能对比

Table 3 Performance Comparison With/Without LiDAR Input

	Detection		Tracking		Mapping	Prediction		Occupancy				Planning	
	NDS	mAP	AMOTA ↑	AMOTP ↓	IoU_lanes ↑	ADE ↓	FDE ↓	VPQ-n ↑	VPQ-f+ ↑	IoU-n ↑	IoU-f+ ↑	CR_avg ↓	L2 ↓
纯图像	0.628	0.619	0.673	0.873	0.403	0.891	1.431	50.54	40.15	59.90	48.37	0.189	0.853
图像&点云	0.804	0.836	0.699	0.745	0.522	0.422	0.727	58.27	49.90	63.33	53.38	0.154	0.566

注：NDS(nuScenes Detection Score)：综合检测指标，反映 3D 目标检测的整体质量。mAP(mean Average Precision)：平均精度，衡量检测器在不同召回率下的平均准确率。AMOTA (Average Multi-Object Tracking Accuracy)：平均多目标跟踪准确率，综合考虑跟踪中的身份匹配、漏检和误检。IoU_lanes：车道线检测的交并比。VPQ-n：视频全景分割质量。IoU-n：语义分割交并比，针对类别 n 计算预测分割区域与真实区域的交集与并集之比。规划指标定义详见 3.2。

我们以有无激光雷达输入影响下的一个典型的三岔路口场景识别为例（如图 4 和图 5）。我们注意到，在

无激光雷达的帮助下，NDS=0.628，mAP=0.619，整体的感知能力较为一般，由于环境很暗，即使对向车辆已经打开了照明灯，但由于逆光环境影响了摄像头的感知能力，使得无法第一时间识别到对方的来车（如图 4）。相较于有激光雷达的场景识别，NDS=0.804,mAP=0.836，表现出较好的感知能力，能够很好地处理光线环境问题，第一时间检测到对向车辆，从而及时准确地预测出对向车辆的行驶轨迹（ADE 从 0.891 降低到 0.422，FDE 从 1.431 降低到 0.727，表明预测的轨迹与实际轨迹较为接

近），并调整自车的行驶轨迹（如图 5），有效地降低了碰撞率，CR_avg 从 0.189 降低到 0.154，L2 从 0.853 降低到 0.566，极大地提升了车辆驾驶的安全性。

此外，对比图 4 和图 5，我们也注意到在有激光雷达的帮助下，对于周围障碍物的识别准确率更高，这对于后续的轨迹规划处理有着重要的影响，VPQ-n 从 50.54 提升到了 58.27，IoU-n 从 59.9 提升到了 63.33，良好的占用预测结果提升了避障能力，有助于提升驾驶的安全性和行驶轨迹的规划。




图 4 无激光雷达通过三岔路口的输出图像
Fig.4. Output image when passing through a T-junction without LiDAR




图 5 有激光雷达通过三岔路口的输出图像
Fig.5. Output image when passing through a T-junction with LiDAR

我们也分别测试了在融合激光雷达环境下，原模型使用的 IPOPT 优化器、一些主流且效果较好的算法以及 L-BFGS 在 nuScenes 黑夜数据集效果，如表 6 所示。我们注意到 L-BFGS 在平均碰撞率（CR_avg）和平均位移误差（L2）上均与 IPOPT 持平，为 0.154%和 0.566%。但在轨迹碰撞率（CR_traj）上从 0.463%降低到了 0.437%，性能提升了 5.6%，相较于 SLSQP 算法，同样也达到了一致的性能，说明两种算法都几乎成功地收敛到了最优解。

结合各种算法在 nuScenes 官方验证场景和 nuScenes 黑夜场景两者的表现下，都证明了通过引入 L-BFGS 算法和轨迹跟踪约束、速度平滑性约束和碰撞避免约束的组合，在规划性能上有着稳定的提升。

表 4 不同优化算法在 nuScenes 黑夜场景结果

Table 4 Performance of Different Optimization Algorithms on nuScenes Night Scenes

方法	CR_avg(%)↓	CR_traj(%)↓	L2(m) ↓
IPOPT ^[11]	0.154	0.463	0.566

Adam ^[9]	0.274	1.003	0.514
Adadelta ^[10]	0.154	0.489	0.560
SLSQP	0.154	0.437	0.566
L-BFGS ^[13]	0.154	0.437	0.566

表 5 不同模型在 nuScenes 黑夜场景性能对比

Table 5 Performance Comparison of Different Models in nuScenes

Night Scenes			
方法	CR_avg/%↓	CR_traj/%↓	L2/m↓
VAD ^[4]	0.168	-	0.687
UniAD ^[3]	0.192	0.92	0.863
FusionAD ^[8]	0.154	0.463	0.566
本模型（无激光雷达）	0.189	0.892	0.853
本模型	0.154	0.437	0.566

我们也对比了部分开源的主流端到端自动驾驶模型的规划性能,以体现本模型在黑夜场景中的性能优势,如表 5 所示。相较于纯视觉模型 VAD 和 UniAD,在无激光雷达下,本模型的优势并不突出,但在引入激光雷达后,本模型性能提升非常明显,比 VAD 和 UniAD 碰撞率分别下降了 8.3%和 19.8%,平均位移误差减小了 17.6%和 34.4%。对比同样有激光雷达输入的 FusionAD,本模型轨迹碰撞率降低了 5.6%。由此可见,本模型融入激光雷达点云,并使用 L-BFGS 轨迹优化的方法对于提升黑夜场景下行驶的安全性是有效的。

4 结论与展望

本研究基于轨迹优化,在FusionAD规划模块中引入 L-BFGS算法替代了牛顿法,并分别在nuScenes验证集和自定义的99个黑夜场景中对分析主流算法和模型的性能,并结合一个典型的三岔路口场景的可视化分析,充分说明了激光雷达输入对自动驾驶模型性能提升的重要,以及本模型在黑夜场景下的可靠性和安全性。在 nuScenes数据集中,碰撞率比UniAD和VAD分别降低了 63%和17%,与原模型FusionAD相比,平均位移误差减小了2%。在nuScenes黑夜场景中,碰撞率比VAD和 UniAD分别下降了8.3%和19.8%,与原模型FusionAD相比,轨迹碰撞率降低了5.6%。

未来的研究将聚焦于进一步尝试主流的多视角图像与激光雷达信息的融合策略加入模型中,探索更好的多模态融合方法。同时研究如VAD^[4]的矢量场景表示和

SparseDrive^[18]的稀疏场景表示,以求更加高效的信息传输和语义表达,在各项指标性能提升上实现更大的突破。

参考文献

[1] Yurtsever E, Lambert J, Carballo A, et al. A survey of autonomous driving: Common practices and emerging technologies[J]. IEEE access, 2020, 8: 58443-58469.

[2] Chen L, Wu P, Chitta K, et al. End-to-end autonomous driving: Challenges and frontiers[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(12): 10164-10183.

[3] Hu Y, Yang J, Chen L, et al. Planning-oriented autonomous driving[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 17853-17862.

[4] Jiang B, Chen S, Xu Q, et al. Vad: Vectorized scene representation for efficient autonomous driving[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 8340-8350.

[5] Bai X, Hu Z, Zhu X, et al. Transfusion: Robust lidar-camera fusion for 3d object detection with transformers[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 1090-1099.

[6] Liu Z, Tang H, Amini A, et al. Bevfusion: Multi-task multi-sensor fusion with unified bird's-eye view representation[C]//2023 IEEE international conference on robotics and automation (ICRA). IEEE, 2023: 2774-2781.

[7] Hu C, Zheng H, Li K, et al. FusionFormer: A multi-sensory fusion in bird's-eye-view and temporal consistent transformer for 3D object detection[J]. arXiv preprint arXiv:2309.05257, 2023.

[8] Ye T, Jing W, Hu C, et al. Fusionad: Multi-modality fusion for prediction and planning tasks of autonomous driving[J]. arXiv preprint arXiv:2308.01006, 2023.

[9] Kingma D P, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.

[10] Zeiler M D. Adadelta: an adaptive learning rate method[J]. arXiv preprint arXiv:1212.5701, 2012.

[11] Biegler L T, Zavala V M. Large-scale nonlinear programming using IPOPT: An integrating framework for enterprise-wide dynamic optimization[J]. Computers & Chemical Engineering, 2009, 33(3): 575-582.

- [12] Liu D C, Nocedal J. On the limited memory BFGS method for large scale optimization[J]. Mathematical programming, 1989, 45(1): 503-528.
- [13] Moritz P, Nishihara R, Jordan M. A linearly-convergent stochastic L-BFGS algorithm[C]//Artificial intelligence and statistics. PMLR, 2016: 249-258.
- [14] Chang D, Sun S, Zhang C. An accelerated linearly convergent stochastic L-BFGS algorithm[J]. IEEE transactions on neural networks and learning systems, 2019, 30(11): 3338-3346.
- [15] Caesar H, Bankiti V, Lang A H, et al. nuscenes: A multimodal dataset for autonomous driving[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11621-11631.
- [16] Li Z, Wang W, Li H, et al. Bevformer: learning bird's-eye-view representation from lidar-camera via spatiotemporal transformers[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 47(3): 2020-2036.
- [17] 周亦威, 夏莫, 朱冰. 城市道路场景下考虑多类交通参与者的多模态车辆轨迹预测方法研究[J]. 汽车工程, 2024, 46(3): 396-406.
- Zhou Y W, Xia M, Zhu B. Research on multi-modal vehicle trajectory prediction method considering multiple types of traffic participants in urban road scenarios[J]. Automotive Engineering, 2024, 46(3): 396-406. (in Chinese)
- [18] Sun W, Lin X, Shi Y, et al. Sparsedrive: End-to-end autonomous driving via sparse scene representation[C]//2025 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2025: 8795-8801.
- [19] Jendoubi F, Djaber A, Khemmar R, et al. OmniNAV: Omniscient Navigation via Unified LiDAR-Camera BEV Fusion for End-to-End Autonomous Driving[C]//IEEE IV 2026. 2026.
- [20] Hu S, Chen L, Wu P, et al. St-p3: End-to-end vision-based autonomous driving via spatial-temporal feature learning[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2022: 533-549.
- [21] Chitta K, Prakash A, Jaeger B, et al. Transfuser: Imitation with transformer-based sensor fusion for autonomous driving[J]. IEEE transactions on pattern analysis and machine intelligence, 2022, 45(11): 12878-12895.
- [22] Chen S, Jiang B, Gao H, et al. Vadv2: End-to-end vectorized autonomous driving via probabilistic planning[J]. arXiv preprint arXiv:2402.13243, 2024.
- [23] 周亦威, 劳逸男, 赵靖, 等. 考虑多类型交通参与者的图遍历多模态车辆轨迹预测[J]. 公路交通科技, 2025, 42(3): 1-10.
- Zhou Y W, Lao Y N, Zhao J, et al. Research on graph traversal multi-modal vehicle trajectory prediction considering multiple types of traffic participants[J]. Journal of Highway and Transportation Research and Development, 1-10. (in Chinese)

作者简介

周亦威（1987—）副教授，博士，主要研究方向为人工智能、自动驾驶、空间计量模型及交通行为分析。

蒋佳凯（2000—）硕士研究生，主要研究方向为人工智能、管理科学及交通行为分析。

陈诗雨（2001—）硕士研究生，主要研究方向为城市极端通勤及交通行为分析。

肖嗣伟（2004—）本科在读，主要研究方向为生成式人工智能。