

无线电工程

Radio Engineering

ISSN 1003-3106, CN 13-1097/TN

《无线电工程》网络首发论文

题目: 大模型驱动的人工智能:理论、挑战、应用及展望
作者: 李薇, 乔少杰
收稿日期: 2025-12-25
网络首发日期: 2026-02-12
引用格式: 李薇, 乔少杰. 大模型驱动的人工智能:理论、挑战、应用及展望[J/OL]. 无线电工程. <https://link.cnki.net/urlid/13.1097.TN.20260212.1433.002>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

大模型驱动的人工智能：理论、挑战、应用及展望

李 薇，乔少杰

（成都信息工程大学 软件工程学院，四川 成都 610225）

摘 要：随着数字经济向深度智能化转型，产业对人工智能（AI）的通用能力与跨域适配性要求持续提升。传统 AI 方法依赖专家经验、泛化能力受限，需构建专属模型、落地成本高企，难以满足规模化产业应用需求。针对大模型驱动的 AI 领域，综述其理论基石、核心挑战、行业应用及未来趋势。重点剖析以 Transformer 架构与“预训练+提示+微调”范式为核心的技术基础，探讨缩放定律与涌现能力的内在关联，并对数据、成本与效率、安全与可信和评估体系等核心技术挑战进行深入分析。结合制造业、农业、文旅业的行业赋能实践，对“通用底座+行业知识+轻量化部署”的落地路径进行实证分析，验证其优化生产流程与提升用户体验的有效性。未来将聚焦数据生态、轻量化技术、安全评估等方向，进一步推动大模型技术高效普惠落地，助力产业智能化升级。

关键词：大模型；人工智能；Transformer；行业赋能；轻量化部署

中图分类号：TP311

文献标志码：A

开放科学(资源服务)标识码(OSID)：



Large Model-driven Artificial Intelligence: Theory, Challenges, Applications, and Prospects

LI Wei, QIAO Shaojie

School of Software Engineering, Chengdu University of Information Technology, Chengdu 610225, China

Abstract: As the digital economy transitions to advanced intelligence (AI), the demands from industries for the versatility and cross-domain adaptability of artificial intelligence continue to rise. Traditional AI methods either rely on expert experience with limited generalization capabilities or require building specialized models with high implementation cost, making it difficult to meet the needs of large-scale industrial applications. In the domain of AI driven by large models, the theoretical foundations, core challenges, industry applications, and future trends are reviewed. Focusing on the technical foundations of the Transformer architecture and the “pre-training, prompting, fine-tuning” paradigm, the intrinsic relationship between scaling laws and emergent capabilities are explored, and an in-depth analysis of core technical challenges such as data, cost and efficiency, security and trustworthiness, and evaluation systems are provided. By reviewing industry applications in manufacturing, agriculture, and cultural tourism, the approach of “general foundation, industry knowledge, lightweight deployment” is empirically analyzed, and its effectiveness in optimizing production processes and improving user experience is verified. Future research will focus on directions such as data ecosystems, lightweight technologies, and security evaluation, further promoting the efficient and widespread implementation of large model technologies to support the intelligent upgrading of industries.

Keywords: large model; artificial intelligence; Transformer; industry empowerment; lightweight deployment

收稿日期：2025-12-25

基金项目：国家自然科学基金(62272066, 62572078)；四川省科技计划资助(2025ZNSFSC0044, 2025YFHZ0194, 2025YFRG0013, 2025YFRG0011, 2025YFRG0007)；成都重点研发支撑计划产业链协同创新项目(2025-XT00-00005-GX)；成都重点研发支撑计划基础研究项目(2025-YF12-00019-RC, 2025-YF12-00012-RC, 2025-YF12-00015-RC)；成都市区域科技创新合作项目(2025-YF11-00050-HZ, 2026-YF11-00061-HZ)。

Foundation item: National Natural Science Foundation of China(62272066, 62572078); Sichuan Science and Technology Program (2025ZNSFSC0044, 2025YFHZ0194, 2025YFRG0013, 2025YFRG0011, 2025YFRG0007); Industry Chain Collaborative Innovation Project of Chengdu Key Research and Development Support Program (2025-XT00-00005-GX); Basic Research Project of Chengdu Key Research and Development Program (2025-YF12-00019-RC, 2025-YF12-00012-RC, 2025-YF12-00015-RC); Chengdu Regional Science and Technology Innovation Cooperation Project (2025-YF11-00050-HZ, 2026-YF11-00061-HZ).

在全球数字经济向深度智能化转型的浪潮中，数据要素的战略价值与算力基础设施的迭代升级，正重塑 AI 领域的技术版图^[1]。我国《数据要素×三年行动计划（2024—2026 年）》明确将“数据与算力协同赋能 AI 创新”列为核心任务，而传统 AI 方法或依赖专家经验、泛化能力不足，或需构建专属模型、落地成本高企，难以满足中小微企业规模化应用需求^[2-3]。在此背景下，以 Transformer 架构^[4]为技术底座的大规模预训练模型（大模型），凭借“预训练+提示+微调”新范式实现了通用知识储备与场景化能力适配的高效统一，推动 AI 从“单点任务优化”迈向“全域能力覆盖”^[5-6]，成为衔接数据价值与产业需求的关键枢纽^[7-9]。

同时，多模态融合技术^[10]突破单一模态局限，实现文本、图像、音频、传感器信号的跨域理解与生成；具身智能^[11-12]则打通虚拟技术与物理世界的交互通道，使大模型从“云端推理”走向“实地执行”，二者共同破解传统 AI “重虚拟轻实体”“重单模态轻协同”的瓶颈。

然而，大模型技术的爆发式发展及其产业化落地仍面临一系列严峻的系统性挑战。在数据层面，高质量、多模态训练数据面临“量质双缺”困境，且合规风险突出^[13-15]；在成本层面，训练与推理的资源消耗巨大，对广大中小微企业构成参与壁垒^[16-17]；在安全与可信层面，“黑箱”特性引发的“幻觉生成”、“对抗攻击”与“价值对齐偏差”等问题，在高风险领域形成应用障碍^[18-19]；在评估层面，现有基准测试覆盖有限且易被“过拟合”，垂直领域缺乏统一、可靠的评估标准^[20-21]。这些挑战相互交织，构成了大模型从实验室走向规模化产业应用的核心梗阻。

在此“机遇与挑战并存”的关键发展期，本文旨在构建一个“技术基础-核心挑战-行业应用-未来路径”的完整分析框架，系统梳理大模型的技术演进逻辑与产业赋能机制。首先将剖析其理论基石与核心技术进展；进而针对上述数据、成本、安全、评估四大挑战进行深入剖析；然后，结合制造业、农业、文旅业的实证分析，验证大模型的赋能路径与价值；最后，基于技术趋势与产业需求，提出具有前瞻性的未来发展路径。本文旨在为学术界厘清研究脉络，为工业界规划技术路线提供参考，并最终推动大模型技术向“高效、普惠、安全、可

控”的方向演进。

1 大模型的理论基石与核心技术进展

大模型的快速发展并非偶然，而是建立在架构创新、规模效应、标准化训练范式及跨学科理论融合的多重技术突破之上。这些理论与技术共同构成了大模型从“概念设想”走向“产业落地”的核心支撑，不仅解决了传统 AI 在泛化能力、任务适配效率上的瓶颈，更推动了 AI 技术从“特定场景优化”向“通用能力具备”的关键跨越。

1.1 核心架构演进

2017 年，Vaswani 等^[22]提出的 Transformer 架构，是大模型技术革命的起点，其核心创新在于自注意力机制，该机制能够直接捕捉序列数据中任意 2 个元素的依赖关系，从根本上解决了传统循环神经网络（Recurrent Neural Network, RNN）存在的“梯度消失”与“长距离依赖建模难”的问题。例如，在处理长文档时，RNN 难以有效捕捉首尾语义关联，而 Transformer 通过全局依赖计算可实现一次性精准建模^[23-25]。Transformer 的卓越性能得益于其精心设计的架构，如图 1 所示。




图 1 Transformer 核心架构示意

Fig.1 Core architecture of Transformer

该架构清晰展示了输入层-编码器-解码器-输出层的完整信号传递链路。输入层负责将文本转化为向量并表示其位置信息；编码器通过多头自注意力层与前馈神经网络，实现双向的深度语义理解；解码器则通过掩码注意力确保自回归生成的准确性，并利用编码器-解码器注意力实现与输入内

容的精准对齐。该架构的并行化特性，为模型参数的指数级增长提供了硬件基础，使得训练千亿级参数模型成为可能^[26-27]。

基于此基础，衍生出两大主流架构分支并持续迭代：其一是以 GPT 系列为代表的解码器架构^[28]，从 GPT-3 的 1 750 亿参数到 GPT-4 的多模态扩展，通过优化自回归生成逻辑与注意力分配策略，在对话生成、代码创作等任务中表现卓越^[29]；其二是以 BERT 系列为代表的编码器架构^[30]，从基础 BERT 到 RoBERTa、ALBERT 的轻量化优化，双向注意力机制在文本分类^[31]、情感分析^[32]、命名实体识别^[33]等理解型任务中效果显著，朱冰林等^[34]研究验证了其在复杂句子分类任务上优于传统模型。这 2 类架构共同构建了大模型在“生成”与“理解”两大核心能力上的坚实底座。

此外，面向多模态任务的 Transformer 变体^[35]持续迭代，形成统一模态表征+跨模态注意力的核心架构。例如 CLIP^[36]通过对比学习实现文本与图像的语义对齐，FLAVA^[37]构建单模态编码器-跨模态融合器-任务解码器的通用框架，可同时处理文本、图像、音频、视频等多类数据；具身智能领域^[38]则衍生出“Transformer+机器人学”的混合架构，如 PaLM-E 将语言模型与视觉-运动模型融合，实现机器人对物理环境的精准感知与执行，为多模态与具身智能的协同奠定架构基础。

1.2 缩放定律与涌现能力

OpenAI 提出的缩放定律^[39-40]系统揭示了模型性能与规模维度（参数规模、训练数据量、计算资源投入）之间的幂律关联。该定律的核心论断为：当参数、数据与计算量三者实现协同扩张时，模型性能将呈现可量化的规律性提升。例如，当模型参数规模从 10 亿级扩展至 100 亿级时，其在通用语言理解基准上的综合得分可实现 7~11 个百分点的稳定提升。

与缩放定律相伴的突破性现象是大模型涌现能力，其核心包含认知涌现与思考涌现双重维度^[41]。认知涌现体现为模型突破基础模式匹配，具备复杂逻辑推理、多步数学运算、跨领域知识迁移等高阶认知能力；思考涌现则是更高级的智能表现，是指模型能够模拟人类的迭代式思考过程，通过生成中间推理链、自我质疑逻辑漏洞、动态修正结论，实现从“直接输出结果”到“可追溯思考路径”的跨越，例如在数学证明、科学问题求解中，模型可逐步拆解问题、验证每一步推导的合理性，而非仅

给出最终答案。

从科学原理来看，涌现能力的产生是大模型内在技术机制协同作用的结果：

① 参数规模临界效应：当模型参数规模突破特定临界阈值时，参数间形成高密度的关联网络，能够捕捉数据中更隐蔽、更复杂的语义模式与逻辑关联，为高阶能力的涌现提供结构基础；

② 层级化信息处理机制：Transformer 架构的编码器-解码器层级结构，配合多头自注意力的不同语义粒度捕捉能力，实现了从基础特征到高阶语义的分层抽象，当层级信息整合达到一定复杂度时，便会催生超越单一层级功能的综合能力；

③ 自监督训练的知识积累效应：预训练阶段通过海量数据的自监督学习，模型积累了海量隐式知识与关联规则，当这些知识量达到临界水平，且通过注意力机制实现高效调用时，便会自发形成复杂的问题解决能力。

这一关联标志着大模型实现了从“性能量变积累”到“能力质变跃升”的关键跨越，同时构成了大模型与传统 AI 方法的核心差异化特征。

1.3 标准化范式

当前大模型落地普遍遵循“预训练+提示+微调”的标准化范式（三阶训练范式）。该范式通过模块化的技术流程，系统性地实现了通用能力的构建与高效迁移，大幅降低了技术应用门槛，为核心论点“一次预训练，多场景复用”提供了可行的工程路径。核心流程与技术逻辑如图 2 所示。




图 2 三阶训练范式流程

Fig.2 Three-stage training paradigm flowchart

预训练阶段^[42]：模型在海量无标注及跨模态数据上进行自监督学习，核心目标是构建覆盖语言语法、世界知识与基础推理的“通用知识底座”。训练数据通常涵盖网页、书籍、学术论文与开源代码等多元来源，同时拓展至图像、工业传感器信号、农业光谱数据、文旅音视频等多模态资源，通过“模

态对齐预训练+跨模态掩码任务”（如“图像-文本配对预测”“传感器信号-故障描述对齐”），使模型掌握异构数据的语义关联能力，构建多模态通用知识底座。通过“下一个词预测”等任务，使模型无需人工标注即可掌握跨领域的通用能力，为后续阶段奠定能力基础^[43]。

提示阶段^[44]：在预训练模型参数固定的前提下，通过自然语言指令（提示工程）直接引导模型完成特定任务，其核心技术机制为上下文学习。该阶段实现了零参数更新下的任务适配，尤其适用于数据稀缺或需求快速迭代的轻量化场景，有效降低了初步应用的试错与部署成本。

微调阶段^[45]：为应对医疗、金融等垂直领域对精度与可靠性的高要求，需利用高质量的领域标注数据对预训练模型进行参数调整，实现从通用到领域专用的深度适配。该阶段技术从结果对齐向过程优化不断深化，主要包括 3 类关键技术：

① 指令微调^[46]：通过“指令 - 响应”配对数据训练，显著提升模型对复杂意图的理解与遵循能力。例如，ChatDoctor 模型^[47]通过指令微调，有效缓解了通用大模型在中文医学问答中的知识错配问题；

② RLHF^[48]：构建“人类评价→奖励模型训练→策略优化”的闭环，使模型的输出风格、价值观

与决策依据更符合人类专家的期望与安全规范，如在金融分析中确保输出结果具备明确的风险提示与数据支撑^[49]。

③ 基于强化学习的深度思考训练^[50]：通过强化学习框架引导模型生成并优化其思考链（如思维树、自我质疑链），其关键在于构建过程奖励机制，对推理步骤的逻辑连贯性、事实一致性和可验证性进行激励，推动大模型实现从生成匹配到思维塑形的范式跨越。例如，GPT-5 通过在其“混合专家”架构中集成过程奖励验证器，对思考链进行逐步优化，在复杂推理任务中显著降低了事实错误率。

该三阶训练范式清晰地勾勒出一条从通用能力构建到场景化能力激活再到专业化能力强化的标准化技术路径。不仅使企业得以基于现有基座模型快速适配业务，大幅缩短了从实验室技术到产业落地的周期，也为下文深入探讨其在制造业、农业等具体行业中的轻量化部署与知识注入应用实践，奠定了统一的方法论基础。

1.4 关键训练技术

训练万亿级参数的大模型，需要克服单设备显存不足、训练效率低、集群稳定性差等一系列工程挑战^[51]。这依赖于分布式训练、内存优化与计算优化等关键技术的支撑。各类技术的原理、特点与适用场景对比见下表。

表 1 关键训练技术的对比

Tab.1 Comparison of key training techniques

技术类别	核心技术	技术原理与特点	典型适用场景
分布式并行策略 ^[52]	数据并行 ^[53]	同一模型副本多设备运行，计算后同步梯度；实现简单，通信开销随模型增大	模型参数量适中，数据量大的场景
	张量并行 ^[54]	拆分模型参数至多设备，各设备负责部分计算；支持超大模型，对设备通信带宽要求高	单设备无法容纳的万亿级参数模型
	流水线并行 ^[55]	按模型层切分至多设备，形成处理流水线；提升吞吐量，存在“流水线气泡”	模型层数极深，需提升训练效率的场景
内存优化	ZeRO ^[56]	优化器状态、梯度、参数在多设备分片存储，消除冗余；显著降低单设备内存占用	超大规模模型，尤其优化器状态占用高的场景
	梯度检查点 ^[57]	仅存储部分层输出，需时重算中间结果；以约 25%额外计算换 30%-70%显存节省	模型层数深、激活值显存占主导的场景
计算优化	混合精度训练 ^[58]	FP16/BF16 用于计算，FP32 维护主权重；提升速度约 2-3 倍，节省约 50%显存	各类规模模型，尤其显存受限场景

在实际应用中，这些技术常被融合为“混合并行策略”。例如，在训练盘古气象大模型时，采用了“ZeRO-3+张量并行+流水线并行+混合精度训练”

的方案：ZeRO-3 分片存储优化器状态降内存压力，张量并行拆分参数跨设备计算，流水线并行切分模型层提升吞吐量，混合精度训练优化效率^[59-61]；

PipeOffload 等方案^[62]的实践进一步证明, 此类混合策略能够支撑万亿参数模型在中等规模的 GPU 集群上成功训练。

1.5 跨学科理论融合

大模型的理论发展并非局限于计算机领域, 而是与物理学、生物学、语言学等学科深度融合, 为模型机理理解、架构优化提供了新视角。

1.5.1 物理学视角

复杂系统理论: 将大模型视为“数百亿参数相互作用的复杂系统”, 参数为“个体”, 权重关联为“个体交互”, 训练为“数据驱动的系统演化”。当规模(参数、数据)超“临界点”时, 系统发生“物理相变”, 参数关联形成全局协同模式, 催生涌现能力(如复杂推理)^[63]。基于此, 研究者提出动态参数调整策略: 实时监测推理准确率变化梯度, 当变化率加快(接近“涌现临界区”)时, 自适应降低学习率, 避免参数震荡, 该策略可提升千亿参数模型收敛速度, 且提前涌现能力的激活临界点^[64-66]。

能量最小化原理: 训练中的梯度下降, 可类比系统在损失函数“能量景观”中找最低能态(全局最优解), 损失函数值为“系统能量”, 参数更新方向为“能量下降方向”^[67]。该类比启发“损失盆地平坦性”研究: 平坦性通过 Hessian 矩阵特征分布量化, 平坦区域梯度变化平缓、参数抗扰动强, 且收敛于此的模型泛化能力更强(跨领域微调性能衰减少、持续学习中少遗忘旧任务)^[68-70]。通过动量优化器+学习率余弦退火策略, 可引导模型向平坦盆地收敛, 显著提升跨领域任务性能稳定性^[71]。

1.5.2 生物学视角

生物大脑高效能与强鲁棒性特性, 为架构创新提供范本:

混合专家模型(Mixture of Experts, MoE)^[72-73]: 借鉴大脑“稀疏激活机制”(如语言任务激活布洛卡区), 通过“路由器模块”分类输入数据, 仅激活部分“专家子网络”(参数子集), 实现“万亿级总参数+低推理计算量”平衡。例如 Google PaLM-E^[74]凭 MoE 架构, 总参 5400 亿却仅需 500 亿参数稠密模型的计算量, 完成“文本-图像-机器人控制”多任务。

具身智能^[75]: 架构设计深度借鉴生物大脑的“感知-决策-执行”闭环机制, 模仿人类视觉-运动协调系统, 构建“多模态感知模块-大模型推理模块-机器人执行模块”的协同链路; 同时借鉴大脑的环

境自适应能力, 引入“动态环境建模+实时反馈调整”机制, 使机器人在复杂工业场景、田间环境中具备自主避障与任务优化能力。

层级化注意力 Transformer^[76-78]: 借鉴大脑皮层低级脑区提局部特征、高级脑区做复杂决策的流程, 模型底层用“局部窗口注意力”(关注局部 token 范围)捕语法、短程语义, 顶层用“全局注意力”(关注全文档 token)整合长程逻辑、文档级语义。该架构在“文档摘要+观点提取”等复杂任务中, 准确率较传统 Transformer 显著提升, 例如文心一言用其处理中文长文档, 多观点冲突识别准确率突出; Deny 等^[79]也证实层级化 Transformer 在脑机接口运动想象信号解码中, 准确率优于传统模型。

1.5.3 语言学视角

计算语言学指导大模型适配不同语种, 解决“语义碎片化、理解偏差”问题^[80-81]:

中文适配: 中文语义依赖上下文、字符组合灵活(如打, 可组打电话/打酱油/打毛衣)^[82]。Huo 等^[83]研究表明, 大模型需精准捕捉上下文关联与多义字符语境差异, 才能在中文文本简化中“保原意、降难度”(如通过优化提示识别“打”的语义指向);

小语种适配: 藏语、塞尔维亚语等存在“词根+词缀”复杂形态变化(如藏语词根加词缀表时态、语态)^[84]。若直接用英语优化的字节对编码(Byte Pair Encoding, BPE)分词器, 易割裂“词根-词缀”语义关联, 导致子词碎片化。Parra 等^[85]研究发现, 合成语(形态丰富语种)本可通过 BPE 形成规律子词, 但生硬套用英语分词配置会破坏语义关联, 需通过定制化 BPE 分词规则、形态学感知分词等方案优化, 显著提升小语种模型的命名实体识别性能。

综上, 物理学提供了系统级行为的理解框架, 生物学启发了高效能的架构设计, 语言学则注入了语言适配的先验知识, 三者共同推动大模型向更智能、更高效、更贴合人类需求演进。

2 当前面临的核心技术挑战

大模型从实验室研究走向产业化规模落地, 必须克服一系列源于其技术本质与产业要求的系统性挑战。这些挑战贯穿于模型研发、训练、部署与验证的全生命周期, 并形成了基础资源制约(数据)-落地成本梗阻(效率)-应用风险壁垒(安全)-衡量标准缺失(评估)的连锁反应, 严重制约了其技术红利的释放, 本节将深入剖析这四大核心挑战。

2.1 数据挑战

数据作为大模型的“燃料”，其供给质量与合规性直接决定模型性能上限。当前面临量质双缺、模态失衡、合规风险突出的三重困境，且各问题相互交织形成制约闭环，如图 3 所示。




图 3 数据的三重困境闭环

Fig.3 Triple dilemma loop of data

量质双缺：高质量、无偏见、多领域的训练数据存在显著缺口。从规模上看，互联网上可用于训练的优质无重复文本数据消耗速度加快，中文等非英文语料的相对规模远小于英文，且优质开源资源占比极低^[86]；从质量上看，网络数据中充斥着重复、低质、带有偏见的内容，单纯扩大数据规模的边际效益持续递减^[87]。核心根源在于：一是高质量标注数据的人工成本极高（单条专业领域数据标注成本可达数百元），且跨领域标注专家稀缺；二是中文等非英文语料缺乏统一的高质量开源库，部分方言、专业领域文本（如古籍文献、行业标准）采集难度大，导致模型在特定场景下的语义理解精度不足。

跨模态对齐：视觉、语言、音频等跨模态数据的精准对齐成为技术难点。构建跨模态训练集需解决异构模态间复杂的语义关联问题，例如将“猫在追球”的图像与文本描述对齐时，不仅要识别物体实体，还需捕捉动态关系、空间上下文与情感倾向。当前技术瓶颈在于跨模态语义表征的统一框架尚未成熟，不同模态的数据分布差异大，导致对齐后的训练数据存在语义偏差，直接制约多模态大模型的生成与理解能力^[88]。

此外，多模态数据还面临采集难度大、标注成本高、模态异质性强的额外困境：工业场景的图像+振动音频+温度传感器数据需专业设备同步采集，农业多模态样本（作物图像+土壤光谱+气象数据）的标注需跨领域专家协作，导致高质量多模态训练数据缺口显著；同时，多模态内容的版权归属更复

杂（如图像-文本配对内容的双重版权），进一步加剧合规风险。

合规风险：生成式 AI 大规模使用受版权保护的文本、图像、代码数据，已引发多起全球范围内的法律诉讼^[89]。核心争议在于现行著作权法的“合理使用”原则能否覆盖海量版权作品的非授权复制与商业利用，而中文语料还额外面临来源合规性、标注准确性的双重挑战。此外，训练数据中可能隐含的个人敏感信息、地域偏见，不仅会引发隐私泄露风险，还会导致模型输出带有歧视性的内容，加剧伦理争议。

数据层面的量质短板与合规约束，不仅直接限制模型性能提升，还迫使研发者投入更多算力进行数据清洗、去重、跨模态对齐，进一步推高了模型训练与推理的资源消耗，形成数据-成本”的连锁挑战。

2.2 成本与效率挑战

大模型的训练与推理过程消耗巨额计算和能源资源，高昂的成本与有限的效率构成规模化部署的主要障碍，尤其对中小微企业形成显著参与壁垒。

训练成本高企：模型参数从 10 亿级扩展至千亿级时，训练成本呈指数级增长，千亿参数级别模型的单次训练成本通常达数百万美元量级，万亿参数模型成本更是突破千万美元^[90-91]。以 GPT-3(1750 亿参数)为例，其训练消耗约 45 TB 文本数据，基于大规模 V100GPU 集群完成，估算训练成本约 1 200 万美元^[92]。同时，训练过程伴随显著碳排放，一次完整的千亿参数模型训练产生的二氧化碳排放量可达数百吨，引发环境影响担忧^[93]。核心根源在于模型参数规模呈指数级增长，而传统全注意力机制的计算复杂度为平方级，即使通过稀疏注意力等算法优化降低部分算力消耗，整体资源需求仍远超中小机构的承受范围。

推理效率不足：大模型的单次查询成本显著高于传统 AI 服务，主流大模型 API 的调用成本比基于规则或轻量级机器学习模型的服务高出 1~2 个数量级^[94]。这一问题的核心在于自注意力机制的计算开销与长序列处理需求的矛盾：处理包含数千 token 的长文本时，模型需消耗大量算力进行全局依赖建模，导致响应延迟较高，难以适配实时交互、大规模用户访问等场景。多模态模型与具身智能的部署进一步放大了效率痛点：多模态数据的实时处理需更高算力支持，具身机器人的边缘端部署对模型轻量化要求更苛刻，例如工业具身机器人需在毫秒级

响应图像缺陷检测结果并执行维修动作，现有模型的推理延迟难以满足需求。

效率 - 性能权衡：为缓解成本与效率问题，模型压缩、量化、知识蒸馏等技术被广泛探索^[95-96]，但这些技术本质上是在效率与性能之间进行权衡。例如，将参数精度从 FP32 降至 INT8 可提升推理速度，但会损失部分模型表达能力，导致复杂任务（如金融风险分析、医疗诊断）的性能下降；知识蒸馏虽能缩小模型规模，但蒸馏过程中会丢失部分高阶知识，影响模型的泛化能力^[97]。即便前文提及的混合并行策略（如 ZeRO-3+张量并行）可降低 50% 以上的内存占用，仍难以平衡超大规模模型的性能与普惠性需求。

高昂的资源消耗导致中小微企业缺乏足够的研发与测试投入，难以对模型进行充分的安全验证，而大模型“黑箱”特性与训练数据的复杂性，进一步放大了安全与可信层面的潜在风险。

2.3 安全与可信挑战

大模型在安全与可信层面的根本性缺陷，源于其技术架构特性与训练数据的复杂性，主要体现在幻觉、对抗性攻击、价值对齐三大维度，构成高风险领域应用的关键障碍。

幻觉^[98]：模型倾向于生成内容连贯、语法正确但与事实不符的虚构信息。其核心技术根源在于 Transformer 架构的“黑箱”特性与自回归生成机制：模型训练的核心目标是优化文本生成的连贯性，而非事实准确性，且预训练数据中的噪声（如错误信息、矛盾表述）会被模型学习并放大。同时，前文提及的三阶训练范式中，微调数据量有限，难以覆盖所有专业领域的事实细节，导致模型在陌生场景下易“编造”信息。这种隐蔽性危害在医疗诊断、法律咨询、新闻事实核查等高风险领域尤为突出，可能引发严重的决策失误与法律责任。

对抗性攻击^[99]：大模型对精心构造的输入扰动高度敏感，攻击者可通过“提示注入”等技术诱导模型突破预设安全边界。例如，通过特定话术诱导模型输出训练数据中的敏感个人信息、执行不当指令，或生成具有偏见、攻击性的内容。技术根源在于模型对输入文本的语义理解缺乏鲁棒性，且注意力机制易被特定关键词、句式引导，导致安全防护机制失效。这种脆弱性对模型部署的隐私保护与内容安全构成持续威胁，尤其在公共服务、网络安全等场景中风险突出。

价值对齐^[100]：模型的世界观、目标与行为难以

与复杂多元的人类价值观有效匹配。核心根源在于预训练数据中隐含的社会偏见（如性别、地域、职业歧视）会被模型继承并放大，且现有对齐技术（如 RLHF、指令微调）存在局限性：RLHF 依赖人类评价的主观性，指令微调的覆盖场景有限，难以应对所有伦理边界问题。例如，模型可能在招聘相关的文本生成中表现出性别歧视倾向，或在公共议题讨论中输出不符合公序良俗的内容，引发社会争议。如何定义、衡量并实现稳健的价值对齐，仍是该领域悬而未决的根本性难题。

安全与可信问题的凸显，对模型评估提出了更高要求，但现有评估体系在覆盖范围、标准统一性、动态适配性上的不足，导致模型真实能力与风险难以量化，反过来制约了高风险场景的应用落地。

2.4 评估体系挑战

构建科学、全面、可靠的大模型评估体系是当前的核心难题，现有方法在评估框架、垂直领域标准、属性衡量、数据质量 4 个层面存在系统性局限，难以准确衡量模型的真实能力与潜在风险。

通用基准局限^[101]：尽管 MMLU、C-Eval 等通用基准被广泛采用，但其涵盖的知识领域与任务类型仍显有限，难以全面评估模型的综合能力。更关键的是，静态基准易引发指标过拟合，模型通过针对性优化基准得分提升性能，而真实泛化能力并未同步改善。根源在于基准数据的更新速度滞后于模型迭代（现有基准多基于 3 年前的知识），且未充分考虑真实场景中的复杂变量（如噪声输入、多任务交织），导致评估结果与实际应用效果存在偏差。

垂直领域标准^[102]：医疗、金融、法律等高风险垂直领域，缺乏统一的评估框架与权威数据集。不同机构采用的评估指标与方法各异，例如医疗大模型评估中，部分机构采用病历问答准确率，部分采用诊断符合率，且缺乏中文权威标注病历数据集（如美国 MIMIC-III 的中文替代版本），导致不同模型的性能无法横向对比与可信认证。这种标准化缺失严重制约了大模型在关键领域的落地应用，增加了产业规模化推广的难度。

属性评估困境^[103-105]：安全性、鲁棒性、公平性等核心属性缺乏可量化的统一标准。这些属性涉及多维度价值判断，难以通过单一指标衡量，例如公平性评估存在群体公平、个体公平等不同理论框架，导致评估结果缺乏可比性；安全性评估需覆盖幻觉、对抗攻击等多种风险，现有指标难以全面捕捉。此外，评估数据可能包含固有社会偏见，或存

在被纳入训练数据的“污染风险”，进一步影响评估结果的可靠性。

动态评估缺失^[106]：现有评估多为静态基准测试，难以适应模型“持续学习”的特性。当模型通过增量训练更新知识后，缺乏动态评估框架衡量其知识更新效果与旧知识遗忘程度。这一缺陷在需要实时迭代的金融、科技、政务领域尤为突出，可能导致模型在知识过时后仍被持续使用，引发决策风险。

3 创新应用与行业赋能

大模型的产业核心价值是通用技术底座适配垂直场景，其赋能逻辑非替代传统技术，而是通过“大模型+传统 AI+行业知识”融合，破解产业数据、算力与效率瓶颈。本节先阐释融合基础，再以制造业、农业、文旅业实践展现赋能价值，最后提炼行业赋能的共性规律与差异化启示。

3.1 技术融合基础

大模型的通用语义理解、跨模态处理能力，与传统 AI 技术的领域特异性、精准感知优势形成互补，通过标准化融合范式，为行业落地奠定技术基础。

与知识图谱融合^[107]：核心逻辑是将大模型的生成能力与知识图谱的结构化知识相结合，解决“幻觉”问题与决策可解释性不足的痛点。

① 关键技术路径：检索增强生成（Retrieval-Augmented Generation, RAG），在模型生成前从知识图谱中检索相关事实作为依据；将知识图谱中的实体关系作为推理规则注入模型，约束生成逻辑。

② 核心价值：使模型输出有明确知识支撑，例如在工业故障诊断中，大模型结合设备知识图谱生成故障原因时，可精准关联部件 - 故障 - 解决方案的结构化关系，提升诊断准确率。

与计算机视觉融合^[108]：依托视觉 - 语言基础模型（CLIP、SAM）实现像素信息与语义信息的对齐，构建感知 - 推理 - 生成的完整链路。

① 技术协同逻辑：视觉模型作为感知编码器，将图像转化为大模型可理解的视觉词元（如图像特征编码、分割掩码）；大语言模型作为核心推理机，完成语义理解与内容生成。

② 典型应用：工业缺陷检测（图像识别+文本诊断报告生成）、农业作物长势监测（图像分析+

产量预测）、文旅场景虚拟导览（图像还原+历史知识解说）。

与推荐系统融合^[109]：利用大模型深度理解长文本信息的能力，推动推荐系统从协同过滤隐式匹配向语义理解显性推荐演进。

① 融合路径：大模型作为序列建模器捕捉用户动态兴趣，或作为特征增强器生成物品丰富语义描述，甚至直接作为生成式推荐器输出个性化推荐列表与解释。

② 价值体现：在制造业供应链推荐中，可理解原材料特性 - 生产工艺 - 产品需求的语义关联，实现精准物料匹配；在文旅推荐中，基于用户偏好文本生成定制化行程。

与具身智能融合^[110]：核心逻辑是将大模型的多模态理解与推理能力，与机器人的感知、执行硬件结合，构建感知 - 推理 - 执行的物理交互闭环。

① 技术协同逻辑：多模态模型作为环境理解与决策中枢，处理机器人采集的图像、音频、触觉等多源数据；具身硬件作为“执行载体”，将大模型生成的方案转化为物理动作，同时通过传感器实时反馈执行效果，反向优化模型决策。

② 典型应用：工业机器人故障维修、农业无人自主作业、文旅导览机器人互动服务。

3.2 行业落地实践

3.2.1 制造业

核心痛点：中小厂商算力不足、工艺参数调试复杂、生产全流程协同效率低^[111]，技术方案如下：

① 多模态大模型框架^[112]：基于 Transformer 架构实现工业图像、传感器信号与生产记录的跨模态语义对齐，采用动态语义令牌化+两阶段训练轻量化策略，在 MS COCO 1k 测试集的文本检索准确率达 95.0%，VQA 2.0 测试集准确率提升至 73.32%，高效解决多源数据融合理解难题。

② 行业专用大模型：注入工业机理模型与专家算法库，适配工艺优化、排产调度等场景。例如卡奥斯 COSMO-GPT^[113]内置 3900+机理模型，采用 LoRA 微调降低部署门槛，使注塑生产调试效率提升 50%、能耗降低 30%，工艺链梳理耗时缩短 40 天；羚羊工业大模型^[114]通过标准化 SaaS 工具包，实现“研产供销服”全流程数字化赋能，推动销售预测准确率提升 30%、排产效率提升 50%，中小企业库存管理效率提升 20%。

③ 轻量化缺陷检测模型：针对实时检测需求优化架构，例如 GDM-YOLO^[115]基于 YOLOv8s，

采用 SPDG 下采样、重参数化等技术,在 NEU-DET 数据集上缺陷检测 mAP@0.5 达 79.3%(较 YOLOv8s 提升 3%),同时参数减少 2.1 M、计算量微降 0.3 GFLOPs,满足工业场景实时检测需求。

④ 具身智能巡检机器人:融合多模态大模型与工业机器人硬件,通过视觉识别零件缺陷、听觉捕捉设备异响、触觉检测装配精度,实现多模态数据采集-故障推理-自主维修全流程自动化。例如李玉峰等^[116]提出的民航机场具身智能巡检机器人,与传统人工巡检方法相比,系统检测效率提高了约 60%,精度提升了 32%。

场景启示:制造业赋能需以“多模态数据融合+行业机理注入+轻量化部署”为核心,既要依托前文提及的混合并行策略降低训练门槛,也要通过 LoRA 等微调技术适配中小厂商算力现状。

3.2.2 农业

核心痛点:数据稀缺、场景分散、自动化水平低,传统 AI 难以适配复杂田间环境^[117]。技术方案如下:

① 小样本知识提取模型^[118]:基于 BERT+CASREL 架构,融合 GHM 损失函数缓解数据不平衡,仅用 5 200 条烟草病虫害领域标注样本完成微调,实现精确率 93.32%、召回率 92.51%、F1-score 92.91%的结构化知识提取,为精准防治决策提供支撑。

② 云边协同边缘 AI 框架^[119]:结合 Kubernetes+ZeroTier VPN 架构、AI 容器化部署技术与多模态传感器(图像、光谱、湿度传感器),将多模态数据预处理与推理任务下沉至边缘端,搭载该框架的具身无人机可自主规划航线、采集作物多模态数据,并基于大模型生成的方案实时执行灌溉、施肥作业,处理 4 KB 多模态数据仅需 2 s,适配田间复杂环境。

③ 生成式大模型机器人算法^[120]:融合 S-RLHF 强化学习与弱监督微调数据生成技术,通过 Realsense D435i 传感器采集多模态数据,仅需 30~100 条小样本即可完成 Yi-VL 基模型适配,在复杂遮挡场景中实现小番茄果柄定位成功率超 90.2%、机器人作业效率达 92%。

场景启示:农业赋能的关键是小样本适配+云边协同+多模态感知,既要利用大模型的知识迁移能力破解数据稀缺难题,也要通过边缘计算技术降低部署成本,适配田间分散场景。

3.2.3 文旅业

核心痛点:文化传递枯燥、体验互动不足、个性化服务缺失,传统文旅模式难以满足深度体验需求^[121],具体技术方案如下:

① VR+大模型沉浸式系统^[122]:融合 VR 几何建模、水墨风格渲染与 ERNIE-Bot、GPT-SoVITS 技术,在虚拟场景中提供场景化解说,短问题响应率达 23.99 字/秒、语音解说满意度 3.9 分,实现“沉浸体验+文化传递”双重价值。

② AR+定位+预测融合系统^[123]:结合 GPS+室内定位技术、CNN-LSTM 混合模型与 AR 技术,实现人群密度预测(MAE 低至 8.2%)、历史场景复原与多语言解说,有效提升游览效率与文化感知深度。

③ 个性化生成式叙事应用^[124]:基于 GPT-4+Stable Diffusion 图像生成管道与 LoRA 技术,通过 RAG 技术确保景点信息准确性,生成“用户为主角的定制叙事”与场景化插图。测试数据显示,该应用身份保留评分达 4.7、视觉-语言对齐评分 4.2,用户参与度 8.3 分、文化知识问卷得分 7.8 分,较传统模式均有明显提升。

④ 具身智能导览系统^[125]:融合多模态交互(语音对话、图像识别、肢体反馈)与具身机器人,可通过视觉识别游客注视行为与人群分布、语音理解咨询需求,实时生成多模态内容(语音解说、肢体指向指引、面部表情反馈),并依托 5G 云边协同架构自主调整导览路线以规避障碍与拥挤区域,用户互动舒适度认可度达 83%。

场景启示:文旅业赋能需聚焦技术沉浸感+文化知识性+用户个性化,通过多模态交互技术提升体验感,同时依托知识图谱注入避免生成式 AI 的“幻觉”问题,确保文化信息传递准确。

3.3 行业赋能的核心规律与未来启示

大模型赋能传统产业的核心规律是遵循“通用底座构建-行业知识注入-轻量化部署-场景化落地”的通用路径,且需坚守“技术适配行业特性、效率与性能平衡、安全与合规优先”三大原则:制造业侧重多模态数据融合+工业机理嵌入,农业聚焦小样本微调+云边协同,文旅业突出多模态交互+文化知识结构化,实现技术价值与产业需求的精准匹配。

多模态融合与具身智能的协同是行业赋能的重要延伸:制造业侧重多模态故障诊断+具身执行,农业聚焦多模态环境感知+具身田间作业,文旅业突出多模态交互体验+具身导览服务,进一步强化

技术与场景的深度适配。

未来需进一步推动供应链上下游的跨行业协同，并结合具身智能等技术开发更灵活的行业应用设备，持续优化轻量化技术以降低中小微企业与偏远地区的部署门槛，最终实现大模型技术红利的广泛普惠化覆盖。

4 未来趋势展望

大模型的未来发展将以“破解核心挑战、释放产业价值、保障安全可控”为核心逻辑，围绕前文数据、成本、安全、评估四大核心挑战，以及行业赋能实践中的痛点，沿着技术突破 - 产业升级 - 治理适配 - 跨域融合的路径递进，实现从“技术创新”到“生态共建”的跨越。

4.1 高质量数据生态与合规技术协同发展

针对前文提及的数据量质双缺、合规风险突出的核心挑战，未来将构建采集 - 标注 - 共享 - 合规全链条数据生态。技术路径上，通过联邦学习+合成数据生成破解优质数据稀缺难题。例如基于扩散模型生成工业缺陷标注数据、农业病虫害样本数据，减少对人工标注的依赖。同时，依托区块链技术实现数据溯源，结合同态加密、差分隐私等隐私计算技术，平衡数据共享与隐私保护，适配《数据安全法》《生成式 AI 服务管理暂行办法》的合规要求。落地场景中，将形成中文等非英文语料的开源共享平台，通过合规审核+质量分级机制，为中小微企业提供低成本、高质量的行业数据资源，支撑中文大模型的泛化能力提升。

4.2 高效模型架构与轻量化技术深度融合

为应对训练成本高企、推理效率不足的瓶颈，未来将聚焦架构优化+工程压缩双轮驱动。架构层面，优化 MoE 的路由器设计，采用动态专家分配机制减少无效计算，同时探索 Transformer+类脑稀疏激活的混合架构，提升模型并行效率。工程层面，融合低精度混合量化+动态令牌剪枝技术，结合前文提及的混合并行策略，降低大规模参数模型的训练成本与推理延迟。落地场景中，工业实时缺陷检测、农业田间边缘计算、文旅实时交互等对成本与延迟敏感的场景，将实现轻量化大模型的规模化部署，让中小微企业无需大规模算力投入即可享受技术红利。

4.3 安全可信技术与动态评估体系同步完善

针对幻觉、对抗攻击、评估体系缺失的痛点，未来将构建安全技术 - 评估框架 - 治理规则的协同

体系。安全层面，通过 RAG+实时事实核查模块嵌入模型流程，降低幻觉风险；采用对抗训练、鲁棒性优化技术增强模型抵御提示注入、数据投毒等攻击的能力。评估层面，建立静态基准+动态监测双轨体系——升级 MMLU、C-Eval 等通用基准的知识覆盖与鲁棒性，构建医疗、金融等垂直领域专属标注数据集；开发动态评估工具，实时监测模型知识更新效果与旧知识遗忘程度，适配持续学习特性。治理层面，形成技术标准（如安全评估指标体系）+行业规范（如高风险场景准入要求）双重约束，推动安全可信技术的标准化落地。

4.4 行业专用模型与跨域协同应用规模化

依托前文三阶训练范式与行业赋能实践，未来将从单场景适配走向全链条赋能+跨行业协同。垂直领域层面，制造业将打造多模态工业大模型+具身机器人+数字孪生系统，实现生产全流程感知 - 决策 - 执行 - 优化闭环；农业将构建多模态小样本模型+具身无人机+物联网传感器网络，覆盖从种植到采收的全链路；文旅业将推出具身智能+多模态沉浸式交互产品，实现文化传递与体验升级。跨行业层面，多模态数据互通与具身设备标准化接口将推动供应链协同，例如制造业生产需求通过多模态模型转化为农业农资供应指令，由具身设备完成精准配送。

4.5 跨学科融合与基础理论突破

延续前文跨学科融合的技术脉络，未来将深化计算机科学+物理学+生物学+语言学的交叉创新。物理学层面，运用复杂系统理论量化模型涌现临界点，指导训练过程中的参数调整与算力分配，提升训练效率；生物学层面，借鉴大脑神经元的层级化连接与动态激活机制，优化 Transformer 的注意力分配策略，增强模型鲁棒性与泛化能力；语言学层面，针对中文、藏语等语言的结构特性，开发形态学感知+上下文关联的专用建模技术，解决语义碎片化问题。基础理论方面，将聚焦涌现能力的底层机理、模型公平性与价值对齐的数学建模等核心问题，推动大模型从经验驱动向理论指导下的精准优化演进，为通用 AI 的长远发展奠定基础。

多模态融合将深度结合神经科学，借鉴人类大脑的多感官整合机制，优化跨模态注意力分配策略，解决异构数据语义鸿沟问题；具身智能将融合机器人学、控制论与认知科学，研发更适配复杂物理环境的动态决策模型，提升机器人的自主适应能力。基础理论方面，将聚焦多模态涌现能力的底层机理、

具身智能的环境建模与实时反馈优化等核心问题，推动大模型从虚拟理解向实体赋能的本质跨越。

综上，大模型的未来发展将以高效、普惠、安全、可控为核心，通过技术突破破解核心挑战、产业应用释放价值、治理规范保驾护航的逻辑闭环，推动其从实验室技术升级为数字经济的核心引擎，深度赋能制造业、农业、文旅业等传统产业转型升级，为全球 AI 技术创新与产业发展提供中国方案。

5 结束语

本文围绕大模型的技术演进、核心挑战、行业赋能与未来趋势展开系统研究，构建了技术基础 - 核心挑战 - 行业应用 - 未来路径的完整分析框架，明确 Transformer 架构与三阶段范式奠定技术底座，跨学科融合推动模型精准优化，而数据 - 成本 - 安全 - 评估的连锁制约是落地核心梗阻，制造业、农业、文旅业的实践则验证了通用技术底座+行业知识注入+轻量化部署的赋能逻辑。其学术价值在于梳理技术脉络与提炼产业赋能框架，实践价值为中小微企业适配与合规落地提供指导。同时本文存在以下局限：一是高风险行业（如医疗、法律）的应用分析仅涉及技术框架，缺乏具体临床验证数据与合规落地案例；二是对新兴技术（如具身智能、量子计算）与大模型的融合路径探讨不足；三是未充分分析大模型落地对就业结构、数据隐私保护的社会影响。后续可聚焦垂直领域深度适配、新兴技术协同、社会影响治理等方向深入研究。助力大模型形成“技术创新、产业赋能、治理规范”三位一体的良性生态，为我国在中文大模型技术研发、产业应用与国际治理领域提供核心支撑，推动数字经济向高效、普惠、安全方向高质量发展，为全球 AI 技术创新与产业升级贡献中国方案。

参考文献

[1] 邵瑞江.数据要素与人工智能发展分析[J].信息技术时代,2025(17):202-204.
[2] LE T M, LE N P L, HUA N G N, et al. Insight Evaluation on Traditional and CNN Features[C]//Proceedings of the 2022 6th International Conference on Machine Learning and Soft Computing. New York: Association for Computing Machinery, 2022: 179-185.
[3] GAO J Q, WU H, CHEUNG Y M, et al. Mitigating Forgetting in Adapting Pre-trained Language Models to Text Processing Tasks via Consistency Alignment[C]//Proceedings of the ACM on Web Conference 2025. New York: Association for Computing

Machinery,2025:3492-3504.
[4] COTFAS L A SANDU A,DELCEA C, et al.From Transformers to ChatGPT: An Analysis of Large Language Models Research[J].IEEE,2025,13:146889-146931.
[5] STOREY V C, YUE W T, ZHAO J L, et al. Generative Artificial Intelligence: Evolving Technology, Growing Societal Impact, and Opportunities for Information Systems Research[J].Information Systems Frontiers,2025,27:2081-2102.
[6] 朱国栋,王晓燕,张智,等.AI 时代颠覆性技术发展现状[J].中国科技信息,2025(20):142-143.
[7] 陈飞.AI 大模型时代档案数据要素价值释放的前景、挑战与策略研究[J].档案管理,2025(4):44-47.
[8] BENDECHACHE M, ATTARD J, EBIELE M, et al. A Systematic Survey of Data Value: Models, Metrics, Applications and Research Challenges[J].IEEE,2023,11:104966-104983.
[9] 黄文倩. AI 大模型时代下智能体发展研究与展望[J]. 数码设计, 2024(15): 84-86.
[10] YOU B. Research on Multimodal Data Fusion Technology based on LLM and Attention Mechanism[C]//Proceedings of 2025 7th International Congress on Human-Computer Interaction, Optimization and Robotic Applications. Ankara: IEEE, 2025: 1-4.
[11] LIU X Q,FARID A, AMANO T,et al. LLM-Powered Embodied Intelligence for Socially-Aware Robot Navigation in Human-Robot Interaction[C]//Proceedings of the 19th International Symposium on Spatial and Temporal Data. New York: Association for Computing Machinery,2025:145-148.
[12] 袁霆宇,刘凯,关标良,等.具身智能大模型综述及展望[J].无线电工程,2025,55(11):2256-2273.
[13] 秦小林,古徐,李弟诚,等.大语言模型综述与展望[J].计算机应用,2025,45(3):685-696.
[14] CHU Z M, SAKAI T, AI Q Y, et al. Chuweb21D: A Deduped English Document Collection for Web Search Tasks[C]//Proceedings of the Annual International ACM SIGIR Conference on Research and Development in Information Retrieval in the Asia Pacific Region. New York: Association for Computing Machinery,2023:63-72.
[15] 李晨曦,李维乾,陈金广.跨模态对齐的多粒度异构图神经网络推荐方法[J/OL].计算机技术与发展, 2025:1-8.
[16] FEDUS W, ZOPH B, SHAZEER N. Switch Transformers: Scaling To Trillion Parameter Models with Simple and Efficient Sparsity[J].Machine Learning Research,2022,23(1):120.
[17] SOOMRO R B, AI-RAHMI W M, DAHRI N A, et al. A SEM-ANN analysis to examine impact of artificial intelligence technologies on sustainable performance of SMEs[J].Scientific Reports,2025,15:5438.
[18] 陈子瑜,程国斌.医疗人工智能中的算法黑箱及其核心伦理问题[J].医学与哲学,2024,45(12):1-5.
[19] 程雪军.金融强国目标下数字金融平台算法黑箱的系统治理机制[J].河海大学学报（哲学社会科学版）,2024, 26(2):107-120.
[20] SINGH S, ROMANOU A, FOURRIER C, et al. Global MMLU: Understanding and Addressing Cultural and Linguistic Biases in Multilingual Evaluation[C]//Proceedings of the 63rd Annual Meeting of

- the Association for Computational Linguistics. Vienna: Association for Computational Linguistics, 2025:18761-18799.
- [21] LI Y C, GUO Y H, GUERIN F, Lin C H. An Open-source Data Contamination Report For Large Language Models[C]//Proceedings of the Association for Computational Linguistics: EMNLP 2024. Miami: Association for Computational Linguistics, 2024: 528-541.
- [22] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is All You Need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. New York: Curran Associates Inc., 2017:6000-6010.
- [23] IIDIZ M E, HUANG Y X, LI Y C, et al. From Self-attention to Markov Models: Unveiling the Dynamics of Generative Transformers[C]//Proceedings of the 41st International Conference on Machine Learning. Vienna Austria: JMLR, 2024: 20955-20982.
- [24] 郑泽, 李鸿燕. 基于 CLDSP 和交叉注意力机制的多模态抑郁症检测[J/OL]. 计算机工程与应用, 2025:1-13.
- [25] YE T Z, DONG L, XIA Y Q, et al. Differential Transformer[C]. arXiv preprint arXiv:2410.05258, 2025.
- [26] 刘晓宇, 曾令仿. 大语言模型检查点机制研究综述[J/OL]. 计算机工程与应用, 2025:1-18.
- [27] 刘永奎, 王芊骥, 朱子璐, 等. 具身智能工业机器人: 体系架构、关键技术与案例研究[J/OL]. 计算机集成制造系统, 2025, 1-33.
- [28] PATIL R, GUDIVADA V. A Review of Current Trends, Techniques, and Challenges in Large Language Models (LLMs)[J]. Applied Sciences, 2024, 14(5):2074.
- [29] MAI L, CARSON-BERNDSEN J. Carson-Berndsen. Enhancing Conversation Smoothness in Language Learning Chatbots: An Evaluation of GPT4 for ASR Error Correction[J]. IEEE, 2024:11001-11005.
- [30] LIU Y Y, HUANG H M, GAO J L, et al. A Study of Chinese Text Classification Based on A New Type of BERT Pre-training[J]. IEEE, 2023:303-307.
- [31] YU B, DENG C, BU L P. Policy Text Classification Algorithm Based on Bert[J]. IEEE, 2022, 488-491.
- [32] 张宇, 吴静. 基于深度学习的商品评论情感分析[J]. 智能计算机与应用, 2024, 14(8):54-58.
- [33] LI J, SUN A X, HAN J L, et al. A Survey on Deep Learning for Named Entity Recognition: Extended Abstract[C]//Proceedings of 2023 IEEE 39th International Conference on Data Engineering (ICDE). USA: IEEE, 2023: 3817-3818.
- [34] ZHU B L, PAN W. A Text Classification Model Based on BERT and Attention[C]// Computers and Artificial Intelligence Technologies (CAIT), International Conference on, Macau, 2023:90-95.
- [35] 李浩然, 陈宇辉, 崔文博, 等. 面向具身操作的视觉-语言-动作模型综述[J/OL]. 自动化学报, 1-34.
- [36] YAO J C, ZHANG J, ZHANG S Y, et al. Cross-Modal Tri-Semantic Correlation-CLIP for Short Video Homogenization Recognition[J]. Association for Computing Machinery, 2025, 21(10):1551-6857.
- [37] WANG T, HE C H, WANG Z, et al. FLAVA: Find, Localize, Adjust and Verify to Annotate LiDAR-based Point Clouds[C]//Proceedings of the 33rd Annual ACM Symposium on User Interface Software and Technology. New York: Association for Computing Machinery, 2020:31-33.
- [38] 王峥, 傅宏宇. 基于人工智能大模型训练的数据安全治理[J]. 中国信息化, 2025(7):60-62.
- [39] KAPLAN J, MCCANDLISH S, HENIGHAN T, et al. Scaling Laws for Neural Language Models[J]. arXiv preprint arXiv:2001.08361, 2020.
- [40] ZHANG G W, HOU Y P, LU H Y, et al. Scaling Law of Large Sequential Recommendation Models[C]//Proceedings of the 18th ACM Conference on Recommender Systems. New York: Association for Computing Machinery, 2024:444-453.
- [41] LUBANA E S, KAWAGUCHI K, P. DICK R, et al. A Percolation Model of Emergence: Analyzing Transformers Trained on a Formal Language[J]. arXiv preprint arXiv:2408.12578, 2024.
- [42] JI L X, XIAO S J, FENG J M, et al. Multimodal Large Model Pretraining, Adaptation and Efficiency Optimization[J]. Neurocomputing, 2025, 619:129138.
- [43] 胡泳, 刘纯懿. 大语言模型“数据为王”: 训练数据的价值、迷思与数字传播的未来挑战[J]. 西北师大学报(社会科学版), 2024, 61(3):43-54.
- [44] KUMAR S, MENDKE S, RAHMAN K L A, et al. Enhancing Zero-shot Chain of Thought Prompting via Uncertainty-Guided Strategy Selection[C]//Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi: Association for Computational Linguistics, 2025:2003-2025.
- [45] ZHANG L, HU Y X. A Fine-tuning Approach Research Of Pre-trained Model With Two Stage[C]//2021 IEEE International Conference on Power Electronics, Computer Applications (ICPECA), Shenyang, China, 2021:905-908.
- [46] WAHIDUR R S M, TASHDEED L, KAYR M, et al. Enhancing Zero-Shot Crypto Sentiment with Fine-tuned Language Model and Prompt Engineering[J]. IEEE Access, 2024, 12:10146-10159.
- [47] ZHANG Z Y, BO X H, MA C, et al. A Survey on the Memory Mechanism of Large Language Model-based Agents[J]. Association for Computing Machinery, 2025, 43(6):1046-8188.
- [48] OUYANG L, WU J, JIANG X, et al. Training Language Models to Follow Instructions with Human Feedback[C]//Proceedings of the 36th International Conference on Neural Information Processing Systems. New York: Curran Associates Inc., 2022: 2011.
- [49] 刘磊, 卢国彬, 杜科, 等. 大模型运营平台建设实践与技术优化[J]. 信息技术与标准化, 2025, (6):71-77.
- [50] JING L. Construction and Research of Multi-Platform Knowledge Collaboration Model Based on Deep Reinforcement Learning Algorithm[C]//Proceedings of the 2023 6th International Conference on E-Business, Information Management and Computer Science. New York: Association for Computing Machinery, 2024: 203-208.
- [51] 高彦杰, 陈跃国. 大语言模型预训练系统关键技术综述[J]. 软件学报, 2026, 37(1):200-229.
- [52] LIANG P, TANG Y, ZHANG X D, et al. A Survey on Auto-Parallelism of Large-Scale Deep Learning Training[J]. IEEE Transactions on Parallel and Distributed

- Systems,2023,34(8):2377-2390.
- [53] LI S, ZHAO Y L, VARMA R, et al. PyTorch distributed: Experiences on accelerating data parallel training[C]//Proceedings of the VLDB Endowment. VLDB Endowment, 2020,13(12):3005-3018.
- [54] D S, LI S W, LAI Z Q, et al. A Memory-Efficient Hybrid Parallel Framework for Deep Neural Network Training[J]. IEEE Transactions on Parallel and Distributed Systems, 2024, 35(4): 577-591.
- [55] AYANAN D, HARLAP A, PHANISHAYEE A, et al. PipeDream: Generalized pipeline parallelism for DNN training[C]//Proceedings of the 27th ACM Symposium on Operating Systems Principles. New York: Association for Computing Machinery, 2019: 1-15.
- [56] RAJBHANDARI S, RASLEY J, RUWASE O, et al. Zero:Memory optimizations toward training trillion parameter models[J]. IEEE, 2020, 1-16.
- [57] 鲁燕清.GPU 内存管理与优化策略在人工智能模型中的应用[J].中国战略新兴产业,2025(8):35-37.
- [58] PUN S W, BAO B Z, FILIP S L, et al. Range Extension with Supernormals for Mixed-Precision 8-bit DNN Training[J]. IEEE, 2025, 1-4.
- [59] EUNG M T, QI P H, LIN M, et al. Balancing Pipeline Parallelism with Vocabulary Parallelism[C]//Proceedings of the 5th Conference on Machine Learning and Systems (MLSys). Santa Clara: MLSys Foundation, 2025: 89-105.
- [60] QI P H, WAN X Y, HUANG G X, et al. Zero Bubble Pipeline Parallelism[C]//Proceedings of the 12th International Conference on Learning Representations (ICLR). Addis Ababa,Ethiopia:Open Review, 2024:1-21.
- [61] BI K F,XIE L X,ZHANG H H, et al. Accurate Medium-Range Global Weather Forecasting with 3D Neural Networks.[J]. Nature,2023,619(7970):533-538. .
- [62] AN X Y, QI P H, HUANG G X, et al. PipeOffload: Improving Scalability of Pipeline Parallelism with Memory Optimization[C]// Proceedings of the 42nd International Conference on Machine Learning, PMLR 267:61942-61955,2025.
- [63] YANG M Z, WANG Z P, LIU K W, et al. Finding emergence in data by maximizing effective information[J]. National Science Review,2025,12(1):279.
- [64] LUBANA E S, KAWAGUCHI K, DICK R P, et al. A Percolation Model of Emergence: Analyzing Transformers Trained on a Formal Language[EB/OL].(2024-8-22)[2024-9-7]. <https://doi.org/10.48550/arXiv.2408.12578>.
- [65] HEN H, YANG X Y, ZHU J Y, et al. Quantifying Semantic Emergence in Language Models[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics. Vienna, Austria: Association for Computational Linguistics,2025:12041-12054.
- [66] RORA S, GOYAL A. A Theory for Emergence of Complex Skills in Language Models[EB/OL].(2023-7-29)[2023-11-6]. <https://doi.org/10.48550/arXiv.2307.15936>.
- [67] 常博,孙灏芸,高清宇,等.传统方法和深度学习用于不同模态心脏医学图像的分割研究进展[J].波谱学杂志,2024,41(2): 224-244.
- [68] BOTTCHE L, WHEELER G. Visualizing high-dimensional loss landscapes with Hessian directions[J]. Journal of Statistical Mechanics: Theory and Experiment, 2024, 1-24.
- [69] EN H R, DONG Y P, ZHU J, et al. Understanding Pre-training and Fine-tuning from Loss Landscape Perspective[C]. arXiv preprint arXiv: 2505.17646, 2025.
- [70] ANG E N, SHEN L, WANG Z Y, et al. Revisiting Flatness-Aware Optimization in Continual Learning With Orthogonal Gradient Projection[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence,2025,47(5):3895-3907.
- [71] UNYAPHIBARN P, LEE J, WANG B, et al. Large Catapults in Momentum Gradient Descent with Warmup: An Empirical Study[EB/OL].arXiv preprint arXiv: 2311.15051, 2024.
- [72] ZHANG Z K, GAO Y J, CHEN D, et al. Exploring and Enhancing Advanced MoE Models: From DeepSpeed-MoE to DeepSeek-V3[J].IEEE,2025:1-6.
- [73] XIAO Y, LIU Y Z, CHEN P, et al. Bio-plausible Reconfigurable Spiking Neuron for Neuromorphic Computing[J]. Science Advances,2025,11(6):6733.
- [74] DRIESS D, XIA F,SMSAJJADI M, et al. PaLM-E:an embodied multimodal language model[J].JMLR,2023,340: 8469-8488.
- [75] LIU H P, GUO D, CANGELOSI A. Embodied Intelligence: A Synergy of Morphology, Action, Perception and Learning[J].Association for Computing Machinery, 57(7): 186.
- [76] LEE K, PENNARTZ C M A, MEJIAS J F. Cortical Networks with Multiple Interneuron Types Generate Oscillatory Patterns During Predictive Coding[J]. PLOS Computational Biology,2025, 21(9): e1013469.
- [77] WAN S S, WEI Y M, KANG L, et al. A Novel Shortcut between Local Windows for Window-based Vision Transformers[J]. IEEE,2023:154-161.
- [78] ADEL A A, BURTSEV M S. Memory Transformer with Hierarchical Attention for Long Document Processing[J]. IEEE,2021:1-7.
- [79] DENY P, CHEON S, SON H, et al. Hierarchical Transformer for Motor Imagery-Based Brain Computer Interface[J]. IEEE Journal of Biomedical and Health Informatics,2023,27(11):5459-5470.
- [80] 杨亦鸣,荀恩东,汪张龙,等.语言智能与技术的发展、应用及使命笔谈[J].语言文字应用,2025(3):2-19.
- [81] JIN Z C, WANG Y J. Task-Specific Bidirectional Knowledge Distillation: Transforming General Large Language Models Into Lightweight Models[J]. IEEE, 2025, 530-534.
- [82] SHAO D G, HUANG G A, MA L, et al. LMR-IPGN: An Effective Model for automatic summarization of Chinese text[J]. Springer Nature,2025,31(267):1-20.
- [83] HUO H Y, FU Z T, YU H C, et al. Chinese Text Simplification Based on Large Language Models[J]. IEEE, 2024, 52-56.
- [84] 仁志降泽.《司都文法详解》中藏语 pa、ba、ma 后缀添加规则与语法功能探析[J].青海民族大学学报(藏文版),2025,41(2):19-35.
- [85] PARRA I. Morphological Typology in BPE Subword Productivity and Language

- Modeling[EB/OL].[2024-10-31].<https://doi.org/10.48550/arXiv.2410.23656>
- [86]高珊,袁宛竹,卢卫,等.面向列语义识别的共现属性交互模型构建与优化[J].软件学报,2023,34(3):1010-1026.
- [87]LI C J, LI S B, FENG Y X, et al. Small Data Challenges for Intelligent Prognostics and Health Management: A Review[J]. Artificial Intelligence Review,2024,57(8):214.
- [88]丁小欧,李映泽,王晨,等.兼顾行列的时序数据质量规则发现[J].软件学报,2023,34(3):1065-1086.
- [89]乔少杰,林羽丰,韩楠,等.基于贡献度证明共识机制的去中心化联邦学习框架[J].软件学报,2023,34(3):1148-1167.
- [90]LI Z H. Empowering Large Language Models with Efficient and Automated Systems[D].Berkeley: University of California,2024.
- [91]ZHAO C G, DENG C Q, RUAN C, et al. Insights into DeepSeek-V3: Scaling Challenges and Reflections on Hardware for AI Architectures[C]. arXiv preprint arXiv: 2505.09343, 2025.
- [92]封帅,薛世钺.开源人工智能与国际政治变革[J].东南亚研究,2025(5):1-16.
- [93]赵洪科,叶倩彤,张志勇,等.低碳算法的发展及压缩和加速技术的应用[J].控制与决策,2025,40(5):1409-1428.
- [94]SAMS I, ZHAO D, MCDONALD J, et al. From Words to Watts: Benchmarking the Energy Costs of Large Language Model Inference[C]. arXiv preprint arXiv: 2310.03003, 2023.
- [95]崔龙飞,王宗水,鲍盈旭,等.大模型时代自动问答系统及评价体系综述[J/OL].计算机工程与应用,1-17.
- [96]TEKE A, PISE N. Generative Models Reimagined: Review into Resource-Efficient Training[C]//Proceedings of 2025 6th International Conference on Control, Communication and Computing (ICCC). Thiruvananthapuram: IEEE,2025: 1-5.
- [97]TRIPATHI K, MALIK D, AKSHAT A, et al. A Survey on 1-bit Quantized Large Language Models[J]. Neural Computing and Applications,2025,37:20823-20878.
- [98]WANG X H, YAN Y L, HUANG L T, et al. Hallucination Detection for Generative Large Language Models by Bayesian Sequential Estimation[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023:15361-15371.
- [99]NGUYEN K N T, ZHANG W Y, LU K K, et al. A Survey and Evaluation of Adversarial Attacks in Object Detection[J]. IEEE Transactions on Neural Networks and Learning Systems,2025,36(9):15706-15722.
- [100]BRUIGER D. Reflections on the AI alignment problem[J]. AI & SOCIETY, 2025,40:4383-4392.
- [101]罗文,王厚峰.大语言模型评测综述[J].中文信息学报,2024,38(1):1-23.
- [102]AWASTHI R, BHATTAD A, RAMACHANDRAN S P, et al. Human Evaluation of Large Language Models In Healthcare: Gaps, Challenges, and the Need for Standardization[J].Health Systems,2025,40:1-8.
- [103]LATIF A, KIM J. Evaluation and Analysis of Large Language Models for Clinical Text Augmentation and Generation[J]. IEEE Access,2024,12:48987-48996.
- [104]孙宇,王红杰,杜彦辉.人工智能安全标准化综述[J/OL].指挥与控制学报,2025:1-15.
- [105]RONVAL B, DUPONT P, NIJSSEN S. Detection of Large Language Model Contamination with Tabular Data[J]. Advances in Intelligent Data Analysis,2025,15669: 234-245.
- [106]WEN X Y, FENG F, ZHANG X. Research on a Dynamic Multi-Dimensional Lightweight Evaluation Framework for Large Language Models[C]//Proceedings of 2025 5th International Conference on Artificial Intelligence, Big Data and Algorithms (CAIBDA). Beijing: IEEE,2025:454-458.
- [107]JIANG X K, ZHANG R Z, XU Y X, et al. HyKGE: A Hypothesis Knowledge Graph Enhanced RAG Framework for Accurate and Reliable Medical LLMs Responses[J]. Association for Computational Linguistics, 2025, 11836-11856.
- [108]MOZAFFARI M H. Deep Learning for Computer Vision Application[J]. Electronics, 2025,14(14):2874.
- [109]LIN X Y, BAO K Q, ZHANG J Z, et al. Navigating Large Language Models for Recommendation:From Architecture to Learning Paradigms and Deployment[C]//Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: Association for Computing Machinery,2025: 4134-4137.
- [110]SANTINA C D, LI X, JIANG S Q, et al. The Evolution of Multimodal Embodied Intelligence: Cutting-Edge Exploration in Empowering Soft Robotics[C]//Proceedings of the 1st International Workshop on Vision-Language in Soft Robot. New York:Association for Computing Machinery,2025:1-2.
- [111]焦方义,刘嘉越.人工智能、数实技术融合与制造业产业链韧性[J].云南民族大学学报(哲学社会科学版),2025,42(6):86-99.
- [112]WANG T Y, ZHANG B W, JIANG D Q, et al. A Multimodal Large Language Model Framework for Intelligent Perception and Decision-Making in Smart Manufacturing[J].MDPI,2025, 25(10):3072.
- [113]孙俊杰.工业大模型多领域展示人工智能应用潜力——卡奥斯工业大模型跨领域前沿探索[J].中国工业和信息化, 2024(4):34-38.
- [114]徐甲甲.工业大模型引领工业互联网发展新趋势[J].数字经济,2023(8):60-63.
- [115]ZHANG T L, PANG H L, JIANG C H. GDM-YOLO: A Model for Steel Surface Defect Detection Based on YOLOv8s[J]. IEEE Access,2024,12:148817-148825.
- [116]李玉峰,宗国庆,张东豪.基于具身大模型的多场景智能巡检机器人系统框架与多机器人协同应用集成研究[J].智能计算机与应用,2025,15(5):37-43.
- [117]BHASME M, ULHE P, GOKHE S. AI in Agriculture: The Future of Robotic Farming and Automation[C]//Proceedings of 2024 2nd DMIHER International Conference on Artificial Intelligence in Healthcare, Education and Industry (IDICAIEI). Wardha: IEEE,2024:1-7.
- [118]LIU K H, ZHANG F, WU Q L, et al. A Joint Knowledge Extraction Model for Tobacco Pest and Disease Prevention Based on BERT+BA+CASREL[J]. IEEE Access,2025,13:125332-125347.

-
- [119] KUM S, OH S, MOON J. Edge AI Framework for Large Scale Smart Agriculture[C]//Proceedings of 2024 27th Conference on Innovation in Clouds, Internet and Networks (ICIN). Paris:IEEE,2024:142-147.
- [120] HOU G Y, NIU R X, CHEN H H, et al. A Robotic AI Algorithm for Fusing Generative Large Models in Agriculture Internet of Things[J].IEEE Internet of Things Journal,2025,12(10):13511-13524.
- [121] VASHISHT S. Road Less Travelled: Travelling Using Augmented reality[C]//Proceedings of 2024 Second International Conference Computational and Characterization Techniques in Engineering & Sciences (IC3TES). Lucknow: IEEE,2024:1-5.
- [122] ZHANG M Z, JIN N L, XIANG N, et al. Immersive Virtual Reality for Digital Cultural Tourism[C]//Proceedings of the 2024 International Conference on Virtual Reality Technology. New York: Association for Computing Machinery,2025:44-50.
- [123] HAN J Y, PAN F. Research on applying Artificial Intelligence to tourism services: personalised recommendations and intelligent navigation case study[C]//Proceedings of the 2025 2nd International Conference on Computer and Multimedia Technology. New York: Association for Computing Machinery,2025:29-33.
- [124] FERRACANI A, BERTINI M, PALA P, et al. Personalized Generative Storytelling with AI-Visual Illustrations for the Promotion of Knowledge in Cultural Heritage Tourism[C]//Proceedings of the 6th workshop on the analySis, Understanding and proMotion of heritAge Contents. New York: Association for Computing Machinery,2024:28-32.
- [125] ROSA S, RANDAZZO M, LANDINI E, et al. Tour Guide Robot: A 5G-enabled Robot Museum Guide[J].Frontiers in Robotics and AI,2024,10:1323675.

作者简介:

李 薇, 女, (2001—), 硕士研究生, 主要研究方向: 数据库, 人工智能。

(*通信作者) **乔少杰**, 男, (1981—), 博士, 教授, 博士生导师。主要研究方向: 数据库, 人工智能。