



哈尔滨工业大学学报
Journal of Harbin Institute of Technology
ISSN 0367-6234, CN 23-1235/T

《哈尔滨工业大学学报》网络首发论文

题目: 知识图谱增强的多模态校园社会情绪感知
作者: 郭晓东, 陈琳, 李振, 展鹏, 李智超, 张洋
收稿日期: 2025-12-05
网络首发日期: 2026-02-13
引用格式: 郭晓东, 陈琳, 李振, 展鹏, 李智超, 张洋. 知识图谱增强的多模态校园社会情绪感知[J/OL]. 哈尔滨工业大学学报.
<https://link.cnki.net/urlid/23.1235.t.20260213.1343.009>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

知识图谱增强的多模态校园社会情绪感知

郭晓东¹, 陈琳¹, 李振^{1*}, 展鹏¹, 李智超², 张洋²

(1. 山东大学 数智化支撑研究院, 济南 250100;

2. 山东大学(威海) 信息化工作办公室, 山东 威海 264209)

摘要：随着互联网与社交媒体的广泛普及，学生群体在网络表达中呈现出表情包文化、圈层术语等独特现象，导致高校舆情数据具有多源异构和高度碎片化的特点，传统通用模型难以实现有效理解。为此，本文提出一种基于知识图谱增强的多模态融合分析框架，旨在提升校园环境社会情绪感知与舆情分类的准确性与鲁棒性。该框架首先借助知识图谱增强模块，采用 SAM 实现图像语义分割，并基于大语言模型提取文本与视觉实体信息，通过实体对齐与链接技术构建融入校园实体与事件关系的领域知识图谱，以缓解语义稀疏与模态割裂问题。其次，设计单模态特征处理模块，融合多尺度卷积与自注意力机制的 TCN-BiGRU 网络，提升各模态内部特征表示质量。最后，进一步构建多功能融合模块，借助跨模态多头注意力机制与 Encoder-Decoder 结构，实现动态的多模态特征融合与重构。在公开数据集与自建校园数据集上进行验证，结果表明，本文所提方法在情感极性识别和事件分类任务上均优于当前主流基线模型，可为校园社会情绪感知提供精度更高、鲁棒性更强的解决方案。

关键词：多模态分析；知识增强；知识图谱；情绪分析；单模态处理

中图分类号：TP391

Multi-modal campus social emotion perception enhanced by
knowledge graphGUO Xiaodong¹, CHEN Lin¹, LI Zhen^{1*}, ZHAN Peng¹, LI Zhichao², ZHANG Yang²

(1. Institute of Digital and Intelligent Support, Shandong University, Jinan 250100, China 2. Informatization Work Office,

Shandong University (Weihai), Weihai 264209, China)

Abstract: With the widespread adoption of the internet and social media platforms, student groups exhibit unique online expressions such as meme culture and community-specific jargon. Campus public opinion data are characterized by multi-source heterogeneity and high fragmentation, making them difficult for general models to comprehend. To address this, this paper proposes a knowledge graph-enhanced multimodal fusion analysis framework, aiming to improve the accuracy and robustness of social emotion perception and public opinion classification in campus environments. The framework incorporates a knowledge graph enhancement module, which employs SAM for image semantic segmentation and leverages large language models to extract textual and visual entity information. Through entity alignment and linking techniques, a domain knowledge graph integrating campus entities and event relationships is constructed to alleviate semantic sparsity and modal isolation. A unimodal feature

收稿日期：2025-12-05；**录用日期：**2026-02-02；

基金项目：国家自然科学基金(62276155)；山东省重点研发计划(2025TSGCCZZB0792, 2025CXPT091)；山东省人工智能教育研究课题(SDDJ202501088)

作者简介：郭晓东(1980—)，男，硕士，高级工程师

通信作者：李振, jens@sdu.edu.cn.

processing module is designed, integrating a TCN-BiGRU network that combines multi-scale convolution with self-attention mechanisms to enhance the quality of intra-modal feature representation. Furthermore, a multifunctional fusion module is developed, utilizing cross-modal multi-head attention mechanisms and an encoder-decoder architecture to achieve dynamic multimodal feature fusion and reconstruction. Experimental results on public datasets and a self-constructed campus dataset demonstrate that the proposed method outperforms current mainstream baseline models in both sentiment polarity recognition and event classification tasks, offering a more accurate and robust solution for campus social emotion perception.

Keywords: multimodal analysis; knowledge enhancement; knowledge graph; sentiment analysis; single modal processing

随着社交媒体与高校自有平台的深度普及,高校舆情数据呈现爆发式增长^[1],与通用社会舆情不同,高校舆情具有强领域关联性、主体特殊性及影响辐射性^[2]。校园社交媒体中的短评、弹幕、帖子常包含“内卷、破防、赶 due”等特定术语和网络梗,青年学生常使用反讽、调侃的图文搭配,或使用特定表情包传递隐含情绪,造成严重的领域语义稀疏问题。

随着深度学习与多模态融合方法的显著进步^[3-4],多模态分析在心理健康监测^[5]、教学评估^[6]及校园舆情管理^[7]等多个方面具有广泛的应用前景。单模态分析主要针对单一数据源进行特征提取与建模^[8-9],所依赖的信息维度有限。多模态情感分析基本思路是整合文本、图像、语音等不同模态的信息。依据融合阶段的不同,可分为前、中、后融合 3 类主要方式。前期融合在特征提取阶段就对不同模态的数据进行整合^[10-11]。中期融合在保留各模态特征独立性的同时,实现有效的跨模态交互^[12]。后期融合是在各个模态上分别进行预测,再通过加权平均等策略对多个预测结果进行集成^[14-15],但后期融合通常计算开销较大。对比学习策略可用于提升跨模态表征质量,如 CLMLF (2022)^[16]通过拉近情感一致样本、推远不一致样本,学习更具判别性的共同表示。近年来,研究重点逐渐转向动态融合与模态校准,如 TETFN (2023)^[17]通过文本引导的交互增强跨模态对齐。尽管这些方法在多模态情感分析任务中取得了显著进展,但面临校园场景中特定术语时仍面临语义理解不充分、模态关联建模不足等挑战。

近年来,知识图谱因其强大的语义表示和关系推理能力被广泛引入情感分析任务,以弥补传统数据驱动方法在领域知识、常识和深层语义关联上的不足。知识增强的预训练模型,主要关注如何将结构化知识注入大规模预训练语言模型。如 K-BERT^[18],通过将知识图谱三元组与句子原文对齐后共同输入 Transformer,有效增强模型的语义表示。在此基础上,EKBSA 模型^[19]进一步构建了高质量的情感知识图谱,并引入句法分析来增强局部注意力机制,在中文情感分析任务上取得了显著提升。但这类方法主要针对纯文本模态,且依赖预先构建的知识图谱,难以处理多模态数据中动态涌现的实体关联。

目前,面向校园的社会情绪感知需解决以下核心科学问题:建模校园领域特有的术语体系与文化语境,以克服短文本语义稀疏;捕捉学生群体中常见的、非字面匹配的图文关联模式,以实现深层次跨模态语义对齐;设计可自适应校园舆情数据稀疏、非对齐分布特点的鲁棒分析框架。针对上述挑战,本文提出知识图谱增强的多模态融合框架(Knowledge graph enhanced multimodal sentiment analysis, KGE-MSA),其核心目标是通过“知识图谱补全语义”与“动态多模态融合”,解决高校舆情中各类问题。本文方法借助 SAM 实现图像分割,并利用大语言模型进行实体抽取,结合 Leiden 聚类算法与跨模态实体对齐技术,构建统一的融合知识图谱,从而有效缓解短文本语义稀疏与多模态语义不匹配的问题。此外,设计了面向单模态的特征处理模块,集成 TCN-BiGRU、多尺度卷积与自注意力机制,增强了模态内特征的表达能力和上下文建模性能。进一步提出多功能融合模块,通过跨模态多头注意力机制与 Encoder-Decoder 架构,实现动态特征重构与多任务联合学习。在多个公开数据集及自建校园数据集上的实验表明,KGE-MSA 在情感极性识别和事件分类任务上均表现优于当前主流基线模型。

1 KGE-MSA模型

本文的任务是通过文本与图像信息预测校园网络社会事件分类、社会情绪的极性。为清晰说明本文模型中涉及的符号及其含义，便于读者理解文中的公式与表述，将全文使用的主要符号整理后列于附录。KGE-MSA模型整体架构如图1所示。模型输入为文本 T 与图像 V ，文本由BERT^[20]处理提取文本特征 T_{out} ，图像由ViT（vision transformer）^[21]处理提取图像特征 V_{out} 送入后续处理，二者经由单模态特征处理模块(unimodal feature processing module, UFPM)提取单模态特征分别生成 T_{out}^u 与 V_{out}^u ，与原本的特征拼接进行后续处理。在知识增强模块中，文本送入LLMs中提取构建文本知识图谱；图像首先由SAM（segment anything model）^[22]进行语义分割，将图像物品类别进行识别，而后使用LLMs提取实体信息，从而构建图像知识图谱结构，分别提取文本与图像的知识图谱后进行融合，形成融合知识图谱特征。之后将原有各自特征及融合知识图谱特征送入多功能融合模块(multifunctional fusion module, MFFM)，经由多模态融合提取最后的校园网络社会事件分类 PS_i 及社会情绪分级数据 Em_i 。




图1 KGE-MSA 模型整体架构

Fig. 1 Overall architecture of the KGE-MSA model

1.1 知识图谱增强

传统方法直接使用原始文本和图像特征进行融合，难以解决校园场景中特有的术语稀疏和图文语义不匹配问题。引入知识图谱，是为了将非结构化的多模态数据转化为结构化的语义网络。通过实体链接显式地建立文本关键词与图像区域间的语义关联，以缓解模态割裂。利用知识图谱中实体丰富的上下文关系，为短文本补充隐含的领域语义，以对抗语义稀疏。

基于MM-ChatAlign^[23]、MERGE^[24]等模型优点，本模块构建了一个面向校园领域的结构化跨模态知识图谱，以融合文本与视觉语义信息。如图2所示，首先基于大语言模型从文本中抽取出实体及其关系；同时，借助SAM模型对图像进行语义分割，并利用多模态大模型识别与描述视觉实体。在此基础上，采用基于Leiden聚类的实体对齐技术，将文本实体与视觉实体进行链接与融合，最终形成统一的跨模态领域知识图谱。

图像被定义为 $V = \{V_1, V_2, \dots, V_N\}$ ，每一张图片 V_i 均包含一系列被抽取的实体信息 $Ev(V_i) = \{ev_1^{(V_i)}, ev_2^{(V_i)}, \dots, ev_L^{(V_i)}\}$ 。文本信息为 $T = \{T_1, T_2, \dots, T_M\}$ ，每个文本块 T_j 包含实体信息为 $Et(T_j) = \{a_1^{(T_j)}, a_2^{(T_j)}, \dots, a_L^{(T_j)}\}$ 。




图 2 知识图谱增强流程架构

Fig. 2 Knowledge Graph Enhancement Process Architecture

对于每个视觉实体 $ev_k^{(v_i)}$ (第 k 张图像中的第 i 个视觉实体), 目标是将其与语义上最相关的文本实体 $et_i^{(t_j)}$ 对齐。由于文本实体的数量通常大于视觉实体的数量, 因此, 任务被分解为两个阶段, 为每个视觉实体生成一组候选文本实体, 以及从该组中选择最对齐的文本实体。

对于每一个图像实体 $ev_k^{(v_i)}$, 其候选集为

$$Candidate(ev_k^{(v_i)}) \subseteq \bigcup_{j=1}^{j+1} Et(T_j) \quad (1)$$

式中 $Candidate(ev_k^{(v_i)})$ 为包含从上下文的文本实体池 T_i 中选择的最相关的文本实体。

最终对齐是通过最大化相似性函数 f 确定,

$$Align(ev_k^{(v_i)}) = \arg \max_{ev \in Candidate(ev_k^{(v_i)})} f(ev_k^{(v_i)}, ev) \quad (2)$$

对齐后, 链接的实体对被传递给基于 LLMs 的融合模块, 以确保其在知识图谱中共享统一的表示。

为了提高候选实体生成的效率和鲁棒性, 本文构建了一种基于 Leiden 聚类的优化策略。重新设计了加权邻接矩阵 A 和相似度矩阵 D , 以捕获实体之间的语义和结构信息。构造邻接矩阵 $Align$ 以反映节点之间的相似性及其之间关系的重要性。

$$Align_{pq} = sim(v_p, v_q) \cdot weight(r_{pq}) \quad (3)$$

式中: v_p 为实体 e_p 的嵌入向量; sim 表示余弦相似度; r_{pq} 为知识图谱中 e_p 和 e_q 之间的关系, 权重 r_{pq} 是反映所评估关系重要性的标量 LLMs。

如果两个实体之间不存在关系, 则将 r_{pq} 设置为 1。相似度矩阵 D 是对角矩阵, 其中每个对角条目 D_{pp} 表示节点 p 的连接强度, 即

$$D_{pp} = \sum_q A_{pq} \quad (4)$$

D 中的每个对角线值表示节点 p 和所有其他节点之间的总加权相似度。然后, 使用最小的 m 个特征向量形成矩阵 $Q = \{u_1, u_2, \dots, u_m\}$, 其中 m 取决于上下文中文本实体的数量。使用 DBSCAN 对 Q 进行聚类, 以获得聚类分区:

$$\text{Cluster}(Q) = \{C_1, C_2, \dots, C_n\} \quad (5)$$

对于每一个图像实体 $ev_k^{(v)}$ ，根据其嵌入与聚类成员之间的余弦相似性来选择最相关的聚类，候选实体集为

$$C(ev_k^{(v)}) = \bigcup_{C_n} \{ev_p \mid ev_p \in C_n\} \quad (6)$$

最后，通过基于 LLMs 的推理完成实体对齐，该过程在复杂对齐场景中展现出高精度与自适应能力。对齐后的融合知识图谱结构随后被送入特征融合模块。

1.2 单模态特征处理模块

原始的单模态特征通常是通用且高维的，可能包含大量与下游情感及事件分类任务无关的冗余信息。基于 ULMD^[25]、EBIA^[26]等模型优点，本文所设计的 UFPM 模块，主要用于单模态特征的提纯与增强。TCN^[27]层利用膨胀卷积捕获长程依赖，BiGRU^[28]层捕捉双向的局部时序模式，二者结合可有效建模文本序列和图结构特征的复杂上下文。引入多尺度卷积与自注意力均都是经过任务自适应优化的强表示。UFPM 模块架构如图 3 所示。




图 3 UFPM 模块架构

Fig. 3 UFPM Module Architecture

输入数据 $X_i \in \mathbb{R}^{T_i \times D_i}$ 首先会被归一化处理，其中 T_i 为序列长度， D_i 为特征维度。通过全连接层进行嵌入变换，嵌入后的序列输入 TCN 层为：

$$X_i^{TCN} = \text{TCN}(X_i) \quad (7)$$

TCN 输出的特征序列被送入 BiGRU 层，从前向后和从后向前两个方向扫描序列，捕捉每个时间点更精确的短期上下文依赖和局部模式，进一步细化特征。从 BiGRU 得到的隐藏状态会被送出做下一步处理，在 TCN 抽象特征基础上捕获双向局部上下文：

$$\begin{cases} \vec{h}_t = \vec{GRU}(X_i^{TCN}, \vec{h}_{t-1}) \\ \overleftarrow{h}_t = \overleftarrow{GRU}(X_i^{TCN}, \overleftarrow{h}_{t-1}) \\ X_i^{BiGRU} = [\vec{h}_t \parallel \overleftarrow{h}_t] \in \mathbb{R}^{T_i \times d_n} \end{cases} \quad (8)$$

式中： X_i^{TCN} 为输入 TCN 提取的高阶时序特征； $\vec{h}_t$ 为前向 GRU 隐藏状态； $\overleftarrow{h}_t$ 为后向 GRU 隐藏状态； $\parallel$ 为向量拼接。

进而得到 TCN-BiGRU 输出为：

$$X_i^{TCN-BiGRU} = \text{TCN-BiGRU}(X_i) \quad (9)$$

式中 $X_i^{TCN-BiGRU} \in \mathbb{R}^{T_i \times d_n}$ ， $X_i \in \mathbb{R}^{T_i \times D_i}$ 。TCN-BiGRU 利用其扩张因果卷积高效地捕捉序列中不同时间跨度的长期依赖关系，并输出一个富含长期特征信息的序列，进而送入空洞卷积层：

$$X_i^{layer} = \text{DilatedConv1D}(X_i^{TCN-BiGRU}, K, F) \quad (10)$$

式中： F 为滤波器数量； K 为卷积核大小。

而后引入多层卷积特征提取过程，为减少冗余信息并整合多级特征，本文将卷积与注意力权重相结合。注意力机制用于突出单模态特征提取过程中最相关的特征：

$$X_i^{self-att} = Attention(X_i^{layer}) \quad (11)$$

式中 $Attention$ 为注意力计算。

为确保通过注意力增强的特征与后续处理所需的尺寸对齐，在注意力机制之后执行上采样操作：

$$X_i^{fusion} = \oplus Unpooling(X_i^{self-att}) \quad (12)$$

式中 $\oplus$ 代表元素添加。

该方法不仅可以保留不同卷积层提取的细粒度信息，还可以整合注意力机制捕获的全局依赖信息。为了满足后续多任务学习的需要，本文添加了一个线性层来实现单模态情感分析：

$$Y_i = \text{soft max}(W_i X_i^{fusion} + b_i) \quad (13)$$

式中： X_i^{fusion} 融合为用于模态间特征融合的隐藏状态； W_i 为权重矩阵； b_i 为相应的偏差； Y_i 为一个单模态标签，用于后续多任务的学习。

1.3 多功能融合模块

传统多模态融合方法通常假设模态间关系固定或简单，难以应对校园舆情中图文复杂多变的对应关系。MFFM 跨模态多头注意力机制允许模型在不同的表示子空间中，灵活地评估并权衡不同模态特征的重要性，后续的 Encoder-Decoder 结构则对交互后的特征进行深度重构，进一步集成全局语义，并通过对齐重构损失与分类损失进行多任务学习，从而提升模型的泛化能力与鲁棒性，避免对单一模态或固定融合模式的过拟合。

通过 UFPM 模块所生成的 X_i^{fusion} 特征将被输入至跨模态交互模块，进而生成融合多模态信息的增强特征 $CrossAttention_{i \rightarrow j}$ 。对这些特征进行拼接后形成统一输入，经由 Encoder-Decoder 结构进一步重构高维语义表示，最终输出面向校园网络社会事件分类 PS_i 及社会情绪分级的预测结果 Em_i 。模型通过多任务优化机制，基于总体损失函数 L_{total} 协调单模态与多模态任务之间的训练过程，从而提升整体泛化能力。对于任意两个模态 i 和 j ，将模态 i 作为 Query，可计算其与模态 j 之间的交叉注意力关系。

1.3.1 特征对齐与投影

首先，使用线性映射模态 i 和模态 j 的内部反馈， $X_i = W_i X_i + b_i$ 和 $X_j = W_j X_j + b_j$ ，其中 $X_i \in \mathbb{R}^{D_e \times D_i}$ ， $W_i \in \mathbb{R}^{D_e \times D_i}$ 。然后将二维空间中的模态 i 定义为 Query，模态 j 定义为 Key 和 Value，将单模态抽象特征映射到统一空间，确保模态可比性。将模态特征 $X_i \in \mathbb{R}^{D_e \times D_i}$ 映射至统一的语义空间：

$$Q_i = W_q X_i, K_j = W_k X_j, V_j = W_v X_j \quad (14)$$

式中： W_q, W_k, W_v 为可学习的投影矩阵； d 为隐层维度； $Q_i \in \mathbb{R}^{D_e \times D_i}$ ； $K_j, V_j \in \mathbb{R}^{D_e \times D_j}$ 。

跨模态表示通过对 Value 进行加权求和获得，其中权重由 Query 与 Key 的相似度计算得出。模态 i 对模态 j 的注意力权重可表示为：

$$CrossAttention(Q_i, K_j, V_j) = \text{soft max} \left(\frac{Q_i K_j^T}{\sqrt{d_k}} \right) V_j \quad (15)$$

式中 d_k 为查询和关键字的设置维度。

与单头交叉模态表示不同，多头交叉模态注意使用不同的参数对查询、键和值进行多次线性投影，其可以跨模态表示不同子空间的特征。而后扩展为 h 个注意力头以捕获异构信息：

$$MultiHead(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W_o \quad (16)$$

式中： $\text{head}_k = Attention(Q_i W_k^q, K_j W_k^k, V_j W_k^v)$ ； W_k^q, W_k^k, W_k^v 为分头投影矩阵； W_o 为输出投影矩阵。

1.3.2 Encoder-Decoder 特征重构

通过编码器网络获得融合模态的高维特征，然后使用解码器网络重建特征。本文将 Encoder-Decoder 网络预测的标签和基于融合特征预测的标签合并到多任务学习中，可以提高模型的泛化性能，其主要包含 3 个子网络层：多头注意机制、层归一化和前馈网络。其中，解码器中多头注意层的输入增加了编码器的输出。

首先，将上一步中获取到的不同模态之间的交叉模态注意力 $CrossAttention_{i \rightarrow j}$ 作为输入送入 Encoder-Decoder 进行处理。对跨模态特征 $Z = [CrossAttention_{i \rightarrow j} || CrossAttention_{j \rightarrow i}]$ 编码：

$$Z_{enc} = \text{LayerNorm}(Z + \text{MultiHead}_{self}(Z_{w_k^Q}, Z_{w_k^K}, Z_{w_k^V})) \quad (17)$$

式中: $\text{CrossAttention}_{i \rightarrow j}$ 为模态 i 到 j 的跨模态输出; $Z_{w_k^Q}$ 表示查询矩阵, 生成一系列注意力权重计算的基准向量, 基准向量将决定希望从其他图像或文本模态中关注哪些重要信息。键矩阵 $Z_{w_k^K}$ 提供与 Query 匹配的关联键, 这些键与查询向量进行匹配, 计算其之间的相似度, 从而决定哪些信息是相关的信息; $Z_{w_k^V}$ 计算相似度得分。

Decoder 通过交叉注意力融合编码器信息, 增强跨模态依赖:

$$Z_{dec} = \text{LayerNorm}(Z' + \text{MultiHead}_{cross}(Z', Z_{enc})) \quad (18)$$

式中 Z' 为解码器输入, 来自解码器上一时间步的输出。之后进行归一化, 在解码器后添加线性层, 以评估重建的特征结果并提高网络的泛化性能。将重建的情感信息的预测标签引入到多任务学习可以优化模型参数。这种方法还可以防止模型由于训练不平衡或数据情感表示不均匀而将高维信息预测到固定标签中。生成校园社会舆情分类与多模态情感预测标签的计算公式为:

$$\begin{cases} PS_i = \text{soft max}(W_{PS} \cdot Z_{dec} + b_{PS}) \\ Em_i = \text{soft max}(W_{Em} \cdot Z_{dec} + b_{Em}) \end{cases} \quad (19)$$

最终, 生成校园网络社会事件分类 PS_i 及社会情绪分级数据 Em_i 。

2 实验结果及分析

2.1 数据集及相关模型

实验数据集主要由两部分组成: 公有数据集及自建校园舆情数据集 (university public opinion dataset, UPOD)。MVSA-Single 与 MVSA-Multiple 是一个广泛应用于多模态情感分析研究的基准数据集^[29]。其核心特点是每条数据均包含文本和图像两种模态, 并由人工标注了情感标签。数据采集于 Twitter。MVSA-Single 包含 4869 个有效的“文本-图像”对。MVSA-Multiple 包含 19600 个图文对, 每个图文对由 3 个注释者独立标记。标签体系采用最常用的 3 分类情感标签: Positive (正面)、Negative (负面)、Neutral (中性)。

UPOD 的构建基于多源公开网络平台, 包括微博中的大学话题社区、知乎的校园讨论区、相关论坛板块、高校官方信息发布平台以及教育领域垂直媒体。图 4 展示了 UPOD 数据集类型分布与感情极性分布等基本情况。数据采集依托开源 python 爬虫工具组合, 实现了对目标页面的全结构抓取与动态渲染内容获取。该数据集共包含 8132 个网页的人工标注结果, 标注的基本单位为整个网页, 包含舆情类别与情感标签。参考 SST-5^[30] 等主流数据库, 设置 5 类感情极性标签。标注体系依据前期实证研究与多轮专家咨询构建, 涵盖高校舆情常见类型, 如教学运行、科研诚信、日常生活、校园安全、学生工作、师生互动及社会议题在校园中的反响等。本研究中仅使用文本与图像数据。




图 4 UPOD 数据集数据分布

Fig. 4 Data distribution of the UPOD dataset

为全面评估 KGE-MSA 性能, 本文梳理了近年来相关模型, 并将本文所提 KGE-MSA 模型与这些基线模型在公共数据集上进行了对比分析。

2.1.1 基于注意力与动态融合

CoMN (2018)^[31]设计了一个共享的记忆模块, 采用迭代式的协同注意力, 允许多模态进行多轮双向信息交互。模型侧重于通过循环注意力建立模态联系, 但模态融合方式相对静态, 缺乏对深层、结构化语义关联的建模。

CLMLF (2022)^[16]框架通过对比学习拉近情感一致的跨模态样本表征、推远不一致的样本, 同时采用多层融合策略从单词级别整合文本与图像特征, 以学习更高质量的情感相关共同表征。尽管通过损失函数实现了模态关系的约束, 但模型仍缺乏对跨模态结构化语义关联的显式构建。

MTAMW (2024)^[37], 其核心创新是引入一个多模态自适应权重矩阵, 能够根据文本、视觉、声学等不同模态的情感分析贡献度分配差异化权重, 摆脱了传统方法模态重要性固定或文本偏置的约束。该模型将不同模态的序列拼接后输入一个单流 Transformer 编码器, 并利用多个 Softmax 函数分别为各模态计算注意力权重。

2.1.2 基于特定神经架构

MGNNS (2021)^[32]通过构建复杂的图结构来整合文本、图像等多源信息, 其核心是利用图神经网络的消息传递机制捕捉模态内和模态间的复杂关联。模型通常将不同模态的数据元素表示为图节点, 并依据语义或共现关系构建边, 以形成多通道交互网络。

ITIN (2022)^[33]设计了一种交互网络, 允许文本单词与图像区域之间进行双向、细粒度的信息交互。通过交互机制, 显式地建模这些情感区域和文本单词之间的语义关系, 并基于这些关系生成一个深度融合的、富含跨模态信息的表征, 用于最终情感分类。

MVCN (2023)^[34]构建多视角校准网络, 从特征、预测和优化 3 个视角, 系统性应对模态异质性带来的挑战, 构建了一个系统的校准体系, 从而更好地应对模态异质性带来的挑战。模型侧重于多角度校准与正则化, 以提升模型鲁棒性, 而非通过注入知识来增强语义表示。

TMRN (2023)^[35]强调文本模态在多模态情感分析中的主导作用。设计以文本为中心的交叉注意力模块 (TCCA) 和文本门控自注意力模块 (TGSA), 并引入自适应融合机制决定各模态在融合中的比例。但知识来源仍局限于数据本身的浅层特征, 未显式引入外部或结构化领域知识来深化语义理解。

FRDIN (2024)^[39], 在特征提取阶段, 模型创新地引入了名为 “Resampler” 的视觉特征增强模块, 并使用基于集成学习思想的图神经网络来提升文本特征的稳定性, 从源头修复和强化输入信息。在模态交互阶段, 其设计了一个以文本模态为中心的动态路由网络, 通过精心构建的 4 种交互单元, 以密集连接方式堆叠, 从而动态且有效地学习模态间的一致性与互补性特征。

2.1.3 基于外部知识增强

K-BERT (2020)^[18]将外部知识图谱三元组注入原始句子, 与文本序列共同输入 Transformer, 增强领域语义表示。模型核心创新在于通过软位置和可见矩阵解决知识注入可能带来的 “知识噪声” 问题。主要用于纯文本的知识增强, 缺乏对多模态数据的处理与融合机制。

BHG (2024)^[36], 其核心创新是构建了一个二部异构图模型, 将对话中的话语和外部常识知识分别建模为图中的异质节点, 并引入两种额外的知识聚合节点来自动进行知识筛选与交互。模型还提出了多维异构图变换器来进行图推理, 能够在处理不同节点类型时保持其特征空间和维度的独立性, 从而防止信息丢失。

2.1.4 基于信息解耦与优化

MIBSA (2024)^[38]基于信息瓶颈理论, 解耦模态的共有信息与私有信息, 并设计双子空间投影进行分别学习。侧重于信息解耦与过滤, 以保留有效信息, 其知识来源仍是数据驱动的特征, 而非外部结构化知识。

CRNet (2024)^[40]首先将语音和视觉模态分别编码为 “不变” 与 “特定” 两个子空间, 再让其与主导的语言模态进行精细交互, 以构建联合表征。为此, 其创新性地设计了一个基于梯度的表征增强模块 (GRE), 用于有效提取表征矩阵中的显著变化信息, 并结合多任务策略优化不同表征组合的训练过程。

2.1.5 基于引导与校准

TETFN（2023）^[17]，设计了文本引导的跨模态交互模块，提升情感特征对齐的精准性，通过增大文本模态的权重提升特征对齐精度，减少融合中的冗余信息。与 TMRN 思路类似，通过文本引导其他模态，但未解决领域术语带来的深层语义稀疏问题。

本文主要选用准确率（Accuracy）与 F1 分数 (F1-score) 来衡量模型的精确度。其计算公式如下：

$$Precision = \frac{TP}{TP + FP} \tag{20}$$

$$Recall = \frac{TP}{TP + FN} \tag{21}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{22}$$

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{23}$$

式中：TP 为正确预测的正例数；TN 为正确预测的负例数；FP 为错误预测的正例数；FN 为错误预测的负例数。

2.2 对比实验

在数据预处理阶段，本文遵循 Xu 等^[41]的研究方法，删除不一致的图像标签和文本标签的图像文本对。如果一个标签是积极或消极的，而另一个是中性的，则这个图像文本对的情感极性视为积极的或消极的。将数据集分别划分成训练集、验证集和测试集，比例为 8：1：1，如表 1 所示。

表 1 数据集统计信息
Tab. 1: Statistical Information of the Dataset

数据集	训练集	验证集	测试集	总计
MVSA-Single	3 611	450	450	4 511
MVSA-Multiple	13 624	1 700	1 700	17 024
UPOD	6 512	810	810	8 132

本文所提方法运行的操作系统为 Ubuntu 16.04 LTS，处理器型号为 Intel core i7-8700。学习率为 0.0003，dropout 为 0.2，优化器为 Adam，batchsize 为 64，epoch 为 60。

为全面验证 KGE-MSA 模型在多模态校园社会情绪感知任务中的性能，以 MVSA、UPOD 数据集为测试对象，选取 2018~2024 年间在该领域具有代表性的 11 种基线模型开展对比实验，从 Accuracy 与 F1 两个核心指标切入，系统分析 KGE-MSA 在语义建模、跨模态融合及领域适配能力上的提升机制，实验结果如表 2 所示。图 5 为不同模型在 UPOD 数据集上的测试结果。

表 2 MVSA 数据集实验

Tab. 2 MVSA dataset experiment

						%
类型	模型	MVSA-Single(Accuracy)	MVSA-Single(F1)	MVSA-Multiple(Accuracy)	MVSA-Multiple(F1)	UPOD
基于注意力与动态融合	CoMN (2018)	61.30	58.21	63.14	55.47	71.25
	CLMLF (2022)	71.46	71.98	72.04	72.43	83.81
	MTAMW (2024)	74.77	73.84	71.34	70.74	85.20
	MGNNs (2021)	71.32	70.06	69.51	69.81	82.47
基于特定神经架构	ITIN (2022)	72.03	71.74	73.48	73.51	83.22
	MVCN (2023)	72.65	72.48	70.35	69.81	84.87
	TMRN (2023)	73.51	73.02	71.19	69.38	85.18
	FRDIN (2024)	75.06	74.55	72.07	71.55	85.72
基于外部知识增强	K-BERT (2020)	70.07	71.24	70.25	68.47	77.53
	BHG (2024)	74.86	73.20	73.11	68.43	85.24

基于信息解耦与优化	MIBSA (2024)	74.33	73.31	72.01	69.70	84.43
	CRNet (2024)	75.11	74.98	73.31	72.01	86.31
基于引导与校准	TETFN (2023)	73.84	72.70	70.98	68.76	84.21
/	KGE-MSA	76.64	75.33	73.64	72.56	86.89




图 5 不同模型的准确率比较

Fig. 5 Comparison of accuracy rates of different models

早期多模态融合模型作为基于协同记忆网络的代表性方法，其通过迭代式协同注意力实现文本与图像的双向交互，但受限于传统序列建模范式，无法有效处理模态语义割裂问题。近期注意力模型性能逐步逼近 75% 的 Accuracy 阈值，但受限于“无知识增强”的技术框架，在处理含领域专属术语的短文本时，仍存在语义理解不充分的问题。KGE-MSA 在 UPOD 上表现优异，主要得益于知识图谱成功嵌入了校园实体关系，使模型能准确理解如“食堂涨价”、“体育馆开放”等事件的情感指向。

KGE-MSA 通过 UFPM 与 MFFM 模块，解决了传统多模态模型因静态融合导致的模态权重失衡问题。其核心在于利用 MFFM 中的跨模态多头注意力机制，动态评估并分配文本、图像与知识图谱特征的权重，并通过 Encoder-Decoder 结构增强表示稳健性。该动态融合策略显著提升了模型对复杂数据的适应能力，在 MVSA-Multiple 数据集上，其 F1 值达 72.56%，优于 FRDIN 模型 1.01%。

2.3 消融实验

为系统评估 KGE-MSA 模型中各核心模块的贡献，本研究设计了一系列消融实验。实验采用 Accuracy 与 F1 作为评价指标，详细结果见表 3。在仅使用单模态融合的基础上引入知识图谱增强模块后，模型性能出现显著提升。与 BERT 单模态基线相比，在 MVSA-Single 数据集上准确率 (Accuracy) 提升 4.22%。这一改进主要得益于该模块构建的“文本-图像”跨模态融合知识图谱，通过结构化语义关联有效缓解了短文本的语义稀疏问题，并改善了传统多模态模型中常见的“模态语义割裂”现象。

表 3 消融实验

Tab. 3 Ablation Experiment

模型	MVSA-Single(Accuracy)	MVSA-Single(F1)	MVSA-Multiple(Accuracy)	MVSA-Multiple(F1)
BERT	70.11	68.98	67.32	66.54

ResNet-50	67.81	65.32	63.42	60.94
+KGE	74.33	73.31	72.01	69.70
+KGE, UFPM	75.06	74.55	72.07	71.55
+UFPM, MFFM	75.11	74.98	73.31	72.01
KGE-MSA	75.84	75.33	73.64	72.56

进一步添加 UFPM 模块后，模型在 MVSA-Single 数据集上的准确率相较“仅添加 KGE”的实验组进一步提升 0.73%。UFPM 的作用机制源于其多尺度特征提取与冗余信息抑制能力：利用 TCN 中的膨胀卷积捕获长程依赖，结合 TCN-BiGRU 处理短时上下文特征，并通过多尺度卷积与自注意力机制强化关键特征、抑制冗余信息。

本文还通过对比实验评估了知识增强模块的有效性。文本知识图谱基于 Qwen2.5-72B-Instruct 进行实体关系抽取，图像知识图谱借助 InternVL2.5-38B-MPO 识别空间及逻辑关系。如表 4 所示，KGE-MSA 在领域适应性与语义增强指标上均取得更优结果，证实了其相较于传统外部知识库方法的优势。

表 4 外部知识增强消融实验

Tab. 4 Ablation experiment of external knowledge enhancement				%
模型	UPOD(Accuracy)	UPOD(F1)	MVSA-Multiple(Accuracy)	MVSA-Multiple(F1)
w/o KGE	84.33	83.31	73.31	72.01
External Knowledge	86.01	85.25	73.47	72.42
KGE-MSA	86.89	86.81	73.64	72.56

本文设计了无知识增强的模型（w/o KGE）与引入外部教育领域知识库的对比实验，通过百度百科接口检索文本 T 相互关联的页面信息，将检索后的摘要文本使用 BERT 模型生成特征拼接至原始输入 T，生成增强文本。

w/o KGE 组为完全移除知识增强模块，仅依赖原始文本与图像特征进行多模态融合，验证知识增强的必要性；External Knowledge 组为采用传统外部知识库增强方式，通过调用百度百科开放接口，检索与文本实体相关的教育领域知识，实现知识补充。w/o MFFM 为 KGE-MSA 模型排除 MFFM 模型。w/o UFPM 为 KGE-MSA 模型排除 UFPM 模型。由表 4 及图 6 可知，KGE 模块在校园领域舆情分析中的表现显著优于传统外部知识库，且在通用场景下性能稳定。




图 6 消融实验数据分布

Fig. 6 Distribution of ablation experiment data

在 UPOD 校园数据集上的实验结果表明，KGE-MSA 取得了最佳性能，其准确率相较于 External Knowledge 方法提高了 1.18%。这一优势主要源于 UPOD 数据中包含大量校园场景特有的术语和实体关系，KGE 模块能够针对该领域精准构建结构化知识图谱，并有效建模实体之间的动态语义关联。相比之下，External Knowledge 方法仅通过文本拼接方式引入外部术语定义，难以捕捉实体间深层的语义联系，甚至可能引入无关信息，从而对情感判断与事件分类产生干扰。

3 结论

本文针对校园社交媒体舆情数据语义稀疏、模态割裂及领域适配性不足等问题，提出了一种知识图谱增强的多模态融合分析框架 KGE-MSA。该框架通过构建跨模态领域知识图谱实现结构化语义补充，结合单模态特征提纯与动态多模态融合机制，有效提升了情感极性识别与事件分类任务的性能。本文主要贡献如下：

1) 提出“知识图谱增强 + 跨模态多头注意力”联合优化机制，构建“知识图谱- 文本- 图像”自适应交互框架，通过结构化语义对齐与动态特征加权，缓解短文本语义稀疏与模态割裂问题。

2) 设计面向校园场景的知识增强策略，利用领域适配的大语言模型提取校园专属实体与关系，构建融合领域术语与事件关联的跨模态知识图谱，突破通用预训练模型在垂直场景中的适应瓶颈。

3) 构建“特征提纯- 动态重构”双模块融合架构，其中单模态特征处理模块融合多尺度卷积与自注意力机制，实现长程依赖与局部特征的协同捕获；多功能融合模块通过跨模态注意力与编码- 解码结构，实现动态权重分配与特征重构。

4) 针对校园舆情数据特点，设计专用数据预处理与标注体系，并结合公开数据集与自建校园数据集进行系统实验。结果表明，所提方法在情感极性识别与事件分类任务上均优于主流基线模型，为校园舆情分析提供了准确、鲁棒的解决方案。

该研究不仅在多模态情感分析的技术路径上提供了新思路，也为高校舆情治理提供了切实可行的智能支持。未来的研究方向包括探索知识图谱的动态更新机制、引入多模态预训练模型以提升语义表征能力以及拓展模型在更多教育相关场景中的应用。

参考文献

- [1] 孟黎,谢良旭.人工智能时代高校网络舆情治理的应对研究[J].传播与版权,2025,(17):66
MENG LI, XIE LIANGXU. Research on the Response to University Online Public Opinion Governance in the Artificial Intelligence Era[J]. Communication & Copyright, 2025, (17):66. DOI:10.16852/j.cnki.45-1390/g2.2025.17.027
- [2] 聂小雄.人工智能时代高校网络舆情治理面临的风险及其应对[J].学校党建与思想教育, 2025(5):83
NIE XIAOXIONG. Risks and Countermeasures of University Online Public Opinion Governance in the Artificial Intelligence Era[J]. Party Building and Ideological Education in Schools, 2025(5):83
- [3] ZHANG R Q, WEN H R, LIN Z, et al. Artificial intelligence-driven drug toxicity prediction: Advances, challenges, and future directions[J]. Toxics, 2025, 13(7): 525.DOI:10.3390/toxics13070525
- [4] CUI W. Research on the effectiveness of probabilistic stochastic convolution neural network algorithm in physical education teaching evaluation[J]. Computational intelligence and neuroscience, 2022, 2022: 4921846.DOI: 10.1155/2022/4921846
- [5] 韩中美, 张歆.人机协同的复合脑启发: 群体认知失调情境下学习者生理—心理—行为耦合的新模式[J].电化教育研究, 2025, 46(8):30
HAN Zhongmei, ZHANG Xin. Human-machine synergistic composite brain inspiration: A new model of learner physiology-psychology-behavior coupling in group cognitive dissonance situations[J]. e-Education Research, 2025, 46(8):30
- [6] ZHANG Y X, WANG Y, FAN G M, et al. Multimodal teaching analytics: The application of SCORM courseware technology integrating 360-degree panoramic VR in historical courses[J]. Scientific reports, 2023, 13(1): 18893
- [7] YANG Z Q, ZHOU L Y, JING Z J. A novel affective analysis system modeling method integrating affective cognitive model and Bi-LSTM neural network[J]. Computational intelligence and neuroscience, 2022, 2022: 1856496.DOI: 10.1155/2022/1856496
- [8] WU L, HOI S C H, YU N H. Semantics-preserving bag-of-words models and applications[J]. IEEE transactions on image processing, 2010, 19(7): 1908.DOI: 10.1109/tip.2010.2042094
- [9] SALTON G, MCGILL M J. Introduction to modern information retrieval[M]. New York: McGraw-Hill, 1983
- [10] PENNINGTON J, SOCHER R, MANNING C. Glove: Global vectors for word representation[C]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). Doha, Qatar. Stroudsburg, PA, USA: ACL, 2014: 1532
- [11] WANG L, WANG W, CHENG X. Bimodal emotion recognition model for speech-text based on Bi-LSTM-CNN[J]. Computer engineering and applications, 2022, 58(4): 192
- [12] 杨力, 文腾, 廖远, 等.面向方面级多模态情感分析的双交互异构图神经网络模型[J].计算机科学与探索, 1
YANG Li, WEN Teng, LIAO Yuan, et al. Dual-Interactive Heterogeneous Graph Neural Network Model for Aspect-Based Multimodal Sentiment Analysis[J]. Journal of Frontiers of Computer Science and Technology, 1
- [13] 王健, 赵小明, 王成龙, 等.基于深度特征交互与层次化多模态融合的情感识别模型[J].计算机应用研究, 2025, 42(7):1978
WANG Jian, ZHAO Xiaoming, WANG Chenglong, et al. Emotion recognition model based on deep feature interaction and hierarchical multimodal fusion[J]. Application Research of Computers, 2025, 42(7):1978
- [14] CHEN S H, TANG J J, ZHU L, et al. A multi-stage dynamical fusion network for multimodal emotion recognition[J]. Cognitive neurodynamics, 2023, 17(3): 671.
- [15] 陈巧红,项深祥,方贤,等.跨模态自适应特征融合的视觉问答方法[J].哈尔滨工业大学学报,2025,57(4):94
CHEN Qiaohong, XIANG Shenxiang, FANG Xian, et al. Visual Question answering method with cross-modal adaptive feature fusion[J]. Journal of Harbin Institute of Technology, 2025, 57(4):94.
- [16] LI Z, XU B, ZHU C H, et al. CLMLF: A contrastive learning and multi-layer fusion method for multimodal sentiment detection[C]//Findings of the Association for Computational Linguistics: NAACL 2022. Seattle, USA. Stroudsburg, PA, USA: ACL, 2022: 2282.
- [17] WANG D, GUO X T, TIAN Y M, et al. TETFN: A text enhanced transformer fusion network for multimodal sentiment analysis[J]. Pattern recognition, 2023, 136: 109259.DOI: 10.1016/j.patcog.2022.109259
- [18] LIU W, ZHOU P, ZHAO Z, et al.K-BERT: Enabling language representation with knowledge graph[C]//National Conference on Artificial Intelligence.Association for the Advancement of Artificial Intelligence (AAAI), 2020.DOI:10.1609/AAAI.V34I03.5681.DOI: 10.1609/AAAI.V34I03.5681
- [19] BAI H, WANG D L, FENG S, et al.EKBSA: A Chinese sentiment analysis model by enhancing K-BERT[J].Journal of

Computer Science and Technology, 2024, 40(1):60.DOI:10.1007/s11390-024-2870-9.DOI: 10.1007/s11390-024-2870-9

- [20] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.
- [21] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]//International Conference on Learning Representations (ICLR). 2021. [2025-08-26].DOI:10.48550/arXiv.2010.11929
- [22] KIRILLOV A, MINTUN E, RAVI N, et al. Segment anything[J]. arXiv preprint arXiv:2304.02643, 2023
- [23] JIANG X , SHEN Y , SHI Z , et al. MM-ChatAlign: A novel multimodal reasoning framework based on large language models for entity alignment[J]. Findings of the Association for Computational Linguistics: EMNLP 2024, 2024: 2637. DOI:10.18653/v1/2024.findings-emnlp.148
- [24] SHANG Y , FU K , ZHANG Z , et al. MERGE: A Modal Equilibrium Relational Graph Framework for Multi-Modal Knowledge Graph Completion[J]. Sensors (14248220), 2024, 24(23): 7605. DOI:10.3390/s24237605
- [25] ZHU L , ZHAO H , ZHU Z , et al. Multimodal sentiment analysis with unimodal label generation and modality decomposition[J]. Information Fusion, 2025, 116: 102787. DOI:10.1016/j.inffus.2024.102787
- [26] ZHANG Y , XIE D , LUO D , et al. Emotional boundaries and intensity aware model for incomplete multimodal sentiment analysis[J]. Digital Signal Processing, 2025, 160: 105023. DOI:10.1016/j.dsp.2025.105023
- [27] BAI S J, KOLTER J Z, KOLTUN V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling[J]. arXiv preprint arXiv:1803.01271, 2018.DOI:10.48550/arXiv.1803.01271
- [28] CHO K, VAN MERRIENBOER B, BAHDANAU D, et al. On the properties of neural machine translation: encoder–decoder approaches[J]. arXiv preprint arXiv:1409.1259, 2014.DOI:10.48550/arXiv.1409.1259
- [29] NIU T, ZHU S A, PANG L, et al. Sentiment analysis on multi-view social data[C]//MultiMedia Modeling. Cham: Springer International Publishing, 2016: 15
- [30] SOCHER R, PERELYGIN A, WU J, et al. Recursive deep models for semantic compositionality over a sentiment treebank[C]//Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing. Seattle, Washington, USA. Stroudsburg, PA, USA: ACL, 2013: 1631.DOI:10.1109/CVPR.2013.123
- [31] XU N, MAO W J, CHEN G D. A co-memory network for multimodal sentiment analysis[C]//The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. Ann Arbor MI USA. ACM, 2018: 929.DOI:10.18653/v1/2021.acl-long.47
- [32] YANG X C, FENG S, ZHANG Y F, et al. Multimodal sentiment detection based on multi-channel graph neural networks[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online. Stroudsburg, PA, USA: ACL, 2021: 328
- [33] ZHU T, LI L D, YANG J F, et al. Multimodal sentiment analysis with image-text interaction network[J]. IEEE transactions on multimedia, 2022, 25: 3375
- [34] WEI Y W, YUAN S Z, YANG R S, et al. Tackling modality heterogeneity with multi-view calibration network for multimodal sentiment detection[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Toronto, Canada. Stroudsburg, PA, USA: ACL, 2023: 5240
- [35] LEI Y X, YANG D K, LI M C, et al. Text-oriented modality reinforcement network forMultimodal sentiment analysis fromUnaligned multimodal sequences[C]//Artificial Intelligence. Singapore: Springer Nature Singapore, 2024: 189
- [36] YANG K , ZHANG T , JI S ,et al.A bipartite graph is all we need for enhancing emotional reasoning with commonsense knowledge[J]. 2023.DOI:10.1145/3583780.3614758
- [37] WANG Y F, HE J H, WANG D, et al. Multimodal transformer with adaptive modality weighting for multimodal sentiment analysis[J]. Neurocomputing, 2024, 572: 127181
- [38] LIU W, CAO S C, ZHANG S. Multimodal consistency-specificity fusion based on information bottleneck for sentiment analysis[J]. Journal of king Saud university - computer and information sciences, 2024, 36(2): 101943.DOI:10.1016/j.jksuci.2024.101943
- [39] ZENG Y F, LI Z X, CHEN Z B, et al. A feature-based restoration dynamic interaction network for multimodal sentiment analysis[J]. Engineering applications of artificial intelligence, 2024, 127: 107335
- [40] SHI H, PU Y Y, ZHAO Z P, et al. Co-space Representation Interaction Network for multimodal sentiment analysis[J]. Knowledge-based systems, 2024, 283: 111149
- [41] XU N, MAO W J. MultiSentiNet: A deep semantic network for multimodal sentiment analysis[C]//Proceedings of the 2017 ACM on Conference on Information and Knowledge Management. Singapore : ACM, 2017: 2399.DOI:10.1016/j.knosys.2023.110789