

融合课程知识图谱与图注意力网络的推荐模型研究^{*}肖克江^{1,2} 陈亮¹ 方铄¹ 庞世燕¹ 邱杰凡³ 董亚宁¹ 杨文齐¹ 郭山锋¹¹(华中师范大学人工智能教育学部 武汉 430079)²(数字教育湖北省重点实验室 武汉 430079)³(浙江工业大学计算机科学与技术学院 杭州 310023)

摘要:【目的】针对在线课程推荐存在数据稀疏、冷启动和特征利用不充分的问题,提出一种融合课程知识图谱与图注意力网络的推荐模型(CKGAT)。【方法】CKGAT的学习者模块通过特征交叉层和全连接层分别提升学习者特征表示的记忆和泛化能力,课程模块基于图注意力网络挖掘课程实体间的高阶关联特征。对两个模块的输出向量进行点积计算后,得到推荐结果。【结果】在基于 MoocCubeX 数据集的对比实验中,CKGAT在ACC、F1值和AUC三个指标上相较于最好的基线模型分别提升1.28%、1.62%和1.00%。【局限】本文的课程知识图谱略显单薄,模型的计算复杂度可进一步优化。【结论】本文提出的CKGAT取得了较好的推荐结果,有助于提升在线课程推荐效果。

关键词: 在线课程 推荐系统 知识图谱 图注意力网络 特征交叉**分类号:** TP393 G250**DOI:** 10.11925/infotech.2096-3467.2024.1116

引用本文: 肖克江, 陈亮, 方铄等. 融合课程知识图谱与图注意力网络的推荐模型研究[J]. 数据分析与知识发现, 2025, 9(12): 96-109.(Xiao Kejiang, Chen Liang, Fang Shuo, et al. Recommendation Model Integrating Course Knowledge Graph and Graph Attention Network[J]. Data Analysis and Knowledge Discovery, 2025, 9(12): 96-109.)

1 引言

在线课程推荐有助于提升资源利用效率。传统的推荐模型只利用交互信息,容易面临数据稀疏和冷启动问题。随着深度学习的发展^[1],知识图谱作为一种辅助信息被应用在推荐任务中,这在一定程度上缓解了数据稀疏和冷启动问题。然而,知识图谱是基于图的数据结构,普通神经网络难以充分利用其特征。同时,知识图谱需要较高的计算成本,如何有效控制图谱规模与汇聚节点信息是当前研究面临的关键问题。

针对上述问题,本文提出一种融合课程知识图谱与图注意力网络的推荐模型(Recommendation Model Fusion Course Knowledge Graph and Graph Attention Network, CKGAT)。CKGAT首先构建一个课程知识图谱,并结合图注意力网络学习课程节点的特征表示。为增强学习者的特征表示,CKGAT单独对学习者的特征进行交叉和全连接操作。最后,在公开的MoocCubeX数据集上对CKGAT进行对比实验、消融实验、参数敏感性实验和计算效率分析,并在工程应用中设计了一种学习者反馈机制来提高推荐内容质量和学习者满意度。

通讯作者(Corresponding author): 邱杰凡(Qiu Jiefan), ORCID: 0000-0003-2198-1875, E-mail: qiujiiefan@zjut.edu.cn。

^{*}本文系国家自然科学基金项目(项目编号: 62377023)、湖北省自然科学基金联合基金重点项目(项目编号: 2025AFD195)和浙江省高等教育“十四五”研究生教学改革项目(项目编号: JGCG2024075)的研究成果之一。

The work is supported by the National Natural Science Foundation of China (Grant No. 62377023), the Key Project of Hubei Provincial Natural Science Foundation Joint Found (Grant No. 2025AFD195), the Graduate Teaching Reform Project for Higher Education During “the 14th Five-Year Plan” in Zhejiang Province (Grant No. JGCG2024075).

本文贡献如下:

(1) 基于双塔模型思想, 将模型分为学习者模块和课程模块, 两个模块仅在最后的预测部分产生关联, 从而降低模型复杂度。

(2) 学习者模块基于 Wide&Deep 模型思想^[2], 利用学习者的特征信息获得学习者的特征表示。通过特征交叉和全连接计算, 分别提升特征表示的记忆和泛化能力。

(3) 课程模块仅基于课程的特征信息构建课程知识图谱, 避免引入学习者而导致图谱过大的问题。通过图注意力网络动态分配邻居节点的权重, 优化课程节点的特征表示。

2 相关工作

2.1 基于特征交叉的推荐

在推荐任务中, 协同过滤依赖于用户-物品交互矩阵, 利用用户和物品间的交互信息进行推荐^[3]。矩阵分解^[4]缓解了协同过滤中交互矩阵过大、泛化能力弱的问题。神经网络协同过滤 (Neural Collaborative Filtering, NeuralCF)^[5]进一步使用深度神经网络替代矩阵分解中的内积操作。与仅利用交互特征不同的是, 基于内容的推荐^[6]依赖于物品的内容特征。面对众多特征, 原始特征可能无法完全表达数据中的复杂关系, 而通过特征交叉可以丰富特征的表达。因子分解机 (Factorization Machine, FM)^[7]对每个特征学习一个隐向量, 通过计算两个特征隐向量的内积实现特征交叉, 从而提升特征表达能力。场感知因子分解机^[8]在 FM 模型的基础上增加特征域的概念, 使同一特征在不同域上具有不同的向量表示。为使模型自动学习特征组合, 一些研究还将深度学习与特征交叉相结合^[9]。基于因子分解机的神经网络^[10]利用 FM 模型预训练得到的特征隐向量初始化深度神经网络的嵌入层, 提升了模型训练效率和特征表达能力。深度交叉模型^[11]通过嵌入层、残差单元和评分层自动学习特征间的复杂关系, 实现了端到端的特征深度交叉。Wide & Deep 模型^[2]将单层的线性模型和深度神经网络相结合, 采用双塔结构, 通过 Wide 部分的特征交叉增强模型的记忆能力, 通过 Deep 部分的深度神经网络增强模型的泛化能力。众多研究对 Wide & Deep 模型的

Wide 与 Deep 部分进行改进, 提出了相关变体, 例如 Deep & Cross 模型^[12]、DeepFM 模型^[13]等。此外, 注意力因子分解机 (Attention Factorization Machine, AFM)^[14]将注意力机制应用到特征交叉中, 强化重要特征, 使模型的表达能力进一步提升。与传统的协同过滤方法相比, 这些基于特征交叉的推荐通过引入非线性特征, 提高了模型的表示能力, 但面临数据稀疏和冷启动的问题。

2.2 基于知识图谱的推荐

在推荐任务中引入辅助信息可缓解数据稀疏和冷启动问题^[15]。知识图谱作为一种辅助信息, 由三元组 (头实体、关系、尾实体) 构成, 将其融入推荐模型能够提高推荐结果的准确性^[16]。根据用户节点是否参与图谱构建, 知识图谱主要分为两大类^[17]: 物品知识图谱与协同知识图谱。前者只单独将物品实体及其关系纳入图谱, 并不涉及用户实体; 后者则将用户实体也纳入图谱, 形成用户-物品交互网络与物品知识图谱相结合的结构。虽然知识图谱中的实体和关系为推荐模型提供了丰富的语义信息, 但其具有复杂的图结构, 需要有效的方法挖掘其中的语义信息。目前, 主流的知识图谱推荐方法可分为基于嵌入的方法、基于路径的方法和混合方法^[18]。

基于嵌入的方法旨在学习知识图谱中实体和关系的嵌入向量^[19]。其中, TransE^[20]能有效建模一对一的简单关系, 但难以处理自反关系与一对多关系。TransH^[21]优化了自反关系, 但难以处理多对多关系。TransR^[22]通过将实体投影到关系向量空间中, 能更好地反映实体和关系的多样性及复杂性。协同知识嵌入 (Collaborative Knowledge base Embedding, CKE)^[23]使用 TransR 学习知识实体的向量表示, 并将物品嵌入向量和用户嵌入向量直接用于评分预测, 但模型容易过拟合, 泛化能力较弱。TransD^[24]解决了 TransR 中实体和关系映射矩阵固定的问题, 使得每个实体-关系对都有独特的映射矩阵。李锴君等^[25]使用 TransD 对存储在图谱结构中的实体和关系进行向量化处理, 并将 TransD 与 TransE、TransH、TransR 进行比较, 验证了使用 TransD 的优势。基于路径的方法旨在利用知识图谱的结构特征探索实体间的多种连接方式^[26]。HeteRec^[27]与 SemRec^[28]是典型的元路径推荐方法, 通过计算不同元路径下实体

间的语义相似度优化用户和物品间的多种关联路径。但是,基于元路径的推荐依赖元路径的质量^[29]。基于混合的方法则在引入向量表示的同时充分利用实体连接关系,实现精准推荐^[30]。例如,李慧等^[31]将学术知识图谱的结构信息融入到节点的向量表示中,通过有偏随机游走与注意力机制生成论文推荐列表,实现了更准确的论文推荐。

从上述方法来看,多数研究将深度学习用于知识图谱,通过传统神经网络对用户和物品进行特征表示学习,捕捉实体间的关系,提升推荐的精度和效果。但知识图谱属于典型的图结构数据,传统的深度神经网络适用于欧氏数据,对图结构数据的特征利用仍存在不充分的问题。

2.3 基于图神经网络的推荐

图神经网络拥有强大的图结构数据建模能力,能够挖掘知识图谱中的高阶信息。常见的图神经网络有图卷积网络^[32]和图注意力网络^[33]。图卷积网络主要通过卷积操作迭代地聚合邻居节点的信息到中心节点。Pin-Sage 模型^[34]是首个在工业级推荐系统中成功应用图卷积网络的模型。神经图协同过滤(Neural Graph Collaborative Filtering, NGCF)^[35]应用图卷积网络的核心思想,通过图卷积操作传播和更新用户及物品的嵌入向量。轻量级图卷积网络(Light Graph Convolutional Network, LightGCN)^[36]精简 NGCF 模型,弃用了特征转换和非线性激活等结构。知识图谱卷积网络(Knowledge Graph Convolutional Network, KGCN)^[37]在知识图谱上使用图卷积网络进行消息聚合,取得了较好的效果。与图卷积网络相比,图注意力网络的特点在于引入注意力机制聚合节点特征信息,能够动态赋予相邻节点不同的权重。知识图谱注意力网络(Knowledge Graph Attention Network, KGAT)^[38]将协同知识图谱与图注意力网络相结合,细致地区分各个邻居节点的重要程度,使模型能够更好地利用图谱中的高阶信息,提升推荐的准确性。众多研究借鉴了 KGAT 模型的思想,将其应用到特定领域。徐春等^[39]将协同知识图谱引入旅游推荐系统中,提出了一种融合知识图谱和图注意力网络的旅游推荐算法。樊海玮等^[40]基于类似的思路提出了一种引文推荐算法。然而,由于协同知识图谱纳入了用户实体,

模型需要随着用户的更新而重建图谱,图注意力网络也需要对相邻节点间的权重逐一进行计算。当图谱规模过大时,上述过程将变得繁琐且易引入噪声。

综上,融合知识图谱与图注意力网络的推荐能够挖掘高阶信息,提升推荐效果。但用户规模的增加会导致知识图谱体积迅速扩大,增加了计算成本。对于在线课程推荐而言,学习者的往来更替会产生大量沉默用户和流失用户。因此,是否将学习者纳入知识图谱成为一个关键问题。如果纳入,则会导致知识图谱的体积迅速膨胀,难以负担计算成本,且大量沉默用户或流失用户会在一定程度上影响模型表达。如果不纳入,则会降低推荐效果。本文通过仅构建课程知识图谱避免引入学习者而导致知识图谱过大的问题。同时,利用学习者的特征信息获得学习者的特征表示,借助特征交叉等操作提升学习者嵌入向量的表示能力,缓解课程知识图谱中未使用学习者特征的问题。

3 CKGAT 模型

3.1 模型总体结构

本文提出的 CKGAT 模型结构如图 1 所示,包括上半部分的学习者模块和下半部分的课程模块。学习者模块通过学习者特征嵌入层和学习者特征提取层得到学习者嵌入向量。课程模块通过课程知识图谱嵌入层和课程注意力传播层得到课程嵌入向量。对两类嵌入向量进行点积计算得到预测结果。

3.2 学习者特征嵌入层

(1) 特征嵌入部分

该部分将学习者原始特征转化为特征的嵌入向量。学习者原始特征的样例如表 1 所示。

从 0 开始,对特征信息进行索引编码,得到特征索引与特征的映射关系,如表 2 所示。定义特征索引的最大值为 fea_idx_max ,则用户所涉及的特征数量为 $N = fea_idx_max + 1$ 。随机初始化该部分,定义特征的嵌入向量维度为 dim 。

(2) 学习者嵌入部分

该部分将多个特征的嵌入向量组合为学习者嵌入向量。假设某一学习者嵌入向量为 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_s]$,其中特征有 s 项($s \leq N$), $\mathbf{x}_i$ 代表第 i 项特征的嵌入向量,取自特征嵌入部分。 $\mathbf{X}$ 的尺寸为 $[s, dim]$,则一批学习者嵌入向量的尺寸为




图1 CKGAT 模型结构

Fig.1 Structure of the CKGAT Model

表1 学习者原始特征的样例

Table 1 Sample of Learner's Original Features

学习者	性别	学校	选课
10001	男	s_01	c_100
10002	女	s_01	c_300
10003	男	s_03	c_100
10004	女	s_03	c_300
...	...	...	...

表2 特征索引和特征的映射关系

Table 2 Mapping Relationship Between Feature Index and Feature

特征索引	特征
0	男
1	女
2	s_01
...	...

[batch_size, s, dim], 其中 batch_size 代表批次大小。

3.3 学习者特征提取层

(1) 特征交叉部分

该部分参考 FM 模型的思想, 对学习者的特征向

量进行特征交叉。在考虑二阶交叉时, FM 模型的特征交叉计算如公式(1)所示^[7]。

$$y(X) = w_0 + \sum_{i=1}^s w_i x_i + \sum_{i=1}^s \sum_{j=i+1}^s (o_i \cdot o_j) x_i x_j \quad (1)$$

其中, w_0 为全局偏差; w_i 为特征 i 的权重; o_i, o_j 均为隐因子向量; $(o_i \cdot o_j)$ 为特征 i 和特征 j 的交叉权重; x_i, x_j 分别为特征 i 和特征 j 的嵌入向量。FM 模型对公式(1)的二次项(特征交叉部分)进行化简, 如公式(2)所示^[7]。

$$\begin{aligned} & \sum_{i=1}^s \sum_{j=i+1}^s (o_i \cdot o_j) x_i x_j \\ &= \frac{1}{2} \sum_{i=1}^s \sum_{j=1}^s (o_i \cdot o_j) x_i x_j - \frac{1}{2} \sum_{i=1}^s (o_i \cdot o_i) x_i x_i \\ &= \frac{1}{2} \left(\sum_{i=1}^s \sum_{j=1}^s o_{ij} o_{ij} x_i x_j - \sum_{i=1}^s o_{ii} o_{ii} x_i x_i \right) \quad (2) \\ &= \frac{1}{2} \left(\left(\sum_{i=1}^s o_{ij} x_i \right) \left(\sum_{j=1}^s o_{ij} x_j \right) - \sum_{i=1}^s o_{ii}^2 x_i^2 \right) \\ &= \frac{1}{2} \left(\left(\sum_{i=1}^s o_{ij} x_i \right)^2 - \sum_{i=1}^s o_{ii}^2 x_i^2 \right) \end{aligned}$$

其中, k 是定义因式分解维度的超参数; $\mathbf{o}_{if}$ 为隐因子向量 $\mathbf{o}_i$ 的第 f 个元素。由于该二次项输出的是一个标量, 令隐因子向量 $\mathbf{o}_i$ 为特征 i 的嵌入向量, 基于独热编码思想, $\mathbf{x}_i$ 可被消去, 如公式(3)所示。

$$\sum_{f=1}^s \sum_{j=f+1}^s (\mathbf{o}_i \cdot \mathbf{o}_j) \mathbf{x}_i \mathbf{x}_j = \frac{1}{2} \sum_{f=1}^s (\sum_{i=1}^s \mathbf{o}_i)^2 - \sum_{i=1}^s \mathbf{o}_i^2 \quad (3)$$

为进一步精简计算, 将学习者嵌入向量直接作为隐因子向量。此外, 可以发现, 对 k 维的结果进行求和池化才导致二次项交互信息降维为标量, 而求和池化本质上可以由神经网络替代。基于此, 定义特征交叉部分的计算方式为 $\text{agg}_{FM}(\mathbf{X})$, 如公式(4)所示。

$$\text{agg}_{FM}(\mathbf{X}) = (\sum_{i=1}^s \mathbf{x}_i)^2 - \sum_{i=1}^s \mathbf{x}_i^2 \quad (4)$$

$\text{agg}_{FM}(\mathbf{X})$ 的输入尺寸为 $[\text{batch_size}, s, \text{dim}]$, 输出尺寸为 $[\text{batch_size}, \text{dim}]$ 。最终, 将单个学习者的输出向量定义为 out_{fm} , 如公式(5)所示。

$$\text{out}_{fm} = \text{agg}_{FM}(\mathbf{X}) \quad (5)$$

(2) 全连接层部分

将学习者嵌入向量展开为一维向量 $\mathbf{x} = [x_1, x_2, \dots, x_{s \times \text{dim}}]$, 并定义该层的计算方式如公式(6)所示。

$$\begin{aligned} \mathbf{H}^{(1)} &= \sigma(\mathbf{x} \mathbf{W}^{(1)} + \mathbf{b}^{(1)}) \\ \mathbf{H}^{(2)} &= \sigma(\mathbf{H}^{(1)} \mathbf{W}^{(2)} + \mathbf{b}^{(2)}) \end{aligned} \quad (6)$$

$$\text{out}_{linear} = \sigma(\mathbf{H}^{(2)} \mathbf{W}^{(3)} + \mathbf{b}^{(3)})$$

其中, $\mathbf{H}^{(i)}$, $\mathbf{W}^{(i)}$, $\mathbf{b}^{(i)}$ 分别为第 i 层的输出、权重和偏置; $\sigma(\cdot)$ 为 ReLU 函数。输出层 out_{linear} 的维度为 dim , 与 out_{fm} 相同。

根据上述正向传播流程, 得到两个维度为 dim 的嵌入表示 out_{fm} , out_{linear} 。对 out_{fm} , out_{linear} 进行拼接操作, 如公式(7)所示, 得到最终的学习者嵌入表示 $\mathbf{u}$ 。其中, $\parallel$ 为拼接操作, $\mathbf{u}$ 的维度为 $\text{dim} \times 2$ 。

$$\mathbf{u} = \text{out}_{fm} \parallel \text{out}_{linear} \quad (7)$$

3.4 课程知识图谱嵌入层

该层首先基于课程三元组数据构建课程图谱, 并利用 TransD 模型进行嵌入学习。设课程图谱 $\mathbf{G}$ 的三元组为 $(\mathbf{h}, \mathbf{r}, \mathbf{t})$, $\mathbf{h}, \mathbf{r}, \mathbf{t}$ 分别代表头实体、关系和尾实体的嵌入向量。引入用于动态构造投影矩阵的向量 $\mathbf{h}_p, \mathbf{r}_p, \mathbf{t}_p$, 其中, $\mathbf{h}, \mathbf{t}, \mathbf{h}_p, \mathbf{t}_p \in \mathbb{R}^n$ 且 $\mathbf{r}, \mathbf{r}_p \in \mathbb{R}^m$ 。

TransD 模型通过 $\mathbf{M}_{rh}$ 和 $\mathbf{M}_{rt}$ 将头尾实体从原空间投影到关系空间, 得到投影向量 $\mathbf{h}_\perp$ 和 $\mathbf{t}_\perp$, 如公式(8)所示^[24]。

$$\begin{aligned} \mathbf{h}_\perp &= \mathbf{M}_{rh} \mathbf{h} \\ \mathbf{t}_\perp &= \mathbf{M}_{rt} \mathbf{t} \end{aligned} \quad (8)$$

$\mathbf{M}_{rh}$ 和 $\mathbf{M}_{rt}$ 的计算如公式(9)所示^[24]。其中, $\mathbf{I}^{m \times n}$ 为单位矩阵。

$$\begin{aligned} \mathbf{M}_{rh} &= \mathbf{r}_p \mathbf{h}_p^T + \mathbf{I}^{m \times n} \\ \mathbf{M}_{rt} &= \mathbf{r}_p \mathbf{t}_p^T + \mathbf{I}^{m \times n} \end{aligned} \quad (9)$$

基于 $\mathbf{h}_\perp$ 和 $\mathbf{t}_\perp$, TransD 模型的嵌入评分函数 $f(\mathbf{h}, \mathbf{r}, \mathbf{t})$ 如公式(10)所示^[24]。

$$f(\mathbf{h}, \mathbf{r}, \mathbf{t}) = \|\mathbf{h}_\perp + \mathbf{r} - \mathbf{t}_\perp\|_2^2 \quad (10)$$

将 $(\mathbf{h}, \mathbf{r}, \mathbf{t})$ 视为正样本, 通过随机替换其尾实体构建负样本 $(\mathbf{h}, \mathbf{r}, \mathbf{t}')$, $(\mathbf{h}, \mathbf{r}, \mathbf{t}') \notin \mathbf{G}$ 。该部分的损失计算参考 KGAT 模型的方法^[38], 如公式(11)所示。

$$L_{KG} = \sum_{(\mathbf{h}, \mathbf{r}, \mathbf{t}, \mathbf{t}') \in T} -\ln \sigma(f(\mathbf{h}, \mathbf{r}, \mathbf{t}') - f(\mathbf{h}, \mathbf{r}, \mathbf{t})) \quad (11)$$

其中, $\sigma(\cdot)$ 为 sigmoid 函数; $T = \{(\mathbf{h}, \mathbf{r}, \mathbf{t}, \mathbf{t}') | (\mathbf{h}, \mathbf{r}, \mathbf{t}) \in \mathbf{G}, (\mathbf{h}, \mathbf{r}, \mathbf{t}') \notin \mathbf{G}\}$ 。损失函数旨在使正样本的损失得分尽可能小, 负样本的损失得分尽可能大。

3.5 课程注意力传播层

(1) 图注意力传播

该部分基于图注意力传播的思想, 如图2所示。设某个头实体节点 $\mathbf{h}$ 的邻居节点集合为 N_h , 通过遍历 N_h , 对每条路径求加权和, 即可将邻居节点的信息聚合到头实体。

设 $\mathbf{e}_h, \mathbf{e}_r, \mathbf{e}_t$ 为邻居节点集合 N_h 中某一节点的嵌入表示(由知识图谱嵌入层可得到), 利用图注意力网络计算 $(\mathbf{h}, \mathbf{r}, \mathbf{t})$ 的注意力分数为 $a(\mathbf{h}, \mathbf{r}, \mathbf{t})$, 如公式(12)所示^[33]。

$$a(\mathbf{h}, \mathbf{r}, \mathbf{t}) = (\mathbf{W}_r \mathbf{e}_r)^T \tanh((\mathbf{W}_r \mathbf{e}_h + \mathbf{e}_t)) \quad (12)$$

其中, $\mathbf{W}_r$ 为关系变换矩阵; $\tanh(\cdot)$ 为非线性激活函数。通过公式(12)得到邻居节点集合 N_h 中所有节点的注意力分数。参考图注意力网络的处理方法, 利用 Softmax 函数对注意力分数进行归一化, 得到 $a(\mathbf{h}, \mathbf{r}, \mathbf{t})'$, 如公式(13)所示^[33]。

$$a(\mathbf{h}, \mathbf{r}, \mathbf{t})' = \frac{\exp(a(\mathbf{h}, \mathbf{r}, \mathbf{t}))}{\sum_{(\mathbf{h}, \mathbf{r}^*, \mathbf{t}^*) \in N_h} \exp(a(\mathbf{h}, \mathbf{r}^*, \mathbf{t}^*))} \quad (13)$$

其中, $a(\mathbf{h}, \mathbf{r}, \mathbf{t})$ 是邻居节点集合 N_h 中某一节点




图 2 知识图谱中的图注意力传播

Fig.2 Graph Attention Propagation in Knowledge Graphs

的注意力分数; $a(h, r^*, t^*)$ 为邻居节点集合 N_h 中其他节点的注意力分数。最后, 参考图注意力网络的处理方法, 在头实体节点 h 的位置汇聚所有邻居节点的注意力权重 e_{N_h} , 如公式(14)所示^[33]。

$$e_{N_h} = \sum_{(h, r, t) \in N_h} a(h, r, t) e_t \quad (14)$$

(2) 信息聚合

为保留来自上一层的自身信息, 将 e_{N_h} 与自身的嵌入表示 e_h 进行信息聚合。聚合方式主要有通过 GCN 聚合器、GraphSage 聚合器和 Bi-Interaction 聚合器的聚合。

GCN 聚合器使用求和聚合, 如公式(15)所示^[32], W 为权重矩阵。

$$f_{GCN} = \text{LeakyReLU}(W(e_h + e_{N_h})) \quad (15)$$

GraphSage 聚合器使用拼接聚合, 如公式(16)所示^[41], W 为权重矩阵。

$$f_{GraphSage} = \text{LeakyReLU}(W(e_h || e_{N_h})) \quad (16)$$

Bi-Interaction 聚合器源自 KGAT 模型, 综合考虑求和聚合和元素积聚合, 如公式(17)所示^[38]。

$$f_{Bi-Interaction} = \text{LeakyReLU}(W_1(e_h + e_{N_h})) + \text{LeakyReLU}(W_2(e_h \odot e_{N_h})) \quad (17)$$

其中, W_1, W_2 为权重矩阵。本文使用 Bi-Interaction 聚合器进行信息聚合。最后, 定义头实体节点 h 的一次注意力传播的结果如公式(18)所示。

$$e_h = f_{Bi-Interaction}(e_h, e_{N_h}) \quad (18)$$

(3) 高阶传播

高阶传播对图注意力层进行三次叠加, 定义其计算方法如公式(19)所示。

$$e_h^{(l+1)} = f_{Bi-Interaction}(e_h^{(l)}, e_{N_h}^{(l)}) \quad (19)$$

其中, $e_h^{(l)}, e_{N_h}^{(l)}$ 分别为第 $l = 1, 2, 3$ 层的 e_h, e_{N_h} 。基于上述计算公式, 得到头实体节点 h 在每个图注意力层的输出为 $\{e_h^{(1)}, e_h^{(2)}, \dots, e_h^{(l)}\}$ 。此外, 原始图中的头实体节点 h 的嵌入向量用 $e_h^{(0)}$ 表示。

(4) 全连接层

为使课程嵌入向量与学习者嵌入向量的维度同步, 使用层聚合机制^[42], 将头实体节点 h 的原始图和各图注意力层的输出进行拼接, 得到 e_{in} 作为全连接层的输入, 如公式(20)所示。

$$e_{in} = e_h^{(0)} || e_h^{(1)} || e_h^{(2)} || \dots || e_h^{(l)} \quad (20)$$

基于上述结果, 以学习者嵌入向量的维度作为输出维度, 经过两层全连接层, 如公式(21)所示, 得到最终的课程嵌入向量 v 。

$$\begin{aligned} H^{(1)} &= \sigma(e_{in} W^{(1)} + b^{(1)}) \\ v &= \sigma(H^{(1)} W^{(2)} + b^{(2)}) \end{aligned} \quad (21)$$

其中, $H^{(i)}, W^{(i)}, b^{(i)}$ 分别为第 i 层输出、权重和偏置; $\sigma(\cdot)$ 为激活函数。

3.6 模型预测与损失函数

对基于学习者模块得到的学习者嵌入向量 u 和课程模块得到的课程嵌入向量 v 进行点积计算, 将点积值作为预测结果, 如公式(22)所示。

$$\hat{y}(u, v) = u \cdot v \quad (22)$$

参考 KGAT 模型关于预测损失的计算方法^[38],

使用贝叶斯个性化排序 (Bayesian Personalized Ranking, BPR) 损失函数作为 CKGAT 模型的预测损失, 如公式 (23) 所示。

$$L_{REC} = \sum_{(u, v^+, v^-) \in K} -\ln \sigma(\hat{y}(u, v^+) - \hat{y}(u, v^-)) \quad (23)$$

其中, $K = \{(u, v^+, v^-) | (u, v^+) \in \mathbb{R}^+, (u, v^-) \in \mathbb{R}^-\}$ 为学习者和课程的交互评分数据集; $(u, v^+) \in \mathbb{R}^+$ 为评分为 1 的样本; $(u, v^-) \in \mathbb{R}^-$ 为评分为 0 的样本。

最终, 全局损失函数为 L_{ALL} , 如公式 (24) 所示, 其中 α 为超参数。

$$L_{ALL} = L_{REC} + \alpha L_{KG} \quad (24)$$

4 实验

4.1 数据集及其处理

实验采用 MoocCubeX 数据集^[43], 其数据来自中国最大的 MOOC 网站之一的学堂在线网站, 基本信息如表 3 所示。

表 3 MoocCubeX 数据集的基本信息

Table 3 Basic Information of MoocCubeX Dataset

类别	数量
课程	4 216 门
视频	230 263 个
用户	3 330 294 个
原始行为	2.96 亿
知识概念	637 572 个

(1) 构建实体特征数据集。对用户、视频、课程和知识概念等实体进行数据转换、格式匹配、异常值过滤和条目去重等处理; 将用户回复、用户评论、教师信息和学校信息等实体信息退化为用户和课程实体的特征; 过滤掉选课少于两门的用户以及课程信息丢失的课程。最终得到初始用户特征数据集 (user_info)、课程特征数据集 (course_info)、视频特征数据集 (video_join_course_info)。

(2) 构建初始关系数据集。基于用户观看视频的行为日志构建细粒度的行为信息, 将课程信息作为视频的特征。此外, 考虑到 MoocCubeX 数据集中用户观看视频的行为通过多个条目记录, 根据用户粒度和视频粒度对视频观看时长、倍速等信息进行求和聚合和平均聚合。最终得到初始关系数据集 (relation_info)。

(3) 构建评分数据集。考虑到初始关系数据集中 (relation_info) 的用户 ID 和视频 ID 并不一定存在于初始用户特征数据集 (user_info) 和视频特征数据集 (video_join_course_info) 中, 只筛选出关系信息中用户特征和视频特征完整的数据。基于此, 根据用户观看视频的总时长和平均倍速确定用户对视频的评分, 其主要思想是: 用户观看某视频的时间越久代表该视频越符合用户需求。定义用户对视频的评分规范如公式 (25) 所示。

$$s = \begin{cases} 0, & time_{uv}/speed_{uv} < 180s \\ 1, & time_{uv}/speed_{uv} \geq 180s \end{cases} \quad (25)$$

其中, $time_{uv}$, $speed_{uv}$ 分别是用户 u 观看视频 v 的总时长和平均倍速。之所以选择 180 s 作为阈值, 是因为笔者通过对用户观看视频的数据进行统计分析后发现, 将 180s 作为分界线能够使 0/1 评分样本的数量差异保持在可接受的范围内, 可以防止实验中因 0/1 评分样本数量不平衡而导致模型训练效果欠佳的问题。通过上述操作, 最终得到评分数据集 (rating), 具体格式如表 4 所示。

表 4 评分数据集的格式

Table 4 Format of the Rating Dataset

列名	说明
user_id	用户 ID
video_id	视频 ID
rating	0/1 评分

(4) 构建用户特征数据集。在线课程平台的用户特征主要分为用户填写特征和用户行为特征。基于初始用户特征数据集 (user_info), 通过用户填写特征和用户行为特征构建用户特征数据集 (user_fea), 格式如表 5 所示。其中每门课程可能会有多个类别, 故抽取近期关注的 5 个类别, 如果数据不足则用现有值填充。

(5) 构建课程知识图谱数据集。基于课程的特征信息, 定义 5 对关系, 即 (视频, 课程)、(视频, 类别)、(视频, 学校)、(视频, 老师)、(视频, 概念), 具体如表 6 所示。抽取课程相关的特征作为实体, 形成知识图谱三元组, 最终构建课程知识图谱数据集 (course_kg)。课程知识图谱以“视频”为单位进行构建, 即将“视频”作为课程推荐结果。

表 5 用户特征数据集的格式

Table 5 Format of the User Feature Dataset

列名	说明
user_id	用户 ID
gender	性别
school_id	学校 ID
comment_cnt	评论数量(分箱处理)
reply_cnt	回复数量(分箱处理)
question_cnt	提问数量(分箱处理)
course_i	近期 3 门选课($1 \leq i \leq 3$)
course_cls_i	近期课程的 5 种类别($1 \leq i \leq 5$)

表 6 课程知识图谱中的关系

Table 6 Relationships in the Course Knowledge Graph

关系索引	关系标签	说明
0	v2course	(视频, 来自, 课程)
1	course2v	(课程, 提供, 视频)
2	v2cls	(视频, 属于, 类别)
3	cls2v	(类别, 拥有, 视频)
4	v2school	(视频, 来自, 学校)
5	school2v	(学校, 开课, 视频)
6	v2teacher	(视频, 负责, 老师)
7	teacher2v	(老师, 讲授, 视频)
8	v2concept	(视频, 涉及, 概念)
9	concept2v	(概念, 关联, 视频)

经过上述处理,得到本文实验所用的数据集,详情如表 7 所示,表中的“课程”是指业务意义上的“视频”。

表 7 数据集详情

Table 7 Details of the Dataset

统计项目	统计值
用户数量	13 746
课程数量	19 242
评分数量	101 727
知识图谱三元组数量	7 256 703

4.2 对比方法与评估指标

(1) 对比方法

①NeuralCF^[5]是基于神经网络的协同过滤模型,具备一定的特征交叉能力。

②Wide & Deep^[2]是基于特征交叉和全连接层的模型,兼具记忆和泛化能力。CKGAT 的学习者模块借鉴了其思想。由于 Wide & Deep 无法利用课程

知识图谱,实验中单独为其引入课程特征。

③AFM^[14]是特征交叉与注意力结合的模型,由于其无法利用课程知识图谱,实验中单独为其引入课程特征。

④GAT^[33]是利用图注意力网络作为消息传递方式的模型,并未利用课程知识图谱的信息。

⑤CKE^[24]是利用知识图谱嵌入的推荐模型。实验中采用 TransD 作为嵌入方式构建课程知识图谱,不引入学习者知识图谱。

⑥KGCN^[37]是利用图卷积网络作为消息传递方式的知识图谱推荐模型。实验中采用 TransD 作为嵌入方式构建课程知识图谱,不引入学习者知识图谱。

⑦KGAT^[38]是利用图注意力网络作为消息传递方式的知识图谱推荐模型。实验中采用 TransD 作为嵌入方式构建课程知识图谱,不引入学习者知识图谱。

(2) 评估指标

本文的推荐任务是一个二分类任务,即输入学习者和课程,输出学习者对课程的评分结果,这里的课程最小单位是视频。根据 4.1 节构建的评分数据集(rating),评分为 1 时,代表该视频适合推荐给学习者,评分为 0 时,代表该视频不适合推荐给学习者。视频评分依据学习者观看视频的总时长和平均倍速确定,具体见公式(25),学习者观看某视频的时间越久,代表该视频越符合学习者的需求。因此,如果 CKGAT 模型针对评分数据集(rating)中评分结果为 1 的视频的预测结果也为 1,说明其成功推荐了该视频。最后,选择准确率(Accuracy, ACC)、 $F1$ 值($F1$ Score, $F1$)与 ROC 曲线下的面积(Area Under Curve, AUC)三个指标综合评估模型的性能。

ACC ^[44]是预测正确的样本占所有样本的比例,计算方法如公式(26)所示。

$$ACC = \frac{TP + TN}{P + N} \quad (26)$$

$F1$ 值^[44]是精确率(Precision)和召回率(Recall)的调和平均数,取值范围在 0~1 之间,计算方法如公式(27)-公式(29)所示。

$$Precision = \frac{TP}{TP + FP} \quad (27)$$

$$Recall = \frac{TP}{TP + FN} \quad (28)$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (29)$$

$AUC^{[44]}$ 是ROC曲线与二维坐标轴围成的面积,取值范围在0~1,值越大,表示模型性能越好。ROC曲线^[44]展示了不同阈值下的真阳性率(True Positive Rate, TPR)与假阳性率(True Positive Rate, FPR)之间的关系。其中, TPR 是正例样本中分类正确的样本,其计算方法同公式(28); FPR 是负例样本中分类错误的样本比例,其计算方法如公式(30)所示^[44]。

$$FPR = \frac{FP}{FP + TN} \quad (30)$$

4.3 参数约束

采用网格搜索检索CKGAT模型的超参数,参数及其范围如表8所示。

表8 用于网格搜索的超参数
Table 8 Hyperparameters for Grid Search

参数	参数范围
学习率	0.05, 0.01, 0.005, 0.001
DropOut	0.0, 0.2, 0.4, 0.6

此外,对于CKGAT模型的超参数,设置的模型相关参数如表9所示。

表9 CKGAT模型参数范围
Table 9 Parameter Range of the CKGAT Model

参数	参数范围
学习者模块特征维度	32, 64, 128, 256
学习者模块 Linear 层数	1, 2, 3, 4
课程模块实体维度	32, 64, 128, 256
课程模块关系维度	16, 32, 64, 128
课程模块 GAT 层数	1, 2, 3, 4
课程模块 Linear 层数	1, 2, 3
α	0.5, 0.05, 0.005, 0.0005

4.4 实验结果分析

(1) 对比实验

对比实验结果如表10所示,CKGAT在所有指标上均取得最好结果。相较于基线模型中表现最好的KGAT,CKGAT在 ACC 、 $F1$ 值和 AUC 三个指标分别提升1.28%、1.62%和1.00%。

进一步分析,NeuralCF因为没有引入更多的特征而表现最差,AFM表现略好于Wide & Deep,说明

表10 对比实验结果

Table 10 Results of the Comparative Experiment

模型	ACC	$F1$ 值	AUC
NeuralCF	0.633 5	0.651 9	0.669 7
Wide & Deep	0.635 1	0.649 2	0.676 9
AFM	0.637 0	0.652 0	0.682 7
GAT	0.647 8	0.666 8	0.688 1
CKE	0.529 8	0.539 7	0.545 9
KGCN	0.657 5	0.679 9	0.711 5
KGAT	0.658 5	0.680 3	0.723 0
CKGAT	0.666 9	0.691 3	0.730 2

相对于全连接层的泛化,注意力机制更能捕捉到高维特征,但相对于NeuralCF提升并不大。这从侧面说明在线课程推荐领域,基于特征交叉的模型获取高质量、多样化的特征仍有一定难度。GAT相对于AFM有一定提升,说明了图注意力机制的优越性。CKE表现最差,因为其基本依赖于知识图谱的质量,但本实验的自建课程知识图谱并未关联外部知识,说明课程知识图谱还有提升空间。对于KGCN和KGAT,其表现已经接近CKGAT,这说明基于课程知识图谱的图注意力消息传播机制起到了主要作用。同时,CKGAT的学习者模块进一步优化了学习者的特征表示,取得了最好效果。另外,对比KGCN和KGAT,发现在课程知识图谱上基于图注意力的传播方式优于图卷积的方式。图注意力动态分配权重的方式比图卷积方式更为灵活,这也是CKGAT选择使用图注意力网络的原因。综上,CKGAT模型以基于课程知识图谱的图注意力传播机制为核心,配合Wide & Deep模型思想对学习者的特征表示进行优化,取得了最好的效果。

(2) 消融实验

上述实验表明CKGAT模型中起到核心作用的是课程模块。为探究CKGAT模型中学习者模块的具体影响,设计CKGATa、CKGATb和CKGATc三个模型变体。CKGATa去除学习者模块中的特征交叉部分;CKGATb去除全连接层部分;CKGATc同时去除特征交叉和全连接层部分,但保留了学习者特征嵌入层,并使用一层神经网络规范输出维度。实验结果如图3所示。

对比CKGAT和三个模型变体,发现CKGATa和




图3 消融实验的结果

Fig.3 Results of the Ablation Experiment

CKGATc(都去除了特征交叉部分)表现最差,可以推断特征交叉部分对于学习者模块的特征提取十分重要。CKGATa比CKGATc多了全连接层部分(本质上多了神经网络层数),但实际提升效果并不明显。所有的模型总体上优于基线KGAT模型,说明学习者特征嵌入层的输出经过少量全连接层后对推荐效果也起到了一定的作用。因此,实验可以印证上文推测,即引入的学习者模块进一步提升了推荐效果。

(3) 参数敏感性实验

①学习者模块全连接层数。将全连接层数设置为[1,2,3,4],结果如图4所示。当层数达到3层之后,模型陷入停滞。但在层数较少时,模型表现为欠拟合。

②课程实体嵌入维度。将课程实体嵌入维度设置为[32,64,128,256],关系维度始终设置为课程实体维度的一半,结果如图5所示。256维的实体向量




图4 学习者模块全连接层数对模型性能的影响

Fig.4 The Impact of the Number of Fully Connected Layers in the Learner Modules on Model Performance

综合性能高于128维,但是为了提升微小的效果而为模型引入大量的参数在实际场景中是得不偿失的,故而使用128维的实体向量。当实体维度降低至32维时,模型性能急剧下滑,说明维度的衰减导致图谱数据中的高阶语义和深层特征无法被有效挖掘。




图5 课程实体嵌入维度对模型性能的影响

Fig.5 The Impact of Course Entity Embedding Dimensions on Model Performance

③课程实体嵌入维度的参数量。将课程实体的嵌入维度设置为[32,64,128,256],关系维度始终设置为课程实体维度的一半,参数量结果如图6所示。随着课程实体嵌入维度的增加,模型参数量增大,例如课程实体嵌入维度从128维增加到256维时,模型参数量增加了8.77百万(M)。




图6 参数量变化

Fig.6 Changes in Parameter Quantities

(4) 计算效率

为全面评估模型性能,进一步分析模型的计算效率。所有模型均在相同的软硬件环境下进行训练和推理,计算效率如表11所示。KGAT和CKGAT相

较于其他模型需要更多的训练和推理时间。可见,基于知识图谱和图注意力传播机制的推荐模型虽在准确率方面取得了较好的结果,但存在计算成本过高的问题。因此,这类推荐模型需要在推荐效果和计算复杂度之间进行权衡。进一步分析,由于CKGAT比KGAT使用了更少的邻居节点数和图注意力传播层数,其计算效率略高于KAGT。这种设计在捕捉高阶语义信息的同时,避免了过多的传播层导致的计算负担。此外,本文通过仅构建课程知识图谱避免引入学习者而导致知识图谱过大的问题,在学习者模块中使用特征交叉和全连接层处理学习者特征,而不是通过复杂的图注意力网络,这在一定程度上也减少了计算量。

表11 计算效率

Table 11 Computational Efficiency

模型	训练集上的 训练时间(秒)	测试集上的 推理时间(秒)
NeuralCF	93.483 2	0.002 9
Wide & Deep	194.675 5	0.005 8
AFM	233.894 9	0.007 9
GAT	291.461 0	0.112 2
CKE	163.494 2	0.003 0
KGCN	355.613 1	0.137 5
KGAT	806.261 0	0.305 0
CKGAT	732.822 3	0.250 6

4.5 学习者反馈机制

在线课程推荐不仅需要精准的推荐结果,还需要考虑学习者对推荐内容的接受程度,即用户反馈。反馈分为显式反馈和隐式反馈^[45]。显式反馈指学习者直接在推荐系统中对推荐内容进行评价,隐式反馈则是从学习者的行为中推断出其感受。学习者反馈有助于推荐系统动态调整推荐内容,使其更符合学习者需求。为此,在工程应用中,本文设计并实现了一种显式反馈机制,如图7所示。

学习者可以对推荐内容进行评价操作(“前往”或“不合适”),推荐系统根据正负反馈结果,动态调整推荐内容。当学习者对推荐内容不满意时,推荐系统对该条推荐内容进行标记,在下次推荐时,将其放置在推荐序列的最后。随着标记次数的增多,不合适的推荐内容将逐渐退出推荐序列,从而逐步提高学习者对




图7 显式反馈机制示例

Fig.7 Example of an Explicit Feedback Mechanism

推荐结果的满意度。未来,笔者计划应用该系统收集学习者的反馈数据,建立学习者反馈数据集,并在推荐模型中设计反馈机制,根据学习者的反馈动态调整模型参数,为学习者推荐更高质量的课程内容。

5 总结

本文针对在线课程推荐中面临的数据稀疏、冷启动和特征利用不充分等问题,提出一种融合课程知识图谱与图注意力网络的推荐模型(CKGAT)。CKGAT构建课程知识图谱,利用图注意力网络进行消息传递,挖掘图结构数据中的高阶语义信息,同时结合学习者模块的特征交叉等操作丰富学习者特征的表达,进一步提升推荐的准确性。同时,相关实验验证了CKGAT的有效性。

本文工作还面临一些不足,未来可进一步探索。一方面,课程知识图谱略显单薄,未来可通过引入外部知识图谱丰富课程实体的表达,挖掘隐含的实体关联。在教育教学领域,课程内容间会存在内在关联,所推荐的内容除了根据学习者的偏好和兴趣外,还要符合认知的规律和教学的基本逻辑。这需要外部知识图谱的支持。另一方面,尽管CKGAT模型在推荐效果上取得了较好的结果,但是基于知识图谱和图注意力网络的模型计算成本较高。本文所做的优化设计仍有提升空间,未来可进一步从模型结构

优化、知识图谱简化、图注意力网络优化等方面探究如何在保持推荐效果的同时优化模型的计算复杂度。

参考文献:

- [1] Guo J, Liu Y, Zou Q, et al. Study on Optimization and Combination Strategy of Multiple Daily Runoff Prediction Models Coupled with Physical Mechanism and LSTM[J]. Journal of Hydrology, 2023, 624: 129969.
- [2] Cheng H T, Koc L, Harmsen J, et al. Wide & Deep Learning for Recommender Systems[C]//Proceedings of the 1st Workshop on Deep Learning for Recommender Systems. ACM, 2016: 7-10.
- [3] Goldberg D, Nichols D, Oki B M, et al. Using Collaborative Filtering to Weave an Information Tapestry[J]. Communications of the ACM, 1992, 35(12): 61-70.
- [4] Koren Y, Bell R, Volinsky C. Matrix Factorization Techniques for Recommender Systems[J]. Computer, 2009, 42(8): 30-37.
- [5] He X N, Liao L Z, Zhang H W, et al. Neural Collaborative Filtering[C]//Proceedings of the 26th International Conference on World Wide Web. ACM, 2017: 173-182.
- [6] 杨恒, 王思丽, 祝忠明, 等. 基于并行协同过滤算法的领域知识推荐模型研究[J]. 数据分析与知识发现, 2020, 4(6): 15-21. (Yang Heng, Wang Sili, Zhu Zhongming, et al. Recommending Domain Knowledge Based on Parallel Collaborative Filtering Algorithm[J]. Data Analysis and Knowledge Discovery, 2020, 4(6): 15-21.)
- [7] Rendle S. Factorization Machines[C]//Proceedings of the 2010 IEEE International Conference on Data Mining. IEEE, 2011: 995-1000.
- [8] Juan Y, Zhuang Y, Chin W S, et al. Field-Aware Factorization Machines for CTR Prediction[C]//Proceedings of the 10th ACM Conference on Recommender Systems. ACM, 2016: 43-50.
- [9] 王永, 陈俊谕, 刘崇, 等. 融合物品受众特征的深度学习推荐模型[J]. 数据分析与知识发现, 2023, 7(12): 114-124. (Wang Yong, Chen Junyu, Liu Dong, et al. A Deep Learning Recommendation Model with Item Audience Feature[J]. Data Analysis and Knowledge Discovery, 2023, 7(12): 114-124.)
- [10] Zhang W N, Du T M, Wang J. Deep Learning over Multi-Field Categorical Data[C]//Proceedings of the 38th European Conference on Information Retrieval. Cham: Springer International Publishing, 2016: 45-57.
- [11] Shan Y, Hoens T R, Jiao J, et al. Deep Crossing: Web-Scale Modeling Without Manually Crafted Combinatorial Features[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM, 2016: 255-262.
- [12] Wang R X, Fu B, Fu G, et al. Deep & Cross Network for Ad Click Predictions[C]//Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM, 2017: Article No.12.
- [13] Guo H, Tang R, Ye Y, et al. DeepFM: A Factorization-machine Based Neural Network for CTR Prediction[C]//Proceedings of the 26th International Joint Conference on Artificial Intelligence. 2017: 1725-1731.
- [14] Xiao J, Ye H, He X N, et al. Attentional Factorization Machines: Learning the Weight of Feature Interactions via Attention Networks[C]//Proceedings of the 26th International Joint Conference on Artificial Intelligence. 2017: 3119-3125.
- [15] 陈玲洪, 潘晓华. 基于知识图谱和读者画像的图书推荐研究[J]. 数据分析与知识发现, 2023, 7(12): 164-171. (Chen Linghong, Pan Xiaohua. Recommending Books Based on Knowledge Graph and Reader Profiling[J]. Data Analysis and Knowledge Discovery, 2023, 7(12): 164-171.)
- [16] 王慧欣, 童向荣. 融合知识图谱的推荐系统研究进展[J]. 浙江大学学报(工学版), 2023, 57(8): 1527-1540. (Wang Huixin, Tong Xiangrong. Research Progress of Recommendation System Based on Knowledge Graph[J]. Journal of Zhejiang University (Engineering Science), 2023, 57(8): 1527-1540.)
- [17] 吴国栋, 王雪妮, 刘玉良. 知识图谱增强的图神经网络推荐研究进展[J]. 计算机工程与应用, 2023, 59(4): 18-29. (Wu Guodong, Wang Xueni, Liu Yuliang. Research Advances on Graph Neural Network Recommendation of Knowledge Graph Enhancement[J]. Computer Engineering and Applications, 2023, 59(4): 18-29.)
- [18] 赵晔辉, 柳林, 王海龙, 等. 知识图谱推荐系统研究综述[J]. 计算机科学与探索, 2023, 17(4): 771-791. (Zhao Yehui, Liu Lin, Wang Hailong, et al. Survey of Knowledge Graph Recommendation System Research[J]. Journal of Frontiers of Computer Science and Technology, 2023, 17(4): 771-791.)
- [19] 张天成, 田雪, 孙相会, 等. 知识图谱嵌入技术研究综述[J]. 软件学报, 2023, 34(1): 277-311. (Zhang Tiancheng, Tian Xue, Sun Xianghui, et al. Overview on Knowledge Graph Embedding Technology Research[J]. Journal of Software, 2023, 34(1): 277-311.)
- [20] Bordes A, Usunier N, Garcia-Durán A, et al. Translating Embeddings for Modeling Multi-Relational Data[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems. ACM, 2013: 2787-2795.
- [21] Wang Z, Zhang J W, Feng J L, et al. Knowledge Graph Embedding by Translating on Hyperplanes[C]//Proceedings of the 28th AAAI Conference on Artificial Intelligence. ACM, 2014: 1112-1119.
- [22] Lin Y K, Liu Z Y, Sun M S, et al. Learning Entity and Relation Embeddings for Knowledge Graph Completion[C]//Proceedings

- of the 29th AAAI Conference on Artificial Intelligence. ACM, 2015: 2181-2187.
- [23] Zhang F Z, Yuan N J, Lian D F, et al. Collaborative Knowledge Base Embedding for Recommender Systems[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM, 2016: 353-362.
- [24] Ji G L, He S Z, Xu L H, et al. Knowledge Graph Embedding via Dynamic Mapping Matrix[C]//Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing. Stroudsburg, PA, USA: ACL, 2015: 687-696.
- [25] 李锴君, 牛振东, 时恺泽, 等. 基于学术知识图谱及主题特征嵌入的论文推荐方法[J]. 数据分析与知识发现, 2023, 7(5): 48-59. (Li Kaijun, Niu Zhendong, Shi Kaize, et al. Paper Recommendation Based on Academic Knowledge Graph and Subject Feature Embedding[J]. Data Analysis and Knowledge Discovery, 2023, 7(5): 48-59.)
- [26] 罗承天, 叶霞. 基于知识图谱的推荐算法研究综述[J]. 计算机工程与应用, 2023, 59(1): 49-60. (Luo Chengtian, Ye Xia. Survey on Knowledge Graph-Based Recommendation Methods[J]. Computer Engineering and Applications, 2023, 59(1): 49-60.)
- [27] Yu X, Ren X, Sun Y Z, et al. Personalized Entity Recommendation: A Heterogeneous Information Network Approach[C]//Proceedings of the 7th ACM International Conference on Web Search and Data Mining. ACM, 2014: 283-292.
- [28] Shi C, Zhang Z Q, Luo P, et al. Semantic Path Based Personalized Recommendation on Weighted Heterogeneous Information Networks[C]//Proceedings of the 24th ACM International Conference on Information and Knowledge Management. ACM, 2015: 453-462.
- [29] 张明星, 张骁雄, 刘姗姗, 等. 利用知识图谱的推荐系统研究综述[J]. 计算机工程与应用, 2023, 59(4): 30-42. (Zhang Mingxing, Zhang Xiaoxiong, Liu Shanshan, et al. Review of Recommendation Systems Using Knowledge Graph[J]. Computer Engineering and Applications, 2023, 59(4): 30-42.)
- [30] 朱冬亮, 文奕, 万子琛. 基于知识图谱的推荐系统研究综述[J]. 数据分析与知识发现, 2021, 5(12): 1-13. (Zhu Dongliang, Wen Yi, Wan Zichen. Review of Recommendation Systems Based on Knowledge Graph[J]. Data Analysis and Knowledge Discovery, 2021, 5(12): 1-13.)
- [31] 李慧, 崔子贤, 王珂. 基于学术知识图谱与有偏随机游走的论文推荐研究[J]. 数据分析与知识发现, 2025, 9(5): 114-124. (Li Hui, Cui Zixian, Wang Yu. Recommending Papers Based on Academic Knowledge Graph and Biased Random Walk[J]. Data Analysis and Knowledge Discovery, 2025, 9(5): 114-124.)
- [32] Kipf T N, Welling M. Semi-Supervised Classification with Graph Convolutional Networks[C]//Proceedings of the 5th International Conference on Learning Representations. 2017: 1-14.
- [33] Veličković P, Cucurull G, Casanova A, et al. Graph Attention Networks[C]//Proceedings of the 2018 International Conference on Learning Representations. 2018: 1-12.
- [34] Ying R, He R N, Chen K F, et al. Graph Convolutional Neural Networks for Web-Scale Recommender Systems[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. ACM, 2018: 974-983.
- [35] Wang X, He X N, Wang M, et al. Neural Graph Collaborative Filtering[C]//Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval. ACM, 2019: 165-174.
- [36] He X N, Deng K, Wang X, et al. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. ACM, 2020: 639-648.
- [37] Wang H W, Zhao M, Xie X, et al. Knowledge Graph Convolutional Networks for Recommender Systems[C]//Proceedings of the 2019 World Wide Web Conference. ACM, 2019: 3307-3313.
- [38] Wang X, He X N, Cao Y X, et al. KGAT: Knowledge Graph Attention Network for Recommendation[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. ACM, 2019: 950-958.
- [39] 徐春, 王萌萌, 孙彬. 融合知识图谱和图注意力网络的旅游推荐算法[J]. 计算机工程与设计, 2024, 45(5): 1420-1427. (Xu Chun, Wang Mengmeng, Sun Bin. Tourism Recommendation Algorithm Based on Knowledge Graph and Graph Attention Network[J]. Computer Engineering and Design, 2024, 45(5): 1420-1427.)
- [40] 樊海玮, 鲁芯丝雨, 张丽苗, 等. 融合知识图谱和图注意力网络的引文推荐算法[J]. 计算机应用, 2023, 43(8): 2420-2425. (Fan Haiwei, Lu Xinsiyu, Zhang Limiao, et al. Citation Recommendation Algorithm Fusing Knowledge Graph and Graph Attention Network[J]. Journal of Computer Applications, 2023, 43(8): 2420-2425.)
- [41] Hamilton W L, Ying R, Leskovec J. Inductive Representation Learning on Large Graphs[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. ACM, 2017: 1025-1035.
- [42] Xu K, Li C, Tian Y, et al. Representation Learning on Graphs with Jumping Knowledge Networks[C]//Proceedings of the 35th International Conference on Machine Learning. 2018: 5449-5458.
- [43] Yu J F, Wang Y Q, Zhong Q Y, et al. MOOCubeX: A Large Knowledge-Centered Repository for Adaptive Learning in MOOCs[C]//Proceedings of the 30th ACM International Conference on Information & Knowledge Management. ACM,

2021: 4643-4652.

- [44] Zangerle E, Bauer C. Evaluating Recommender Systems: Survey and Framework[J]. ACM Computing Surveys, 2022, 55(8): Article No.170.
- [45] 杨瑞仙, 楚晨, 金燕, 等. 融入用户反馈的网络知识社区好友推荐模型构建研究[J]. 现代情报, 2024, 44(5): 83-94. (Yang Ruixian, Chu Chen, Jin Yan, et al. Research on Building a Friend Recommendation Model Integrating User Feedback[J]. Journal of Modern Information, 2024, 44(5): 83-94.)

作者贡献声明:

肖克江: 提出研究选题, 项目执行管理;
陈亮: 提出研究思路, 负责实验, 撰写论文初稿;
方铄: 算法设计, 编程实验程序, 设计实验方案;

庞世燕: 修改实验方案;
邱杰凡: 修改论文, 项目执行管理;
董亚宁: 清洗和分析数据;
杨文齐、郭山锋: 修改论文。

利益冲突声明:

所有作者声明不存在利益冲突关系。

支撑数据:

[1] 清华大学知识工程实验室 .MoocCubeX 数据集 .<https://github.com/THU-KEG/MOOCcubex>.

收稿日期: 2024-11-25

收修改稿日期: 2025-07-18

Recommendation Model Integrating Course Knowledge Graph and Graph Attention Network

Xiao Kejiang^{1,2} Chen Liang¹ Fang Shuo¹ Pang Shiyan¹
Qiu Jiefan³ Dong Yaning¹ Yang Wenqi¹ Guo Shanfeng¹

¹(Faculty of Artificial Intelligence in Education, Central China Normal University, Wuhan 430079, China)

²(Hubei Key Laboratory of Digital Education, Wuhan 430079, China)

³(College of Computer Science and Technology, Zhejiang University of Technology, Hangzhou 310023, China)

Abstract: [Objective] This paper proposes an online course recommendation model that integrates a course knowledge graph with a graph attention network (CKGAT), to address issues such as data sparsity, cold start, and insufficient feature utilization. [Methods] In CKGAT, the learner module enhances the memorization and generalization capabilities of learner features through a feature-crossing layer and a fully connected layer. The course module, based on a graph attention network, extracts higher-order semantic features among course entities. The final recommendation is obtained by calculating the dot product of the output vectors from the two modules. [Results] In comparative experiments conducted on the MoocCubeX dataset, CKGAT improved ACC, F1, and AUC by 1.28%, 1.62%, and 1.00%, respectively, compared to the best baseline model. [Limitations] The course knowledge graph in this paper is relatively sparse, and the computational complexity of the model could be further optimized. [Conclusions] The proposed CKGAT model achieves strong recommendation performance and contributes to improving online course recommendation.

Keywords: Online Courses Recommendation System Knowledge Graph Graph Attention Network Feature Crossing